





IMPLEMENTACIÓN DE MODELO DE GESTIÓN DE COBRANZA: APLICACIÓN DE UN MODELO LOGIT PARA LA CLASIFICACIÓN DE CLIENTES EN EL ÁREA COMERCIAL RESIDENCIAL EMPRESA FLUX SOLAR ENERGÍAS RENOVABLES SPA

Alumno Ingeniería Civil Industrial
Ramiro David Zegarra Morán
rzegarra@alumnos.uai.cl
Profesor Guía
Nicolas Sebastián Pérez Briones
nicolas.perez@edu.uai.cl

05-12-2023





<u>Índice</u>

Resumen Ejecutivo	3
Executive Summary	4
Contexto	5
Objetivos	7
Objetivo General	7
Objetivos Específicos	7
Estado del Arte	7
Soluciones Propuestas	9
Evaluación Económica	10
Metodologías	11
Métricas de Desempeño (KPI)	15
Desarrollo e implementación	16
Extracción de datos	16
Aplicación de software	19
Resultados	24
Conclusión y Discusión	25
Referencias	26
Anavos	27





Resumen Ejecutivo

Durante el periodo de pasantía en la empresa Flux Solar en el área comercial residencial, se realizó el proyecto de implementación de modelo de gestión de cobranza junto con la aplicación del modelo *logit*. Debido a la creciente deuda por morosidad de los clientes, mediante la recopilación y utilización de datos de clientes y los flujos de procesos, se identificó que esta deuda se debe principalmente a la deficiente gestión de cobranza, pues durante el periodo inicial de práctica se tenía un índice de eficiencia de cobranza del 62%, lo cual es considerado bajo en el rubro de construcción a nivel residencial.

Con el objetivo general de reducir la deuda asociada a la cartera de clientes en un 15% y disminuir las cuentas por cobrar no vigentes, se siguió un proceso de recopilación, análisis y limpieza de datos de clientes con herramientas de visualización, la extracción de variables para su análisis en el software estadístico, el ajuste del modelo de regresión logística y la aplicación de los resultados obtenidos para desarrollar el modelo de gestión de cobranza. Durante el primer mes de implementación se disminuyó en 11,5% la cifra adeudada. A fines de noviembre, con una implementación del 75% de la solución, se logró mejorar el índice de eficiencia de cobranza a un 69% y una disminución de la cifra adeudada en 18,5%, cumpliéndo así el objetivo general y logrando una recaudación de 45 millones de pesos en facturas vencidas. Esta disminución se refleja en el monto acumulado de la cobranza atrasada y el aumento de la cobranza vigente.

Por otro lado, durante la implementación y análisis de resultados, surgió en el área de finanzas un punto clave a mejorar para la validación de datos, por lo que se decidió no aprobar proyectos en caso de que el contrato y otros documentos no vengan firmados y, si bien se logró aumentar el índice de eficiencia, aún existe un amplio margen de mejora. Así, se anticipa una disminución en las tarifas por cobranza externa y la remuneración por gestión de cobranza, junto con un aumento en el ahorro de intereses financieros y la reducción de gastos en cobranza judicial.

En conclusión, una gestión de cobranza profesional y proactiva contribuye a la retención de clientes y fortalece la reputación de la empresa al abordar los problemas financieros de manera respetuosa, resultando en una mayor fidelidad del cliente a largo plazo y en la apertura a futuras transacciones comerciales exitosas.





Executive Summary

During the internship period in the residential commercial area in the company Flux Solar, the project for the implementation of a collection management model was carried out, together with the application of the Logit model. Due to the growing debt due to customer delinquency, through the collection and use of customer data and process flows, it was identified that this debt is mainly due to poor collection management, since during the initial internship period there was a collection efficiency rate of 62%, which is considered low in the residential construction industry.

With the overall objective of reducing the debt associated with the customer portfolio by 15% and reducing non-performing accounts receivable, a process of collecting, analyzing and cleaning customer data with visualization tools, extracting variables for analysis in statistical software, adjusting the logistic regression model and applying the results obtained to develop the collection management model was followed.

During the first month of implementation, the amount owed was reduced by 11.5%. By the end of November, with 75% of the solution implemented, a decrease of 18.5% was achieved. This decrease is reflected in overdue collections, while current collections are expected to increase. In addition, a decrease in external collection fees and collection management fees is anticipated, along with an increase in financial interest savings and a reduction in judicial collection expenses.

On the other hand, during the implementation and analysis of results, a key point for improvement in data validation arose in the finance area, so it was decided not to approve projects if the contract and other documents are not signed and, although the efficiency index was increased, there is still ample room for improvement. Thus, we anticipate a decrease in external collection fees and remuneration for collection management, together with an increase in financial interest savings and a reduction in judicial collection expenses.

In conclusion, professional and proactive collections management contributes to customer retention and strengthens the company's reputation by addressing financial issues in a respectful manner, resulting in increased long-term customer loyalty and opening up future successful business transactions.





Contexto

Fundada el 2011 por David Rau, la empresa desarrolladora de proyectos de energía "Flux Solar" ha crecido sostenidamente hasta la actualidad. Esta busca implementar tecnologías que permitan generar, almacenar y gestionar energía limpia y segura a partir de la radiación solar, siguiendo una visión de soluciones de generación que abarca 3 unidades de negocio de proyectos: Pequeño medio de generación distribuida (PMGD), Comercial e industrial (C&I) y Residencial. Un PMGD consiste en un sistema de generación de energía renovable, en este caso paneles, que cumple con los límites establecidos por las regulaciones energéticas y actúa sobre un sistema eléctrico de potencia, inyectando energía a la parte encargada de distribuirla a los consumidores finales, abasteciendo industrias, hogares, iluminación urbana y otros usuarios. Por otro lado, la unidad de negocio Comercial e Industrial tiene como objetivo vender e instalar proyectos a nivel industrial, de manera que la empresa pueda autoabastecerse de energía y sea capaz de utilizar este recurso como estime conveniente.

Por último, el área Residencial tiene un acercamiento directo con las personas, con el fin de aproximar al usuario común y a sus hogares las tecnologías de generación de energía solar y que, por consiguiente, pueda disfrutar de los beneficios que significa autoabastecerse de esta. Estas utilidades se pueden observar tanto en hogares que tienen dificultades de acceso a la red como en domicilios que se encuentran en zonas donde los cortes de luz son frecuentes. Además, se obtienen beneficios económicos, ya que se genera su propia energía. Por otro lado, gracias a la ley Net Billing, el usuario puede inyectar directamente a la red el excedente de energía generado y venderla.

Ahora bien, un hito importante de la empresa fue que el año 2019 se vendió un 80% de esta a la Compañía de Petróleos de Chile (COPEC), lo cual significó una oportunidad de crecimiento para Flux Solar en lo que respecta a las áreas de negocio mencionadas anteriormente. Esto se puede apreciar en diversos aspectos, tales como: creación de áreas de negocio, aumento en la mano de obra, incremento en la cuota de mercado, desarrollo de nuevas tecnologías dentro de la empresa, entre otros. Sin embargo, este acelerado progreso que fue generado por la inversión de COPEC afectó la organización y ejecución de proyectos de diversas áreas, dando pie a una brecha de oportunidad de mejora.

Para efectos de este proyecto, se estudiará las oportunidades o brechas de mejora dentro del área residencial. Ante el crecimiento de la cuota de mercado que COPEC tenía previsto para Flux Solar, se establecieron ciertas metas que evalúan la venta final, midiendo la potencia instalada anualmente y, por consiguiente, la cantidad de ventas mensuales para alcanzar dicho potencial anual. Así pues, el





área residencial se enfocó fundamentalmente en aumentar sus ventas de proyectos solares en los hogares chilenos, ocasionando inconvenientes dentro de los procesos de flujos de venta y en las posteriores etapas de desarrollo del proyecto, además de afectar en la comunicación entre las áreas de negocio. Todo lo anterior se debe a que la base del negocio no era lo suficientemente robusta para soportar el incremento apresurado en el número de proyectos. En la imagen siguiente se evidencia el aumento en la cantidad de proyectos anualmente en el área residencial:

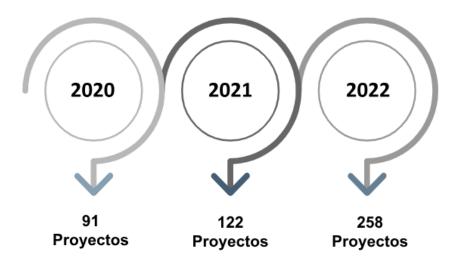


Figura 1: Esquema de datos recolectados sobre la realización de proyectos por año. Fuente: Elaboración propia



Figura 2: Esquema representativo de estudio y análisis de repositorio de clientes. Fuente: Elaboración propia

Siguiendo con este orden de ideas, en la Figura 2 se puede observar que, de los proyectos realizados





desde el año 2020, se tiene que el 63% de estos no tienen contrato o no ha sido firmado. De ello, un 41% de los clientes no ha pagado, lo que ha generado una deuda que supera los 220 millones de CLP.

Objetivos

Objetivo General

Disminuir la cantidad de clientes morosos en un 15% para un plazo de 4 meses mediante la clusterización de la cartera de clientes que permita desarrollar una mejor estrategia de cobro.

Objetivos Específicos

- 1. **Levantamiento de situación original** mediante el entendimiento de las distintas partes involucradas en el proyecto y análisis de datos.
- 2. **Identificar aplicaciones precedentes de modelos** *Logit* en ambientes similares.
- 3. **Definir variables** a partir de la cartera de clientes de la empresa.
- 4. **Aplicar el modelo** *Logit* para estimar la probabilidad de morosidad de un cliente.

Estado del Arte

Ante el crecimiento exponencial de datos en todos los ámbitos, las empresas se encuentran en un entorno más exigente ya que se ven enfrentadas no sólo a los avances tecnológicos, el aumento de demanda y de la calidad de productos y servicios por parte de otros negocios, sino que también se enfrentan a las exigencias impuestas por parte de los consumidores. Sin embargo, esta fuente de información genera la oportunidad de diferenciar los distintos perfiles de clientes para así identificar sus necesidades y segmentarlos en cuanto a los objetivos de la empresa.

Actualmente, en Chile se promueve el uso de Energías Renovables no Convencionales mediante un marco normativo que impulsa esta forma de generación de energía y, aunque hay una gran cantidad de competidores, estos son relativamente nuevos, por lo que no hay una referencia en la cual basarnos en cuanto a las estrategias actuales de identificación y selección de clientes en este rubro. Aún así, en otros sectores como el financiero se realiza una categorización de clientes en base a variables como el comportamiento bancario, el entorno y aspectos personales como la edad, renta, estado civil, etc. De esta forma, predicen la fuga de clientes usando métodos estadísticos y modelos matemáticos de minería de datos. Ahora bien, se han demostrado estudios que utilizan técnicas para estimar clientes que no pagarán, como el modelo de bosques aleatorios balanceados para construir un sistema de





clasificación, el cual está enfocado en las estrategias de cobranza de clientes morosos (Sun et al. 2014) También se utilizan modelos de puntuación de crédito o *credit scoring* para identificar potenciales clientes en base a los principales indicadores financieros (Bravo, 2012), previniendo la morosidad según el peso atribuido a los indicadores, o modelos econométricos de regresión logística para realizar predicciones a partir de un resultado binario, donde se describe un código 0 para un sujeto que no entrará en mora y un código 1 para aquel que lo hará.

Por otro lado, empresas como Tresmontes Lucchetti han desarrollado una segmentación de los clientes de canal de ventas de almacenes bajo los conceptos de comportamiento de compra a partir de datos obtenidos de la facturación, todo esto mediante un procesamiento ETL de datos y la aplicación de algoritmos de segmentación como K-means y DBSCAN, lo que permitió tener una mirada de la realidad que vive la empresa desde el punto de vista de los procesos y sus interacciones (Rojas, 2017).

Siguiendo con este orden de ideas, en el área de telecomunicaciones se ha estudiado la fuga de clientes a través de la minería de datos con procesos como el *Knowledge Discovery in Databases* o KDD, el cual sigue un proceso de análisis de bases de datos que indaga relaciones inesperadas que son de interés . Así, se realiza primeramente una selección de variables o integración junto con la implementación de un data warehouse, luego se hace la imputación de datos con técnicas como *simple imputation* y *multiple imputation*. A continuación, se transforman las variables originales y se analizan los datos para descubrir un algoritmo ad-hoc que sea capaz de producir una enumeración de patrones que considere las restricciones que impone la computación. Finalmente, se evalúa y trasponen los resultados técnicos, con técnicas como *holdout* y validación cruzada, a niveles comerciales (Barrientos & Ríos, 2013).

Soluciones Propuestas

A partir de lo expuesto, se destaca que los modelos estadísticos tienen la capacidad de prever la probabilidad de que ocurra o no un evento, basándose en variables analizadas previamente. En el contexto de identificar clientes morosos, se consideran tres modelos potenciales (Consultar Anexo 1 para obtener detalles adicionales): *Bosques Aleatorios, K-means y Regresión Logística* (logit).

El modelo de Bosques Aleatorios emplea múltiples árboles de decisión, entrenados en subconjuntos aleatorios de datos y características. La combinación de estas predicciones genera una salida robusta. Sin embargo, su eficacia requiere una cantidad significativa de datos, lo cual es un desafío dada la





limitada y baja calidad de la información disponible en la empresa. Además, el modelo demanda más recursos computacionales, tiempo, etc. para realizar sobreajustes, lo que debe ser controlado para evitar un rendimiento deficiente en datos no vistos previamente (Medina-Merino & Ñique-Chacón, 2017).

En relación con el modelo K-means, este realiza un agrupamiento de datos en k clusters basándose en la similitud entre observaciones. Inicia con k centroides aleatorios y asigna cada punto de datos al cluster que tenga su centroide más cercano. Aunque es un algoritmo de agrupamiento eficaz, determinar el número de clusters (k) es un desafío, ya que distintos valores de k pueden conducir a resultados de agrupamientos diferentes y puede ser sensible a valores atípicos donde los centroides se mueven hacia el centroide del cluster afectado por esos valores.

A pesar de su eficacia en la formación de varios grupos, el modelo K-means no se ajusta a los requisitos específicos y las necesidades empresariales en este contexto. La empresa busca clasificar a los clientes en sólo dos grupos: incobrables y aquellos a los que se debe realizar cobros.

Considerando lo anterior, se incorpora el modelo de regresión logística (logit) para la predicción de eventos binarios a partir de una muestra de 120 clientes, ya que, de un total de 643, solamente se tiene la data limpia de 211 clientes. Este modelo estima la probabilidad de que una variable de salida pertenezca a una categoría específica mediante el análisis de una o más variables predictoras. Su flexibilidad en la manipulación de variables independientes, ya sean categóricas o continuas, lo convierte en una herramienta adaptable a una amplia variedad de conjuntos de datos, incluyendo la diversidad de datos de clientes de Flux Solar.

Es esencial destacar que este modelo puede operar eficazmente incluso en casos donde los datos no sigan una distribución normal. Además, muestra resistencia a la colinealidad entre variables, siendo particularmente relevante en áreas como medicina, ciencias sociales, marketing, entre otras, para abordar cuestiones de clasificación y predicción.





Evaluación Económica

En la evaluación económica, se realizó un cálculo del flujo de caja del área de facturación y cobranza, con un enfoque especial en la cobranza atrasada para reducir la deuda actual de los clientes mediante una gestión más efectiva. A mediano y largo plazo, se busca minimizar la morosidad de los clientes, manteniendo la eficacia de la estrategia de cobranza propuesta.

La inversión se calculará considerando la mejora del módulo de cobranza ERP, un equipo computacional, y un pago inicial a una empresa externa. Los egresos mensuales incluirán la remuneración variable del encargado de la gestión de cobranza, la remuneración del analista tomando como referencia el sueldo de un analista del área de Tecnologías de la Información (TI) en Flux Solar y la comisión de la empresa externa. Además, se utilizará el software SPSS Statistics.

Dado que el proyecto no genera utilidades directas, los ingresos se calcularán a través del ahorro en intereses financieros, provenientes de la negociación de facturas vencidas y el financiamiento utilizado para mantener el flujo de caja. También se contempla el ahorro en costos asociados a la cobranza judicial, debido a que el nuevo modelo de gestión retrasa el inicio de este proceso. Además, se prevé una reducción en los gastos legales relacionados con la cobranza judicial. El flujo de caja inicial es negativo debido a la inversión, y se han calculado el Valor Actual Neto (VAN) y la Tasa Interna de Retorno (TIR) para evaluar la rentabilidad y viabilidad financiera del proyecto.

		1T	2T	3T	4T
Inversión					
Mejora módulo de cobranza ERP	\$2.500.000				
Equipo computacional	\$650.000				
Pago inicial emp.externa	\$150.000				
Ingresos					
Ahorro en intereses financieros		\$4.650.090	\$5.035.512	\$5.568.240	\$5.991.390
Ahorro en cobranza judicial		\$0	\$3.450.000	\$3.105.000	\$2.794.500
Total Ingresos		\$4.650.090	\$8.485.512	\$8.673.240	\$8.785.890
Egresos Gestión Cobranza					
Remuneración Analista		\$3.050.000	\$3.050.000	\$3.050.000	\$3.050.000
Comisión cobranza emp.externa		\$0	\$387.501	\$736.251	\$662.625
Nuevo modelo de remuneración		\$729.999	\$803.001	\$899.361	\$1.007.283
Gastos telefónicos		\$150.000	\$150.000	\$150.000	\$150.000
Plan software Spss Statistics		\$261.063	\$261.063	\$261.063	\$261.063
Total egresos		\$4.191.062	\$4.240.502	\$4.685.612	\$4.719.908
Flujo de caja	-\$3.300.000	\$459.028	\$4.245.010	\$3.987.628	\$4.065.982
Tasa de descuento	10%				
Valor actual neto	\$6.398.655				
TIR	64,48%				

Tabla 1A: Flujo de Caja unidad de implementación de gestión de cobranza (trimestral).





		1T	2T	3T	4T
Ingresos					
Ingresos por ventas		\$306.218.904	\$312.072.306	\$299.825.968	\$341.254.22
Otros ingresos		\$9.007.430	\$7.003.490	\$8.324.100	\$8.259.670
Total Ingresos		\$315.226.334	\$319.075.796	\$308.150.068	\$349.513.89
Egresos					
Gastos fijos					
Servicios básicos (luz, agua,internet,tele	éfonos,etc)	\$903.000	\$903.000	\$903.000	\$903.000
Arriendos (oficina, autos)		\$1.250.000	\$1.250.000	\$1.250.000	\$1.250.000
Remuneraciones					
Remuneraciones administrativas		\$36.568.000	\$36.568.000	\$36.568.000	\$36.568.000
Pago proveedores materiales					
Materiales		\$235.553.003	\$240.055.620	\$230.635.360	\$262.503.250
Gastos financieros					
Gastos bancarios e intereses por présta	imos	\$16.920.105	\$16.501.050	\$16.801.290	\$16.951.620
Implementación gestión de col	oranza				
Mejora módulo de cobranza ERP Equipo computacional	\$2.500.000 \$650.000				
Pago inicial emp.externa	\$150.000				
Remuneración Analista		\$3.050.000	\$3.050.000	\$3.050.000	\$3.050.000
Comisión cobranza emp.externa		\$0	\$387.500	\$736.250	\$662.62
Comisión cobranza personal interno		\$730.000	\$803.000	\$899.360	\$1.007.28
Total egresos	\$3.300.000	\$294.974.108	\$299.518.170	\$290.843.260	\$322.895.77
Flujo de caja	-\$3.300.000	\$20.252.226	\$19.557.626	\$17.306.808	\$26.618.11

Tabla 1B: Flujo de Caja unidad de negocio residencial (trimestral).

Metodologías

Para cumplir con los objetivos propuestos y alcanzar el objetivo general, se buscará implementar el modelo Logit, el cual implica seguir una metodología estructurada para guiar el proceso:

- 1. Recopilación y análisis de datos con el uso de técnicas de Data Science y herramientas de visualización para encontrar las variables independientes o predictoras.
- 2. Realizar tareas de preprocesamiento de datos, como la limpieza de datos faltantes, la codificación de variables categóricas y la normalización de variables si es necesario.
- 3. Utilizar un Software estadístico o de análisis de datos o herramientas de análisis de datos que permitan ajustar un modelo de regresión logística.
- 4. Ingresar dichas variables a un Software estadístico. Esto implica estimar los coeficientes de regresión que describen la relación entre las variables independientes y la variable dependiente, lo que permitirá sacar conclusiones sobre las relaciones entre las variables y el evento que se está tratando de predecir.
- 5. Revisar la actual gestión de cobranza y ajustarla en base a la capacidad actual de Flux Solar.





• Modelo de regresión logística *Logit*.

Técnica de modelado estadístico no lineal utilizada para predecir la probabilidad de eventos binarios como sí/no o éxito/fracaso. Se basa en variables predictoras para predecir a qué grupo pertenece cada individuo. La relación entre las variables predictoras y la probabilidad del evento se modela mediante una transformación logarítmica llamada función logit. Esta función asigna una probabilidad de éxito en los extremos del espectro, y el modelo se ajusta utilizando el método de máxima verosimilitud, que considera una función de colas más anchas, dando mayor peso a los extremos (Wijewardhana, s. f.). La función logit se define de la siguiente manera:

$$logit(p) = ln(\frac{p}{(1-p)})$$

Donde Logit(p) es el logaritmo natural del cociente de la probabilidad p del evento sobre la probabilidad complementaria (1 - p) del evento, siendo p la probabilidad del evento de interés.

El modelo se formula como:

$$logit(p) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + ... + \beta_k X_k$$

-logit(p): transformación logarítmica de la probabilidad p.

-β₀: intercepto.

 $-\beta_1, \beta_2, ..., \beta_k$: coeficientes de regresión asociados a las variables predictoras $X_1, X_2, ..., X_k$.

El método de máxima verosimilitud se emplea para estimar los coeficientes del modelo logístico, buscando valores óptimos (β_0 , β_1 , β_2 , ..., β_k) que maximizan la probabilidad de observar los datos. La relevancia de los coeficientes, es decir, si una variable tiene peso significativo, se puede evaluar mediante el estadístico de Wald. Este estadístico realiza pruebas de hipótesis sobre coeficientes individuales en el modelo logit, donde la hipótesis nula plantea que un coeficiente específico es cero (sin efecto), y la hipótesis alternativa sugiere que el coeficiente es diferente de cero.

• Suposiciones del Modelo de Regresión Logística:

-Linealidad en el logit: Asume que la relación entre las variables predictoras y el logit de la probabilidad es lineal. No obstante, no es necesario que las relaciones entre las variables y la probabilidad sean lineales en el espacio de las variables predictoras.





-Independencia de observaciones: Asume que las observaciones son independientes entre sí. Es decir, la ocurrencia de un evento en una observación no afecta la ocurrencia en otras observaciones.

-Ausencia de multicolinealidad: Se espera que las variables predictoras no estén altamente correlacionadas entre sí, ya que la multicolinealidad puede dificultar la interpretación de los coeficientes.

• Interpretación de Coeficientes:

Se interpretan como el cambio en el logaritmo de la razón de probabilidades por unidad de cambio en la variable predictora, manteniendo constantes las demás variables. Es decir, un aumento de una unidad en una variable predictora se asocia con un cambio multiplicativo en la probabilidad del evento.

Predicciones de probabilidad:

Una vez estimados los coeficientes, el modelo se puede utilizar para predecir la probabilidad del evento para nuevos datos. La fórmula del modelo se aplica a las variables predictoras del nuevo caso. Por lo general, se elige un umbral de probabilidad (por ejemplo, 0.5) para clasificar las observaciones en una de las dos categorías.

Evaluación del Modelo:

Para evaluar el rendimiento del modelo de regresión logística, se realizará un ajuste a través de la iteración de este.

Métricas de Desempeño (KPI)

Dado que se quiere analizar y monitorear el desempeño de la solución, se utilizará la variación porcentual de ciertas variables de interés, para así describir la relación entre los valores que se tenían inicialmente en la empresa antes de implementar la solución y los valores que se tienen actualmente con la solución descrita.

Clientes morosos identificados.

$$\frac{\Delta Cantidad\ de\ clientes\ morosos\ identificados}{Cantidad\ de\ clientes\ morosos\ identificados\ inicialmente} imes 100$$

Así, se obtendrá el porcentaje de cambio entre la cantidad de clientes que se encontraban morosos antes y después de la solución.





Eficiencia de la Cobranza.

$$\frac{\textit{Cobros en un periodo}}{\textit{Cuentas por cobrar iniciales}} \times 100$$

Representa la eficacia de la empresa para convertir las cuentas por cobrar en efectivo.

Índice de morosidad.

Muestra el porcentaje de cuentas por cobrar que están vencidas en relación con el total de cuentas por cobrar.

Desarrollo e implementación.

En el proceso de recopilación de datos, se inició con un análisis del diagrama de procesos del área comercial residencial, con el objetivo de entender el flujo desde la venta hasta la ejecución del proyecto. Se examinaron las partes relacionadas y el manejo de la información del cliente (Revisar Anexo 1). Tras conversaciones con responsables de distintos departamentos, se concluyó que el área comercial no es la única responsable de gestionar la información del cliente. El equipo de finanzas, especialmente el departamento de administración de contratos desempeña un papel esencial.

En el área comercial residencial, el equipo de ventas recopila información clave para propuestas personalizadas a través de la plataforma *CRM Pipe Drive*. El Project Manager coordina y supervisa la ejecución y el progreso de los proyectos, lo cual está vinculado a la facturación al cliente. En el departamento de administración de contratos, validan y registran datos en el sistema *ERP Flexline*, gestionan facturación y se comunican con clientes sobre pagos.

El uso extensivo de herramientas de *Google*, especialmente *Google Sheets*, es notable en estas áreas, aunque presenta desafíos para la recopilación efectiva de información. Este enfoque diverso se extiende a toda la organización, resaltando la necesidad de una gestión integral y centralizada de la información del cliente en las áreas Comercial Residencial y Administración de Contratos. También subraya la importancia de abordar los desafíos relacionados con el uso diversificado de herramientas de *Google* para una gestión de datos más efectiva a nivel empresarial.





Extracción de datos

En el contexto de la investigación y análisis de datos empresariales, se adoptó un enfoque integral utilizando *MySQL* y *Power BI* para leer, comprender y depurar datos. Estas herramientas se conectaron eficientemente a tablas en el sistema *ERP* y *PipeDrive*, proporcionando una visión global de la información empresarial.

El análisis de datos involucró la integración de diversas fuentes mediante un identificador único, el centro de costo. Este método permitió la extracción de datos relevantes, como nombre del cliente, Rut, estado civil, vendedor asociado, entre otros. Se realizaron cálculos específicos y se recopiló información adicional como incidencias en mora, estado del contrato y motivos de la mora.

Una fase crucial fue el procesamiento y depuración de datos, que incluyó la eliminación de valores nulos y la identificación de valores atípicos. Se implementó una estrategia de selección de datos, excluyendo proyectos con antigüedad considerable para mantener la relevancia de la información. La eliminación de valores atípicos fue esencial para preservar la integridad y precisión de los datos analizados.

Variable	Descripción
Venta neto	Monto neto en que se vendió el proyecto
Cuota neto	Valor de la cuota neto en caso de ser leasing o membresía
Cantidad de cuotas	Número de cuotas en que se pagara el proyecto
CantCuotEm	Cantidad de cuotas facturadas o emitidas
MUltPag	Indica el último mes que el cliente hizo algún pago
PagCuot	Indica si ha pagado alguna cuota o ninguna
cantD	Días entre fecha de emisión y pago de factura
Mora	Valor acumulada de la mora
CantMora	Número de veces que ha estado en mora
MotMora	Indica el motivo de la mora
Client	Ingreso mensual cliente
ECivil	Estado civil
NEstu	Nivel de estudios
Edad	Edad del cliente
Sexo	Genero del cliente
Región	Región donde se encuentra la vivienda
Comuna	Comuna donde se encuentra la vivienda
TVenta	Venta directa , Leasing, Membresia
Econtra	Estado del contrato: Contrato firmado, Sin firma, Sin contrato
Eprov	Etapa de avance del proyecto: Por coordinar, Coordinado, Ejecución, et

Tabla 2: Variables recopiladas.

Se realizaron procesamientos en las variables según la Tabla 2, transformando las cualitativas en cuantitativas mediante asignación de números asociados a características específicas. Además, se convirtieron ciertas variables en respuestas binarias mediante la técnica de variables dummy, estas





son útiles cuando se requiere incorporar información categórica en modelos numéricos. La recopilación adicional de datos reveló que la mayor proporción de situaciones de mora entre los clientes está vinculada a aspectos relacionados con la gestión de cobranza. Este hallazgo destaca la necesidad de abordar de manera efectiva y estratégica los factores que influyen en el proceso de recuperación de pagos.



Gráfico 1: Distribución porcentual de motivo de mora en muestra de clientes.

En particular, dos variables clave han emergido como elementos significativos que influyen en la morosidad de los clientes:

• Falta de Cobranza (25,6%):

Esta variable refleja la incomunicación entre áreas, lo que resulta en la falta de gestión de la cobranza del cliente. Esto destaca la importancia de mejorar la coordinación y comunicación interna para garantizar una gestión de cobranza más eficiente y oportuna.

• Olvido o Descuido (35,6%):

Los resultados indican una oportunidad para mejorar la eficacia de la gestión de cobranza al aplicar una mayor presión o recordatorio hacia los clientes. Estrategias que refuercen esta comunicación pueden reducir significativamente la morosidad, destacando la importancia de medidas proactivas en la optimización de la gestión de cobranza, tanto en la coordinación interna como en la comunicación efectiva con los clientes.

El análisis exhaustivo de la estructura organizativa y el personal reveló una deficiencia significativa en la gestión de cobranza del área residencial. La concentración de responsabilidades en una única persona, encargada de las funciones de facturación y cobranza, presenta desafíos que afectan la eficiencia del proceso, especialmente dada la limitación de tiempo para comunicarse adecuadamente





con los clientes, dados los volúmenes en el área residencial (consultar Anexo 3). Estos hallazgos resaltan la necesidad de revisar la asignación de responsabilidades para asegurar una gestión de cobranza más efectiva.

Otro factor que impacta la efectividad de la gestión de cobranza es la falta de un enfoque específico y de incentivos económicos para la persona responsable de estas tareas. Dada la falta de dedicación exclusiva a la cobranza y la ausencia de incentivos financieros directos, se identifica una oportunidad para reconsiderar la estructura de compensación y proporcionar estímulos adicionales que impulsen un mejor rendimiento en este aspecto.

Aplicación de software

Se llevó a cabo el análisis y la estimación de la probabilidad de incobrabilidad mediante la introducción en el programa SPSS de una muestra aleatoria de 120 clientes extraída de la base de datos actual, con lo que se obtuvieron los siguientes resultados:

Casos no ponderados		N	Porcentaje
Casos seleccionados	Incluidos en el análisis	120	100.0
	Casos perdidos	0	.0
	Total	120	100.0
Casos no seleccionados		0	.0
Total		120	100.0

Tabla 3:Resumen de procesamiento de datos.

Valor original	Valor interno
Incobrable	1
Cobrable	0

Tabla 4: Codificación de la variable dependiente.

			Pronosticado		
			inif		
	Observado		Fuera de Incobrables	Está en incobrables	Porcentaje correcto
Paso 0	inif	Fuera de Incobrables	0	87	.0
		Está en Incobrables	0	33	100.0
	Porcentaj	e global			53.2

Tabla 5: Tabla de clasificación.

La evaluación del ajuste del modelo se realiza mediante la comparación entre los valores predichos y los observados, utilizando un punto de corte predeterminado de probabilidad de Y, establecido en 0.5 en este caso. De acuerdo con esta clasificación, los clientes con una probabilidad menor a 0.5 se consideran cobrables (0), mientras que aquellos con una probabilidad mayor o igual a 0.5 se





consideran incobrables (1). En la primera iteración, el modelo logró clasificar correctamente al 53.2% de los casos, según el análisis de la Tabla 5.

Paso	-2 log de la verosimilitud	R cuadrado de Cox y Snell	R cuadrado de Nagelkerke
1	494.437a	.509	.623

Tabla 6: Resumen del modelo.

Al analizar tanto el R cuadrado de Nagelkerke como el de Cox y Snell, se evidencian valores de 0.509 y 0.623, respectivamente. Estos valores, al estar alejados de 1, indican la precisión del modelo. En este caso, al distanciarse de 1, sugieren que el modelo tiene un bajo valor predictivo, por lo que debe ser ajustado para aumentar la precisión.

	·	В	Wald	gl	Sig.	Exp(B)
Paso 1ª	Venta neto	.303	1.077	1	.503	1.124
	Cuota neto	1.202	102.500	1	.112	4.050
	Cantidad de cuotas	1.504	110.671	1	.320	4.007
	CantCuotEm	.142	.428	1	.776	1,076
	MUltPag	.000	.001	1	.981	1.342
	PagCuot	076	.332	1	.860	.978
	cantD	1.809	19.386	1	.204	4.667
	Mora	2.331	105.003	1	.051	2.122
	CantMora	.510	2.430	1	.073	.203
	MotMora	.044	.498	1	.542	.957
	IClient	-0.605	2.543	1	.077	.225
	ECivil	.005	.014	1	.650	.780
	NEstu	-1.183	.010	1	.402	.898
	Edad	.207	13.890	1	.000	2.667
	Sexo	.000	.002	1	.997	1.032
	Región	.000	.003	1	.365	1.096
	Comuna	.001	.021	1	.734	1.004
	Venta	.000	.010	1	.452	1.207
	Econtra	.025	.176	1	.224	1.025
	Eproy	1.432	108.760	1	.110	4.117

Tabla 7: Variables en la ecuación.

Después de llevar a cabo la primera iteración con las variables de la tabla 2 y analizar su significancia, podemos concluir que las variables CantCuotEm, MUltPag, PagCuot, MotMota, ECivil,NEstu, Sexo, Región, Comuna, Venta y Econtra no son significativas. Esto se debe a que no tienen influencia en el modelo o están relacionadas con otras variables. De manera consistente, estas mismas variables son descartadas al analizar el estadístico de Wald, ya que sus coeficientes son cercanos a cero, lo que indica que no contribuyen de manera significativa al modelo.





		В	Wald	gl	Sig.	Exp(B)
Paso 6ª	Venta neto	.493	1.232	1	.003	1.133
	Cuota neto	1.282	103.250	1	.012	4.061
	Cantidad de cuotas	1.714	112.621	1	.000	4.022
	cantD	1.903	20.236	1	.004	4.669
	Mora	2.472	107.001	1	.001	2.131
	CantMora	.690	6.020	1	.003	.196
	IClient	-0.359	2.593	1	.000	.220
	Edad	.334	14.520	1	.000	2.670
	Econtra	.221	.908	1	.024	1.030
	Eproy	1.528	110.128	1	.000	4.120

Tabla 8: Variables en la ecuación, ajustado.

Una vez ajustado el modelo, se procedió a emplear los coeficientes calculados mediante el programa con el objetivo de determinar la probabilidad de que un cliente sea considerado como incobrable. La estrategia determinada en conjunto con finanzas y comercial residencial para aplicar dichos resultados es la siguiente:

				Pronosticado	
			inif		
	Observac	do	Fuera de Incobrables	Está en incobrables	Porcentaje correcto
Paso 6	inif	Fuera de Incobrables	72	0	.0
		Está en Incobrables	48	0	100.0
	Porcenta	je global			65.3

Tabla 9: Resumen modelo, ajustado.

En la tabla de clasificación más reciente, notamos que el porcentaje de clasificación ha experimentado un aumento, alcanzando el 65.3%. Aunque ha mejorado, aún queda espacio para mejoras adicionales. Esto sugiere que el equipo de ventas y administración de contratos podría beneficiarse al recopilar y registrar información de mejor calidad.

Finalmente, los coeficientes obtenidos serán de ayuda para darle una segmentación a los clientes de flux, permitiendo agilizar la gestión, así como también gastar menos tiempo y energía del personal.

El nuevo modelo de gestión de cobranza se aprovechará el uso de herramientas tecnológicas avanzadas y estrategias analíticas para optimizar la eficiencia y mejorar la experiencia del cliente, de tal manera el nuevo modelo de gestión de cobranza seguirá el siguiente esquema:





ESQUEMA DE GESTIÓN DE COBRANZA.

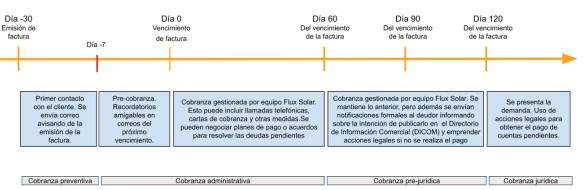


Figura 3: Esquema de Gestión de Cobranza.

En la gestión de cobranza representada en el esquema, se parte de la fecha de vencimiento de la factura, establecida actualmente a 30 días. La estrategia comienza 30 días antes del vencimiento, abordando proactivamente cuentas pendientes para evitar morosidad y preservar relaciones con los clientes. Esto incluye una cobranza preventiva y pre-cobranza.

Tras el vencimiento, se avanzan a etapas más formales a medida que los pagos se vuelven más difíciles de obtener, con recordatorios y comunicaciones más persistentes, como mensajes, correos electrónicos y llamadas frecuentes.

Entre el día 60 y el día 120 después del vencimiento, se lleva a cabo la cobranza pre-jurídica. Esta etapa busca resolver la situación de manera amigable, identificando problemas, negociando acuerdos de pago flexibles y evitando la escalada a acciones legales.

La fase final es la cobranza jurídica, una etapa avanzada activada cuando los esfuerzos previos no han tenido éxito. Implica acciones legales para obtener el pago, considerándose un último recurso debido a los costos legales y la falta de garantía de recuperación total de la deuda.

Utilizando la probabilidad de incobrabilidad obtenida a través de la regresión logística se clasificaron los clientes en distintos segmentos:

- 0-20%: Clientes Tipo A
 - Descripción: Clientes con alta probabilidad de pago que regularmente cumplen con sus facturas sin requerir acciones adicionales.
- 20-50%: Clientes Tipo B





- Descripción: Clientes con probabilidad media de pago. Usualmente requieren de recordatorios por correos electrónicos y llamadas telefónicas.
- 50-65%: Clientes Tipo C
 - Descripción: Clientes con baja probabilidad de pago. Se requerirá una gestión de cobro más constante.
- 65-100%: Clientes Tipo D
 - Descripción: Clientes con probabilidad muy baja o nula de pago. La gestión de cobranza será manejada por una empresa externa o se llevará directamente a cobranza judicial.

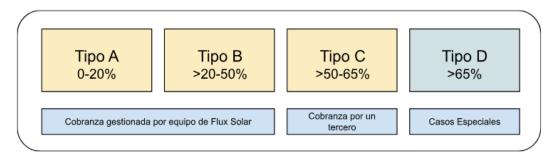


Figura 4: Clasificación según probabilidad de incobrabilidad del modelo logit.

Luego de ser clasificados los clientes, los que entren en el rango A y B su cobranza será gestionada por el equipo de Flux Solar, mientras que los que sean de tipo C serán gestionados por un equipo de cobranza externo. Para los casos críticos mayores a un 65% de incobrabilidad se analizarán caso a caso con el respaldo del área legal de Copec.





Resultados



Gráfico 2: Variación de la deuda asociada a la cartera de clientes morosos.

Del gráfico 2, podemos observar que durante los meses de julio, agosto y septiembre, la cartera de morosos ha ido en aumento, sin embargo, a finales de septiembre se comenzó a hacer los primeros avances en el modelo de gestión, lo que ha reducido significativamente a finales del mes de octubre, tomando como valor inicial el mes de agosto, esto implica una disminución para finales de octubre de un 11.5% aproximadamente, y se está cerrando el mes de noviembre con una disminución aproximada de un 18,5%

La implementación del nuevo modelo de gestión de cobranza, que incorpora la regresión logística, se inició a principios de la segunda semana de octubre. A la fecha, se ha aplicado un 75% del modelo propuesto. Este porcentaje se ha utilizado para calcular la probabilidad de incobrabilidad en la cartera de clientes vigentes, incluyendo aquellos con vencimientos en menos de 120 días.

Según los resultados de probabilidad, Flux Solar ha asumido la gestión de cobranza de clientes hasta el tipo C, ya que actualmente no cuentan con un tercero. Estos clientes, junto con los del tipo D, representan aproximadamente el 85% de los clientes con más de 120 días de morosidad. Además, se ha reorganizado la gestión de cobranza para cumplir con los aspectos preventivos, administrativos, pre-jurídicos y judiciales. Antes de la implementación, la cobranza jurídica se iniciaba a los 90 días sin gestionar una cobranza pre-jurídica. Actualmente, Flux Solar está en proceso de licitación con empresas especializadas para gestionar la cobranza de clientes tipo C. Mientras tanto, se ha decidido iniciar la cobranza pre-jurídica para esta categoría a partir de los 45 días.





Conclusión y Discusión

Los hallazgos confirman que la clusterización de clientes genera una reducción en la deuda de la cartera de clientes morosos, superando el objetivo planteado en un 3% con un cierre contable a noviembre 2023 y con una recuperación de deuda de aproximadamente \$45 millones de pesos. Es por ello que una gestión de cobranza eficiente no solo ayuda a garantizar el flujo de efectivo y reducir las pérdidas por incobrabilidad, sino que también contribuye a una mejor planificación financiera y a la optimización de recursos. Al implementar un modelo de gestión de cobranza basado en análisis de datos, la empresa puede prever de manera más precisa el comportamiento de pago de los clientes. Esto permite una estimación más precisa de las provisiones necesarias, evitando provisiones excesivas o insuficientes.

A pesar de las mejoras significativas del monto de morosidad, aún hay un potencial de mejora mayor, teniendo como consideración que el modelo ha debido adaptarse para obtener resultados en un corto plazo. Por otro lado, en lo referente al modelo de regresión logística, no solo cabe la mejora de la recopilación de datos, sino que, además, es necesario agregar a futuro una nueva variable que permita tener un mejor ajuste del modelo. Lo que se espera de esta variable es que mida la credibilidad del cliente, asignando un score dependiendo del cumplimiento de la palabra del cliente. Esto permitirá que el modelo *logit* entregue un resultado más preciso con clientes que no tienen un historial de comportamiento.





Referencias

- Asana, T. (s. f.). ¿Qué es la gestión de proyectos Lean? Los 5 principios para
 implementarla [2022] Asana. Asana. https://asana.com/es/resources/lean-project-management
- Barrientos, F., & Ríos, S. (2013). Aplicación de Minería de Datos para Predecir
 Fuga de Clientes en la Industria de las Telecomunicaciones. En Revista Ingeniería de Sistemas (pp. 73-103).
- BRAVO, C. (2012). MÉTODOS PARA ESTIMAR RIESGO CREDITICIO EN
 BASE A MINERÍA DE DATOS Y TEORÍA DE JUEGOS [TESIS POR
 COMPENDIO DE PUBLICACIONES PARA OPTAR AL GRADO DE DOCTOR
 EN SISTEMAS DE INGENIERÍA]. UNIVERSIDAD DE CHILE.
- Díaz Piraquive, F. N., (2008). Gestión de procesos de negocio BPM (Business Process Management), TICs y crecimiento empresarial. ¿Qué es BPM y cómo se articula con el crecimiento empresarial?. Universidad & Empresa, 7(15), 151-176.
- Dynamic. (2021, 29 mayo). Lean en Toyota. El inicio de la metodología DYNAMIC. DYNAMIC. https://www.dynamicgc.es/metodo-lean-toyota/
- Kirasich, K., Smith, T., & Sadler, B. (2018). Random Forest vs Logistic Regression:
 Binary classification for heterogeneous datasets. SMU Data Science Review, 1(3),

 9.https://scholar.smu.edu/cgi/viewcontent.cgi?article=1041&context=datasciencere view





- Medina-Merino, R. F., & Ñique-Chacón, C. I. (2017). Bosques aleatorios como extensión de los árboles de clasificación con los programas R y Python. Interfases, 0(010), 165. https://doi.org/10.26439/interfases2017.n10.1775
- Rojas, J. (2017). DISEÑO DE PROCESOS PARA LA SEGMENTACIÓN DE
 CLIENTES SEGÚN SU COMPORTAMIENTO DE COMPRA Y HÁBITO DE
 CONSUMO EN UNA EMPRESA DE CONSUMO MASIVO [PROYECTO DE
 GRADO PARA OPTAR AL GRADO DE MAGÍSTER EN INGENIERÍA DE
 NEGOCIOS CON TECNOLOGÍAS DE INFORMACIÓN]. UNIVERSIDAD DE
 CHILE.
- Sun, Z., Wiering, M. A., & Petkov, N. (2014a). Classification system for mortgage arrear management. IEEE/IAFE Conference on Computational Intelligence for Financial Engineering, Proceedings (CIFEr), (February), 489–496.
 https://doi.org/10.1109/CIFEr.2014.6924113
- Torres Navarro, C. A., & Callegari Malta, N. (2016). Criterios para cuantificar costos y beneficios en proyectos de mejora de calidad. Ingeniería Industrial,
 (Wijewardhana, s. f.)XXXVII(2), 151-163.
- Wijewardhana, U. A. (s. f.). A Mathematical Model for Predicting Debt Repayment:
 A technical note. Research Online. https://ro.uow.edu.au/aabfj/vol12/iss3/8/





Anexos

• Anexo 1: Cuadro comparativo modelos probabilísticos.

Modelo	Ventajas	Desventajas	Estudio
Bosques Aleatorios	Manejo de múltiples características: Maneja datos de alta dimensionalidad sin necesidad de reducirla, lo que lo hace un modelo adecuado para problemas que contengan un gran número de variables Reducida sensibilidad a valores atípicos: La combinación de los múltiples árboles cancelan los errores individuales entre sí.	Interpretación compleja: Ante la gran cantidad de árboles que requiere el modelo para mejorar tanto la generalización como la estabilidad de las predicciones, se ve dificultada la interpretación de contribución individual de cada árbol. Alto requerimiento de datos: Para aprovechar al máximo este modelo y evitar el sobreajuste, se necesita de una cantidad de datos considerable, por lo que si el conjunto de datos es pequeño, como el caso de Flux Solar, los bloques pueden tener dificultades para capturar patrones, dando lugar a un rendimiento deficiente en aquellos datos que sean nuevos o que no se hayan visto.	obtuvo que en todos los estudios de casos simulados, se encontró consistentemente que la tasa de falsos positivos para bosques aleatorios con 100 árboles era estadisticamente diferente a la regresión logística. Para proporcionar una cuantificación estadistica de si una diferencia en el rendimiento del modelo fue lo suficientemente concluyente como para afirmar que la diferencia es significativa o si la diferencia observada se debe al azar, se
Aleatorios	Manipulación eficaz de datos desequilibrados: Es capaz de ajustar los pesos de las clases durante el entrenamiento cuando una de las clases tiene muchas más instancias que otra.	Tendencia al sobreajuste: Esto ocurre debido a la adaptación del modelo a las peculiaridades, en lugar de trabajar los patrones subyacentes y relaciones generales, resultando en un modelo deficiente, comprometiendo la generalización	utilizó una prueba t de dos muestras por pares. Se descubrió que existe una diferencia estadísticamente significativa en las métricas de clasificación al variar las características de los datos utilizando un alfa de 0,05. Aumentar la varianza en
	No necesita de codificación especial para utilizar variables categóricas: Se pueden usar conjuntos de datos que contengan tanto variables categóricas como numéricas.	Alto uso de recursos: La naturaleza del modelo necesita de más recursos, por lo que implica también un mayor costo de inversión en requerimientos computacionales (Hardware potente o mayor tiempo de procesamiento), almacenamiento, paralelización, entre otros.	las variables explicativas y de nuido provocará una variación estadística diferencia significativa en la precisión y la tasa de verdaderos y falsos positivos.
	Rapidez computacional: Es un algoritmo simple y eficiente, lo que lo hace făcil de entender.	Mal funcionamiento ante estructuras complejas: Los clusters irregulares o de tamaños muy distintos no funcionan bien, ya que se asume que sean esféricos y de tamaños semejantes.	
K-means	La existencia de un centroide ayuda a describir la solución: Estos puntos son representativos de cada cluster y son clave para el proceso de agrupación.	Funciona en base a la k escogida: Seleccionar el número de clusters es subjetivo y puede afectar drásticamente los resultados.	
		Sensible a Outliers: Los centroides se pueden ver influenciados por puntos externos o valores atípicos.	
		No maneja datos categóricos: Está diseñado para utilizar distancias euclidianas.	
Regresión	Sencilla interpretación: Los coeficientes interpretados como odds ratio facilitan la comprensión de cada variable. Además, es capaz de manejar variables categóricas sin la necesidad de hacer una recodificación muy larga.	Dependencia cantidad y calidad de datos: los datos ausentes afectan la validez. Al igual que el número de características, ya que al ser grande en relación con el tamaño de la muestra, es probable que surjan	
Logística	No necesita de un supuesto en la distribución de errores: Otros modelos requieren de una regresión líneal, en cambio en este no se asume tal distribución.	Sensibilidad a Outliers o valores atípicos.	
		Multicolineadad severa: Las variables están fuertemente correlacionadas.	

Anexo 2

Estado Actual Proyecto		Transformación a dummy	Motivo de mora		
Por Coordinar	1	0	Olvido/Descuido	1	
Coordinado	2	0	Desempleo	2	
En Ejecución	3	0	Insatisfacción	3	
Preparación Certificación	4	0	Sin respuesta	4	
En Certificación	5	0	Evade contestar	5	
Notificación de Conexión	6	0	Falta de cobranza	6	
Conectado	7	1			
			Tipo de venta		
			Venta Directa	1	
			Leasing	2	
			Membresía	3	





 Anexo 3: Actual distribución de tareas en la administración de contratos en el área residencial (1.5 hr cada bloque)

<u>Facturación y Cobranza</u> Distribución de Principales Tareas						
- Se realiza revisión de	- Se realiza cobranza.	- Se realiza revisión de	- Se realiza cobranza.	- Se realizan llamados		
los clientes por		casos especiales.		telefónicos a clientes		
facturar en planilla de				que no contestan los		
estado de clientes.				correos de la semana.		
- Se realiza	- Se realizan facturas	- Se realiza revisión de	- Se realizan facturas	- Se contestan correos		
seguimiento a	en caso de requerirlo.	los clientes por	en caso de requerirlo.	de los clientes con		
clientes morosos.		facturar en planilla de		consultas o medios de		
		estado de clientes.		pago.		
- Se realizan facturas	- Se contestan correos	- Se realizan facturas	- Se contestan correos			
en caso de requerirlo.	de los clientes con	en caso de requerirlo.	de los clientes con			
	consultas o medios de		consultas o medios de			
	pago.		pago.			
- Se realiza revisión de		- Se contestan correos				
casos especiales.		de los clientes con				
		consultas o medios de				
		pago.				
- Se contestan correos						
de los clientes con						
consultas o medios de						
pago.						

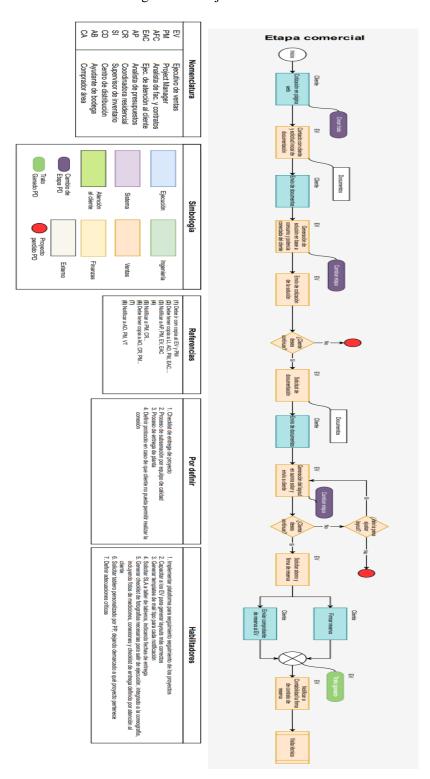
• Anexo 4: Cuentas por cobrar vigentes y vencidas agosto-noviembre

Meses	0 Días	30	60	90	120	más de 120	Total
Julio	\$70.150.023	\$23.491.505	\$30.667.040	\$15.209.015	\$28.932.506	\$80.221.025	\$248.671.114
Agosto	\$72.993.005	\$20.967.199	\$33.191.346	\$13.424.304	\$27.273.314	\$81.880.217	\$249.729.385
Septiembre	\$77.244.507	\$21.578.900	\$31.556.660	\$16.330.005	\$28.447.000	\$80.055.007	\$255.212.079
Octubre	\$68.449.002	\$21.040.512	\$20.304.680	\$11.004.559	\$22.330.800	\$78.004.055	\$221.133.608
Noviembre	\$62.644.881	\$19,420,350	\$17.343.666	\$9.543.526	\$19.546.785	\$75.122.354	\$203.621.562



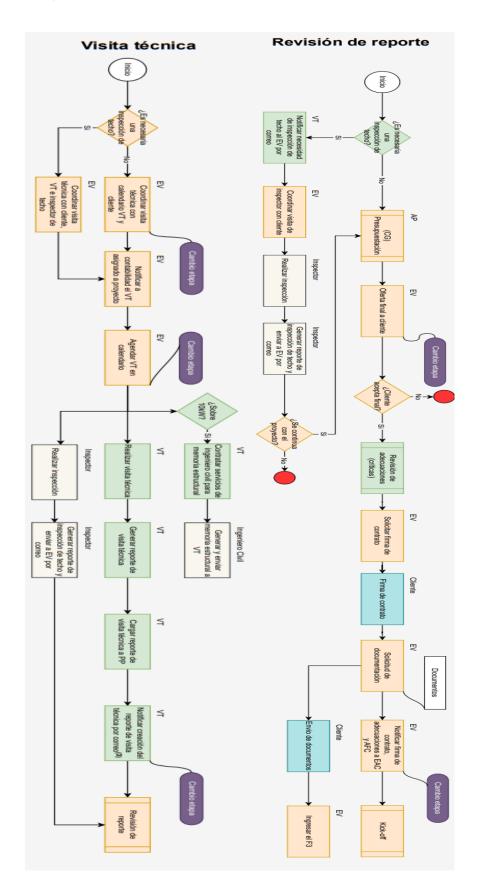


• Anexo 5: Diagrama de flujo área comercial residencial.



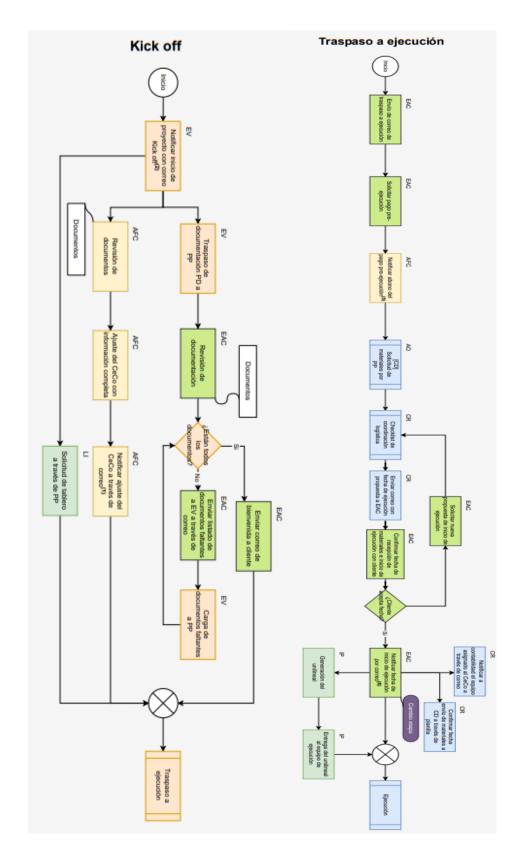






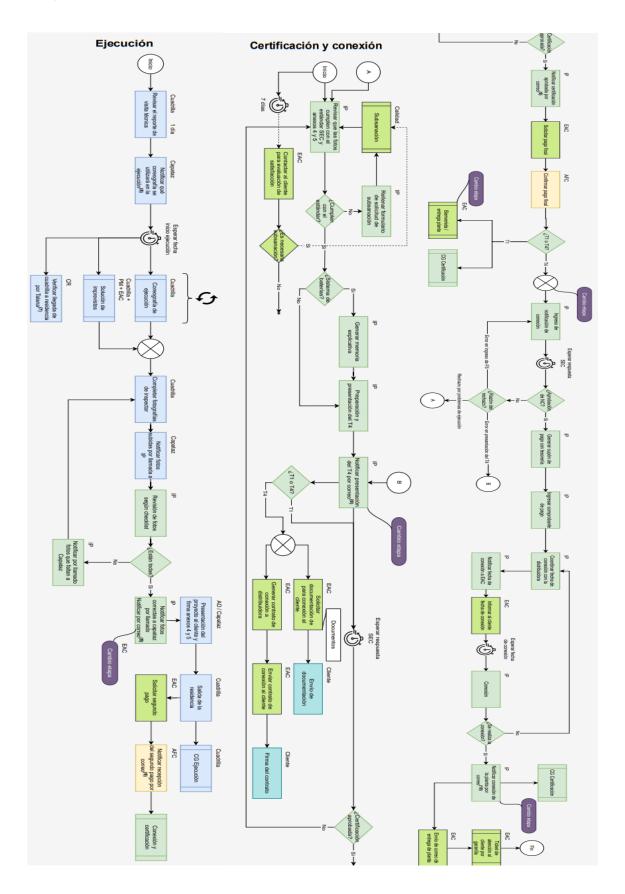








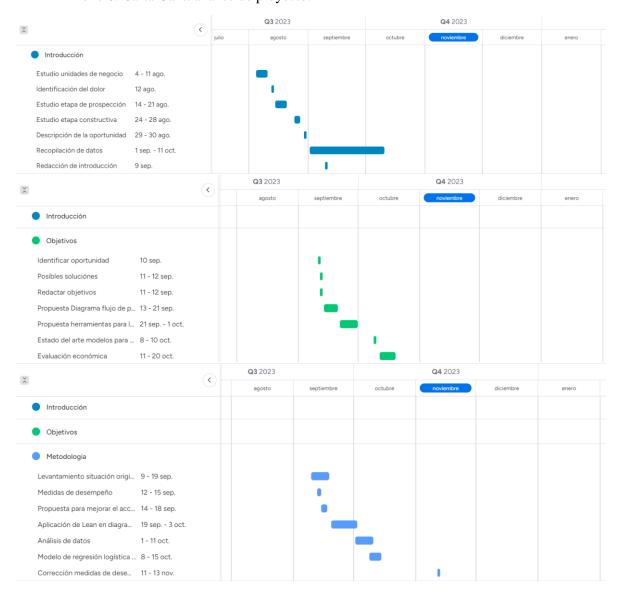








• Anexo 6: Carta Gantt avance de proyecto.







1	(Q3 2023			Q4 2023		
		agosto	septiembre	octubre	noviembre	diciembre	enero
Ejecución							
Diseñar diagrama de flujo 1 - 13 oct.							
Desarrollo herramienta 4 - 19 oct.							
Plan de implementación 10 - 20 oct.							
Matriz de riesgo 12 - 15 oct.				•			
Avance de implementación 19 - 31 oct.							
Pruebas en software probabili 23 - 26 oct.				•			
Analisis							
Resultados de avance y result 7 - 12 nov.							
Redacción de discusión 11 - 18 nov.							
Redacción de conclusión 11 - 15 nov.							
	< -	Q3 2023		Q4 2023			
	·	agosto	septiembre	octubre	noviembre	diciembre	enero
Introducción							
Objetivos							
Metodologia							
Ejecución							
Analisis							