

UNIVERSIDAD ADOLFO IBÁÑEZ
FACULTAD DE INGENIERÍA Y CIENCIAS



Clasificación de Reclamos

“Costumer Voice AI”.

Alumno: Héctor Saavedra González

Carrera: Ingeniería Civil Industrial

Universidad Adolfo Ibáñez

Empresa/Gerencia, Área: Walmart/Operaciones, Mejora continua

Profesor: Fernando Vásquez Acuña

2º Semestre 2023

Resumen Ejecutivo:

Walmart Chile, la reconocida empresa líder en el sector minorista, enfrenta desafíos en la gestión eficiente de reclamos de sus clientes. La plataforma "Hola!" hoy en día tiene una tasa de reclamos del 6,25% donde se encuentran reclamos mal categorizados, muy extensos o irrelevantes, lo que dificulta el análisis efectivo y veloz de los reclamos, ya que estos deben ser leídos de principio a fin, lo cual hasta antes de la implementación del proyecto era realizado por dos analistas, quienes solo se encargan de analizar reclamos referidos a las causas "incumplimiento de entrega" y "producto no corresponde", dejando la mayoría de los reclamos sin ser analizados, lo que provoca dificultades a la hora de mitigar los dolores de los clientes referidos al servicio entregado desde el centro de distribución desde el inventario de productos CATEx (inventario de Walmart referente a productos pequeños, medianos, grandes y muy grandes, muchos de estos no se venden en formato presencial por su tamaño o demanda), los reclamos revisados por las analistas, además, no especifican sobre qué producto está reclamando el cliente, lo que es otro problema cuando la compra asociada al reclamo posee más de un producto asociado, lo que dificulta aún más el análisis sobre los reclamos.

Dicho lo anterior, se ha planteado el **objetivo general de lograr agilizar el proceso de análisis de reclamos en un 85%, en un plazo de 4 meses**, lo que logrará realizar una clasificación de la totalidad de reclamos, donde además reducirá costos asociados al análisis de reclamos.

Para lograr lo planteado anteriormente se investigó que se estaba haciendo hoy en día en el mercado, donde se analizaron dos casos, uno que usa inteligencia artificial y otro que entrenó a un modelo de Machine Learning, se evaluaron ambos y se decantó por realizar dos modelos de Machine Learning, uno que clasifique reclamos y otro que busque el producto asociado al comentario.

Luego de la implementación de la solución se ha podido observar una reducción en el tiempo que toma en promedio analizar un reclamo de un 83,4%, lo que ha dotado a los analistas de reclamos de más tiempo para destinarlo a realizar análisis profundos de los dolores de los clientes. La solución final entrega información a través de tablas e "*insights*" por medio de un Dashboard realizado en Power BI. La solución logrará reducir los costos asociados a la clasificación de reclamos en \$1.836.000 CLP mensuales y permite clasificar todos los reclamos a gran velocidad.

Abstract:

Walmart Chile, the renowned leader in the retail sector, faces challenges in efficiently managing customer complaints. The "Hola!" platform currently has a complaint rate of 6.25%, including misclassified, overly lengthy, or irrelevant complaints, which hinders effective and swift analysis. Previously, these complaints had to be read from start to finish, a task performed by two analysts who only analyzed complaints related to "delivery non-compliance" and "incorrect product", leaving the most of complaints unexamined. This leads to difficulties in mitigating customer service issues arising from the distribution center and the CATEX product inventory (Walmart's inventory for small, medium, large, and very large products, many of which are not sold in stores due to their size or demand). Moreover, the complaints reviewed by the analysts do not specify the product in question, complicating the analysis further, especially when the associated purchase includes multiple products.

Given this situation, the primary goal has been set to expedite the complaint analysis process by 85% within four months. This will enable the classification of all complaints and reduce costs associated with complaint analysis.

To achieve this, market research was conducted, analyzing two cases: one using artificial intelligence and another training a machine learning model. After evaluation, it was decided to develop two machine learning models, one for classifying complaints and another for identifying the product associated with the feedback.

Following the implementation of the solution, there has been an observed reduction in the average time taken to analyze a complaint by 83.4%, providing analysts with more time for in-depth analysis of customer issues. The final solution delivers information through tables and insights via a Power BI Dashboard. This solution is expected to reduce the costs associated with complaint classification by \$1.836.000 CLP per month.

Definición del contexto:

Walmart es una de las cadenas minoristas más importantes del mundo, la compañía trabaja con distintos formatos en tiendas minoristas, supermercados, hipermercados, en muchos países, desde Estados Unidos a Chile, donde son conocidas como LIDER, Express de Líder, Central Mayorista y Super Bodega A Cuenta. En Chile se erradica desde 2009 luego de la adquirir una participación mayoritaria en la cadena D&S (Distribución y Servicio), empresa matriz de los formatos de Walmart Chile; Hiper Líder, Express de Líder, Ekono, Super Bodega aCuenta, la cual formo parte de la estrategia de expansión internacional de la empresa.

La integración a Chile implico la implementación de practicas comerciales y operativas alineadas con las políticas de Walmart y las normativas chilenas. Este proceso implicó desafíos importantes, dado que la empresa debió adaptarse a las particularidades del mercado chileno, donde se incluyeron preferencias del consumidor y dinámica competitiva del sector minorista.

La empresa se constituye de 7 gerencias, donde se encuentran las de Operaciones Logísticas Omnicanal, Innovación y Tecnología, Distribución Omnicanal, Replenishment, Delivery Experience, Personas y Protección de Activos. Dentro de la gerencia de Operaciones Logísticas Omnicanal se encuentra la subgerencia de Mejora Continua, la cual nace como soporte para e-commerce debido a su expansión en los últimos 4 años, la sugerencia está compuesta por 6 integrantes; un subgerente, un jefe de proyectos, ingeniero de proyectos, un ingeniero en gestión de mejora continua, un jefe de mejora continua y 2 analistas senior. La subgerencia se desempeña en ámbito de la eficiencia operativa, ya que el área tiene como misión optimizar la cadena de suministros, logística y gestión de inventarios mediante el uso de tecnologías y técnicas avanzadas¹.

Para Walmart, el cliente es el centro de su atención, donde la satisfacción del cliente es un indicador critico que afecta a la empresa y a su éxito. Para poder atacar este objetivo es necesario poder procesar de forma correcta y luego analizar productiva y efectivamente todos reclamos que llegan desde los clientes a las plataformas de la empresa bajo los diferentes canales disponibles (tienda, gerencia, *callcenter*). El gran dolor respecto a los reclamos que llegan a la plataforma "¡Hola!" Es la dificultad que implica la revisión de los reclamos ingresados por los clientes, donde abundan reclamos

¹ Información obtenida desde documentación interna de Walmart Chile.



que no califican para ser reclamos, o reclamos que no corresponden al producto ingresado, sumado a la lectura obligatoria del reclamo, factores como estos dificultan la identificación de los dolores reales de los clientes de la empresa. Hoy en día la tasa de reclamos por venta es del 6,25, se pretende disminuir este índice al menos hasta un 5%. Se ha estudiado que más de un 30% de los reclamos categorizados como CATEx (CE). Se contabilizaron más de 544.400 reclamos desde enero a septiembre de este año, solo en la primera semana de septiembre se contabilizaron 429.502 ventas, de las cuales 26.837 poseían reclamos, que representa un 6,23% de los reclamos².

² Información obtenida del dashboard interno de Walmart Chile. Este documento contiene datos específicos sobre las operaciones y el rendimiento de la compañía, accesibles solo para autorizados. (Walmart Chile, 2023).

Objetivos:

Los objetivos de este proyecto se establecen considerando la metodología SMART.

Objetivo SMART:

Agilizar análisis de reclamos en un 85%, automatizando la clasificación de la causa de este y el producto por el cual se reclama, en un plazo de 4 meses.

Objetivos Específicos:

1. Desarrollar una solución que automatice la categorización de los reclamos: La situación sin proyecto implica la lectura de cada reclamo, lo que dificulta el análisis de la totalidad de estos.
2. Aumentar el rendimiento del analista de reclamos investigados en la plataforma "¡Hola!": Se pretende que el análisis de reclamos como proceso en su totalidad se vea optimizado, así la detección de dolores de los clientes.
3. Evaluar el impacto de la implantación de la solución mediante la encuesta NSL, que mide la satisfacción del cliente: El trasfondo final de este proyecto es poder detectar los dolores de los clientes para así poder resolverlos y entregar un mejor servicio, lo cual será evaluado en la encuesta NSL.
4. Disminuir la cantidad de reclamos que llegan a la plataforma: Como resultado de la solución implementada y la resolución de dolores se debe ver rejado una disminución en la cantidad de reclamos recibidos.

Medidas de desempeño:

- Encuesta NPS (Net Promoter Score): Uno de los objetivos específicos es evaluar esta encuesta, que permite a los clientes calificar a la empresa entre una experiencia mala, neutra o recomendable, sirve para determinar la lealtad de los clientes a una empresa. Mide a través de una encuesta que tiene una única pregunta que se puntúa con valores entre -100 y +100, donde el objetivo es obtener la puntuación más alta.

$$NPS(final) - NPS(inicial)$$

	NPS actual	NPS esperado
NPS	52,2% ³	61%

Tabla: Net Promoter Score (Encuesta de satisfacción)⁴

- Tasa de reclamos: La cantidad de reclamos que llega de acuerdo con cada venta también es un indicador que será medido para el desempeño, debido a que mientras la solución sea beneficiosa esta debiese disminuir la cantidad de reclamos que llegan de acuerdo con la cantidad de ventas. Se analizará la variación de esta medida.

³ Información obtenida del dashboard interno de Walmart Chile. Este documento contiene datos específicos sobre las operaciones y el rendimiento de la compañía, accesibles solo para autorizados. (Walmart Chile, 2023).

⁴ Desarrollo de proyecto (Héctor Saavedra, 2023)

<i>Cantidad de reclamos</i> <i>Cantidad de ventas</i>		
	Tasa actual	Tasa esperada
Valor	6,25% ⁵	5,00%

Tabla: Tasa de reclamos.⁶

- Tasa de procesamiento de reclamos: El objetivo central de este proyecto es aumentar la eficiencia con que se analizan y procesan los reclamos, es por eso por lo que si la solución logra su objetivo la cantidad de reclamos procesados por hora debiese aumentar considerablemente. Se analizará la variación de esta medida.

<i>Cantidad de reclamos procesados</i> <i>Cantidad de horas de trabajo</i>		
	Tasa actual	Tasa esperada
Valor	30 (reclamos/hora) ⁷	120 (reclamos/hora)

Tabla: Tasa de reclamos.⁸

- Precisión del modelo propuesto sobre la categorización de reclamos: Se analizará si el modelo predice correctamente según sus cuatro causas principales y si predice correctamente el ítem o ítems por el cual se realiza el reclamo.

⁵ Información obtenida del dashboard interno de Walmart Chile. Este documento contiene datos específicos sobre las operaciones y el rendimiento de la compañía, accesibles solo para autorizados. (Walmart Chile, 2023).

⁶ Desarrollo de proyecto (Héctor Saavedra, 2023)

⁷ Información obtenida del dashboard interno de Walmart Chile. Este documento contiene datos específicos sobre las operaciones y el rendimiento de la compañía, accesibles solo para autorizados. (Walmart Chile, 2023).

⁸ Desarrollo de proyecto (Héctor Saavedra, 2023)

$$\frac{\text{Predicciones bien realizadas}}{\text{Cantidad de reclamos}}$$

Precisión esperada modelo clasificación	Precisión esperada modelo identificación
90%	80%

Tabla: Precisión esperada del modelo.⁹

⁹ Desarrollo de proyecto (Héctor Saavedra, 2023)

Metodología:

Para la metodología de este proyecto se abordó la metodología Scrum, donde el líder Scrum fue Marianny Godoy, el cliente será la analista de reclamos y el equipo desarrollador es el equipo de la gerencia de Excelencia Operacional OSCh de Operaciones, para el control de los avances del proyecto se realizaron “sprints” de manera periódica.

Objetivo Especifico 1	1.0 Identificación de tipo de solución.
	1.1 Recopilación y modificación de datos.
	1.2 Desarrollo y entrenamiento del modelo.
Objetivo Especifico 2	1.0 Identificación de herramientas útiles.
	1.1 Desarrollo de herramienta de visualización en Power BI para obtener el detalle sobre el resultado de los datos procesados.
Objetivo Especifico 3	1.0 Toma continua de la encuesta NPS.
Objetivo Especifico 4	1.0 Identificación de dolores de clientes.
	1.1 Levantamiento de soluciones sobre dolores
	1.2 Contabilizar la variación de cantidad de reclamos que llegan en determinado tiempo.

Tabla: Objetivos Específicos del Proyecto.¹⁰

¹⁰Desarrollo de proyecto (Héctor Saavedra, 2023)

Estado del Arte:

Para investigar posibles soluciones o ideas que implementar para atacar al problema que es la gran cantidad de reclamos que llegan a la plataforma de Walmart, de los cuales no hay ninguna forma de ser procesados de forma de generar un dato realmente valioso, se investigaron otros casos de éxito de empresas que hayan atacado problemas similares, este es el caso de ZTZ TECH GROUP que es una empresa de desarrollo de softwares, Comcast, empresa líder en prestación de servicios de telefonía y televisión en Estados Unidos y DeepTalk, empresa desarrolladora erradicada en Chile, para estudiar estos casos se siguió la siguiente estrategia.

ZTZ TECH GROUP¹¹:

- **Implementación de Inteligencia Artificial (IA):** La introducción de un sistema basado en IA ha permitido a ZTZ gestionar reclamos de forma automática y eficiente. A través de algoritmos avanzados, el sistema es capaz de entender, clasificar y direccionar los reclamos sin intervención humana, logrando reducir significativamente el tiempo de respuesta. De un promedio de 48 horas, la respuesta se ha acelerado a un impresionante promedio de 2 horas.
- **Análisis Predictivo:** Más allá de la gestión reactiva, ZTZ ha implementado modelos predictivos para anticipar posibles inconvenientes. Esto no solo reduce la cantidad de reclamos recibidos, sino que también permite a la empresa solucionar problemas antes de que escalen o incluso antes de que ocurran. Los resultados obtenidos por la implementación de estas soluciones son notables:
 - Se observó un aumento en la **eficiencia operativa** con una reducción del 40% en la carga de trabajo en atención al cliente. Esto se traduce en menos tiempo invertido en procesar reclamos y más tiempo disponible para otras tareas esenciales.
 - El incremento en la **satisfacción del cliente** ha sido significativo, registrando una mejora del 30% en las puntuaciones de satisfacción. Este es un indicador clave de que la solución no solo es beneficiosa para la empresa, sino también para el cliente, quien recibe respuestas más rápidas y soluciones más efectivas.

¹¹ ZTZ, TECH GROUP. Aprende a ordenar y clasificar tus reclamos. <https://ztz.ai/ahora-puedes-tener-el-control-aprende-a-ordenar-y-clasificar-tus-reclamos/>

- **Retorno de Inversión (ROI).** La implementación de estas tecnologías ha demostrado ser económicamente rentable, con un retorno del 150% en el primer año.

COMCAST¹²:

- **Adopción de la Inteligencia Artificial (IA):** Comcast ha incorporado sistemas basados en IA diseñados para agilizar y mejorar la eficiencia de su atención al cliente. Estos sistemas pueden entender y procesar rápidamente las solicitudes de los usuarios, direccionándolos hacia las soluciones adecuadas o derivándolos a un agente humano cuando sea necesario.
- **Uso del Análisis Predictivo:** Para evitar interrupciones en el servicio y anticipar posibles problemas, Comcast ha adoptado modelos predictivos. Estos modelos analizan patrones de uso y otros datos para prever y prevenir problemas antes de que afecten a los clientes.

Resultados notables de la implementación de estas soluciones incluyen:

- **Mejora en la Eficiencia Operativa:** Al automatizar parte del proceso de atención al cliente y anticipar problemas, Comcast ha reducido significativamente el tiempo de resolución de inquietudes y reclamos.
- **Aumento en la Satisfacción del Cliente:** Gracias a respuestas más rápidas y soluciones proactivas, los índices de satisfacción del cliente han mostrado una tendencia al alza.
- **Retorno de Inversión (ROI):** La inversión en estas tecnologías ha resultado en beneficios económicos tangibles para la empresa, no solo por la reducción de costos operativos, sino también por la retención de clientes satisfechos.

DEEPTALK¹³:

- **Uso de Inteligencia Artificial (AI):** DeepTalk incorpora herramientas de IA como IBM Watson, Google AI y Amazon Comprehend para comprender y analizar el mensaje que se transmite en un texto.

¹² Morrison, Gwen, and Susan Westwater. "Voice: The future of customer experience." *Journal of Brand Strategy* 11.3 (2022): 206-219.

¹³ Deep Talk, Voice of the Customers. Analyze the evolution of customer conversation <https://www.deep-talk.ai/voice-of-customer>.

- **Dashboards Interactivos:** DeepTalk usó herramientas de visualizaciones de datos como Power BI o Tableau para identificar tendencias y áreas de problemas rápidamente.

Los resultados de la implementación de estas herramientas:

- **Mejora en Eficiencia del Proceso de Análisis:** Reducción en el tiempo requerido para procesar y responder reclamos y aumento de capacidad de análisis de reclamos.
- **Reducción de Costos Operativos:** Disminución en la necesidad de personal para analizar reclamos y sus costos asociados.
- **Generación de Datos Valiosos para Mejora Continua:** Los datos recopilados son utilizados para mejorar el servicio entregado, debido a la posibilidad de integrar las conclusiones de los análisis de reclamos en las tomas de decisiones de la empresa.

Estrategia de Búsqueda de Casos para el Estado del Arte:

Para la búsqueda se usaron palabras claves como “Machine Learning”, “gestión de reclamos” y “procesamiento de lenguaje natural”, se usaron los motores de búsqueda de Google Scholar, IEEE Xplore y JSTOR e informes de la industria de Gartner y McKinsey. Se siguió con un análisis y síntesis de la información, donde se identificaron las tecnologías que se están usando en la industria, las tendencias y tecnologías emergentes y diferencias que se pudieran encontrar respecto a nuestras necesidades. Finalmente se verificó que las fuentes fueran confiables y estén reconocidas en el ámbito académico y profesional.

Elección de la solución:

Se usó una matriz de asignación de puntajes con una escala del 1 al 5 tipo Likert, siendo 1 muy bajo y 5 muy alto, se usó un número impar para evitar neutros. Para asignar el puntaje correctamente se discutió con el equipo de análisis de datos para considerar que aspectos podrían ser más relevantes para la solución. Se determinaron los siguientes criterios y ponderaciones de acuerdo con su importancia:

Criterio	Consideraciones	Ponderación
Automatización de categorización	Eficiencia en la categorización automática, reducción de errores,	30%

	adaptabilidad a nuevos tipos de reclamos.	
Rendimiento del analista	Mejora en la productividad del analista, tiempo de respuesta, calidad del análisis.	25%
Impacto mediante NSL	Mejora en la satisfacción del cliente, feedback positivo, resolución efectiva de problemas.	25%
Reducción de reclamos	Disminución en el volumen total de reclamos, efectividad en la prevención.	20%

Tabla: Ponderaciones elección de solución.¹⁴

Con una escala de Likert del 1 al 5 junto con la tabla anterior se asignaron puntajes a cada solución para COMCAST y ZTZ, a continuación, la puntuación de COMCAST.

Solución	Automatización de categorización	Rendimiento del analista	Impacto mediante NSL	Reducción de reclamos	Ponderación final
COMCAST	5	4	4	3	4.3

¹⁴ Desarrollo de proyecto (Héctor Saavedra, 2023)

ZTZ	4	5	3	4	4.1
DeepTalk	5	4	3	3	4.1

Tabla: Elección de solución.¹⁵

De esta matriz, se seleccionan las tres soluciones con la mayor puntuación final en relación con los criterios y objetivos del proyecto. Como resultado, se proponen las siguientes medidas de implementación para COMCAST:

1. La implementación de técnicas avanzadas como el procesamiento del lenguaje natural (NLP) y el análisis de sentimiento indica un enfoque tecnológico y moderno hacia la resolución de problemas similar a los que se poseen en esta organización, donde los comentarios al igual que en Walmart son sin una estructura definida.
2. Implementación de herramientas de análisis predictivo para anticipar tendencias y optimizar la estrategia de negocio.
3. El aumento en la encuesta Net Promoter Score (NPS) del 25% la cual se asemeja al objetivo fijado como equipo de trabajo, la cual además refleja una solución enfocada en el cliente.

La solución escogida ha sido la llevada a cabo por Comcast, de esta forma nos hemos planteado desarrollar un modelo capaz de convertir los comentarios de los clientes en datos procesables, de tal manera que logre identificar a la causa asociada al reclamo y el producto por el cual se reclama. Por ejemplo, se tiene un reclamo con el código de seguimiento SG igual a 510567678, el cual posee dos productos asociados, un celular Galaxy s23 y unos audífonos, mientras que el comentario del reclamo es: "Cliente molesto porque solo le llegó los audífonos a su pedido". El resultado de nuestro modelo para este caso sería causa iguala producto faltante y producto corresponde a audífonos.

¹⁵ Desarrollo de proyecto (Héctor Saavedra, 2023)

Desarrollo del Modelo de Identificación de Producto.

Se empezó trabajando para crear el modelo de identificación de producto, para implementar esta solución se está trabajando con variables como: ITEM, DESCRIPCION, FINELINE_DESC, CASENUMBER, NUMERO_SG2 Y PRODUCTO. Estas variables corresponden al código del producto, la descripción de este, FINELINE_DESC es un tipo de familia del producto (sillas, mesas, televisores, etc.), CASENUMBER se refiere a un código de seguimiento por reclamo, es decir que un SG puede tener más de un CASENUMBER, NUMERO_SG2 (SG) se refiere al código de seguimiento de la compra, el cual tiene los productos asociados a esta, finalmente PRODUCTO es la variable que posee el nombre del ITEM.

	ITEM	DESCRIPCION	FINELINE_DESC	Descripción	CASENUMBER	NUMERO_SG2	SG_PADRE_INT	ITEM_y	PRODUCTO
0	787920	MESA INFANTIL TINCHY	MESAS Y SILLAS	caso asociado descripción fecha de reti...	4639979	51011586620	51011586620	787920	Mesa Infantil Blanco
1	787920	MESA INFANTIL TINCHY	MESAS Y SILLAS	mesa infantil blanco cantidad unidad marca...	4804146	51012825854	51012825854	787920	Mesa Infantil Blanco
2	787920	MESA INFANTIL TINCHY	MESAS Y SILLAS	cliente manifiesta mi producto llevo incompli...	4810921	51012825854	51012825854	787920	Mesa Infantil Blanco
3	782505	MESA PLEG 152 NEGRO	MESAS PLEGABLES COMEDOR	cliente vino a retirar su producto (una mesa "p...	4610266	51011821532	51011821532	782505	Mesa Plegable 152 Negro
4	782505	MESA PLEG 152 NEGRO	MESAS PLEGABLES COMEDOR	caso de reclamo creado mediante dmfo en hola	4644604	51011821532	51011821532	782505	Mesa Plegable 152 Negro
...
4483	106026	CAMA AILA MULTI 1.5P	"CAMA 1.5 PLAZA "	que la cama no tiene instructivo ni piezas par...	4782294	51012031645	51012031645	106026	Cama Aila Multifuncional 15 Plaza
4484	5005204	CAF 1.5P PL +RES+TOP	"CAMA 1.5 PLAZA "	que no le llevo el manual para armar la cama...	4759895	51012097820	51012097820	5005204	Cama Americana Funcional 15 Plaza Plus + Respa...
4485	5005204	CAF 1.5P PL +RES+TOP	"CAMA 1.5 PLAZA "	que le llevo incompleto este pedido foto una...	4815536	51012257771	51012257771	5005204	Cama Americana Funcional 15 Plaza Plus + Respa...
4486	809607	CAMA 1.5P LATINO MO	"CAMA 1.5 PLAZA "	que a la cama le hace falta tomadores las ma...	4664070	51011478993	51011478993	809607	Cama 15 Plazas Con 4 Puertas Latino Montana
4487	809607	CAMA 1.5P LATINO MO	"CAMA 1.5 PLAZA "	caso de reclamo creado mediante dmfo en hola	4693414	51011478993	51011478993	809607	Cama 15 Plazas Con 4 Puertas Latino Montana

Tabla: DataFrame unión reclamos con Finesline del producto.¹⁶

Se separaron los datos en datos de entrenamiento y de validación, para esto primero nos quedamos con los datos de SG que solo tuvieran un producto asociado a la compra, los cuales corresponden al 84,5% de los casos. Se separo el DataFrame en valores como X e Y, variable dependiente y la variable independiente de nuestro modelo, lo que en este caso serán el comentario como la variable dependiente y la primera palabra del FINELINE como la variable independiente, la idea es que el modelo busque este FINELINE en el comentario del cliente para de esta forma poder asociar el reclamo a un producto.

A continuación, se convirtieron los valores Y (primeras palabras de FINELINE), respecto a esto, se tienen 1478 productos distintos, donde se obtuvieron 327 FINELINES_DESC, los cuales fueron ajustados por distintos errores y conveniencias para el modelo, de esta

¹⁶ Desarrollo de proyecto (Héctor Saavedra, 2023)

forma se está trabajando con 225 valores finales a los cuales se les llamo “primera_palabra”.

Se continuo con la tokenización, el cual es un proceso que ayuda a convertir el texto en una forma que las máquinas puedan entender y analizar de forma más eficiente.

```
# Tokenizar el texto
tokenizer = Tokenizer(num_words=15000) # Limitamos el número de palabras
tokenizer.fit_on_texts(X_train)

X_train = tokenizer.texts_to_sequences(X_train)
X_val = tokenizer.texts_to_sequences(X_val)
X_test = tokenizer.texts_to_sequences(X_test)

print("Ejemplo 1:", X_train[0])
print("El dato tiene", len(X_train[0]), "tokens")
print("Ejemplo 2:", X_train[1])
print("El dato tiene", len(X_train[1]), "tokens")
print("")

# Paso 5: Pad sequences para que tengan la misma longitud
max_len = 200 # Definimos una longitud máxima para las secuencias
X_train = pad_sequences(X_train, maxlen=max_len)
X_val = pad_sequences(X_val, maxlen=max_len)
X_test = pad_sequences(X_test, maxlen=max_len)

print("Ejemplo 1:", X_train[0])
print("Ejemplo 2:", X_train[1])
print("Los datos tienen", X_train.shape[1], "características")
```

Figura 2: Tokenización.¹⁷

Luego se entrenó y trabajo sobre un modelo de red neuronal que sea capaz de predecir lo expuesto anteriormente.

1. **Entrenamiento del Modelo:** El modelo se entrena usando los datos de entrenamiento preparados. Este proceso ajusta los parámetros del modelo para minimizar el error de predicción del producto.
2. **Ajuste de Hiperparámetros:** Se realiza la búsqueda de hiperparámetros para obtener la configuración óptima que haga al modelo lo más asertivo posible, lo que incluyó la modificación de la tasa de aprendizaje, el numero de capas y neuronas de la red neuronal.

¹⁷ Desarrollo de proyecto (Héctor Saavedra, 2023)

3. **Validación del Modelo:** Se usó el conjunto de datos de validación para evaluar el rendimiento de la red.
4. **Métricas de Rendimiento:** Se aplicaron métricas sobre el rendimiento en la precisión del modelo, recall y F1-score para evaluar la calidad de precisión.

Desarrollo Modelo de Clasificación de Reclamos.

Siguiendo con la mejora continua para agilizar la gestión de reclamos de clientes en Walmart Chile, se desarrolló un modelo de clasificación de reclamos capaz de seleccionar entre varias causas comunes de descontento. Su desarrollo se detalla en 5 partes:

1. Selección y Preparación de Datos:

- **Recopilación de Datos:** Se trabajó con bases de datos que incluyen más de 10.000 reclamos reales de clientes de Walmart Chile.
- **Categorización de Reclamos:** Los reclamos se clasificaron en las siguientes causas:
 1. Incumplimiento de entrega.
 2. Producto no corresponde.
 3. Producto deteriorado.
 4. Accesorio o pieza faltante
 5. Producto faltante
 6. Causa desconocida.
- **Marcadores Adicionales:** Se agregaron marcadores que indican si el reclamo explicita algún producto y si implica devoluciones de dinero.

2. Evaluación de Modelos:

- Se analizaron tres modelos: BERT (por sus capacidades en el procesamiento de lenguaje natural), RandomForest (por su robustez y fácil interpretación) y Redes Neuronales (por su capacidad de aprendizaje profundo).

3. Implementación del Modelo:

- **Instalación de bibliotecas:** Se instalaron las bibliotecas necesarias en Python, donde se incluye Pandas para la manipulación de datos, scikit-learn para algoritmos de Machine Learning y TensorFlow para redes neuronales.

- Limpieza de datos: Se desactivaron advertencias de Pandas, eliminación de caracteres de escape, estandarización del texto, eliminación de acentos, símbolos, números, direcciones de correos electrónicos, saltos de línea y palabras o frases no relevantes.
- Exportación: Los datos limpios se exportaron en formato CSV para su uso.

4. Preparación de Datos para el Modelo:

- Selección de variables: Se usaron las columnas "Descripción" (reclamo) y "Causa Real" del DataFrame, la clasificación del reclamo como variables independientes y dependientes, respectivamente.

5. Desarrollo y Validación del Modelo:

- División de datos: Se dividió el conjunto de datos en uno de entrenamiento y otro de prueba para su uso en la validación del modelo.
- Creación y configuración de Pipeline: Se configuro un pipeline en scikit-learn, que incluye vectorización TF-IDF y RandomForestClassifier, integrando el procesamiento de texto y clasificación en un solo flujo.
- Optimización de Hiperparámetros: Uso de GridSearchCV para explorar y obtener los parámetros que optimizan el rendimiento del modelo.
- Entrenamiento y elección: El modelo se entrenó y se seleccionó el de mejor rendimiento, considerando, además validación cruzada.
- Evaluación y resultados: Se evaluó el mejor modelo usando "classification_report()", proporcionando un análisis detallado del rendimiento, con recall y F1-score para cada causa.

Creación de Dashboard en Power BI.

Luego de desarrollar los modelos de clasificación de texto, se siguió con la creación de un dashboard en Power BI, que permite visualizar la información obtenida de manera clara e iterativa, para esto se siguieron los siguientes pasos:

1. Exportación de Datos de Modelos:

Los resultados como causas y productos asociados a reclamos, como palabras más repetidas son exportadas en formato CSV de forma que pueda ser leído por Power BI.

2. Creación de Dashboard en Power BI:

Usando el software se crea dashboard que importan los datos explorados.

3. Visualizaciones:

- Tablas de Productos más Asociados a Tipos de Reclamo: Una tabla que muestra los productos más relacionados a causas específicas.
- Análisis de Texto: Visualización de nube de palabras que muestra las palabras más repetidas en los reclamos.

4. Interactividad y Filtrado:

El dashboard permite a los usuarios filtrar según causa específica, fecha, entre otros. Esto facilita un análisis más profundo y segmentado de la información cargada.

Implementación:

- Pre-Lanzamiento:
 - Configuración y validación de modelos de Machine Learning para clasificar reclamos automáticamente.
 - Entrenamiento de analistas en interpretación de datos y uso del nuevo dashboard de Power BI.
- Día 0:
 - Implementación de modelos de Machine Learning y entreno del dashboard para el monitoreo en tiempo real de reclamos.
 - Monitorización cuidadosa para facilitar la transición a las nuevas herramientas y flujos de trabajo.
- Post-Lanzamiento:
 - Cambio en la operativa de los analistas de reclamos, que ahora deben priorizar la revisión de insights del dashboard antes que leer reclamos.
 - Revisión y ajuste continuo del proceso de trabajo y las herramientas basándose en el rendimiento de los modelos y el feedback del equipo.

Revisión Final:

1. Evaluación de Desempeño: Se analiza el funcionamiento de los modelos y del dashboard, considerando KPIs.
 2. Feedback de Analistas: Recopilación de comentarios y feedback de los usuarios, para considerar futuras mejoras.
- Planificación de Mantenimiento: Se establece un plan para futuras actualizaciones o ajustes basados en la experiencia de implementación y los cambios respecto a productos.

Análisis de Riesgos y Matriz de Mitigación para el Modelo de Clasificación de Reclamos de Cliente.

Matriz de Riesgo

Riesgo	Probabilidad de Ocurrencia	Impacto	Estrategia de Mitigación
Modelo no es preciso	Media	Alto	Validación cruzada, ajuste de parámetros, revisión de la calidad de los datos
Datos de entrenamiento no representativos	Media	Alto	Recolección diversa de datos, revisión de fuentes, aumento de datos
Sesgos en el modelo (e.g. hacia ciertos productos o tipos de reclamo)	Media	Alto	Análisis de sesgo, diversificación de datos, retroalimentación modelo.
Cambios el inventario de productos	Alta	Medio	Reentrenamiento periódico, adaptación dinámica, retroalimentación constante ¹⁸

Tabla: Matriz de riesgo.¹⁹

Clasificación de Riesgos

- Riesgos Técnicos: Relacionados con la construcción, entrenamiento y precisión del modelo.
- Mitigación: Validación constante, mejora continua del modelo, exploración de nuevos algoritmos.
- Riesgos de Datos: Problemas asociados a la calidad, cantidad y representatividad de los datos de entrenamiento.
- Mitigación: Auditorías de datos, recolección diversa, limpieza y preprocesamiento adecuado.
- Riesgos de Interfaz y Usuario: Dificultades o confusiones al usar el modelo.
- Mitigación: Diseño de interfaz intuitiva, capacitaciones, soporte técnico.
- Riesgos Temporales: Cambios en los patrones de reclamos o en los productos a lo largo del tiempo.

¹⁸ Desarrollo de proyecto (Héctor Saavedra, 2023)

¹⁹ Desarrollo de proyecto (Héctor Saavedra, 2023)



- Mitigación: Reentrenamiento periódico, revisiones constantes, adaptabilidad del modelo.

Resultados Proyecto Clasificación de Reclamos

Modelo 1: Identificación del Producto Reclamado

- Precisión de predicción: El modelo hoy es capaz de identificar con una precisión del 30,10% el producto por el cual reclaman se debe considerar que solo en un 63,2% de los casos se habla del producto, así, el modelo predice bien un 47%.

```
18/18 [=====] - 0s 2ms/step - loss: 2.9824 - accuracy: 0.3011
Loss: 2.9824376106262207, Accuracy: 0.301075279712677
```

Imagen: Precisión modelo identificación de producto

- Precisión en identificación: El 84,3% de los reclamos poseen asociado a su número de compra un solo producto, por lo tanto, en estos casos el producto es identificado, así resulta una precisión de identificación el 89% de los casos:
 - $100\% - 84,3\% = 15,7\%$
 - $30,1\% * 15,7 = 4,72\%$
 - $4,72\% + 84,3\% = 89,03\%$
- Reducción del Tiempo de Procesamiento: Mediante la identificación automática del producto, se reduce el tiempo de identificación de producto en un 70%.

Medición	Buscar 'CAMA NIDO' (seg)	Leer Directamente 'CAMA NIDO' (seg)
1	17.29	5.05
2	13.94	4.67
3	12.80	5.94
4	14.49	4.98
5	16.05	6.30
6	20.50	6.69
7	11.52	4.11
8	18.04	5.32
9	12.78	4.41
10	17.05	3.50

Tabla: Mediciones resultado solución.²⁰

- Promedio al Buscar Rápidamente 'CAMA NIDO': 15.45 segundos
- Promedio al Leer Directamente 'CAMA NIDO': 5.10 segundos
 - $\frac{5,10}{15,53} = 34,8$
 - $100 - 34,8 = 67,2$

²⁰ Desarrollo de proyecto (Héctor Saavedra, 2023)

La solución optimiza el tiempo de identificación de producto en un 67,2% del tiempo.

Modelo 2: Clasificación del Tipo de Reclamo

- Precisión de Clasificación: El modelo clasifica correctamente según la causa en un 82% de los casos.

```
Exactitud del TRAIN: 0.9748743772506714
Exactitud del VAL: 0.8790954923629761
Exactitud del TESTEO: 0.8762650465965271
Reporte de clasificación:
      precision    recall  f1-score   support

 Faltante pieza y accesorio      0.79      0.78      0.79         83
 Incumplimiento en entrega de pedido 0.79      0.84      0.82        137
   Producto deteriorado         0.85      0.91      0.88        172
   Producto faltante            0.89      0.89      0.78         97
   Producto no corresponde       0.86      0.86      0.86         97
     Sin información            0.89      0.78      0.78         78

 accuracy                   0.88                   664
 macro avg                  0.88      0.88      0.88      664
 weighted avg               0.82      0.82      0.82      664
```

Imagen: Precisión modelo de identificación de causa.²¹

- Reducción del Tiempo de Procesamiento: La solución reduce el tiempo de clasificación de reclamos en un 95%.

Medición	Identificar Leyendo Todo el Comentario (seg)	Leer Directamente 'Incumplimiento de Entrega' (seg)
1	50.74	3.10
2	49.79	3.51
3	43.92	3.42
4	59.31	2.86
5	55.75	3.78
6	34.18	3.85
7	52.65	4.16

²¹ Desarrollo de proyecto (Héctor Saavedra, 2023)

8	52.80	4.08
9	58.09	3.50
10	45.77	4.10

Tabla: Mediciones resultado modelo de clasificación.²²

- Leer todo el comentario: 50,3 segundos.
- Leer directamente “Incumplimiento de entrega”: 3,63 segundos.

La solución optimiza el tiempo de clasificación en un 92,77% del tiempo.

Dashboard en Power BI

- Visualización Clara: El dashboard muestra los principales indicadores relacionados a los reclamos, donde se especifican las causas más reclamadas y los productos asociados a ella, además se incorporó una nube de palabras donde se encuentran las palabras mas usadas para describir un reclamo asociado a un producto o no.
- Filtrado causa: El Dashboard permite gestionar la información de acuerdo con las causas asociadas.
- Actualización en Tiempo Real: La información mostrada en el dashboard se actualiza de forma que refleja la situación actual del CD y los clientes.
- Detalle de cantidad de reclamos recibidos en un tiempo determinado y los productos asociados a este.
- Tablas con información sobre los productos mas reclamados y las palabras más repetidas en los comentarios.

²² Desarrollo de proyecto (Héctor Saavedra, 2023)

Reclamos Catex

CAUSA DESCONOCIDA	Faltante pieza y accesorios	Incumplimiento en entrega de pedido	producto deteriorado	Producto faltante	Producto no corresponde
-------------------	-----------------------------	-------------------------------------	----------------------	-------------------	-------------------------

387

CANTIDAD RECLAMOS

274

PRODUCTOS

24

Reclamos del día

TOP 20 PRODUCTO RECLAMADOS	
PRODUCTO	CANTIDAD
Microondas 27 Lts ME0113M81	6
Televisor 55Uq7500Psf 55 Pulgadas 4K Ultra Hd	6
Cama Europea Apolo Black 2 Plazas BN + Set Asturias	5
Corta Cesped Electrico 1700 W Capacidad Caja Rec	5
Almohada Comprimida 50x70	4
Camarote New Texas 1 Plaza	4
Fridora de Aire Smart 35 lts	4
Lavadora Semiautomatica Twister S300 Blue 4 kg	4
Mesa Gamer Zebra King Con Luces	4
MIC SG ME0114M81/XZS	4
Protector Piso Gamer 117x117 Cm Cmc C D-4 Negro-Az	4
Bicicleta Magnetica MTPD-652-S-2	3
Closet Charm New 6 Puertas Caoba	3
Colchon New Ortopedic 15 Plaza	3
Cuna Colecho Lora Essential Grey	3
Juego de Sábanas Gris 300 Hilos 100 Algodon King	3
Living Kahlo 3 Cuerpos + 2 Pouf Tela Cc	3
Mueble Organizador 2 Puertas	3
Respaldo Verde Boton	3
Sofa Negro	3
Total	77

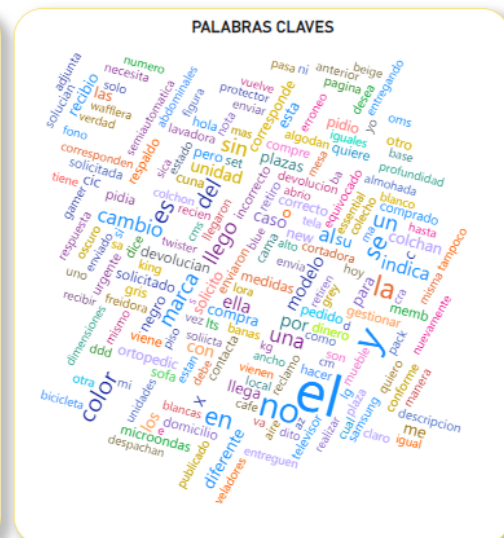


Imagen: Visualización dashboard “Reclamos Catex”.²³

Finalmente, gracias al proyecto se lograron impactar los siguientes KPIs:

²³ Desarrollo de proyecto (Héctor Saavedra, 2023)

Medidas de desempeño (KPIs)

Los resultados del proyecto se pueden calcular considerando los siguientes indicadores:

- Tasa de procesamiento de reclamos:

$$\frac{\text{Cantidad de reclamos procesados}}{\text{Cantidad de horas de trabajo}} = \frac{16.671 (\text{reclamos mensuales})}{180 (\text{horas})} = 92,61 (\text{reclamos})$$

Gracias a la implementación de la solución hoy en día se logran analizar mas de 90 reclamos en una hora,

- Precisión del modelo propuesto sobre la categorización de reclamos: El modelo de clasificación de categoría logró una precisión del 90%, mientras que se predice el producto correspondiente el 89% de las veces.

Por otro lado, respecto a la encuesta "NPS" (Net Promoter Score) de satisfacción logística aplicada sobre los clientes, la solución aún no ha tenido un impacto, debido a su reciente implementación, de igual forma, la Tasa de Reclamos" la solución implementada aún no ha tenido un impacto al nivel de hacer que disminuya la tasa de reclamos, se esperan cambios en estos indicadores a largo plazo.

Evaluación Económica

La implementación del proyecto ha sido evaluada económicamente, considerando métricas claves como el Valor Actual Neto (VAN), que trae a valor presente los flujos futuros, y la Tasa Interna de Retorno (TIR), la tasa de interés en la que el VAN de la inversión es igual a cero.

Para la evaluación económica del proyecto se consideraron las siguientes variables:

Variable	Descripción
Costos anuales del proceso (HH de responsables)	Costos asociados al desarrollo del modelo (salarios de practicantes)
Costos Anuales Fijos	Costos relacionados a los salarios que se dejaran de pagar en una situación con proyecto.
<i>Tabla: Variables a considerar en evaluación de costos.²⁵</i>	
Utilidad Antes de Impuestos	Utilidades antes de la aplicación de impuesto a la renta, correspondiendo a 10% en Chile.
Utilidades Después de Impuestos	Utilidades luego de la aplicación del impuesto a la renta.
Flujo Operacional	Suma de Ingresos Operacionales
Inversión Fija	Inversión llevada a cabo por Walmart para llevar a cabo el proyecto, se hace solo una vez e implica el costo relacionado a horas pagadas de los practicantes que tardaron en realizar el proyecto.
Flujo de Capitales	Suma del movimiento de capitales.
Flujo de Caja privado	Suma de flujo operacional más flujo de capitales. ²⁴

Se realizaron dos flujos de caja, uno de la situación sin proyecto y otro de la situación en que Costumer Voice es aplicado. Para esto se consideraron las siguientes variables:

²⁴ Desarrollo de proyecto (Héctor Saavedra, 2023)

²⁵ Desarrollo de proyecto (Héctor Saavedra, 2023)

Consideraciones de Costos

Costos Hundidos y Servicios Preexistentes: En el contexto de la evaluación económica de Costumer Voice AI, es importante aclarar que recursos y servicios, que, aunque fueron utilizados para la creación de los modelos de Machine Learning, son considerados como costos hundidos y, por lo tanto, no se incluyeron en el análisis económico del proyecto, donde se incluye:

- Power BI pro: Esta licencia, utilizado para la visualización y análisis de datos ya formaba parte de las herramientas que posee la empresa desde antes del inicio del proyecto, por lo tanto, es considerado como un costo hundido.
- Servidores de fuentes de datos: De la misma forma, los costos asociados a mantención de servidores con bases de datos no fueron considerados para la evaluación económica del proyecto, ya que también fue considerado como un costo hundido.

Flujo de Caja sin Proyecto						
Año	0	1	2	3	4	5
Costo Fijo		\$ -2.400.000,00	\$ -2.400.000,00	\$ -2.400.000,00	\$ -2.400.000,00	\$ -2.400.000,00
Utilidad Antes de Impuestos		\$ -2.400.000,00	\$ -2.400.000,00	\$ -2.400.000,00	\$ -2.400.000,00	\$ -2.400.000,00
Impuesto a las empresas		\$ 240.000,00	\$ 240.000,00	\$ 240.000,00	\$ 240.000,00	\$ 240.000,00
Utilidad Despues de Impuestos		\$ -2.160.000,00	\$ -2.160.000,00	\$ -2.160.000,00	\$ -2.160.000,00	\$ -2.160.000,00
Flujo de Caja Privado (Sin Proyecto)		\$ -2.160.000,00	\$ -2.160.000,00	\$ -2.160.000,00	\$ -2.160.000,00	\$ -2.160.000,00

Tabla: Flujo de caja anual de proceso sin proyecto.²⁶

Flujo de Caja con Proyecto						
Año	0	1	2	3	4	5
Costo Fijo		\$ -360.000,00	\$ -360.000,00	\$ -360.000,00	\$ -360.000,00	\$ -360.000,00
Utilidad Antes de Impuestos		\$ -360.000,00	\$ -360.000,00	\$ -360.000,00	\$ -360.000,00	\$ -360.000,00
Impuesto a las empresas		\$ 36.000,00	\$ 36.000,00	\$ 36.000,00	\$ 36.000,00	\$ 36.000,00
Utilidad Despues de Impuestos		\$ -324.000,00	\$ -324.000,00	\$ -324.000,00	\$ -324.000,00	\$ -324.000,00
Flujo Operacional		\$ -324.000,00	\$ -324.000,00	\$ -324.000,00	\$ -324.000,00	\$ -324.000,00
Inversión Fija	\$ -2.304.000,00					
Flujo de Capitales						
Flujo de Caja Privado (Con Proyecto)	\$ -2.304.000,00	\$ -324.000,00	\$ -324.000,00	\$ -324.000,00	\$ -324.000,00	\$ -324.000,00

Tabla: Flujo de caja anual de proceso con proyecto.²⁷

Tabla: Flujo de Caja Anual Proceso con Proyecto.

Luego, se realizó una comparación entre ambos flujos.

Año	0	1	2	3	4	5
Flujo de Caja Privado (Sin Proyecto)		\$ -2.160.000,00	\$ -2.160.000,00	\$ -2.160.000,00	\$ -2.160.000,00	\$ -2.160.000,00
Flujo de Caja Privado (Con Proyecto)	\$ -2.304.000,00	\$ -324.000,00	\$ -324.000,00	\$ -324.000,00	\$ -324.000,00	\$ -324.000,00
Delta Situaciones con y sin proyecto	\$ -2.304.000,00	\$ 1.836.000,00	\$ 1.836.000,00	\$ 1.836.000,00	\$ 1.836.000,00	\$ 1.836.000,00

²⁶ Desarrollo de proyecto (Héctor Saavedra, 2023)

²⁷ Desarrollo de proyecto (Héctor Saavedra, 2023)

Tabla: Delta flujo de caja anual proceso con y sin proyecto.²⁸

Se puede observar, que, a pesar de la inversión inicial de la situación con proyecto, esta inversión es rápidamente recuperada, de hecho, es recuperada en menos de dos años, disminuyendo notablemente los costos asociados a los flujos. Además, se debe considerar que la solución implementada aumentara la cantidad de reclamos analizados en comparación con la situación sin proyecto.

Ahora, también es necesario hacer análisis de indicadores financieros como VAN y TIR relacionados al proyecto, también se hizo el cálculo del CAPM, para el cual se consideraron los siguientes datos:

Tasa de Mercado (Chile)	11,25%
Beta Retail (General)	1,6
Premio por Riesgo (Chile)	5,25%
Tasa Libre de Riesgo	6,00%

Tabla: Variables a considerar para cálculo de CAPM²⁹

Los datos referentes a Tasa de Mercado (Chile) y Beta relacionado a retail fueron obtenidos desde los registros del Banco Central de Chile³⁰ y los registros de Beta Global del sitio investigador financiero Aswath Damodaran³¹. El CAPM se obtuvo de la siguiente forma:

$$CAPM = Tasa Libre de Riesgo + \beta * (Tasa de Mercado - Tasa Libre de Riesgo)$$

CAPM	10,05%
-------------	---------------

Tabla: Resultado CAPM del proyecto.³²

Luego, usando funciones de Excel se obtuvo el VAN y TIR relacionado al proyecto:

VAN	\$4.232.622
TIR	75%

Tabla: Resultado de VAN y TIR del proyecto.³³

El proyecto posee un VAN positivo y una TIR sobre la TLR (Tasa Libre de Riesgo), VAN de \$4.232.622 y una gran TIR del 75%. Estos resultados no solo indican la viabilidad

²⁸ Desarrollo de proyecto (Héctor Saavedra, 2023)

²⁹ Desarrollo de proyecto (Héctor Saavedra, 2023)

³⁰ Banco Central de Chile, 2023. Tasas de interés de colocaciones.

<https://www.bcentral.cl/web/banco-central/areas/estadisticas/tasas-de-interes>.

³¹ Damodaran, 2023. Total Beta by industry sector.

https://pages.stern.nyu.edu/~adamodar/New_Home_Page/datacurrent.html.

³² Desarrollo de proyecto (Héctor Saavedra, 2023)

³³ Desarrollo de proyecto (Héctor Saavedra, 2023)

económica del proyecto, sino que también su alta rentabilidad. La implementación de los modelos descritos de Machine Learning en Walmart Chile no solo promete mejorar la gestión de los reclamos, sino que también demuestra ser una inversión rentable en la reducción a costos relacionado a la operación, ofreciendo beneficios sustanciales para la empresa a través de la automatización de procesos que antes se realizaban de forma manual y menos eficiente.

Análisis de Sensibilidad

Debido a que no se encontraron variables sensibles como precio o costos que puedan hacer que el rendimiento económico del proyecto variable, pero si se considero que el tiempo que pueda durar la solución implementada puede jugar un rol crucial respecto a los beneficios totales entregados por el proyecto, se consideró hacerlo respecto a los años de duración, ya que se piensa que debido a los avances tecnológicos, es posible que se implemente una nueva solución antes o después del tiempo que tenemos estipulado.

De este modo en análisis de sensibilidad en función de la duración del proyecto permite comprender como la vida útil del proyecto puede afectar a la rentabilidad de este:

Duración del proyecto (años)	VAN (\$CLP)
3	1.944.470
4	3.021.859
5	3.990.299
6	4.860.806
7	5.643.285

Tabla: Variación del VAN según la duración del proyecto.³⁴

³⁴ Desarrollo de proyecto (Héctor Saavedra, 2023)

Conclusión

El proyecto implementado de automatización de clasificación de reclamos en Walmart Chile, que se centra en el desarrollo y aplicación de modelos de Machine Learning, ha demostrado ser una iniciativa efectiva y económicamente rentable. La implementación de la solución permite a Walmart Chile enfrentar desafíos significativos en la gestión de reclamos, lo que refleja un avance notable en su enfoque hacia la excelencia operacional y satisfacción del cliente.

Aspectos Claves del Proyecto:

1. **Mejora de Eficiencia Operativa:** La implementación de los modelos ha resultado en una reducción importante del tiempo de análisis de reclamos, con una precisión importante en la identificación de productos y causas.
2. **Impacto Económico:** El proyecto demostró ser económicamente rentable con un Valor Actual Neto (VAN) positivo y una Tasa Interna de Retorno (TIR) de gran magnitud. Lo cual no solo indica la viabilidad del proyecto, sino que también el potencial de generar ahorros significativos y aumentar la eficiencia a largo plazo, lo que va de la mano con las misiones de la empresa.
3. **Mejora de la Experiencia del Cliente:** A pesar de que aun es pronto para apreciar el impacto del proyecto en la experiencia del cliente y la encuesta NPS (Net Promoter Score), la gestión oportuna de reclamos sugiere una mejora potencial en la identificación de dolores del cliente y su satisfacción.
4. **Adaptabilidad y Futuro del Proyecto:** El análisis de sensibilidad del proyecto indica que el proyecto puede ser aún más beneficioso a largo plazo, aun con la evolución de la tecnología, los modelos podrán seguir clasificando reclamos e identificando productos si son actualizados cuando sea pertinente.

Recomendaciones para el Futuro:

- **Estandarización de Toma de Reclamos:** Es vital para el rendimiento de los modelos que los comentarios posean un patrón establecido, es por eso que se recomienda considerar aplicar un instructivo para todos los formatos de carga de reclamos a la plataforma “¡Hola!”.
- **Continuar la Monitorización y Mejora:** Es importante seguir monitoreando el rendimiento de los modelos y hacer ajustes necesarios, especialmente si se consideran cambios en el comportamiento del consumidor, tendencias del mercado o de ítems en inventario.
- **Expansión de la Aplicación del Modelo:** Se recomienda explorar la posibilidad de aplicar tecnologías similares a otras áreas de la empresa para mejorar la eficiencia y experiencia del cliente, e incluso la comunicación interna.

Se concluye que el proyecto significa un paso importante para Walmart Chile en la innovación y la excelencia operacional. Al abordar de forma efectiva los desafíos de la gestión de reclamos, Walmart Chile no solo mejorará su eficiencia interna, sino que también podrá entregar una mejor experiencia al cliente.

Referencias:

¹ Desarrollo de proyecto (Héctor Saavedra, 2023)

² ZTZ, TECH GROUP. Aprende a ordenar y clasificar tus reclamos. <https://ztz.ai/ahora-puedes-tener-el-control-aprende-a-ordenar-y-clasificar-tus-reclamos/>

³ Morrison, Gwen, and Susan Westwater. "Voice: The future of customer experience." *Journal of Brand Strategy* 11.3 (2022): 206-219.

⁴ Deep Talk, Voice of the Customers. Analyze the evolution of customer conversation
<https://www.deep-talk.ai/voice-of-customer>.

⁵ Banco Central de Chile, 2023. Tasadeinterésdecolocaciones.
<https://www.bcentral.cl/web/banco-central/areas/estadisticas/tasas-de-interes>.

⁶ Damodaran, 2023. Total Beta by industry sector.
https://pages.stern.nyu.edu/~adamodar/New_Home_Page/datacurrent.html.