



UNIVERSIDAD ADOLFO IBÁÑEZ
FACULTAD DE INGENIERÍA Y CIENCIAS



Pronósticos de demanda para productos del Centro de Distribución

Juan Pablo González Zapata

Ingeniería Civil Industrial con mención en tecnologías de
información

08-12-2023

Contenido

Resumen Ejecutivo	4
Abstract	4
Introducción:	5
El Proceso S&OP (Sales and Operations Planning): Integrando Precisión en la Gestión Estratégica ..	6
Optimización de Pronósticos de Demanda para el Centro de Distribución: Una Oportunidad Estratégica para Mejorar la Eficiencia Operativa en la Empresa de Retail	7
MAPE (Mean Absolute Percentage Error)	8
Base de datos	9
Análisis General del MAPE (Semana 1 a Semana 38, 2023)	9
Análisis de categoría SNACKS	11
OBJETIVO GENERAL:	13
OBJETIVOS ESPECÍFICOS	13
a) Identificación de Productos Clave:	13
b) Evaluación de Modelos de Pronóstico:	13
c) Implementación de Modelos de Pronósticos:	13
ESTADO DEL ARTE	14
Python en Pronósticos de Demanda:	15
Excel en Pronósticos de Demanda:	16
Software de pronósticos de demanda	16
SOLUCIONES PROPUESTAS	18
Excel:	18
Python:	19
Software (DataRobot):	19
Selección de soluciones propuestas	19
Descripción de la solución seleccionada:	20
Matriz de riesgo	21
Evaluación económica	21
METODOLOGÍA	23
DESARROLLO DEL PROYECTO	24
Modelo Prophet:	24
Modelo SARIMA:	25
Modelo Holt-Winters:	25

Análisis estadístico descriptivo de la demanda del producto "BARRA WILD PROT CHOCO 16X45GR":	27
Evaluación de modelos.....	28
Análisis de las Predicciones del Modelo de Holt-Winters	28
1. Comparación Visual:.....	28
2. Métricas de Rendimiento:	29
3. Análisis de Residuos	29
3.1) Análisis Visual de los Residuos	30
3.1) Estadísticas Descriptivas de los Residuos	30
3.3) Distribución de los Residuos	30
Análisis de las Predicciones del Modelo SARIMA.....	31
Ajustes del modelo	31
1. Comparación Visual:.....	32
2. Métricas de Rendimiento:	32
3. Análisis de Residuos	33
3.1. Estadísticas Descriptivas de los Residuos:	33
3.2. Histograma de los Residuos:	33
3.3. Interpretación.....	33
Análisis de las Predicciones del Modelo Prophet.....	34
1. Comparación Visual.....	34
2. Métricas de Rendimiento	34
3. Análisis de Residuos	35
3.1 Estadísticas Descriptivas de los Residuos:	35
3.2. Histograma de Residuos	35
Conclusión Completa sobre el Modelo Prophet	36
Medición y desempeño	36
Conclusiones	37
Bibliografía	39
Anexos	40

Resumen Ejecutivo

Arcoprime, con más de 30 años en el mercado chileno, se ha establecido como una cadena líder en tiendas de conveniencia y estaciones de servicio. El informe aborda la problemática de altos niveles de MAPE (Error Porcentual Absoluto Medio) en la previsión de demanda. Se detectó que el MAPE oscilaba entre valores preocupantes como 114% y 113% en ciertas semanas, reflejando una precisión insuficiente en las proyecciones de demanda. Para abordar este desafío, se implementaron modelos avanzados en Python, integrando técnicas estadísticas y algoritmos de aprendizaje automático. Este enfoque permitió una evaluación detallada y la iteración continua para mejorar la precisión de los pronósticos. Con el objetivo de reducir el MAPE en un 5% en cinco meses, se seleccionaron modelos específicos y se realizó un seguimiento continuo para adaptarlos a las necesidades cambiantes del mercado. El proyecto representa un paso significativo hacia la excelencia operativa y la adaptación continua a las demandas y expectativas de los clientes, fortaleciendo la capacidad de Arcoprime para responder proactivamente a las dinámicas del mercado.

Abstract

Arcoprime, with over 30 years in the Chilean market, has established itself as a leading chain in convenience stores and service stations. The report addresses the issue of high MAPE (Mean Absolute Percentage Error) levels in demand forecasting, with observed MAPE values reaching concerning levels such as 114% and 113% in certain weeks, indicating a lack of precision in demand projections. To tackle this challenge, advanced Python-based models were implemented, integrating statistical techniques and machine learning algorithms. This approach enabled detailed evaluation and continuous iteration to enhance forecast accuracy. Aiming to reduce the MAPE by 5% within five months, specific models were selected, and continuous monitoring was conducted to adjust them according to the evolving market needs. This project represents a significant step toward operational excellence and ongoing adaptation to customer demands and expectations, enhancing Arcoprime's ability to proactively respond to market dynamics.

Introducción:

Con más de 30 años de trayectoria, Arcoprime se ha consolidado como una de las cadenas de conveniencia más grandes de Chile. Desde sus humildes inicios en 1990 con la apertura de la primera tienda Pronto en Nos, Arcoprime ha experimentado una evolución significativa, expandiéndose de Arica a Punta Arenas y estableciéndose como un referente en el sector de tiendas de conveniencia y estaciones de servicio.

La historia de Arcoprime está marcada por hitos clave, desde la creación de Prime y Arco en 1998 hasta la fusión que dio origen a Arcoprime en 2004. A lo largo de los años, la empresa ha demostrado un compromiso no solo con la expansión y la innovación, sino también con la sostenibilidad y el bienestar ambiental.

En este contexto, el proyecto de tesis que se presenta tiene como objetivo fundamental abordar un componente esencial de la operación de Arcoprime: la optimización de los pronósticos de demanda en su centro de distribución. Este proyecto representa una respuesta a la necesidad de perfeccionar la gestión de inventario y garantizar una oferta continua y eficiente a lo largo de la extensa red de tiendas y estaciones de servicio.

El centro de distribución, como epicentro logístico, desempeña un papel crítico en esta cadena operativa. Su demanda, que refleja las solicitudes de las tiendas a lo largo y ancho del país, es un factor clave en la planificación y ejecución de la cadena de suministro. Es en este punto estratégico donde el proyecto centrará su atención, utilizando modelos avanzados de pronóstico implementados con Python para mejorar la precisión y la agilidad en la respuesta a las necesidades del mercado.

La combinación de técnicas estadísticas y algoritmos de aprendizaje automático permitirá mejorar la precisión de los pronósticos, adaptándose dinámicamente a los patrones cambiantes de la demanda y a las complejidades inherentes al mercado de conveniencia.

Se utilizará un enfoque integral que abarcará la selección de modelos, la evaluación de su desempeño y la iteración continua para la mejora constante. La herramienta Python desempeñará un papel crucial en este proceso, facilitando la implementación ágil y la adaptabilidad a futuras necesidades de pronóstico.

A través de esta investigación, se espera proporcionar a Arcoprime una herramienta estratégica que fortalezca su capacidad para anticipar y satisfacer las demandas del mercado en constante evolución. Este proyecto representa un paso significativo hacia la excelencia operativa y la continua adaptación a las demandas y expectativas de sus clientes.

En resumen, la historia de Arcoprime se encuentra en constante evolución, y este proyecto de tesis busca contribuir a su narrativa, aportando una nueva dimensión de eficiencia y anticipación en su gestión de inventario y operaciones.

El Proceso S&OP (Sales and Operations Planning): Integrando Precisión en la Gestión Estratégica

El proceso de Planificación de Ventas y Operaciones, conocido como S&OP por sus siglas en inglés (Sales and Operations Planning), se erige como la columna vertebral de la gestión estratégica en empresas como Arcoprime. Este proceso, de vital importancia en la cadena de suministro, busca alinear la oferta con la demanda, integrando eficientemente las áreas de ventas, operaciones, finanzas y marketing.

En esencia, el S&OP se desarrolla en un ciclo mensual que involucra diversas etapas: la recopilación y análisis de datos, la planificación de la demanda, la revisión de la capacidad de producción, y la elaboración de un plan consolidado. Este último se convierte en la brújula estratégica que guía las decisiones empresariales y opera como una herramienta fundamental para anticipar y gestionar cambios en el entorno del mercado.

La importancia del S&OP radica en su capacidad para alinear todos los aspectos de la empresa hacia un objetivo común. Al contar con una planificación robusta y basada en datos precisos, se optimiza la utilización de los recursos, se minimizan los riesgos y se mejora la capacidad de respuesta ante cambios en la demanda o en las condiciones del mercado.

En este contexto, el pronóstico de demanda del centro de distribución se convierte en una piedra angular del proceso S&OP. Un pronóstico preciso alimenta la toma de decisiones en cada etapa del proceso, desde la planificación de la producción hasta la gestión de inventario y la distribución eficiente de productos. La precisión en el pronóstico garantiza que los recursos se asignen de manera

adecuada, evitando tanto la sobreproducción como la falta de inventario, ambas situaciones costosas y perjudiciales para la eficiencia operativa.

Optimización de Pronósticos de Demanda para el Centro de Distribución: Una Oportunidad Estratégica para Mejorar la Eficiencia Operativa en la Empresa de Retail

En el dinámico mercado de conveniencia en el que opera Arcoprime, donde las tendencias y preferencias de los consumidores pueden cambiar rápidamente, la necesidad de un pronóstico de demanda preciso se vuelve aún más crítica. La empresa se enfrenta a una amplia gama de productos y a una red extensa de tiendas y estaciones de servicio, lo que agrega complejidad al desafío de la gestión de inventario. Un pronóstico exacto sirve como un faro que guía la empresa a través de estas complejidades, permitiéndole anticipar, adaptarse y prosperar en un entorno empresarial dinámico.

Uno de los efectos más notorios de un mal pronóstico de demanda es la gestión ineficiente de inventario. El sobre stock conlleva a costos adicionales de almacenamiento, riesgo de obsolescencia de productos y la necesidad de realizar descuentos para deshacerse de productos no vendidos. Por otro lado, el quiebre de stock resulta en oportunidades de venta perdidas, clientes insatisfechos y una reputación afectada.

Además, un mal pronóstico de demanda tiene ramificaciones más allá de las fronteras internas de la empresa. Se traduce en una comunicación disonante con los proveedores, ya que la empresa no puede anticipar con precisión sus necesidades de aprovisionamiento. Esta falta de alineación con los proveedores impacta directamente en el nivel de servicio, llevando a un suministro inconsistente y, en última instancia, afectando la capacidad de la empresa para cumplir con la demanda real.

Para cuantificar y comprender a fondo el impacto de los pronósticos actuales, se llevó a cabo una medición del MAPE (Mean Absolute Percentage Error) en el centro de distribución. El MAPE, una medida estándar para evaluar la precisión de los pronósticos revelará la discrepancia entre las predicciones y la demanda real. Este análisis, respaldado por ejemplos concretos y datos tabulados, arrojará luz sobre la magnitud de los desafíos actuales y proporcionará una base cuantitativa para la optimización propuesta. Además, para obtener una perspectiva más completa y cuantificar la diferencia financiera asociada, también se realizó un análisis de la diferencia en pesos entre la demanda real y el pronóstico.

MAPE (Mean Absolute Percentage Error)

El MAPE, o Error Porcentual Absoluto Medio, es un indicador clave en la evaluación de la precisión de los pronósticos. Su principal función es proporcionar una medida cuantitativa de qué tan cerca están las predicciones de la demanda real, expresada como un porcentaje del valor real. Este indicador es fundamental en el análisis de la calidad y confiabilidad de los pronósticos en entornos comerciales y de planificación.

El MAPE se calcula utilizando la siguiente fórmula:

$$MAPE = \frac{1}{n} \sum_{t=1}^n \frac{|A_t - F_t|}{A_t} \times 100\%$$

Foto 1: Ecuación del MAPE

Donde:

- A_t : valor de la demanda real en t
- F_t : valor del Forecast en t
- n: número total de periodos

Interpretación del MAPE:

El resultado del MAPE se expresa como un porcentaje, representando el error promedio porcentual absoluto entre los pronósticos y los valores reales de la demanda. Un MAPE más bajo indica una mayor precisión del pronóstico, mientras que un MAPE más alto sugiere una menor precisión y, por lo tanto, mayores discrepancias entre los pronósticos y la realidad.

Significado Práctico:

Un MAPE del 0% indicaría una predicción perfecta, donde los valores pronosticados coinciden exactamente con los valores reales.

Un MAPE del 100% indicaría que los pronósticos son, en promedio, el doble del valor real.

Un MAPE superior al 100% señalaría una discrepancia significativa y posiblemente inconsistencias fundamentales en el proceso de pronóstico.

Utilidad del MAPE:

El MAPE es valioso en la toma de decisiones estratégicas y tácticas, proporcionando una métrica clara para evaluar la efectividad de los modelos de pronóstico. Permite identificar áreas de mejora en el proceso de pronóstico y respalda la implementación de estrategias para optimizar la precisión y eficiencia operativa. Además, el MAPE es una herramienta esencial en el contexto del proceso S&OP (Planificación de Ventas y Operaciones), donde una precisión de pronóstico mejorada contribuye directamente a la alineación estratégica y la toma de decisiones informada.

Base de datos

El análisis del indicador MAPE se ha llevado a cabo utilizando la base de datos interna de la empresa, que registra minuciosamente los movimientos de los productos en el centro de distribución. Esta base de datos es crucial, ya que contiene información clave, incluyendo las columnas fundamentales: item, semana, Forecast, demanda real y diferencia en pesos.

En este proceso analítico, se procedió a realizar un cruzamiento exhaustivo de los datos para obtener el MAPE global, así como segmentaciones específicas que permiten una comprensión más detallada de la precisión de los pronósticos para diferentes productos o categorías. Este enfoque segmentado es esencial para identificar áreas de fuerza y oportunidades de mejora.

La inclusión de la diferencia en pesos como parte integral del análisis agrega una dimensión financiera esencial, cuantificando el impacto económico directo de las discrepancias entre los pronósticos y la demanda real. Esta métrica ofrece una perspectiva más completa al evaluar no solo la precisión cualitativa, sino también la implicación financiera de los pronósticos inexactos.

Análisis General del MAPE (Semana 1 a Semana 38, 2023)

El análisis general de los resultados del MAPE revela una variedad de niveles de precisión en los pronósticos a lo largo de las semanas. Aquí hay algunas observaciones clave:

Tendencias de Variabilidad:

Se observa una variabilidad significativa en los resultados del MAPE, indicando fluctuaciones en la precisión de los pronósticos a lo largo del período analizado.

La amplia gama de valores sugiere que ciertas semanas experimentaron pronósticos más precisos, mientras que otras presentaron desafíos en la estimación de la demanda.

Semana 1 y Semana 15:

La Semana 1 se destaca con un MAPE del 114%, indicando una discrepancia sustancial entre los pronósticos y la demanda real.

La Semana 15 también muestra un MAPE elevado del 113%, lo que podría señalar desafíos específicos en la predicción durante ese período.

Tendencia General:

A pesar de las variaciones semanales, no se observa una tendencia clara en la mejora o empeoramiento constante del MAPE a lo largo del tiempo.

Es crucial identificar patrones específicos o eventos excepcionales que podrían haber influido en la precisión de los pronósticos en semanas particulares.

Desafíos y Oportunidades:

Las semanas con MAPE más alto (por encima del 100%) indican desafíos sustanciales y podrían requerir una revisión detallada de los factores que afectaron los pronósticos.

Las semanas con MAPE más bajo presentan oportunidades para comprender qué estrategias o modelos contribuyeron a una mayor precisión.

El MAPE general de lo que lleva el año es de un 71.7%.




Gráfico 1: MAPE general 2023

Análisis de categoría SNACKS

La categoría de Snacks, con un total de 58 SKU*, presenta un MAPE general del 55%, indicando una precisión moderada en los pronósticos para esta categoría específica. Sin embargo, la diferencia en pesos es de \$1.438.277.804 lo cual resalta un impacto a la operación y capacidad de respuesta significativo debido a las discrepancias entre los pronósticos y la demanda real.




Gráfico 2: MAPE por semana categoría SNACKS




Gráfico 3: Diferencia financiera entre pronósticos y demanda real categoría SNACKS

*SKU: unidad de medida utilizada en gestión de inventario para identificar y rastrear un producto específico.

OBJETIVO GENERAL:

Tras el detallado análisis del MAPE (Mean Absolute Percentage Error) y las consecuentes diferencias financieras reveladas en el centro de distribución, se ha identificado la urgente necesidad de optimizar la precisión de los pronósticos de demanda. En este contexto, el objetivo general SMART de este proyecto es claro y específico: **reducir en un 5% el MAPE de los productos de interés en el centro de distribución en un periodo de cinco meses**. Este enfoque estratégico tiene como meta directa abordar las discrepancias identificadas y mejorar la eficacia operativa del centro, impactando positivamente en los resultados financieros de la empresa.

OBJETIVOS ESPECÍFICOS

a) Identificación de Productos Clave:

- Utilizar criterios como rotación, margen de contribución y volumen de ventas para asignar niveles de prioridad.

b) Evaluación de Modelos de Pronóstico:

- Seleccionar modelos de pronóstico avanzados, considerando tanto métodos estadísticos clásicos como algoritmos de aprendizaje automático.
- Evaluar el desempeño de los modelos utilizando métricas como MAPE, MSE y otros indicadores relevantes.
- Adaptar los modelos a las características específicas de cada producto y su comportamiento histórico.

c) Implementación de Modelos de Pronósticos:

- Desarrollar un plan de implementación que incluya la integración de modelos de pronóstico seleccionados en el sistema existente del centro de distribución.
- Establecer un proceso de seguimiento continuo para monitorear la precisión de los pronósticos y realizar ajustes según sea necesario.

- Garantizar la actualización regular de los modelos para adaptarse a cambios en la demanda y mejorar la capacidad predictiva a lo largo del tiempo.

ESTADO DEL ARTE

El estado del arte de los pronósticos de demanda de productos de Retail en 2023 se centra en un enfoque más preciso y adaptado a las necesidades y comportamientos cambiantes de los consumidores, utilizando herramientas y metodologías avanzadas.

1. Diferenciación entre Pronóstico de Ventas y Pronóstico de Demanda: Una distinción importante es entre el pronóstico de ventas y el pronóstico de demanda. Mientras que los pronósticos de ventas se basan principalmente en las ventas pasadas para extrapolar tendencias hacia el futuro, los pronósticos de demanda consideran cientos de factores que influyen en la demanda de cada SKU en cada canal, como el precio, eventos, familias de productos, surtido y canibalización de productos.
2. Técnicas y Metodologías de Pronóstico de Demanda: Se emplean varias metodologías, incluyendo pronósticos cualitativos basados en investigaciones de mercado y predicciones de expertos, pronósticos de series temporales que se centran en análisis de ventas históricas de SKUs existentes, y modelado causal que usa simulaciones para crear predicciones de demanda más precisas.
3. Importancia de la Previsión de Demanda en Análisis de Grandes Datos**: El inventario representa la mayor inversión para los minoristas. Una estimación precisa de la demanda es crucial para optimizar las inversiones en inventario, ya que subestimar la demanda puede resultar en estantes vacíos y clientes insatisfechos, mientras que sobrestimarla puede llevar a un exceso de inventario y descuentos de liquidación costosos.

4. Desafíos en el Pronóstico de Demanda y el Papel de la IA: La pandemia de COVID-19 y la recesión subsiguiente han alterado significativamente el panorama minorista, presentando desafíos en el pronóstico de demanda, como cambios en las preferencias del cliente, problemas en la cadena de suministro, y escasez de mano de obra. Para abordar estos desafíos, se están adoptando tecnologías de próxima generación y soluciones de software incorporadas con IA y aprendizaje automático (ML), que pueden manejar datos granulares en tiempo real y aprender de experiencias pasadas para entregar predicciones más precisas.

5. Casos de Estudio y Ejemplos del Mundo Real**: Empresas de alimentos y bebidas, bienes de consumo y mercancías deportivas han utilizado soluciones de IA para superar desafíos en la planificación de ventas, ineficiencias en la cadena de suministro y para mejorar la visibilidad de la demanda. Estas soluciones han permitido a las empresas descubrir oportunidades de venta cruzada y aumentar la visibilidad de la demanda en un 60%, entre otros beneficios.

En resumen, el pronóstico de demanda de productos de retail en 2023 se caracteriza por una mayor precisión y adaptabilidad, con un enfoque en la integración de tecnologías avanzadas como la IA y el ML para navegar un entorno de mercado en constante cambio y desafiante. Estas tecnologías no solo ayudan a prever la demanda sino también a planificar de manera más eficiente, considerando una multitud de factores y tendencias cambiantes.

La utilización de Python y Excel en el pronóstico de demanda de productos de retail complementa y enriquece las técnicas avanzadas como la IA y el aprendizaje automático, permitiendo un análisis más detallado y personalizado.

Python en Pronósticos de Demanda:

1. Flexibilidad y Potencia: Python es un lenguaje de programación versátil y potente, especialmente útil en el análisis de datos y machine learning. Permite a los minoristas procesar grandes volúmenes

de datos, aplicar complejos algoritmos estadísticos y de aprendizaje automático, y desarrollar modelos predictivos personalizados.

2. Bibliotecas Especializadas: Python ofrece una amplia gama de bibliotecas como Pandas para manipulación de datos, NumPy para cálculos numéricos, y Scikit-learn para machine learning. Estas herramientas facilitan la realización de análisis sofisticados y la creación de modelos de pronóstico precisos.

3. Integración con Otras Herramientas: Python se integra bien con otras plataformas y herramientas de datos, lo que permite una mayor flexibilidad en la recopilación y análisis de datos desde diferentes fuentes.

Excel en Pronósticos de Demanda:

1. Accesibilidad y Familiaridad: Excel es una herramienta ampliamente utilizada y familiar para muchos profesionales. Ofrece una plataforma accesible para realizar análisis básicos de datos y visualizaciones.

2. Funciones y Herramientas de Pronóstico: Excel incluye funciones integradas para pronósticos, como las tablas dinámicas y diversas funciones estadísticas, que pueden ser útiles para análisis y pronósticos rápidos y relativamente sencillos.

3. Limitaciones y Complementariedad: Si bien Excel es útil para análisis de datos a pequeña escala y tareas de pronóstico más básicas, tiene limitaciones en cuanto al tamaño de los conjuntos de datos y la complejidad del análisis. Por lo tanto, a menudo se utiliza en conjunto con herramientas más avanzadas como Python para una mayor profundidad y precisión en el análisis de datos.

Python y Excel representan un enfoque multifacético para el pronóstico de demanda en Retail. Mientras que Python ofrece capacidades avanzadas y personalizables, Excel proporciona una solución más accesible y familiar para tareas de análisis y pronóstico a menor escala.

Software de pronósticos de demanda

La utilización de software especializado en pronósticos de demanda que incorpora inteligencia artificial (IA) y aprendizaje automático (ML) es un aspecto crucial en la gestión moderna del Retail.

Estos sistemas ofrecen capacidades avanzadas para analizar y predecir la demanda de productos con mayor precisión y eficiencia.

1. **Análisis Predictivo Avanzado:** Estos softwares utilizan algoritmos de IA y ML para analizar patrones históricos de datos y predecir tendencias futuras. Pueden identificar patrones y correlaciones que no son evidentes para el análisis humano o métodos de pronóstico tradicionales.

2. **Automatización y Eficiencia:** La automatización de procesos de pronóstico ahorra tiempo y reduce el margen de error humano. Estos sistemas pueden procesar rápidamente grandes volúmenes de datos, proporcionando pronósticos rápidos y precisos.

3. **Personalización y Adaptabilidad:** El software de pronóstico de demanda suele ser altamente configurable, permitiendo a los minoristas adaptar los modelos a las especificidades de su negocio, como la variabilidad de la demanda por estacionalidad, ubicación geográfica, o cambios en el comportamiento del consumidor.

4. **Integración de Diversas Fuentes de Datos:** Estos sistemas pueden integrar datos de diversas fuentes, incluyendo datos internos de ventas, datos de mercado, tendencias de redes sociales, condiciones climáticas, entre otros, para proporcionar un análisis más holístico y preciso de la demanda.

5. **Análisis en Tiempo Real y Respuesta Rápida:** La capacidad de analizar datos en tiempo real permite a los minoristas responder rápidamente a los cambios en la demanda, optimizando así la gestión de inventarios y la planificación de la cadena de suministro.

6. Predicción de Demanda a Nivel de SKU: Estos sistemas pueden predecir la demanda a nivel de SKU (unidad de mantenimiento de stock), lo que permite una gestión de inventario más detallada y precisa, reduciendo el exceso de stock y evitando faltantes.

En resumen, el software de pronóstico de demanda que incorpora IA y ML ofrece a los minoristas herramientas poderosas para mejorar la precisión de sus pronósticos, optimizar la gestión de inventarios, y tomar decisiones más informadas y estratégicas en un mercado en constante cambio.

SOLUCIONES PROPUESTAS

Se expondrán tres posibles soluciones para abordar el problema en cuestión. Para facilitar una decisión informada, se elaborará una tabla descriptiva que analizará cada alternativa bajo criterios técnicos y económicos. Este enfoque ayudará a determinar la opción más adecuada.

Para completar la información faltante en el cuadro, se puede proporcionar un resumen general basado en conocimientos comunes sobre las ventajas, desventajas y costos de utilizar Excel, Python y software especializado para pronósticos de demanda, como DataRobot.

Excel:

- Ventajas: Fácil acceso, ampliamente utilizado en entornos empresariales, interfaz de usuario familiar, capacidad para realizar análisis estadísticos básicos y visualizaciones de datos.
- Desventajas: Limitaciones en el manejo de grandes conjuntos de datos, carencia de funciones avanzadas de pronóstico sin complementos adicionales, posibilidad de error humano en el manejo de fórmulas.
- Costos: Dependiendo de la versión y si se incluye como parte del paquete de Microsoft Office, puede haber un costo inicial o una suscripción mensual/anual.

Python:

- Ventajas: Gran biblioteca de paquetes para análisis de datos y aprendizaje automático es gratis y de código abierto, altamente escalable y versátil, y tiene una comunidad de apoyo muy activa.
- Desventajas: Requiere conocimiento de programación para su uso efectivo, puede ser menos intuitivo para los usuarios no técnicos.
- Costos: Python es gratuito, pero puede haber costos asociados con el entrenamiento del personal o el desarrollo de soluciones personalizadas.

Software (DataRobot):

- Ventajas: Proporciona soluciones de pronóstico de demanda altamente avanzadas y automatizadas, utiliza técnicas de aprendizaje automático y es adecuado para usuarios sin experiencia en programación.
- Desventajas: Puede ser costoso, especialmente para pequeñas empresas, y puede requerir una suscripción basada en la nube o licencias.
- Costos: Los precios de DataRobot no se publican abiertamente, ya que generalmente se personalizan en función de las necesidades del cliente y el alcance del uso.

Selección de soluciones propuestas

Para definir como se abordará la oportunidad, se analizará por medio de una matriz de criterios las alternativas de solución descritas anteriormente en base a los siguientes criterios (Tabla 3).

Criterios	Excel	Python	Software (DataRobot)
Nivel de dificultad en la implementación	Media	Media-Alta	Alto
Tiempo de implementación	Media	Media	Alto

Tiempo de Capacitación	Baja	Media	Alto
Nivel de automatización	Baja	Alta	Alto
Costos	Bajo	Bajo	Alto
¿Soluciona todos los problemas?	No	Si	Si

Tabla 1: Tabla de criterios

Descripción de la solución seleccionada:

La elección de Python como solución para el desarrollo del proyecto se basa en su equilibrio entre complejidad y potencial de automatización. A pesar de tener un nivel de dificultad de implementación medio-alto, Python sobresale por su capacidad de automatización y su habilidad para resolver problemas complejos de manera integral. Su naturaleza de código abierto y el amplio soporte de bibliotecas dedicadas al análisis de datos y aprendizaje automático lo hacen ideal para proyectos que requieren soluciones de pronóstico avanzadas y personalizables. Aunque el tiempo de capacitación es mediano, la inversión se ve compensada por la flexibilidad y robustez que Python aporta al manejo y procesamiento de grandes conjuntos de datos, así como por su capacidad para integrarse con otras herramientas y sistemas, lo que finalmente puede facilitar la toma de decisiones basada en datos complejos.

Matriz de riesgo

MATRIZ DE RIESGO	PROBABILIDAD DE OCURRENCIA				
	Improbable	Poco Probable	Medianamente Probable	Probable	Seguro
Leve			Resistencia para capacitarse	Mismo Producto con distintos códigos SAP	
Preocupante			Demora en la obtención de la data necesaria para realizar los pronósticos.	Pérdida de información en las bases de datos	
Grave		Fallas en códigos	MAPE alto en ciertos productos que no hay suficiente data histórica		
Catastrófica					

Tabla 2: Matriz de riesgos

La matriz de riesgo presentada categoriza los riesgos potenciales en términos de probabilidad de ocurrencia y gravedad del impacto. Los riesgos varían desde "Improbable" a "Seguro" para la probabilidad, y de "Despreciable" a "Catastrófica" para el impacto. Riesgos como "Resistencia para capacitarse" y "Demora en la obtención de data" son considerados menos graves y probables. Mientras tanto, "MAPE alto en ciertos productos" se considera preocupante y medianamente probable. El riesgo de "Pérdida de información en las bases de datos" es catalogado como probable y grave, lo que sugiere que requiere atención inmediata para mitigarlo.

Evaluación económica

La evaluación económica del proyecto se fundamenta en el costo del "fill rate" o nivel de servicio de los proveedores, calculado a partir de las unidades no entregadas de cada producto. Este método se eligió debido a la naturaleza confidencial de los costos detallados de la empresa. Así, el costo mensual se deriva del producto del precio por unidad por la cantidad no suministrada por el proveedor, aplicado a todo el inventario del centro de distribución. Además, la inversión se considera como el pago mensual de \$230.000 al estudiante. Se anticipa que la implementación del nuevo

sistema de pronóstico de demanda mejore el nivel de servicio en un 5%, lo cual se reflejaría en una disminución correspondiente de los costos. Finalmente, la tasa de descuento del 9,5% fue seleccionada en concordancia con las prácticas estándar previas de la empresa.

Sin proyecto			
	Costo de FR	Inversión	Flujo
Agosto	\$39.844.765	\$ -	\$39.844.765
Septiembre	\$53.391.985	\$ -	\$53.391.985
Octubre	\$47.761.920	\$ -	\$47.761.920
Noviembre	\$49.188.362	\$ -	\$49.188.362
Diciembre	\$46.533.506	\$ -	\$46.533.506

K	9,50%
VPN	\$181.068.995,15

Tabla 3: Calculo VPN sin proyecto

Con proyecto			
	Costo de FR	Inversión	Flujo
Agosto	\$37.852.527	\$ 230.000	\$38.082.527
Septiembre	\$50.722.386	\$ 230.000	\$50.952.386
Octubre	\$45.373.824	\$ 230.000	\$45.603.824
Noviembre	\$46.728.944	\$ 230.000	\$46.958.944
Diciembre	\$44.206.830	\$ 230.000	\$44.436.830

K	9,50%
VPN	\$172.898.678,41

Tabla 4: Calculo VPN con proyecto

Cómo podemos observar, en caso de implementar el proyecto, nos entrega un beneficio de un \$8.180.317 de pesos. Por lo tanto, del punto de vista económico, el proyecto es viable.

METODOLOGÍA

1. Recopilación de datos históricos de ventas y demanda de todos los productos del CD:
 - Extraer datos de ventas y demanda de los productos del centro de distribución para construir una base de datos histórica.
 - Asegurarse de incluir variables relevantes como fecha, volumen de ventas, y cualquier factor externo que pueda influir en la demanda.

2. Análisis exploratorio de datos:
 - Realizar un análisis detallado de los datos para identificar patrones de demanda, estacionalidad, ciclos y tendencias.
 - Utilizar herramientas visuales y estadísticas descriptivas para obtener información valiosa sobre el comportamiento histórico de los productos.

3. Selección de modelos de pronósticos:
 - Aplicar un Correlograma para evaluar la autocorrelación de los datos y determinar posibles modelos de pronóstico.
 - Utilizar técnicas como suavizado exponencial, SARIMA u otros métodos avanzados, seleccionando modelos que se ajusten a las características específicas de cada tipo de producto.

4. Prueba de los modelos seleccionados a través de Python:
 - Implementar los modelos seleccionados en un entorno de programación, como Python, para evaluar su desempeño.
 - Utilizar métricas como MAPE y MSE para comparar la precisión de los modelos y seleccionar los más adecuados.

5. Implementación y seguimiento del desempeño:
 - Integrar los modelos seleccionados en el sistema existente del centro de distribución.
 - Establecer un sistema de seguimiento continuo para evaluar la precisión de los pronósticos en tiempo real y realizar ajustes según sea necesario.

6. Ajustes y documentación:

- Realizar ajustes a los modelos en función del seguimiento del desempeño y cambios en la demanda.
- Documentar de manera detallada los procedimientos, parámetros y resultados para facilitar la replicabilidad y la toma de decisiones futuras.

DESARROLLO DEL PROYECTO

Para la generación de pronósticos de demanda, es crucial evaluar diversos modelos de series temporales y sus elementos constituyentes para seleccionar la opción más adecuada. Dada la extensa variedad de SKU que posee el centro de distribución, es prácticamente inviable examinar individualmente cada componente como la tendencia y estacionalidad. Por ello, se analizarán tres modelos matemáticos que examinan estos componentes, eligiendo aquel que mejor refleje la realidad o, más precisamente, la demanda real. Estos modelos son Prophet, Sarima y Holt-Winters, y se implementarán utilizando Python debido a su eficacia en el manejo de datos y cálculos estadísticos.

Modelo Prophet:

El Modelo Prophet está optimizado para pronosticar series temporales con patrones estacionales fuertes y efectos de días festivos. Es flexible y se adapta bien a cambios en tendencias con su capacidad para manejar datos faltantes y cambios en la tendencia, lo que lo hace ideal para aplicaciones empresariales con necesidades de pronóstico a diario, semanal y anual.

Modelo SARIMA:

El modelo SARIMA es particularmente eficaz en series temporales donde la estacionalidad es pronunciada. Su estructura permite capturar tanto la estacionalidad como las tendencias no estacionales y ajustarse a la autocorrelación de diferentes órdenes, facilitando pronósticos que reflejan patrones complejos en los datos históricos.

Modelo Holt-Winters:

El modelo Holt-Winters se destaca por su capacidad de descomponer series temporales en componentes y proporcionar pronósticos cuando hay tendencias y estacionalidades claras. Es especialmente útil para pronósticos a corto plazo y se adapta bien a cambios en las tendencias y patrones estacionales con el ajuste de sus parámetros de suavizado.

$$L_t = \alpha(Y_t - S_{t-p}) + (1 - \alpha)[L_{t-1} + T_{t-1}] \quad (1)$$

$$T_t = \beta(L_t - L_{t-1}) + [(1 - \beta)(T_{t-1})] \quad (2)$$

$$S_t = \delta(Y_t - L_t) + [(1 - \delta)(S_{t-p})] \quad (3)$$

$$Y'_t = L_{t-1} + T_{t-1} + S_{t-p} \quad (4)$$

Cada uno de estos modelos proporcionará un enfoque diferente para el pronóstico, y la elección dependerá de cuál se alinee mejor con la naturaleza de los datos históricos y la demanda real. Utilizar Python para esta tarea ofrece la ventaja de bibliotecas especializadas que facilitan la implementación de estos modelos complejos, permitiendo así análisis más eficientes y detallados.

Con el objetivo de desarrollar un pronóstico de demanda individualizado para cada SKU que el centro de distribución ofrece, se inició la programación en Python usando Google Colab para aplicar los modelos matemáticos mencionados. El principal reto en la creación de este programa radica en generar una predicción precisa para la multitud de productos distintos del cliente. El primer paso fue la importación de las bibliotecas necesarias y la carga del archivo pertinente para efectuar los pronósticos. Este archivo se prepara manualmente, organizando los códigos de producto (Cod.

Cliente), Descripción del producto, año-semana y la cantidad demandada correspondiente a cada fecha en columnas específicas. Fue necesario agregar una columna extra donde se indica fecha en formato DD-MM-YYYY para poder correr los datos como una serie de tiempo.

	A	B	C	D	E
1	Cod. Cliente	Descripción	año-semana	demanda	fecha
2	174835	PAN HAMBURG BRIOCHE 10CM 1X60U	2022-1	1310	2022-01-03
3	175093	PAN HOTDOG TRADICI 17CM 1X80UN	2022-1	1389	2022-01-03
4	175694	BARRA WILDFIT CHOC COCO 16X35G	2022-1	212	2022-01-03
5	174835	PAN HAMBURG BRIOCHE 10CM 1X60U	2022-2	675	2022-01-10
6	175093	PAN HOTDOG TRADICI 17CM 1X80UN	2022-2	684	2022-01-10
7	175694	BARRA WILDFIT CHOC COCO 16X35G	2022-2	207	2022-01-10
8	174835	PAN HAMBURG BRIOCHE 10CM 1X60U	2022-3	1090	2022-01-17
9	175093	PAN HOTDOG TRADICI 17CM 1X80UN	2022-3	1371	2022-01-17
10	175694	BARRA WILDFIT CHOC COCO 16X35G	2022-3	226	2022-01-17
11	174835	PAN HAMBURG BRIOCHE 10CM 1X60U	2022-4	1154	2022-01-24
12	175093	PAN HOTDOG TRADICI 17CM 1X80UN	2022-4	1558	2022-01-24
13	175694	BARRA WILDFIT CHOC COCO 16X35G	2022-4	277	2022-01-24
14	174835	PAN HAMBURG BRIOCHE 10CM 1X60U	2022-5	965	2022-01-31
15	175093	PAN HOTDOG TRADICI 17CM 1X80UN	2022-5	1283	2022-01-31
16	175694	BARRA WILDFIT CHOC COCO 16X35G	2022-5	300	2022-01-31
17	174835	PAN HAMBURG BRIOCHE 10CM 1X60U	2022-6	810	2022-02-07
18	175093	PAN HOTDOG TRADICI 17CM 1X80UN	2022-6	1084	2022-02-07
19	175694	BARRA WILDFIT CHOC COCO 16X35G	2022-6	317	2022-02-07
20	174835	PAN HAMBURG BRIOCHE 10CM 1X60U	2022-7	580	2022-02-14

Foto 5: Extracto de data utilizada para el proyecto.

Dentro del conjunto productos almacenados en nuestro centro de distribución, se ha llevado a cabo un análisis meticuloso para identificar aquellos productos que registran los índices más altos de rotación y demanda comercial. Fruto de este examen, hemos seleccionado cinco productos que destacan por su fluidez en la cadena de suministro y su sólido historial de ventas. Este enfoque selectivo nos permite concentrar nuestros esfuerzos en optimizar el manejo y la distribución de los artículos más influyentes en nuestro inventario.

Con el propósito de ilustrar de manera concreta el progreso y las metodologías aplicadas en el proyecto, nos centraremos en el análisis detallado del producto conocido como "BARRA WILDFIT CHOC COCO 16X35G". A través de este ejemplo específico, delinearemos las estrategias de gestión implementadas, las mejoras en los procesos logísticos y los resultados alcanzados. Esta aproximación práctica no solo proporcionará una visión clara del trabajo efectuado, sino que también servirá como

un modelo replicable para la optimización de otros productos dentro de nuestra operación. Actualmente el producto cuenta con un MAPE promedio de un 58%, con el modelo actual, el cual es alisado exponencial doble.




Gráfico 4: Comportamiento del MAPE del SKU 173645




Gráfico 6: Histograma de la distribución de la demanda del SKU 173645

Análisis estadístico descriptivo de la demanda del producto "BARRA WILD PROT CHOCO 16X45GR":

Estadísticas Descriptivas Básicas

- Cantidad de Registros (count): 95.
- Media (mean): Aproximadamente 219.77 unidades.
- Desviación Estándar (std): Alrededor de 80.22 unidades, lo que indica una variabilidad significativa.
- Mínimo (min): 31 unidades.
- Máximo (Max): 424 unidades.
- Cuartiles:
 - 25%: 160 unidades.
 - 50% (Mediana): 212 unidades.
 - 75%: 260.5 unidades.

Evaluación de modelos

Análisis de las Predicciones del Modelo de Holt-Winters

1. Comparación Visual:

- El gráfico muestra la demanda real en comparación con las predicciones realizadas por el modelo de Holt-Winters. (anexo 1)
- Podemos observar cómo las predicciones se alinean o desvían de los valores reales a lo largo del tiempo.




Gráfico 7: Demanda real vs Forecast modelo Holt-Winters

2. Métricas de Rendimiento:

- Error Cuadrático Medio (MSE): 3508.77. Esta métrica indica el promedio de los cuadrados de los errores. Cuanto menor sea el MSE, mejor será el modelo.
- Error Absoluto Medio (MAE): 45.73. El MAE proporciona una idea de cuán grandes son los errores en términos absolutos.
- Error Absoluto Medio Porcentual (MAPE): 26.05%. El MAPE expresa la precisión del pronóstico, mientras más cercano a 0 mejor.

Estas métricas proporcionan una cuantificación del rendimiento del modelo. Un MSE y MAE más bajos indican un mejor rendimiento del modelo en términos de ajuste a los datos reales.

3. Análisis de Residuos

El análisis de residuos del modelo de Holt-Winters proporciona información valiosa sobre su rendimiento:

3.1) Análisis Visual de los Residuos




Gráfico 8: Residuos modelo Holt-Winters

- El primer gráfico muestra los residuos (la diferencia entre la demanda real y la predicción) a lo largo del tiempo.
- La línea roja representa un residual de cero.
- Si los residuos se distribuyen aleatoriamente alrededor de esta línea y no muestran patrones claros, es una indicación de que el modelo está realizando bien.

3.1) Estadísticas Descriptivas de los Residuos

- Mean: Un promedio cercano a cero (-0.755) sugiere que no hay un sesgo sistemático en las predicciones.
- Std: La desviación estándar de los residuos es aproximadamente 59.54.
- Min/Max: Los residuos varían desde -167.60 a 141.60.

3.3) Distribución de los Residuos




Gráfico 9: Distribución residuos Holt-Winters

- El histograma muestra cómo se distribuyen los residuos.
- Una distribución aproximadamente simétrica y centrada en torno a cero es generalmente un buen signo.

Análisis de las Predicciones del Modelo SARIMA

Ajustes del modelo

Se ajusta un modelo SARIMA con los siguientes parámetros:

- ``order= (1, 0, 1)``: Estos parámetros representan el componente autorregresivo (AR), el nivel de diferenciación (I), y el componente de media móvil (MA), respectivamente.
- ``seasonal_order= (0, 1, 1, 52)``: Estos parámetros adicionales representan la parte estacional del modelo SARIMA, donde se especifica el orden estacional AR, el nivel de diferenciación estacional, el orden estacional MA y la longitud de la temporada (52 semanas al año).
- ``enforce_stationarity=False, enforce_invertibility=False``: Estas opciones relajan las restricciones sobre la estacionariedad y la invertibilidad durante el proceso de ajuste del modelo. Esto puede ser útil en series que son difíciles de modelar con restricciones estándar.

1. Comparación Visual:

- El gráfico muestra cómo las predicciones del modelo SARIMA se comparan con la demanda real a lo largo del tiempo. (Anexo 2)

- Esta visualización ayuda a identificar cómo el modelo se ajusta a las tendencias y variaciones en los datos.




Gráfico 10: Demanda real vs Modelo SARIMA

2. Métricas de Rendimiento:

- Error Cuadrático Medio (MSE): 7427.82. Una medida del promedio de los cuadrados de los errores. Un MSE más bajo indica un mejor ajuste del modelo.

- Error Absoluto Medio (MAE): 68.45. Proporciona una medida de la magnitud media de los errores en términos absolutos.

- Error Absoluto Medio Porcentual (MAPE): 33.84%. El MAPE expresa la precisión del pronóstico, mientras más cercano a 0 mejor.

3. Análisis de Residuos

3.1. Estadísticas Descriptivas de los Residuos:

- Mean: 31.31, lo que indica un sesgo en las predicciones, ya que no están centradas en cero.
- Std: La desviación estándar es de aproximadamente 80.72, sugiriendo una variabilidad considerable en los errores de predicción.
- Min/Max: Los residuos van de -245.13 a 223.00, indicando que hay algunas predicciones que están significativamente desviadas de los valores reales.

3.2. Histograma de los Residuos:




Gráfico 11: Distribución residuos Modelo SARIMA

- La distribución de los residuos se muestra en el histograma.
- La distribución no está centrada en cero y parece sesgada, lo que podría indicar un modelo que sistemáticamente sobreestima o subestima la demanda.

3.3. Interpretación

- La presencia de un sesgo en los residuos y los valores relativamente altos de MSE y MAE sugieren que el modelo SARIMA podría no estar capturando toda la complejidad de los datos.

- La distribución de los residuos y la magnitud de los errores podrían señalar la necesidad de revisar los parámetros del modelo o considerar la inclusión de variables externas o transformaciones adicionales de los datos para mejorar el rendimiento del modelo.

Análisis de las Predicciones del Modelo Prophet

1. Comparación Visual

- La gráfica muestra la demanda real y las predicciones hechas por el modelo Prophet. El área gris representa el intervalo de confianza, que muestra la incertidumbre en las predicciones. (Anexo 3)

- Se puede observar cómo las predicciones se alinean con la demanda real y cómo fluctúan dentro del intervalo de confianza.




Gráfico 12: Demanda real vs Modelo Prophet

2. Métricas de Rendimiento

- Error Cuadrático Medio (MSE): 2756.09. Indica el promedio de los errores al cuadrado, siendo un valor más bajo indicativo de mejores predicciones.

-Error Absoluto Medio (MAE): 43.83. Representa el error promedio en términos absolutos, lo que proporciona una comprensión de la magnitud promedio de los errores de predicción.

- Error Absoluto Medio Porcentual (MAPE): 23.93%. El MAPE expresa la precisión del pronóstico, mientras más cercano a 0 mejor.

3. Análisis de Residuos

3.1 Estadísticas Descriptivas de los Residuos:

- La media prácticamente en cero (-0.000031) sugiere que no hay un sesgo sistemático en las predicciones.
- La desviación estándar de aproximadamente 52.78, indica la variabilidad de los errores de predicción.
- Los valores mínimos y máximos (-126.31 y 123.70, respectivamente) muestran la amplitud de los errores.

3.2. Histograma de Residuos

- El histograma muestra la distribución de los residuos del modelo Prophet.
- La forma de la distribución sugiere que la mayoría de los errores están concentrados alrededor de la media, con algunos errores más significativos que son menos frecuentes.




Gráfico 13: Distribución residuos Modelo Prophet

Conclusión Completa sobre el Modelo Prophet

El modelo Prophet parece tener un buen desempeño en general, con un MAE y un MSE inferiores a los observados en los modelos anteriores, indicando predicciones más precisas en promedio. La media de los residuos cerca de cero sugiere que no hay un sesgo significativo en las predicciones y la distribución de los residuos es razonablemente simétrica.

El intervalo de confianza proporcionado por Prophet es una ventaja, ya que ofrece una visión de la incertidumbre asociada con las predicciones, algo que es valioso para la toma de decisiones en un entorno empresarial.

En comparación con los otros modelos, Prophet muestra un rendimiento sólido y parece ser una buena opción para pronosticar la demanda para este conjunto de datos. Sin embargo, como con cualquier modelo predictivo, es importante considerar su aplicación dentro del contexto específico del negocio y continuar monitoreando y ajustando el modelo a medida que se dispone de nuevos datos.




Gráfico 14: Comparación MAPE entre modelos utilizados

Medición y desempeño

La compañía recibió el modelo, sin embargo, optó por iniciar su ejecución a partir del 1 de diciembre de 2023, por lo que todavía no se ha podido determinar su desempeño efectivo. Se está considerando el método para comparar la precisión en las proyecciones de demandas de este modelo con las técnicas de pronóstico usadas previamente.

Conclusiones

El proyecto desarrollado en Arcoprime representa un hito significativo en la aplicación de tecnologías avanzadas en la gestión de pronósticos de demanda. Central en este esfuerzo ha sido el uso del lenguaje de programación Python, un pilar en el desarrollo de modelos de aprendizaje automático y estadísticos. La implementación de estos modelos ha demostrado ser crucial para mejorar la precisión de los pronósticos, un componente esencial para el eficaz funcionamiento del proceso de S&OP (Sales and Operations Planning).

La exactitud en los pronósticos de demanda no solo mejora la eficiencia operativa y reduce el desperdicio, sino que también proporciona una base sólida para tomar decisiones estratégicas más informadas en Arcoprime. Esto se traduce en una mejor alineación de la producción y la distribución con las necesidades del mercado, optimizando recursos y minimizando el impacto ambiental.

Además, este proyecto abre un abanico de posibilidades para aplicar técnicas similares en otras áreas de la empresa. Por ejemplo, se podrían adaptar estos modelos para mejorar la gestión de la cadena de suministro, la asignación de recursos humanos o incluso en la planificación estratégica de marketing y ventas. La adaptabilidad de estas herramientas tecnológicas asegura que su aplicación pueda ser versátil y beneficiosa en distintos contextos dentro de la organización.

Desde un punto de vista ético y social, el proyecto subraya la responsabilidad de Arcoprime hacia una operación empresarial sostenible y respetuosa con el medio ambiente. La eficiencia mejorada en la gestión de inventario, impulsada por una mayor precisión en los pronósticos, conduce a una reducción significativa en el desperdicio de recursos. Esto, a su vez, contribuye a un modelo de negocio más sostenible y eco-amigable. Además, la eficacia en satisfacer las demandas del mercado

refuerza el compromiso de la empresa con las comunidades a las que sirve, asegurando que sus necesidades sean atendidas de manera responsable y oportuna.

En conclusión, este proyecto no solo resalta la importancia de la integración de tecnologías avanzadas en las operaciones comerciales, sino que también establece un precedente para futuras iniciativas dentro de Arcoprime. Al equilibrar los objetivos comerciales con el impacto social y ambiental, el proyecto demuestra un enfoque holístico y ético hacia la gestión empresarial.

Bibliografía

1. Alonso-Cortés, M., & Arribas, V. (2022, abril 26). Análisis y Predicción de Series Temporales con FB Prophet Python. *Model Differently*. https://www.modeldifferently.com/2022/04/analisis_prediccion_ts_prophet/
2. ChatGPT. (s/f). Openai.com. Recuperado el 8 de diciembre de 2023, de <https://chat.openai.com/>
3. Chinlli, C. M. (s/f). *Modelización de Series Temporales modelos clásicos y SARIMA*. Ugr.es. Recuperado el 8 de diciembre de 2023, de https://masteres.ugr.es/estadistica-aplicada/sites/master/moea/public/inline-files/TFM_MIRANDA_CHINLLI_CARLOS.pdf
4. De suavizado exponencial, E. T. A. un M. P. a. las O. R. y. un M. P. a. las O. M. A. A. E. T. T. se L. C. C. T. (s/f). *Caso de estudio: Método de Holt-Winters*. Scalahed.com. Recuperado el 8 de diciembre de 2023, de https://gc.scalahed.com/recursos/files/r161r/w24932w/S4_M1CDN107_C.pdf
5. *Gestión de inventarios en retail: mejores prácticas en tiempo de recesión*. (2023, febrero 22). THE LOGISTICS WORLD | Conéctate e inspírate; THE LOGISTICS WORLD. <https://thelogisticsworld.com/almacenes-e-inventarios/gestion-de-inventarios-en-retail-mejores-practicas-en-tiempo-de-recesion/>
6. Guevara, D. E. R., & Zuluaga, A. G. (2020). Metodología aplicada para el pronóstico de demanda de fondo de cambio en empresas de retail. *Contexto*, 9(1), 33–45. <https://doi.org/10.18634/ctxj.9v.1i.1049>
7. Småros, J., & Kaleva, H. (2020, agosto 6). *Guía: Machine Learning en la Previsión de la Demanda*. RELEX Solutions. <https://www.relexsolutions.com/es/publicaciones/la-guia-completa-sobre-machine-learning-en-la-prevision-de-la-demanda-en-retail/>
8. Tatiana, J., & Mejia, G. (s/f). *PLANEACIÓN DE LA DEMANDA EN LA INDUSTRIA RETAIL*. Edu.co. Recuperado el 8 de diciembre de 2023, de <https://repository.unimilitar.edu.co/bitstream/handle/10654/17120/GalvisMejiaJessicaTatiana2017.pdf?isAllowed=y&sequence=2>

Anexos

Códigos utilizados para la realización de pronósticos.

Anexo 1:

```
def holt_winters_forecast_to_excel(data, sku_description, file_name='holt_winters_forecast.xlsx'):
    sku_data = data[data['Descripción'] == sku_description].copy()
    if sku_data.empty:
        print(f"No se encontraron datos para el SKU: {sku_description}")
        return

    # Ajustar el modelo Holt-Winters sin estacionalidad
    model = SimpleExpSmoothing(sku_data['demanda'])
    fit = model.fit(optimized=True)

    # Predecir
    sku_data['forecast'] = fit.predict(start=0, end=len(sku_data)-1)

    # Calcular el MAPE
    sku_data['abs_pct_error'] = 100 * (sku_data['demanda'] - sku_data['forecast']).abs() /
    sku_data['demanda']
    mape = sku_data['abs_pct_error'].mean()
    print(f"El MAPE promedio de las predicciones es: {mape:.2f}%")

    # Graficar los resultados
    plt.figure(figsize=(12, 6))
    plt.plot(sku_data['fecha'], sku_data['demanda'], label='Demanda real')
    plt.plot(sku_data['fecha'], sku_data['forecast'], label='Pronóstico Holt-Winters')
    plt.title(f"Pronóstico de demanda con Holt-Winters para el SKU: {sku_description} - MAPE:
    {mape:.2f}%")
    plt.xlabel("Fecha")
    plt.ylabel("Demanda")
```



```
plt.legend()
plt.grid(True)
plt.show()

# Crear un DataFrame para guardar los resultados
forecast_df = sku_data[['fecha', 'demanda', 'forecast']]

# Guardar el DataFrame en un archivo Excel
forecast_df.to_excel(file_name, index=False)
print(f'Las predicciones se han guardado en {file_name}')

# Llamar a la función con el SKU de ejemplo y un nombre de archivo específico
holt_winters_forecast_to_excel(data, data['Descripción'].iloc[0], 'holt_winters_predictions.xlsx')
```

Anexo 2:

```
def sarima_forecast_to_excel(data, sku_description, file_name='sarima_forecast.xlsx'):
    sku_data = data[data['Descripción'] == sku_description].copy()
    if sku_data.empty:
        print(f"No se encontraron datos para el SKU: {sku_description}")
        return

    # Ajustar el modelo SARIMA
    model = sm.tsa.statespace.SARIMAX(sku_data['demanda'], order=(1, 0, 1), seasonal_order=(0, 1,
    1, 52), enforce_stationarity=False, enforce_invertibility=False)
    results = model.fit()

    # Realizar predicciones
    sku_data['forecast'] = results.predict(start=0, end=len(sku_data)-1)

    # Calcular el MAPE
```

```
sku_data['abs_pct_error'] = 100 * (sku_data['demanda'] - sku_data['forecast']).abs() /
sku_data['demanda']

mape = sku_data['abs_pct_error'].mean()

print(f"El MAPE promedio de las predicciones es: {mape:.2f}%")

# Graficar los resultados
plt.figure(figsize=(12, 6))

plt.plot(sku_data['fecha'], sku_data['demanda'], label='Demanda real')
plt.plot(sku_data['fecha'], sku_data['forecast'], label='Pronóstico SARIMA')

plt.title(f"Pronóstico de demanda con SARIMA para el SKU: {sku_description} - MAPE:
{mape:.2f}%")

plt.xlabel("Fecha")
plt.ylabel("Demanda")
plt.legend()
plt.grid(True)
plt.show()

# Crear un DataFrame para guardar los resultados
forecast_df = sku_data[['fecha', 'demanda', 'forecast']]

# Guardar el DataFrame en un archivo Excel
forecast_df.to_excel(file_name, index=False)

print(f"Las predicciones se han guardado en {file_name}")

# Llamar a la función con el SKU de ejemplo y un nombre de archivo específico
sarima_forecast_to_excel(data, data['Descripción'].iloc[0], 'sarima_predictions.xlsx')
create_download_link('sarima_predictions.xlsx')
```

Anexo 3:

```
def prophet_forecast_to_excel(data, sku_description, file_name='prophet_forecast.xlsx'):
```

```
sku_data = data[data['Descripción'] == sku_description]

if sku_data.empty:

    print(f"No se encontraron datos para el SKU: {sku_description}")

    return

# Preparar datos para Prophet
prophet_data = sku_data[['fecha', 'demanda']].rename(columns={'fecha': 'ds', 'demanda': 'y'})

# Crear y ajustar el modelo
model = Prophet(yearly_seasonality=True, weekly_seasonality=False, daily_seasonality=False)
model.fit(prophet_data)

# Solo hacer predicciones para el rango de fechas existente
forecast = model.predict(prophet_data)

# Calcular el MAPE para el rango de fechas existente
sku_data['forecast'] = forecast['yhat']
sku_data['abs_pct_error'] = abs((sku_data['demanda'] - sku_data['forecast']) /
sku_data['demanda']) * 100
mape = sku_data['abs_pct_error'].mean()
print(f"El MAPE promedio de las predicciones es: {mape:.2f}%")

# Graficar la predicción
fig = model.plot(forecast)

plt.title(f"Pronóstico de demanda con Prophet para el SKU: {sku_description} - MAPE:
{mape:.2f}%")
plt.xlabel("Fecha")
plt.ylabel("Demanda")
plt.show()

# Preparar el DataFrame de predicciones para guardar en Excel
# Incluyendo solo el rango de fechas para el cual tenemos datos reales
```

```
forecast_to_save = forecast[['ds', 'yhat', 'yhat_lower', 'yhat_upper']].copy()
forecast_to_save.rename(columns={'ds': 'Fecha', 'yhat': 'Predicción', 'yhat_lower': 'Límite
Inferior', 'yhat_upper': 'Límite Superior'}, inplace=True)
forecast_to_save = forecast_to_save[forecast_to_save['Fecha'].isin(sku_data['fecha'])]

# Guardar el DataFrame en un archivo Excel
forecast_to_save.to_excel(file_name, index=False)
print(f'Las predicciones se han guardado en {file_name}')

# Llamar a la función con el SKU de ejemplo y un nombre de archivo específico
prophet_forecast_to_excel(data, data['Descripción'].iloc[0], 'prophet_predictions.xlsx')
create_download_link('prophet_predictions.xlsx')
```