

Implementación modelo para identificación y clasificación de fallas de desbalanceo en Maquinaria Industrial en licitación de Nicolaides, Santiago

Gonzalo Javier de Camino Trombert

Profesor: Nicolas Cenzano

Índice:

Resumen Ejecutivo.....	2
Abstract.....	2
Introducción.....	3
Objetivos.....	6
Metodologías.....	6
Estado del arte.....	7
Solución escogida.....	10
Riesgos considerados.....	11
Evaluación Económica.....	11
Plan de implementación.....	12
Medidas de desempeño.....	15
Desarrollo	16
Resultados.....	19
Conclusiones.....	20
Anexo.....	21

Resumen ejecutivo:

Este proyecto se centra en la implementación de un modelo de aprendizaje automático para la detección de fallas en sensores de vibración y temperatura en la planta de la papelera CMPC de Nicolaides Industrial. Se identificaron exitosamente dos casos específicos de desbalanceo en los assets 19-23-097 y 048-23-096 utilizando el modelo IsolationForest, logrando una precisión del 90% en la detección de errores seleccionados. Esta precisión se validó comparando con los casos de falla de estos sensores históricos recientes.

A pesar de los resultados exitosos en la identificación de errores específicos, se destacó la limitación del modelo debido a la escasez de datos de prueba. La baja cantidad de datos de fallas efectivas plantea desafíos para generalizar el modelo a otros tipos de fallos en la maquinaria. Se enfatiza la necesidad de ampliar el alcance del proyecto para validar su aplicabilidad en diversos motores, no solo en la planta de CMPC, sino en futuros casos.

Se lograron cumplir tres métricas clave de desempeño: la identificación del 90% de las velocidades naturales de los motores con una precisión de ± 300 RPM, la detección del 100% de las fallas identificadas durante los períodos analizados y una reducción del 90% en las horas hombre debido a la rápida accesibilidad de los datos relevantes de fallas, reduciendo el tiempo de análisis de 160 horas a solo 5 minutos.

En conclusión, el modelo demostró eficacia en la identificación de patrones de fallas específicas. Sin embargo, su aplicabilidad y validez deben ser evaluadas con una mayor diversidad de datos para garantizar su utilidad en una gama más amplia de escenarios de fallas en maquinaria industrial.

Abstract:

This project focuses on implementing a machine learning model for detecting faults in vibration and temperature sensors at CMPC's Nicolaides Industrial plant. Two specific cases of imbalance were successfully identified in sensors 19-23-097 and 048-23-096 using the IsolationForest model, achieving a 90% accuracy in selected error detection. This accuracy was validated through evaluation with known recent data from failings.

Despite the successful results in identifying specific errors, the model's limitation due to the scarcity of test data was highlighted. The low amount of effective fault data poses challenges for generalizing the model to other types of machinery failures. There's an emphasis on the need to expand the project's scope to validate its applicability in various engines, not only in the CMPC plant but in future cases as well.

Three key performance metrics were achieved: identification of 90% of natural engine speeds with an accuracy of ± 300 RPM, detection of 100% of identified faults during the analyzed periods, and a 90% reduction in man-hours due to the rapid accessibility of relevant fault data, reducing analysis time from 160 hours to just 5 minutes.

In conclusion, the model demonstrated effectiveness in identifying specific fault patterns. However, its applicability and validity need to be assessed with a greater diversity of data to ensure its utility in a wider range of industrial machinery failure scenarios.

Introducción:

El contexto del problema se desarrolla en la empresa Nicolaidés. Fundada en 1953, su principal rubro se encuentra en la importación de tecnologías de punta desde proveedores internacionales para solucionar problemas en Chile. Esta se encuentra dividida en distintas empresas las cuales se encargan de los distintos negocios (filtraciones, tratamiento de agua, olores y confiabilidad y monitoreo). La empresa como tal posee presencia en todo Chile, donde tienen presencia en las principales empresas en las áreas de Vinos, Alimentos, Minería, Petroquímica, Celulosa, Construcción y Generación de Energía.

Al tener un rango de rubros tan considerablemente amplios, la empresa se divide a su vez en empresas asociadas al nombre Nicolaidés. Nicolaidés Industrial es la empresa específica en la cual se está trabajando en este proyecto. El organigrama de la empresa se encontrará en el Anexo 1.

Nicolaidés Industrial como tal presenta 4 áreas de trabajo: Aislación industrial, Procesos industriales, Monitoreo de variables críticas e integración y servicios. El proyecto presentado en este informe está focalizado en el área de monitoreo de variables críticas. En esta área, la empresa posee un contrato con la papelera CMPC para la instalación de monitoreo 4.0 en la planta de la empresa ubicadas en la ciudad de Laja. Este proyecto empezó en agosto de 2017, instalándose 159 sensores repartidos

en cada uno de los motores, incineradores, ventiladores y bombas existentes en la fábrica. Estos sensores provienen de la empresa belga llamada I-Care, la cual es un exponente mundial en el mantenimiento predictivo y prescriptivo alrededor del mundo. Para solucionar la necesidad de CMPC, Nicolaides formó un vínculo con I-Care, donde Nicolaides Industrial encarga los sensores a I-CARE para instalarlos en la misma empresa.

Los sensores fueron actualizados durante el mes de agosto de 2023, donde se reemplazaron sensores los cuales poseían canales Mono-axiales (Modelo Wi-care - 110) con sensores capaces de obtener lecturas Tri axiales de dos generaciones distintas (Wi-care – 130 y Wi-care 130X), es decir, poseen un canal de transmisión para cada eje (Axial, horizontal y vertical). Ambos tipos de sensores son capaces de medir cada cierto periodo de tiempo tanto las ondas de vibración de los maquinas analizadas como la temperatura a la cual estas operan. Los sensores de la empresa son luego capaces de interpretar esta información y guardarla en la base de datos de I-CARE, donde se acceden típicamente mediante el acceso a la página web y revisión de las variables. En la instalación, los sensores 130X fueron colocados en los motores críticos para el funcionamiento de la planta de CMPC, conformando 60 de los 159 sensores. Los 99 sensores restantes son de nueva generación fueron ubicados en la maquinaria restante. La diferencia principal entre ambos tipos de sensores es que los sensores de nueva generación no requieren de un repetidor para funcionar y son más precisos a la hora de medir las ondas de vibración, pudiendo medir ondas de hasta 18000 hertz en menores intervalos.

La instalación de estos sensores posee una relevancia importante ya que tanto el monitoreo de condiciones como los métodos predictivos de mantenimiento de maquinaria son importantes para la garantizar la utilidad de la vida útil en maquinaria moderna¹, por lo que para una empresa como CMPC le es relevante instalar este tipo de sensores para estar completamente pendiente de la maquinaria y evitar pérdidas millonarias producto a fallas no detectadas a tiempo por rodamientos. También se debe considerar que de acuerdo con una investigación hecha por la misma empresa Nicolaides para el sexto congreso Internacional de automatización en la minería el 80% de las

¹ Omar AlShorman, M. I. (2020). A Review of Artificial Intelligence Methods for Condition Monitoring and Fault Diagnosis of Rolling Element Bearings for Induction Motor. *Shock and Vibration*, 20.

detenciones imprevistas de los motores son producto de problemas que se muestran en la vibración de los equipos.²

La base de este análisis de las mediciones de vibración se conoce como “mantenimiento preventivo en base a análisis de vibración” y se conoce como un método usado para el diagnóstico de fallas en maquinaria que usa sistemas de rodamiento. Esto se realiza analizando los gráficos producidos por los sensores de las máquinas y logrando buscar distintos patrones típicos de fallas. Los sensores de la empresa I-CARE proveen lecturas de cada medición en 3 representaciones distintas: Gráfico amplitud/tiempo de medición, gráfico de velocidad/vibración y gráfico aceleración/vibración. Estos últimos dos gráficos son los que principalmente se utilizan a la hora de analizar la presencia de anomalías en el funcionamiento de los motores, los cuales se mostraran en el Anexo 2.

Cada tipo de falla posee un patrón distinto, pero cada uno de estos patrones se busca en relación con una vibración siempre presente en cada motor en funcionamiento: la frecuencia natural de funcionamiento de un motor. En base a esta, se busca la información de las vibraciones respecto a los múltiplos de la vibración natural del motor en cuestión (llamados NX donde N es el múltiplo de la frecuencia natural), donde se identifican y analizan los patrones en cuestión.

La problemática se encuentra en que la revisión de estas variables toma tiempo para los trabajadores. El estudio cuidadoso y meticuloso para la predicción de fallas basado en el análisis del espectro de vibración a través del tiempo toma valioso tiempo para los trabajadores de la empresa. Este tiempo es relevante ya que los técnicos contratados del área de monitoreo deben estar haciendo constantemente otras tareas en paralelo durante el mes y a su vez estar constantemente verificando presencialmente la instalación de los equipos, lo cual implica viajes y más tiempo empleado. Es por esto por lo que se decide empezar a considerar en una solución que conduzca hacia la automatización de este proceso.

Este proceso para cada sensor individualmente toma entre 1 hora y 3 horas, esto dependiendo de que tan rápido se puede determinar la falla y que tan claramente se muestra a través del tiempo. Si hacemos un análisis de predicción en nuestro caso actual, un análisis de predicción equivaldría a una duración de un mínimo de 160 horas de trabajo, donde la duración del análisis depende casi mayoritariamente de que tan compleja es la localización de las fallas en cuestión³. Por otra parte, la

² Luis Saez, N. P. (2018). Wireless Remote Vibration and Temperature Condition Monitoring: Application at CMPC Pulp Plant. *6th International Congress on Automation in Mining*, Chapter 6

³ Datos proporcionados de acuerdo con los analistas de la empresa

periodicidad de análisis de equipos depende del nivel de criticalidad que poseen para la empresa. Se estipula que, en caso de equipos críticos, se hace un análisis predictivo una vez por mes mientras que en el resto de los equipos se realiza cada 2 meses.

Objetivos:

Objetivo: Reducir en 70% horas hombre⁴ en la detectabilidad de fallas de rodamiento a través de modelo aprendizaje (IA) autónomo o automático de sensores de vibración y temperatura en un importante cliente de Nicolaides al detectar al menos un patrón de falla de vibración.

Objetivos específicos:

Los objetivos específicos detallados para la guía y evaluación del proyecto son los siguientes

- 1) Alcanzar un 90% de accuracy con el modelo (comprobación de la efectividad del modelo)
- 2) Alcanzar un mínimo de 160 horas hombre reducidas (corresponde al mínimo de las horas hombre utilizadas en el análisis)
- 3) Encontrar con un modelo la velocidad de funcionamiento natural de los motores con una precisión del 90% (variable esencial al momento de la clasificación de las anomalías)

Metodologías

La metodología de trabajo definida será una metodología personalizada basada en la comunicación entre mi persona y el supervisor de la empresa para ir midiendo el avance del proyecto. Esta se basará en el cumplimiento de hitos en ciertos períodos de tiempo (los cuales serán detallados más adelante) en los cuales se hará un seguimiento cada 2 semanas para comunicar el avance del proyecto y poder efectivizar el avance en este.

Específicamente, esta metodología de trabajo correspondería a una metodología lineal de cascada con elementos de metodologías ágiles como Scrum/Kanban ya que una metodología ágil no hace sentido a la hora de ser un proyecto de una persona ya que no existe un equipo al cual estar coordinado con el desarrollo de la solución. Sin embargo, la presencia de comunicación constante entre la empresa y mi persona es suficientemente importante como para mantenerla en

⁴ Este porcentaje se obtiene tomando en cuenta que la mayor parte del análisis predictivo requiere de la búsqueda de errores en cuestión. Luego, la reducción de esta búsqueda en un 90% lograría una reducción del proceso en cuestión.

consideración de esta metodología, por lo que se añadirá a la metodología en cascada el aspecto de revisión constante mediante reuniones el cual poseen metodologías ágiles como SCRUM.

Por otra parte, los conocimientos que se esperan utilizar a través del proyecto son plenamente del área de informática e incluyen:

- 1) Data Science
- 2) Ingeniería de Software
- 3) Machine Learning

Estado del arte y propuestas de solución

En la actualidad existen distintos acercamientos a la idea de utilización de automatización del proceso de análisis predictivo. Al hacerse este proceso típicamente por un analista y requerir al momento un input humano necesario debido a la especificidad del análisis en cuestión. Es por esto por lo que las implementaciones que serán estudiadas para la solución del problema van direccionadas a la asistencia del analista para que se reduzca el tiempo necesario empleado para hacer la tarea como tal.

Realizando una búsqueda el mercado actualmente existen diversas plataformas que están concentradas en las soluciones de carácter puramente analítico de la data. Ejemplos de empresas en el mercado que se dedican a la predicción de fallos en equipamiento industrial podemos encontrar a Viking Analytics, Artemis modal y SKF ai-driven industrial análisis. De estas opciones, la más presente es el AI-driven industrial análisis de SKF debido a que ellos se encuentran como la distribuidora principal no solo de equipos de medición, sino que también de assets mismos en el mundo industrial como motores y reductores industriales.

Como se menciona anteriormente, el hecho de no poder conocer el patrón de funcionamiento normal, además de no poseer el acceso total a la data histórica y debidamente marcada de cada uno de los motores de una fábrica induce a que estas empresas provean su utilidad al calcular los distintos modos de operación de cada máquina. Esto lo hacen tomando las mediciones históricas de las máquinas y, utilizando algoritmos no supervisados de Machine Learning, agrupan estas en distintos conjuntos los cuales se describen como modos de operación que tiene la máquina en cuestión a través del tiempo. Luego, se notifica al analista si existe un nuevo patrón de

comportamiento si en primer lugar existe un aumento anormal de las variables globales del motor (subida anormal de velocidad promedio o de vibración promedio, por ejemplo).

El uso de algoritmos de Machine Learning es el más popular debido a su capacidad de discernir patrones entre grandes cantidades de data y clasificarlos de acuerdo con los distintos algoritmos que existen de clasificación de data. Generalmente estas opciones tienden a variar de acuerdo con la necesidad que cada problema intuye, siendo estas las siguientes:

- Disponibilidad de datos
- Linealidad de los datos
- Features de las ondas consideradas

En términos de tipos de algoritmos de Machine Learning que se pueden utilizar, se encontró que las empresas poseen sistemas de evaluación de modelos automáticas las cuales son capaces de encontrar el modelo más apto para los casos que se encuentran disponibles para la clasificación. Hablando en términos del problema, este sería un problema de clasificación, por lo que todo modelo de clasificación (SVM, KNN, Naive Bayes) es válido para la búsqueda de datos de fallo en una muestra.

Sin embargo, como fue destacado anteriormente, no poseemos data clasificada para entrenar a un modelo supervisado. Existen reportes de datos de fallas en los motores de la planta en cuestión, los cuales son en total 12. Si se separan los reportes de errores y se clasifican tanto por motores con velocidad de funcionamiento similar como por tipo de error, encontramos que tenemos como máximo 3 errores utilizables para una comparación. Es por esto por lo que se prefiere un alcance no supervisado a la hora de encontrar los distintos errores de funcionamiento, como los que se encontraron disponibles en el mercado.

Por otra parte, existen una serie de herramientas que se encuentran recientemente siendo desarrolladas de parte de empresas las cuales poseen una presencia considerable en el mundo del almacenamiento Cloud⁵. Tanto los servicios de Amazon Web Service como los de Microsoft Azure

⁵ El almacenamiento Cloud se refiere a la práctica de guardar datos en servidores remotos a través de internet en lugar de almacenarlos localmente en dispositivos físicos, como discos duros o unidades USB. Estos servidores remotos son mantenidos por proveedores de servicios en la nube y ofrecen capacidad de almacenamiento a usuarios para guardar y acceder a sus archivos desde cualquier ubicación con conexión a internet

poseen plataformas de Machine Learning en la nube (Amazon Sagemaker/Kinesis y Microsoft Anomaly Detector, respectivamente) las cuales son capaces tanto de hacer un seguimiento de los datos que se suben a la nube como hacer detección de anomalías probando con distintos algoritmos al mismo tiempo, los cuales luego son filtrados automáticamente con distintos métodos de performance⁶.

Esta opción, si bien fue considerada, se dejó de lado al considerarse el querer tener mayor control a la hora de elegir y revisar los datos de las mediciones. Cada medición de cada maquina distinta posee múltiples variables que pueden ser únicas a su caso (conexión del motor a otros tipos de máquinas y el modelo de la maquina) por lo que el contexto de cada una de estas es suficientemente relevante como para tener que estar en cuenta constantemente y ser capaz de discriminar la data en base a este.

A la hora de elegir algoritmos no supervisados que pudieran hacer esta distinción de datos atípicos se encontró como opciones varios tipos de algoritmos no supervisados tanto en el área del clustering como en la reducción de dimensionalidad. Generalmente la reducción de dimensionalidad es usada como parte del preprocesamiento de los datos, ya que permite generar dependiendo del caso nuevas features que son capaces de representar otras features.

De los candidatos, los modelos que fueron probados fueron PCA (para el preprocesamiento de datos y reducción de dimensión de las variables) así como los siguientes modelos de clustering para encontrar la presencia de outliers: DBSCAN, K Means, Isolation Forest y Local Outlier Factor. Estos algoritmos fueron elegidos ya que es necesario probar que tipo de algoritmos es mejor a la hora de buscar la solución al problema. De los algoritmos mencionados anteriormente, DBSCAN es el único algoritmo que asume una distribución no linear de los clusters, mientras que Kmeans, Isolation Forest y Local Outlier Factor asumen una distribución linear de la data. Esto sirve de comparación para lograr identificar si es más correcto un acercamiento linear o no linear a la solución. Estos 4 algoritmos se explicarán brevemente en el anexo 3.

⁶ mrbullwinkle. (18 de 07 de 2023). *Anomaly Detector Documentation*. Obtenido de Microsoft Learn Site: <https://learn.microsoft.com/en-us/azure/ai-services/anomaly-detector/overview>

Se puede resumir esta información en la siguiente tabla:

Candidato de solución:	Características a favor	Problemas relacionados al caso
Uso de herramientas de AI como "Anomaly detector" de Microsoft para encontrar las anomalías	-Eficiente a la hora de cargar los datos -No requiere almacenamiento físico de las mediciones	- Es muy generalista, no es capaz de tomar en cuenta diferencias como la fabricación de cada motor.
Creación de un modelo supervisado para la clasificación de las ondas proveídas	-Clasificación certera de cada uno de los datos si son anómalos o no -Al ser basada en clases es fácilmente comprobable	-La base de datos de ISEE no se encuentra clasificada, por lo que los modelos supervisados son inviables.
Creación de un modelo de un modelo puramente no supervisado para detectar outliers	-Viable con la data disponible, ya que no requiere de datos clasificados de distintos tipos	-Una vez que consigue calcular outliers, no es capaz de clasificarlos bajo distintos tipos.

Solución escogida:

La solución propuesta, teniendo las consideraciones mencionadas anteriormente, sería entonces la aplicación de un modelo de anomaly detection no supervisado en conjunto con un algoritmo de clasificación manual heurístico para clasificar efectivamente cual es el outlier encontrado con el primer método. Esta clasificación manual se lograría implementando un algoritmo que calcule la velocidad natural de un motor de la medición de outlier y compare en base a esta los patrones de outliers.

La estructura completa de esta solución consistiría en un script que descarga constantemente la data de cada día, donde se analizaría constantemente para generar reportes donde existan medidas que se consideren como outliers con respecto al resto. Esta descarga constante de datos se almacenaría para conveniencia de los analistas en un container de Microsoft Azure de 100 GB, lo cual debe considerar ampliarse a futuro de acuerdo con cuanta data resulte guardándose.

El lenguaje de programación del script como tal es Python y se hará uso de librerías de Machine Learning como Tensorflow y Sklearn. El display de los datos se programará haciendo uso de React para hacer un frontend simple donde se pueda ver localmente la data.

Al ser una aplicación de uso para analistas de la empresa, en un principio esta se encontraría instalada en uno de los computadores de la empresa, los cuales se encienden todos los días.

Análisis de riesgos:

Los riesgos encontrados asociados a la implementación del proyecto se destacarán a continuación:

- a) Cambio de sensores de lugar por falta de batería/falla
- b) Bajada de electricidad en la planta corta los sensores
- c) Mal/No uso del software desarrollado
- d) Desarrollo de una adición similar por el lado de ICARE en Bélgica
- e) Expectativas incumplidas:
- f) Atraso en los tiempos de entrega
- g) Cantidad de casos de errores de prueba pocos o nulos

Cabe destacar que las posibles mitigaciones de estos riesgos, así como una tabla de riesgos serán encontrados en el anexo 4.

Evaluación Económica:

La evaluación económica empieza identificando los costos del proyecto, los cuales se ven evidenciados en la siguiente tabla:

Tabla 1: Evaluación Económica

	Costo/hora	Horas Mensuales	Costo total mensual
Pasante	1389	180	250000
Plan de almacenamiento Cloud 100 GB (Azure)			37000
Asesoría técnica del proyecto	8888.0	16	142208
Total costos por mes			\$429,208.00
Resumen costos implementacion software (5 meses)	\$2,146,040.00		

Estos costos se consideran tomando en cuenta el sueldo del practicante, la asesoría de los demás trabajadores de la empresa (tomada como 4 horas a la semana en total) y el precio el cual correspondería la implementación de una base de datos de 100 GB en Microsoft Azure con access tier hot, asumiendo la actualización de la data por día.

Luego, los beneficios del proyecto serian representados por la cantidad de dinero ahorrado por la implementación del proyecto y lo que ese ahorro significa en términos de dinero para un analista. Esto puede calcularse tomando el tiempo estimado el cual se demoraría en promedio un analista en analizar los motores de la instalación y multiplicarlo por el valor de la hora de cada hora del trabajador, asumiendo que el proyecto reduce efectivamente en un 50%,70% y 90% las horas requeridas del análisis:

Tabla 2: Beneficio otorgado segun reducción de tiempo

Hora promedio por motor	4
Sueldo mensual analista	1600000
Sueldo por hora analista	8888.9
Cantidad motores	38
Beneficio total (1 mes, 50%)	\$675,555.56
Beneficio total (5 meses, 50%)	\$3,377,777.78
Beneficio total (1 mes, 70%)	\$945,777.78
Beneficio total (5 meses, 70%)	\$4,728,888.89
Beneficio total (1 mes, 90%)	\$1,216,000.00
Beneficio total (5 meses, 90%)	\$6,080,000.00

Plan de implementación:

El tiempo para hacer la práctica es de 20 semanas, se inició el 31 de julio y tiene como objetivo finalizarse durante la semana del 11 de diciembre, con una presentación del proyecto a la misma empresa. Antes de esto, debe estar estipulado en el avance que la presentación e informe final de la pasantía se realizará durante las últimas semanas de noviembre, fecha por definir.

Por lo tanto, se reconocen 5 hitos importantes durante el avance de la pasantía:

- a) Definición del alcance del problema (30 de agosto)
- b) Obtención data limpia (29 de septiembre)
- c) Modelo de ML a usar definido (23 de octubre)
- d) Validación del modelo (9 de noviembre)
- e) Display de datos funcional listo para presentarse (20 de noviembre)
- f) Fin de la pasantía (15 de diciembre)

Los recursos utilizados para la realización del proyecto corresponden a la información presente en la base de datos de I-Care

Se definen las siguientes actividades las cuales se realizarán durante el semestre para lograr la llevada a cabo del proyecto. En este índice también se describirá el trabajo que se ha hecho para la empresa, ya que este tiene directo impacto con la disponibilidad de material para entrenar el modelo.

1) Estudio de la materia fundamental correspondiente a los datos:

Esto se realizó desde el inicio de la práctica durante el primer mes de pasantía en paralelo al resto de las actividades realizadas. El objetivo de este estudio fue tanto aclimatarse a la empresa como al problema en mano, aprendiendo la parte teórica del problema lo más posible. En este ámbito la empresa proporcionó amplio material para aprender sobre el funcionamiento de los sensores, así como la parte teórica del problema de tipos de errores que pueden existir en un motor como tal. Por lo tanto, además de investigar sobre posibles soluciones al problema, se estudió sobre el significado de la data de vibraciones con el objetivo de lograr entender la data que se estaba implementando

2) Instalación correcta de los sensores en la base de datos I-CARE de la empresa:

Esta tarea consistió en la configuración los sensores tanto antiguos como nuevos del proyecto en CNGC en Laja.

La configuración consistió en un principio en acceder a la base de datos del proveedor de los sensores Isee, encontrar los sensores antiguos que fueron asignados para el proyecto y luego reubicarlos a sus carpetas correspondientes. Luego, a cada uno de estos sensores se les crearon nuevos measurement points, los cuales están ligados a cada canal que poseen y poseen la medición

de cada coordenada en un canal. Measurement points corresponden a puntos en la base de datos donde se almacenan las medidas de cada uno de los sensores en un canal en particular. El sensor genera distintas mediciones de acuerdo con los modos de medición que se selecciona para cada canal mediante las tareas, por lo que es necesario crearlas con los tipos de medición e intervalos correctos.

3) Acceso a la API y descarga de datos:

La tarea en sí describe el tiempo requerido en el acceso a la api y recuperación de datos. Esta comprende tanto el acceso a la API, la descarga de estos mismos datos y la ideación de una manera de almacenarlos la cual sea eficiente y correcta para su posterior uso en el entrenamiento. Esto último incluye lograr la equivalencia entre los datos de los sensores de antigua generación con los de nueva generación.

4) Limpieza de datos:

Corresponde a la limpieza de los datos descargados de los sensores para evitar outliers que empeoren el aprendizaje del modelo. Esto también incluye la eliminación de datos nulos y mediciones que no tengan sentido para el entrenamiento del modelo.

5) Búsqueda y definición del modelo:

Esta tarea consiste en la búsqueda y definición del modelo basado en las variables que obtenemos en el proyecto. En este punto también se considerará la búsqueda de una manera para encontrar las variables del modelo, entre las cuales se encuentra la velocidad natural del modelo en sí.

6) Entrenamiento y refinamiento del Modelo:

Esta tarea comprende todo lo que se refiere con el entrenamiento del modelo y técnicas de refinamiento de este, como la modificación de hiperparámetros.

7) Validación del modelo:

En esta tarea se identifica la prueba del modelo con la data y su capacidad efectiva de poder predecir correctamente la presencia de patrones anómalos en los datos. En esta tarea también se evalúa el modelo de acuerdo con las métricas definidas para los objetivos 1 y 2, ya que estas métricas tienen que ver exclusivamente con calidad del modelo.

8) Creación display y deployment del modelo:

Por último, la etapa final consiste en la creación tanto del display del proyecto con todas sus características funcionales externas al análisis del proyecto. Esto incluye, su instalación en un computador local en la empresa, un frontend simple donde el analista revisa los análisis entregados

por el software y la creación de una base de datos en la nube de la dependencia de Microsoft Azure con el almacenamiento necesario para llevar el proyecto (al menos 20 GB).

El plan de implementación se describe en el siguiente en parte en el siguiente diagrama, donde se detallan los distintos hitos importantes del proyecto:

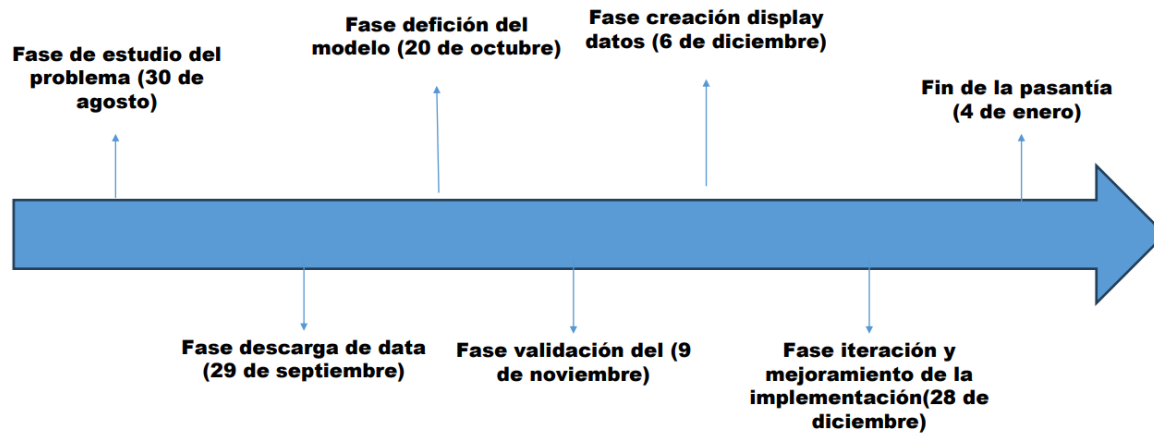


Ilustración 1: Plan del proyecto a través del tiempo

Medidas de desempeño:

La primera medida de desempeño se referirá a la evaluación del objetivo de mejorar la precisión del modelo. Para esto, se usará una métrica que consistirá en comparar las predicciones del modelo correctas respecto a las predicciones totales, método que se utiliza para predecir la capacidad del modelo de lograr predecir correctamente las anomalías de un dataset. Sin embargo, cabe destacar que este método no es sin sus fallas, ya que existen problemas a la hora de que detectar efectivamente el desbalance del modelo (en otras palabras, si encontramos si los errores más prevalentes que poseemos son falsos positivos o verdaderos negativos). Sin embargo, para efectos del problema no es importante identificar la minoría de datos mal previstos ya que un caso de falso positivo sería solucionado revisando las lecturas anteriores del sensor y, al ser predictivo, no posee una inmediatez de solución.

La fórmula del accuracy del modelo correspondería a la siguiente:

$$ACC = \frac{\text{Número de predicciones correctas}}{\text{Número total de predicciones}}$$

La segunda medida de desempeño correspondió a la cantidad de horas hombre reducidas será medida con respecto a la cantidad mensual que el trabajador gasta a la hora de hacer el análisis predictivo de vibraciones. Como anteriormente fue definido, esta cantidad de horas se define en alrededor de 160 mensuales cuando se realiza mantenimiento predictivo de motores tanto no críticos como críticos. Luego, la cantidad de horas hombre restadas equivaldrían a:

$$\text{Horas hombre reducidas} = HH_i - HH_f$$

HH_i corresponde a la cantidad de horas hombre antes de la implementación y HH_f corresponde a la cantidad de horas hombre ocupadas luego de la implementación.

La última medida de desempeño corresponde a la cantidad de motores los cuales se les encontró efectivamente su velocidad correcta del funcionamiento. Esta medida en principio depende completamente de la data a la cual se tenga acceso en el momento sobre las velocidades efectivas de los motores a disposición, por lo que se encuentra severamente limitada a la información real de los motores.

Este KPI sería de carácter cuantitativo y correspondería a la siguiente formula:

$$\text{velocidades comprobadas} = \frac{\text{motores predecidos correctamente}}{\text{motores con data de velocidad disponible}}$$

Desarrollo de la implementación:

En un principio se consideró descargar la data de todos los sensores de cada uno de los motores, pero luego se concluyó que reducir la cantidad de motores sería preferible para poder probar con las predicciones de los modelos con mayor exactitud. Se probaron distintos alcances para la obtención de la solución de acuerdo con lo definido en el estado del arte. Al ser este un problema de algoritmos no supervisados, se probó la data de 2 assets en particular los cuales poseían fallas similares (específicamente los assets 48-23-096 y 19-23-097, los cuales se pueden apreciar en el Anexo 5), además de poseer una composición similar (una bomba unida a un motor, sin reductores ni más componentes de por medio) y, más relevante aun, datos de errores recientes. Estos datos de errores recientes se encuentran en forma de informes escritos por analistas los cuales describieron

errores de tipo Desbalanceo en las medidas de la primera quincena de agosto de ambos sensores. En el Anexo 6 se pueden apreciar los distintos tipos de Desbalanceo y sus técnicas para detectarse.

Al reducir las variables de trabajo, se comenzaron a probar modelos los cuales pudieran encontrar correctamente los pocos casos de fallo disponibles. También en esta etapa se empezó primero trabajando con la onda de cada una de las mediciones antes de un rango de los 3000 [cpm]. Esto debido a lo mencionado en la introducción del problema donde se señala que el componente principal de ciertos tipos de fallas visibles con el análisis predictivo es la velocidad natural del motor. Esta fue encontrada mediante el algoritmo el cual comparaba el peak más consistente a través de las medidas de los motores mencionados anteriormente desde el 1 de enero de 2022 hasta la fecha actual.

Cabe destacar que cuando se habla de Machine Learning en análisis predictivo, todos los alcances investigados hacen una etapa de preprocesamiento previa de una manera u otra, donde se separan las features de cada onda y son estas la que se alimentan a los algoritmos como tal. Esto se llegó como conclusión luego de probar en un primer lugar insertando la onda completa de cada uno de los puntos de medida de un sensor en un algoritmo no supervisado. Durante este proceso se probó ampliamente la implementación del modelo de manera que se la transformada de Fourier en su totalidad se ingresaba a los modelos para que rápidamente este encontrara las discrepancias en las muestras de las ondas. Sin embargo, esto resultó siendo un acercamiento incorrecto debido a dos grandes razones.

La primera es el hecho de que muy pocos modelos son capaces de obtener resultados notables de utilizando toda la onda como variable. Al tomarse cada punto de vibración como una feature en sí, el modelo toma demasiadas dimensiones por lo que cualquier diferencia encontrada entre las mediciones en sí tendría que ser ampliamente notable para ser considerada como outlier.

La segunda es que, al resumir la transformada de Fourier en sus componentes básicos se aumentaría la performance del modelo a nivel de procesamiento ya que el modelo no se basaría en tantas features.

Por lo tanto, se eligieron las siguientes features para extraer en cada una de las transformadas de Fourier considerando las siguientes variables:

S = Banda de poder asociada a la frecuencia

n = cantidad de frecuencias de la onda

f = frecuencia en particular

-Media de banda de velocidades

$$S_{\mu} = \frac{1}{n} \sum_{i=1}^n S(f)_i$$

-Máximo de banda de velocidades

$$S_{MAX} = \max (S(f)_i)$$

-Suma total de transformada

$$S_{SBP} = \sum_{i=1}^n S(f)_i$$

-Varianza

$$S_V = \frac{\sum_{i=1}^n (S(f)_i - S_{\mu})^2}{n - 1}$$

-Desviación estándar

$$\sigma = \sqrt{\frac{\sum_{i=1}^n (S(f) - S_{\mu})^2}{n}}$$

-Descentralización (skewness)

$$S_s = \frac{1}{n} \frac{\sum_{i=1}^n (S(f)_i - S_{\mu})^3}{S_V^{3/2}}$$

-Kurtosis

$$S_K = \frac{1}{n} \frac{\sum_{i=1}^n (S(f)_i - S_{\mu})^4}{S_V^{4/2}}$$

Estas features fueron decididas basados en las características importantes que distinguen una onda de otra.

Otro aspecto para considerar es que las features consideradas en este caso fueron solamente las de la transformada de Fourier y no la onda per se ya que es esta la que los analistas usan para evaluar la posibilidad de distintas fallas. Si bien sería un análisis más completo si se consideraran las features de la onda como tal, esto no es necesario ya que la medición de las ondas no posee variación en el tiempo, por lo que no considerar las features en este eje pueden ser ignoradas.

Los modelos no supervisados que fueron probados para encontrar los distintos outliers fueron los siguientes: Isolation Forest, Local Outlier Factor, DBSCAN y K nearest neighbors.

De estos modelos, DBSCAN fue inmediatamente descartado ya que este no poseía un buen comportamiento con las features, ya que estas poseían densidades diversas entre sí lo que resultó en predicciones las cuales no se acercaban de ninguna manera a los datos de prueba. De las selecciones restantes, se prosiguió a encontrar los outliers con el algoritmo restante.

Este algoritmo consiste en encontrar la velocidad en metros por segundo correspondiente a la velocidad natural del motor en Hertz. Esto se hace midiendo si:

- A) Existe un peak de velocidad en la frecuencia natural de funcionamiento notable (mayor a 2.8 [m/s]^7)
- B) En el caso Desbalanceo de rotor voladizo, comprobar la existencia de este peak en los otros ejes.

Resultados:

En esta sección quedarán expuestos los resultados que se obtuvieron a la hora de aplicar los algoritmos para la detección de errores en la data de los sensores evidenciados, con el objetivo de encontrar dos casos de patrones irregulares de desbalanceo en particular que se detectaron como errores (específicamente, dos casos de desbalanceo en los sensores 19-23-097 y 048-23-096).

⁷ Esto de acuerdo a la norma ISO 18016 que describe los valores de funcionamiento correcto de maquinaria industrial, Anexo 8

Con respecto a las medidas de desempeño del proyecto, se pudieron comprobar las 3 medidas de trabajo desempeño que van al caso.

En primer lugar, se pudo encontrar efectivamente más del 90% de las velocidades naturales (1x) de cada uno de los motores de acuerdo con los datos proporcionados, como se puede apreciar en las siguientes dos imágenes:

CE	DESCRIPCION	MOTOR
006-23-1603/01	BOMBA MC ALIMENTACION A TAC	SIEMENS
		1242 RPM
09-010	BOMBA MC DE ALIMENTACION ETAPA O2	MEA-884-001
	POTENCIA	400 KW
	RPM	1488 RPM
	MARCA	SIEMENS
	MODELO	1LA8357-4PB90-Z
	RODAMIENTO L/A	6322 C3
	RODAMIENTO L/V	6220 C3
FV184		
21-125	BOMBA PASTA MEDIA CONSISTENCIA N°2	MEA-026-003
	POTENCIA	220 Kw
	RPM	1490 rpm
	MARCA	US ELECTRICAL
	MODELO	
	RODAMIENTO L/A	6313
	RODAMIENTO L/V	6313
21-130	BOMBA PASTA MEDIA CONSISTENCIA N°3	
	POTENCIA	
	RPM	1613 RPM
	MARCA	
	MODELO	
	RODAMIENTO L/A	6316
	RODAMIENTO L/V	6313

Ilustración 2: Datos de los motores proporcionados

	maximo_velocidad	maximo_frecuencia	codigo_asset
28	0.295181	1200.0	006-23-1603/01 MC
	maximo_velocidad	maximo_frecuencia	codigo_asset
29	0.098886	1687.5	09-010 Bba
	maximo_velocidad	maximo_frecuencia	codigo_asset
31	0.148279	1875.0	21-125 Bba MC2
	maximo_velocidad	maximo_frecuencia	codigo_asset
20	1.193731	1612.5	21-130 Bba MC3

Ilustración 3: Velocidad de funcionamiento calculada

Como se puede apreciar, la velocidad en RPM de los 4 motores proporcionados para la creación de esta parte del algoritmo fue destacados en el sistema con una precisión dentro de los 300 rpm.

En relación con la medida correspondiente con la predicción de las fallas, podemos concluir que esta se cumplió al 100% considerando los datos de fallas analizados correspondientes con las fallas disponibles. El algoritmo de Isolation Forest fue el único de los algoritmos posibles a probar el cual detectó las lecturas correspondientes a en los dos períodos considerados sin considerar el modelo algorítmico en primer lugar. En el anexo 7 se pueden observar las medidas que fueron consideradas

como outliers y clasificadas como desalineamientos. En el asset 019-23-097 se clasificaron las medidas como Desbalanceo sin tipo, mientras que las medidas del asset 048-23-096 se clasificaron como Desbalanceo de rotor voladizo debido a la presencia de outliers en ejes radial como axial.

Por último, las horas hombre se lograron reducir en un 90%, debido a que, gracias a la implementación del proyecto, los datos de identificados como datos relevantes de fallos se pueden acceder en 5 minutos, en relación con el estimado que se manejaba al principio del proyecto de un mínimo de 1 hora, considerando el mejor de los casos.

Conclusiones:

Al analizar los datos obtenidos, se puede encontrar que el método elegido fue exitoso al encontrar los datos atípicos. Sin embargo, se debe destacar que el debido a la poca cantidad de datos de prueba, no se pudo probar el sistema de clasificación en su totalidad. Si bien el conjunto de modelos y algoritmos pudo detectar con precisión ambos casos y clasificarlos correctamente como casos de desbalanceo, la poca presencia de datos no hizo posible el probar la clasificación de otros tipos de data (particularmente los algoritmos de clasificación de tipos de desalineación).

Es necesario agregar que, el alcance logrado desde un principio tiene problemas para ser comprobable. La poca cantidad de datos de problemas efectivos hace que cualquier comprobación del modelo tenga que tomarse con suma precaución ya que solamente 2 casos de errores en motores distintos no se puede considerar como significativo y a la hora de ampliarse este proyecto a otros motores, se debe tener en consideración lo anterior para comprobar absolutamente todos los pasos que se pueda para verificar si efectivamente la solución propuesta es iterable en los diversos tipos de motores que existen no solamente en la planta de CMPC, sino en cualquier caso en el futuro.

Corresponde para dar por terminados este proyecto la correcta implementación de la visualización de datos para poder lograr que los técnicos de la empresa puedan utilizar y lograr comprobar la utilidad del modelo.

Anexos:

Anexo 1:

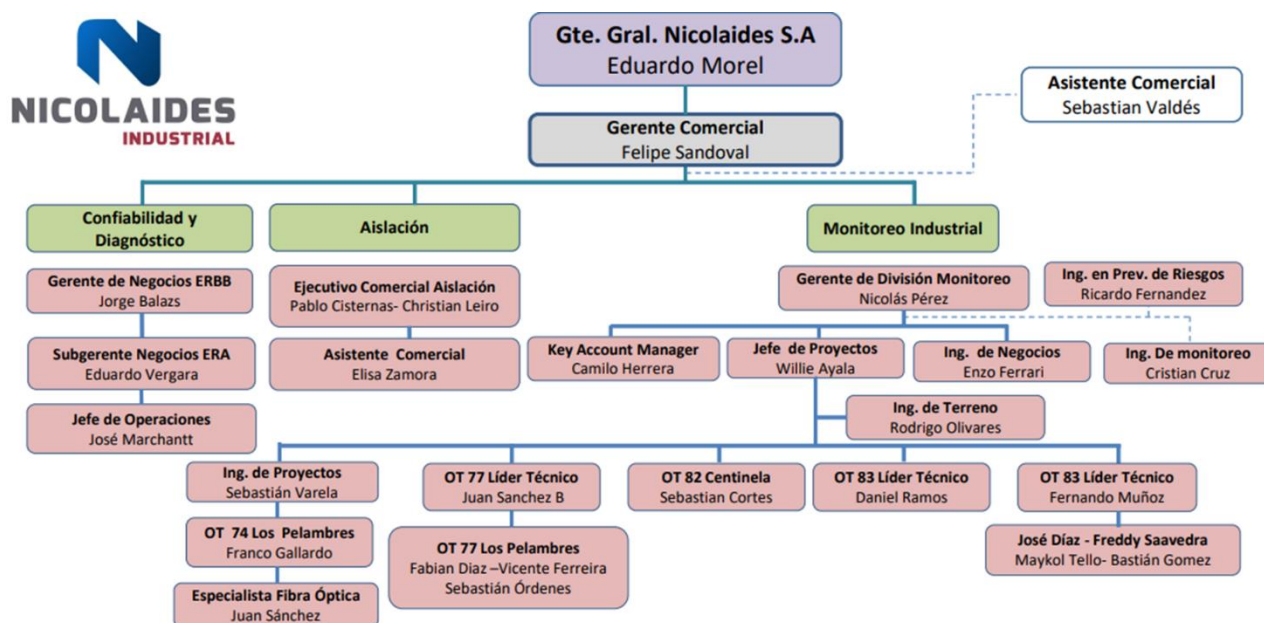


Ilustración 4: Organigrama de Nicolaides Industrial

Anexo 2:




Ilustración 5: Representación de ISEE Transformada Fourier

Anexo 3:

DBSCAN: Es un algoritmo de clustering que identifica grupos basados en la densidad de puntos en un conjunto de datos, categorizando puntos como centrales, fronterizos o de ruido según su densidad local y parámetros como ϵ y MinPoints. Utiliza la densidad para formar clústeres de formas y tamaños variados, resistente al ruido, clasificando puntos como centrales con suficientes vecinos, fronterizos dentro del alcance ϵ pero sin la densidad requerida, y ruido como puntos aislados que no cumplen los criterios de densidad.

Isolation Forest: Es una técnica de detección de anomalías que identifica puntos atípicos en un conjunto de datos mediante la construcción de árboles de decisión aleatorios. Evalúa la rareza de las observaciones al separarlas en ramas cortas, considerando que las anomalías requieren menos divisiones para ser aisladas que las observaciones normales. Proporciona puntuaciones de anomalía basadas en la cantidad de divisiones necesarias para aislar cada muestra, identificando como más anómalas aquellas que requieren menos divisiones. Es eficiente para detectar observaciones atípicas en grandes conjuntos de datos debido a su enfoque en la capacidad de aislar anomalías con árboles aleatorios.

K-means: Es un algoritmo de clustering que agrupa datos en k grupos basados en la similitud de características. Funciona iterativamente asignando puntos a clústeres cercanos mediante la minimización de la distancia entre ellos y los centros de los clústeres. Calcula centroides para cada grupo y reasigna puntos hasta que la variación dentro de los grupos sea mínima, formando clústeres según la cercanía a estos centroides. Es efectivo para separar datos en grupos homogéneos, pero requiere especificar previamente el número de clústeres (k).

Anexo 4:

a) Cambio de sensores de lugar por falta de batería/falla

Mitigación: El código tomará en cuenta el cambio de sensores siempre y cuando no se eliminen los puntos de medida de cada uno de los assets y se reasignen a los sensores que entran.

b) Bajada de electricidad en la planta corta los sensores

Mitigación: Notificar al equipo que es de suma importancia poder reiniciar los sensores apenas muestren signos de no estar funcionando luego de un cierto periodo de tiempo (máximo 2 días)

c) Mal/No uso del software desarrollado

Mitigación: Iterar constantemente en la manera de visualizar los datos por el lado del frontend para asegurar que la información entregada sea útil para el analista

d) Desarrollo de una adición similar por el lado de ICARE en Bélgica

Mitigación: Continua comunicación con el equipo de Bélgica para estar al tanto de avances de su lado.

e) Expectativas incumplidas:

Mitigación: Revisar que el proyecto vaya siempre en buena dirección y ser capaz prontamente de reconocer cuando el camino hacia una solución tomado no sea el correcto.

f) Atraso en los tiempos de entrega

Mitigación: Estar siempre pendiente en el avance del plazo del proyecto y generar una carta Gantt para tener al tanto lo que se debiera llevar en cada fecha.

g) Cantidad de casos de errores de prueba pocos o nulos

Mitigación: Al estar en común contacto con los técnicos, se le puede hacer consultas constantemente a los analistas de la empresa con respecto a los casos que el algoritmo detecta y corroborar la precisión encontrada.

Tabla 3: Riesgos del proyecto clasificados según probabilidad y riesgo

	Riesgo		
Probabilidad	Bajo	Medio	Alto
Baja		2 6 5	
Media	1 3	4	
Alta		7	

Anexo 5:




Ilustración 6: Asset 048-23-096



Ilustración 7: Asset 019-23-097

Anexo 6:

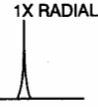
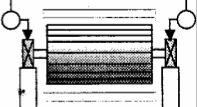
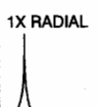
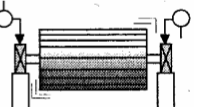
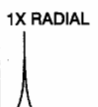
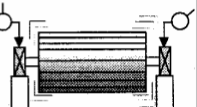
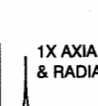
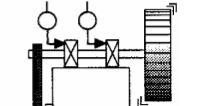
FUENTE DEL PROBLEMA	ESPECTRO TÍPICO	RELACIÓN DE FASE	OBSERVACIONES
Desbalanceo A. Desbalanceo Estático			El Desbalanceo Estático estará en fase y estable. La amplitud debido al desbalance aumentará por el cuadrado de la velocidad incrementada estando por debajo de la primera crítica del rotor (un incremento de velocidad de 3X = una vibración a 9X mayor). 1XRPM siempre estará presente y por lo general domina el espectro. Puede ser corregido colocando un solo peso de corrección de balance en un plano en el Centro de Gravedad del Rotor (CG). Una diferencia de fase aproximadamente de 0° debe existir entre los Horizontales OB&IB, así como entre las Verticales OB&IB. Usualmente también ocurre una diferencia de fase aproximadamente de 90° entre las lecturas de fase Horizontal y Vertical en cada rodamiento del rotor desbalanceado ($\pm 30^\circ$).
B. Desbalanceo de Par de Fuerzas			Un Desbalanceo de Par de Fuerzas resulta en un desfase de 180° del movimiento en el mismo eje. 1XRPM siempre está presente y normalmente domina el espectro. La amplitud varía por el cuadrado de la velocidad incrementada por debajo de la primera velocidad crítica del rotor. Puede causar una alta vibración axial así como radial. La corrección requiere la colocación de los pesos de balance en al menos 2 planos. Note que debe existir una diferencia aproximada de 180° entre las Horizontales OB&IB así como entre las Verticales OB&IB. También usualmente ocurre una diferencia aproximada de 90° entre las lecturas Horizontal y vertical en cada rodamiento ($\pm 30^\circ$).
C. Desbalanceo Dinámico			El Desbalanceo Dinámico es el tipo de desbalanceo que se consigue más comúnmente y es una combinación de Desbalanceo estático y de par de fuerzas. 1XRPM domina el espectro y realmente necesita una corrección en 2 planos. Aquí la diferencia de fase Radial entre los rodamientos externos e internos puede estar en cualquier lugar del rango entre 0° y 180°. Sin embargo, la diferencia de fase Horizontal debe cuadrar usualmente con la diferencia de fase Vertical, cuando se comparan las mediciones de los rodamientos externos e internos ($\pm 30^\circ$). Si el desbalance predomina una diferencia de fase de 90° resulta entre las lecturas Horizontal y Vertical de cada rodamiento ($\pm 40^\circ$).
D. Desbalanceo de Rotor en Voladizo			El Desbalanceo de Rotor en Voladizo causa un alto 1XRPM en las direcciones Axial y Radial. Las lecturas Axiales tienden a estar en fase mientras que las lecturas de fase Radial pueden estar inestables. Sin embargo, las diferencias de fase Horizontal usualmente cuadrarán con las diferencias de fase Vertical en el rotor desbalanceado ($\pm 30^\circ$). Los Rotores en Voladizo tienen desbalances Estáticos y de Par de Fuerzas, cada uno de los cuales requiere una corrección. Así, los pesos de corrección casi siempre tendrán que ser colocados en dos planos para contrarrestar ambos desbalances, el estático y el de par de fuerzas.

Ilustración 8: Tipos de Desbalanceo existentes

Anexo 7:

			fecha	sensor	eje	codigo_asset
0	2023-08-05	10:20:36	7936	Vertical	019-23-097	Extractor de Gases DNCG
3	2023-08-05	14:19:03	7936	Vertical	019-23-097	Extractor de Gases DNCG
6	2023-08-06	10:26:24	7936	Vertical	019-23-097	Extractor de Gases DNCG
8	2023-08-06	14:24:53	7936	Vertical	019-23-097	Extractor de Gases DNCG
11	2023-08-07	10:32:17	7936	Vertical	019-23-097	Extractor de Gases DNCG
14	2023-08-08	10:23:16	7936	Vertical	019-23-097	Extractor de Gases DNCG
17	2023-08-08	14:21:42	7936	Vertical	019-23-097	Extractor de Gases DNCG
19	2023-08-09	10:29:06	7936	Vertical	019-23-097	Extractor de Gases DNCG
22	2023-08-09	14:27:35	7936	Vertical	019-23-097	Extractor de Gases DNCG
33	2023-08-11	14:24:30	7936	Vertical	019-23-097	Extractor de Gases DNCG
			fecha	sensor	eje	codigo_asset
1	2023-08-05	10:26:27	7895	Vertical	048-23-096	Ventilador
2	2023-08-05	12:51:05	7952	Vertical	048-23-096	Ventilador
4	2023-08-05	14:24:13	7895	Vertical	048-23-096	Ventilador
5	2023-08-05	16:47:54	7952	Vertical	048-23-096	Ventilador
7	2023-08-06	10:27:53	7895	Vertical	048-23-096	Ventilador
9	2023-08-06	14:25:39	7895	Vertical	048-23-096	Ventilador
10	2023-08-07	10:29:22	7895	Vertical	048-23-096	Ventilador
12	2023-08-07	14:27:10	7895	Vertical	048-23-096	Ventilador
13	2023-08-07	16:53:33	7952	Vertical	048-23-096	Ventilador
15	2023-08-08	10:30:53	7895	Vertical	048-23-096	Ventilador
16	2023-08-08	12:52:08	7952	Vertical	048-23-096	Ventilador
18	2023-08-08	16:48:56	7952	Vertical	048-23-096	Ventilador
20	2023-08-09	12:47:32	7952	Vertical	048-23-096	Ventilador
21	2023-08-09	14:00:26	7895	Horizontal	048-23-096	Ventilador
23	2023-08-09	16:29:31	7952	Horizontal	048-23-096	Ventilador
24	2023-08-09	16:54:41	7947	Vertical	048-23-096	Ventilador
25	2023-08-10	09:57:52	7905	Vertical	048-23-096	Ventilador
26	2023-08-10	10:04:04	7895	Horizontal	048-23-096	Ventilador
27	2023-08-10	12:28:11	7952	Horizontal	048-23-096	Ventilador
28	2023-08-10	14:01:49	7895	Horizontal	048-23-096	Ventilador
29	2023-08-10	14:08:45	7905	Vertical	048-23-096	Ventilador
30	2023-08-10	16:24:58	7952	Horizontal	048-23-096	Ventilador
31	2023-08-10	16:56:37	7947	Vertical	048-23-096	Ventilador
32	2023-08-10	17:11:29	7947	Axial	048-23-096	Ventilador
34	2023-08-11	15:47:12	7895	Axial	048-23-096	Ventilador
35	2023-08-11	17:46:05	7895	Axial	048-23-096	Ventilador
36	2023-08-12	09:51:58	7895	Axial	048-23-096	Ventilador
37	2023-08-12	11:50:51	7895	Axial	048-23-096	Ventilador
38	2023-08-12	13:49:44	7895	Axial	048-23-096	Ventilador
39	2023-08-12	14:47:14	7952	Vertical	048-23-096	Ventilador
40	2023-08-12	15:48:37	7895	Axial	048-23-096	Ventilador
41	2023-08-12	16:45:38	7952	Vertical	048-23-096	Ventilador
42	2023-08-12	17:47:30	7895	Axial	048-23-096	Ventilador
43	2023-08-13	10:45:53	7952	Vertical	048-23-096	Ventilador

Ilustración 9: Medidas identificadas como outliers, agrupadas según asset

Anexo 8:

Tabla 4: Norma ISO 10816 estandar de vibración

Velocidad 10 - 1000 Hz r > 600 rpm	Velocidad 2 - 1000 Hz r > 120 rpm	in/s rms	mm/s rms								
		0,43	11								
		0,28	7,1								
		0,18	4,5								
		0,14	3,5								
		0,11	2,8								
		0,09	2,3								
		0,06	1,4								
		0,03	0,71								
BASE				Rígida	Flexible	Rígida	Flexible	Rígida	Flexible	Rígida	Flexible
Tipo de máquina				Bombas > 15 KW Flujo radial, axial o mixto				Tamaño medio 15 KW < P ≤ 300 KW Motores 160 mm ≤ H < 315 mm		Máquinas grandes 300 KW < P ≤ 50 MW Motores 315 mm ≤ H	
				Motor integrado		Motor separado		Grupo 2		Grupo 1	
Grupo				Grupo 4		Grupo 3					

A

Máquina nueva o reacondicionada

C

La máquina no puede operar un tiempo prolongado

B

La máquina puede operar indefinidamente

D

La vibración está provocando daños

Trabajos citados

- Luis Saez, N. P. (2018). Wireless Remote Vibration and Temperature Condition Monitoring: Application at CMPC Pulp Plant. *6th International Congress on Automation in Mining*, Chapter 6.
- mrBullwinkle. (18 de 07 de 2023). *Anomaly Detector Documentation*. Obtenido de Microsoft Learn Site: <https://learn.microsoft.com/en-us/azure/ai-services/anomaly-detector/overview>
- Omar AlShorman, M. I. (2020). A Review of Artificial Intelligence Methods for Condition Monitoring and Fault Diagnosis of Rolling Element Bearings for Induction Motor. *Shock and Vibration*, 20.