



UNIVERSIDAD ADOLFO IBÁÑEZ
FACULTAD DE INGENIERÍA Y CIENCIAS

“Diseño modelo de selección de surtido para zona oscura en
tiendas híbridas”

Lukas Uslar Larrea
Ingeniería Civil Industrial

Contenido

Introducción.....	5
Contexto de la empresa	5
Problemática.....	8
Objetivos	12
Estado del arte.....	13
Solución.....	15
Alternativas de solución.....	15
Solución escogida.....	16
Metodología.....	17
Riesgos y plan de mitigación	18
Medidas de desempeño.....	19
Desarrollo e implementación de la solución	20
Resultados.....	28
Conclusiones	31
Bibliografía.....	32
Anexos.....	33

Resumen Ejecutivo

El área de Omnichannel Replenishment está constantemente intentando garantizar una disponibilidad permanente para los clientes omnicanal. Con un aumento sostenido en el comercio ecommerce en Chile y el mundo, Walmart al igual que muchas empresas de retail adoptó el concepto de tiendas híbridas con zonas oscuras, la cual es un sector cerrado al público, con el fin de facilitar la preparación de los pedidos ecommerce.

La problemática abordada es la cantidad de ítems con quiebre dentro de la zona oscura, lo cual tiene una serie de causas al igual que consecuencias para la tienda.

El objetivo propuesto es poder reducir la cantidad de ítems con quiebre en el sector de la zona oscura en un 50%, en un plazo de 4 meses.

La solución escogida para poder resolver la problemática fue la modificación del modelo para la elección del surtido actual, con la finalidad de encontrar un surtido con un espacio disponible que no genere quiebres en góndola. Para esto, se tomaron en cuenta tanto filtros para eliminar los ítems que no calificarán para la ZO, como ciertas variables a las cuales les fueron asignados un ponderador escalado para poder generar un ranking entre los ítems calificados.

Como resultado se obtuvo una disminución del surtido de 2448 a 2050 ítems, con el nuevo surtido se logró una reducción en los quiebres en góndola dentro de la zona oscura en un 50%, además de un aumento en el porcentaje promedio de las ordenes de compra completadas por los ítems del surtido, en comparación al surtido original ajustado a nuevas reglas de Walmart desde un 42,46% a un 46,61%.

En conclusión, a pesar de que el objetivo de un nivel de servicio en la ZO de 96% no se cumple, hay que considerar que hubo una reducción del surtido para cumplir con las dos cajas, con un menor porcentaje de las ventas y un mayor porcentaje de completitud de las órdenes de compra, queda en manos de la empresa decidir a que darle prioridad. Se recomienda darle valor al porcentaje de la orden de compra completada ya que esto afecta positivamente en la eficiencia de recolección de los ítems por parte de los shopper.

Abstract

The Omnichannel Replenishment area is constantly striving to ensure a consistent availability for omnichannel customers. With a constant increase in e-commerce trade in Chile and around the world, Walmart, like many other retail companies, has adopted the concept of hybrid stores with dark zones. The dark zone concept is a closed-off area to the public, and it originated with the aim of facilitating the preparation of e-commerce orders.

The issue addressed is the quantity of out-of-stock items within the dark zone, which has a variety of causes and consequences for the store. The proposed objective is to reduce the number of out-of-stock items in the dark zone sector by 50% within a timeframe of 4 months.

The chosen solution to address the issue was the modification of the current assortment selection model. The goal was to find an assortment with available space that would not lead to out-of-stock items on the shelves. In this process, filters were applied to eliminate items that did not qualify for the dark zone (ZO), and certain variables were considered, each assigned a scaled weight to generate a ranking among the qualified items.

The result was a reduction in the assortment, decreasing from 2,448 to 2,050 items. With this new assortment, a 50% reduction in out-of-stock incidents was achieved in the shelves within the dark zone. Additionally, there was an increase in the average percentage of purchase orders completed by assortment items, compared to the original assortment adjusted to Walmart's new rules, rising from 42.46% to 46.61%.

In conclusion, despite not meeting the 96% service level goal in the Dark Zone, it is important to consider that there was an assortment reduction to accommodate the two boxes, resulting in a lower percentage of sales but a higher percentage of order completion. It is now up to the company to decide which aspect to prioritize. It is recommended to give value to the percentage of completed purchase orders, as this positively impacts the efficiency of item collection by shoppers.

Introducción

Contexto empresa

Walmart Chile es una filial de la empresa estadounidense de retail minorista más grande del mundo, Wal-Mart Stores Inc., creada en 1969 por Sam Walton en Bentonville, Arkansas, Estados Unidos.

Por su parte, Walmart Chile es uno de los principales actores en la industria de la venta al por menor del país. Su actividad principal consiste en la venta de alimentos, mercadería y productos no comestibles como electrodomésticos, vestuario, artículos para el hogar, entre otros. Esta actividad la lleva a cabo a través de sus más de 370 locales de los formatos Líder, Express de Líder, Líder.cl, SuperBodega a Cuenta y Central Mayorista, distribuidos a lo largo de todo el territorio nacional desde Arica hasta Punta Arenas.


La empresa concentra constantemente sus esfuerzos para poder cumplir con su misión, la cual es "Ahorrarles dinero a nuestros clientes, para que puedan vivir mejor" (Walmart Chile, s.f.).

Una parte esencial del funcionamiento de Walmart es el abastecimiento, por lo que cuenta con 6 Centros de Distribución. La mitad de estos se encuentra en la Región Metropolitana, ubicándose en Quilicura, Lo Aguirre y El Peñón, mientras que los tres restantes se encuentran en Antofagasta, Chillán y Temuco. El Centro de Distribución El Peñón ha sido una de las mayores inversiones internacionales de Wal-Mart Stores, con un valor de más de 180 millones de dólares, siendo uno de los centros más modernos de Latinoamérica (Mares, 2019).

Walmart Chile cuenta actualmente con 3 tiendas híbridas (TH) en funcionamiento y 2 prontas a su apertura, éstas tienen la particularidad de contar no sólo con una bodega y un piso de venta como el que todos conocemos, sino también con un área restringida al público llamada zona oscura.

Con un crecimiento constante en el comercio ecommerce en Chile, más del 230% en los últimos años, como se puede ver en el siguiente gráfico (Figura 1):

Global Retail eCommerce Sales (2014-2023)

*Figura 1: Ventas globales de retail en billones de dólares desde el año 2014 al 2023*

La zona oscura nace con la finalidad de conseguir los siguientes beneficios: al estar separada del piso de venta permite que los shopper puedan preparar los pedidos de comercio electrónico sin interferencia de clientes que realizan compras en la tienda física, mejorando así la eficiencia en la preparación de pedidos.

Esto también ocurre en el otro sentido, mantener a los shopper alejados del área de la tienda física puede mejorar la experiencia general de compras para los clientes tradicionales y reducir así congestiones en pasillos.

Antes de continuar, hay que tener en mente que durante el desarrollo de este informe los datos que se mostraran, se han modificado a manera de mantener información confidencial para la empresa. La información mostrada a pesar de no ser real servirá para representar cómo se desarrolló el proyecto.

Para esta zona oscura, al ser un área reducida en comparación con la sala de ventas, se selecciona una fracción del surtido de la sala para que esté disponible en esta área. En la actualidad, para una de las tiendas híbridas, específicamente el local 97, el surtido de la tienda llega a los 14.571 ítems, la selección de ítems para la zona oscura de este local es de 2.448, los cuales son elegidos mediante un modelo que tiene en consideración una serie de factores que veremos más adelante.

Los factores que se consideran actualmente para hacer un ranking de ítems a elegir son: cantidad de unidades vendidas del ítem en los últimos 3 meses, cantidad de pedidos en los que estuvo presente el ítem y por último, la cantidad de días en los que se vendió el ítem.

Es importante mencionar que el porcentaje de venta que alcanza este surtido en el local es del 60%, siendo lo mínimo aceptado por la empresa un 25%, es decir, del total de unidades vendidas de todos los ítems de la tienda, la cantidad de ventas en unidades de los ítems escogidos para la zona oscura representan el 60% del total.

Problemática

El área donde se llevó a cabo este proyecto de pasantía se denomina Omnichannel Replenishment, y su principal misión es garantizar una disponibilidad constante para los clientes omnicanal, manteniendo los costos lo más bajos posible y asegurar una buena experiencia de compra.

Con el fin de conocer la disponibilidad de un producto según el inventario a nivel de tienda y empresa, se utiliza un KPI fundamental llamado INSTOCK. "Es un indicador binario que mide la disponibilidad de los productos en la tienda. Si el stock del producto en la tienda es suficiente para cubrir la demanda esperada de ese producto para ese día, entonces el Instock es 1; en caso contrario, es 0. El Instock porcentual se calcula como el total de combinaciones ítem-local con Instock 1, sobre el total de combinaciones ítem-local".

En relación con el KPI anterior, este nos permite identificar los quiebres de un producto que ocurren en la empresa, siendo un quiebre la situación en la que el producto no está disponible. Pueden ocurrir dos casos en un quiebre: en primer lugar, que el ítem no esté disponible en la tienda en su totalidad (ni en bodega ni en la góndola de la zona oscura o sala); y en segundo lugar, el caso sería que no esté disponible en la góndola de la zona oscura, pero sí esté disponible en la góndola de la sala o en bodega. Cabe destacar que, independiente de que tipo de quiebre sea, las repercusiones son las mismas, las cuales veremos más adelante.

Para este proyecto, nos enfocaremos en el último caso, donde el quiebre se origina únicamente en la góndola de la zona oscura. En el siguiente gráfico (Figura 2) se presenta la tendencia de la cantidad total de ítems con quiebre en la zona oscura y cuantos hubieran sido de haber tenido una buena reposición, en otras palabras, los quiebres por falta de stock en local.




Figura 2: Gráfico cantidad de ítems con quiebre en la ZO. Elaboración propia

Como podemos ver en el gráfico anterior, en promedio hay 200 ítems con quiebre al día en la ZO, de los cuales un 50% si estaba disponible en bodega, es decir, fueron quiebres sólo en góndola y no en local.

Los quiebres afectan de manera directa en el KPI Nivel de servicio de la ZO, este KPI es muy importante, ya que, muestra lo que se conoce en Walmart como la sanidad de la ZO. Lo cual indica una relación entre la cantidad de ítems del surtido y la cantidad de ítems que están con quiebre. Es un indicador útil ya que no es lo mismo tener un surtido de 100 con 10 ítem con quiebre, que un surtido de 1.000 con los mismos 10 ítem quebrados.

Lo que ocurre en estos casos de quiebres en la zona oscura, es que el picker o shopper al no encontrar el producto que está buscando, puede hacer una de dos cosas: seguir comprando y dirigirse posteriormente a la sala de ventas para poder ahí encontrar lo que está buscando o, por otra parte, ingresar el quiebre y esperar por una sustitución para el producto requerido.

El primer caso en donde sale de la zona oscura en dirección al piso de ventas genera una baja en la productividad del picker, pues tardará más en completar su pedido. Esto genera que se pierda el objetivo principal de la zona oscura el cual es la velocidad de piqueo y la reducción de la presencia de los picker en la sala de ventas. Por otro lado, si se opta por la segunda opción, también tiene consecuencias negativas, ya que, si el cliente no está dispuesto a sustituir el producto solicitado,

bajar la completitud del pedido. La completitud es la proporción de productos pedidos y la cantidad de productos piqueados, por otra parte, si el cliente está dispuesto a sustituirlo se mantendrá la completitud del pedido, pero no tendrá la misma calidad que el original. Además de la calidad, también se genera una pérdida de tiempo para el picker, debido a la espera de la respuesta del cliente por un sustituto.

Para un shopper, el tiempo total que tarda en el armado de un pedido, considera pre-picking, picking, espera y sustitución por quiebres. El tiempo que consume para la etapa de la búsqueda de sustitutos es de entre un 10% y 13% del tiempo total de armado.

A continuación, podemos ver un gráfico (Figura 3) de cómo se encuentra la productividad (unidades piqueadas por hora) por parte de los pickers y shopper.




Figura 3: Gráfico cantidad de ítems con quiebre en la ZO. Elaboración propia

Podemos ver que en este periodo de tiempo la productividad, medida en unidades piqueadas por hora (UPH), no ha tenido el nivel esperado por parte de la empresa de 150 UPH, sino tan sólo 100 UPH, lo cual es un indicador de un mal funcionamiento de la ZO en base a lo esperado por la empresa.

Según lo averiguado en la empresa, existen distintas causas para los dos casos de quiebres. En el caso de los quiebres en local las causas pueden ser: falla por parte del proveedor lo que provoca una falta de disponibilidad de este ítem en la tienda; la otra causa puede ser una falla en el Forecast, provocando una predicción de ventas bajas a las reales terminando con un quiebre de inventario.

Por otra parte, los quiebres en góndola de la zona oscura pueden ser provocados por una reposición deficiente, ya sea por falta de personal o por ineficiencia de este. Con ineficiencia se refiere a que, a lo informado por parte del local, que hay una gran falta de disciplina y entrenamiento por parte de los reponedores. Esto se informó dado que el personal de reposición, especialmente durante la noche, son identificados en sus dispositivos móviles sin atender a sus obligaciones. Otra causa es que existen ítems en la zona oscura que tienen un dimensionamiento en góndola subdimensionado, es decir, el espacio volumétrico que se le asignó al ítem en la góndola no es suficiente para cubrir la venta del día, provocando quiebres.

La problemática encontrada se representa con un diagrama de Ishikawa (Figura 4) en la cual se presentan 4 factores relevantes en la problemática a evaluar, Fillrate, Forecast, Personas y Espacio físico.

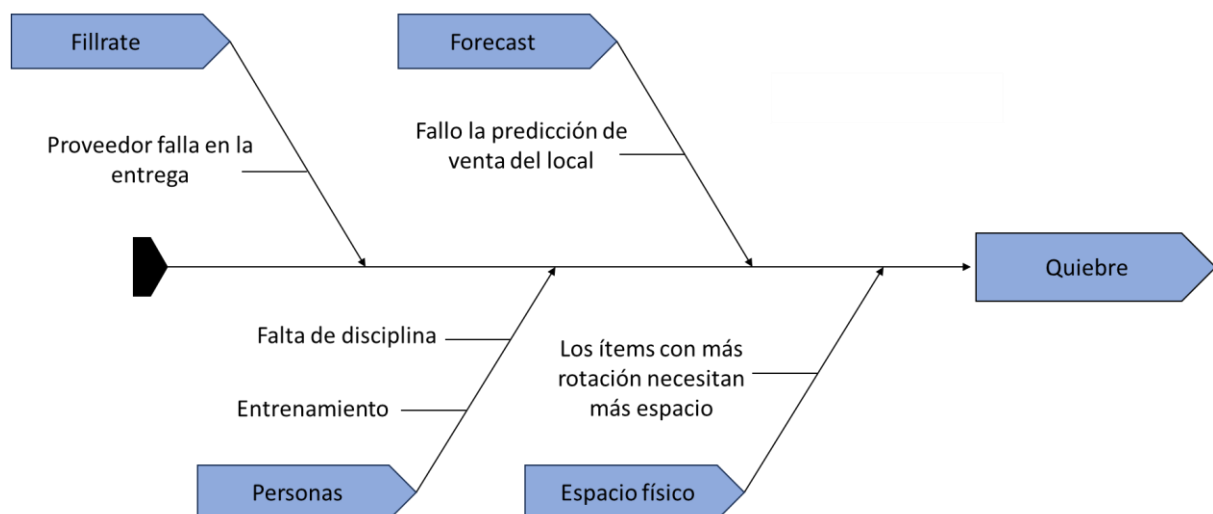


Figura 4: Diagrama de Ishikawa. Elaboración propia

Objetivos

Objetivo general

Reducir la cantidad de ítems con quiebre en el sector de la ZO en un 50%, en un plazo de 4 meses.

Objetivos Específicos

- A. Aumentar el nivel de servicio de la zona oscura desde un promedio de 92% a un 96%
- B. Mantener un mínimo de pickeo en la zona oscura de 25% del pedido.

Estado del arte

Por el crecimiento de la venta ecommers tanto a nivel mundial como nacional, los supermercados están experimentando cambios por la incorporación de las zonas oscuras. Las zonas oscuras o “Dark Stores” son similares a centros de distribución, que se utilizan exclusivamente para preparar y enviar pedidos en línea. A diferencia de las tiendas físicas tradicionales, las tiendas oscuras no están abiertas al público en general y no tienen una presencia visible para los clientes. En lugar de eso, estas tiendas se utilizan para almacenar productos y preparar pedidos en línea de manera eficiente y rápida.

Las tiendas oscuras fueron una respuesta a la creciente demanda de compras en línea, especialmente durante la pandemia de COVID-19, cuando muchas personas prefirieron hacer sus compras desde la comodidad de sus hogares. Al no tener que preocuparse por la atención al cliente en una tienda física, las tiendas oscuras pueden centrarse en la eficacia y la prontitud en la preparación y envío de pedidos.

A pesar de que Walmart no es la única empresa que las ha implementado con el objetivo de agilizar el picking de los pedidos ecommers, el correcto funcionamiento de las zonas oscuras representa una ventaja competitiva para las empresas de este rubro. Es por esta razón que es complejo obtener información sobre el problema que se está abordando, pero este se puede dividir en distintas partes para su estudio.

Analizando el problema, se puede identificar que una de las características del contexto de la ZO es que se dispone de un espacio mucho más reducido para la disposición de productos en comparación a una sala normal, por lo que, para este proyecto, se consideró información de un estudio realizado para la elección de surtido en una tienda de conveniencia (Pronto Copec).

Se utilizó este estudio, puesto que, se enfrentan a un desafío similar en donde deben escoger meticulosamente qué ítems ingresar a sus tiendas al presentar un público específico y un espacio reducido en comparación a una tienda de retail, como un supermercado.

Se definió que, para determinar el surtido para una tienda, hay que tener en consideración 14 indicadores, sin embargo, el análisis realizado en el estudio afirma que estos 14 indicadores pueden ser agrupados debido a su correlación entre ellos en 3 factores: ventas, rentabilidad y rotación de inventario. (Regina, 2007)

En relación con la problemática de los quiebres en góndola, los retailers utilizan distintas técnicas que los ayudan con el fin de evitar esta situación: En primer lugar, existe la inspección visual, en la cual se le asigna una persona para que regularmente revise las góndolas. Esto es ineficiente debido a la cantidad de productos que puede vigilar y el costo asociado al personal destinado a esta labor.

En segundo lugar, otra solución utilizada es la identificación por radiofrecuencia, cada producto tiene un identificador remoto que informa sobre su estado en góndola. Posee una alta eficiencia, pero los costos para implementar esta tecnología son altos, por lo que no es aplicable a todos los productos.

Una tercera técnica que aplican las cadenas de retail es el uso de cámaras en las góndolas, que a pesar de tener información inmediata, dependen de alguien que las monitoree, además de presentar limitaciones técnicas.

Con relación a lo anterior, indagando cómo se podría mejorar el funcionamiento de estas cámaras y teniendo en mente la situación actual, con un auge en el uso de la inteligencia artificial, era lógico pensar que Walmart no se estuviera quedando atrás. Mediante una búsqueda y conversaciones con la empresa, se informó sobre una tecnología aplicada en las cajas de autoservicio, aquí una cámara mediante inteligencia artificial es capaz de identificar diferentes ítems con la finalidad de evitar que el cliente pueda pasar un producto por otro al momento de pagar, dando aviso al personal y así evitando mermas.

Solución

Alternativas de solución

Para abordar la problemática se definieron 3 alternativas de solución. La primera solución consiste en diseñar un modelo de elección de ítems para formar parte del surtido presente en la zona oscura, lo que reducirá el surtido actual a una selección que acorde al espacio físico disponible y su demanda, y así puedan permanecer sin quiebres en góndola por falta de reposición.

La idea es realizar un ranking de los ítems mediante una serie de factores como unidades vendidas, cantidad de órdenes en el que está un ítem, rotación de inventario, entre otros. Obteniendo una lista desde el más indicado para estar en la zona oscura, hasta el menos calificado. Se agregará a la selección el primer ítem y se tomará en cuenta cuál es su demanda diaria para calcular el espacio físico requerido para que no quiebre en góndola, así se seguirá sucesivamente hasta el punto en que el espacio físico disponible se agote, es ahí donde se cortará la selección de ítems y se obtendrá el surtido final.

Además de esto, se analizaría la correlación entre diferentes ítems de un pedido común de ecommers, es decir, si tras analizar lo anteriormente descrito se determina que el ítem A debería estar presente en la zona oscura, se estudiará si hay un ítem B que esté relacionado con el A dentro de los pedidos para que éste también esté presente. Un ejemplo de esto sería que se determine que un ítem de la categoría de pastas esté presente, pero además se descubre que el queso rallado comúnmente está también dentro del mismo pedido, ya que, son “complementarios”. La finalidad de esto es obtener un surtido que permita maximizar la completitud de los pedidos dentro de la zona oscura, en el ejemplo anterior, si el shopper encuentra la pasta en la zona oscura, pero debe salir a la sala a buscar el queso rallado no se estará cumpliendo la finalidad de la zona oscura.

La segunda solución consiste en un análisis de los días y horarios con mayor demanda mediante la data de transacción del local 97 durante los últimos tres meses, esto con el objetivo de determinar el requerimiento de reposición de las góndolas de la zona oscura. Así se podría aumentar la frecuencia de reposición para estos peak y evitar los quiebres en góndola. El beneficio de esto es que no será necesario tener personal que esté revisando el estado de las góndolas en todo momento, sino que será para horas y días en específico.

La tercera opción de solución consiste en la incorporación de cámaras en las góndolas, al usar la tecnología que ya ha puesto uso Walmart para sus cajas de autoservicio, es decir, cámaras con inteligencia artificial que sean capaces de reconocer los diferentes ítems en la góndola y poder también identificar cuántas unidades quedan disponibles. Esta tecnología permitiría enviar alertas tempranas a personal de reposición para actuar antes de llegar al quiebre, además de no tener que contar con personas extras que estén al tanto de las cámaras, lo que representa una de las fallas del sistema de cámaras convencional.

Para evaluar las propuestas de solución se definen 4 criterios para poder jerarquizar y así elegir la alternativa que más se ajuste a lo requerido, los criterios serán evaluados del 1 al 7, siendo 1 la nota más baja, para cada criterio además se determinará una ponderación considerando la importancia de este para la solución.

- **Requerimiento de datos:** Cuál es la disponibilidad a data que se tiene, ya sea por la existencia de esta o por permisos requeridos como practicante para tener acceso.
- **Tiempo de desarrollo:** Tiempo que se tiene disponible vs cuánto tiempo es el requerido para la solución.
- **Costo económico:** Cuál es el costo de implementación de esta solución.
- **Área:** Cuál es el alcance que tiene el área en donde se desarrolla el proyecto (Supply Chain) para implementar la solución.

Solución	Datos (25%)	Tiempo (25%)	Costo (20%)	Área (30%)	Evaluación
Solución 1	6	6	6.5	6	6.1
Solución 2	5	4	4	4	4.3
Solución 3	4	3	3	4	3.6

Solución escogida:

Considerando la evaluación realizada, si bien las tres soluciones son factibles y logran abordar la problemática, la primera alternativa recibe la mejor valoración para solucionar la problemática. Se descarta la solución 2 principalmente por requerir un tiempo mayor para su implementación, un costo extra posiblemente requiriendo la contratación de más personal, además de no estar dentro de las decisiones que toma el área, complicando así la implementación de esta.

Por otra parte, la solución 3 a pesar de poder solucionar la problemática de forma muy efectiva, sus altos costos de desarrollo la hacen una opción menos rentable, además de que es una solución local que sólo aborda la góndola que está al alcance visual de la cámara. Por otra parte, la implementación de esta solución no estaría en manos del área de Supply Chain, por lo que su desarrollo no sería conveniente para este proyecto.

Luego, la alternativa 1 es la mejor solución de las planteadas para desarrollar el proyecto, tiene un costo prácticamente nulo, sólo contando horas hombre de personal del área. El acceso a los datos requeridos es sencillo, además de ser una opción en la que su implementación depende estrechamente del área de la empresa en la que se está trabajando.

Además, esta solución permitirá tener un surtido más sano dentro de la zona oscura reduciendo así los quiebres en góndola además de permitir aumentar la productividad por parte de los shopper.

Finalmente, esta solución será una herramienta que no es específica para la zona oscura de la tienda híbrida del local 97, sino que podrá ser fácilmente aplicada a las demás tiendas híbridas ya existentes y a las próximas a abrir (local 41).

Metodología

Para poder implementar esta solución se escogió la metodología “Scrum”. El Scrum es un marco de trabajo ágil que se utiliza comúnmente en el desarrollo de software, pero que también se puede aplicar en este contexto. Se basa en principios de transparencia, inspección y adaptación, y se centra en la entrega continua de un producto de alta calidad. La metodología cuenta con 7 componentes:

- I. Roles
- II. Definición del Backlog del modelo
- III. Planificación de Sprint
- IV. Desarrollo Iterativo
- V. Revisión de Sprint
- VI. Entrega incremental
- VII. Adaptabilidad a Cambios

Riesgos y Plan de Mitigación

Para abordar los posibles riesgos que pueden aparecer afectando la efectividad del modelo se presenta el siguiente plan de mitigación.

Riesgo	Descripción	Probabilidad	Impacto	Criticidad	Plan de Mitigación
Cambio en el comportamiento de las ventas ecommerce.	Si cambia el comportamiento en ventas ecommerce es posible que algunos ítems que están dentro de la ZO pasen a ser un ítem con pocas ventas y rotación.	0.5	0.4	0.2	Se puede volver a correr la data para así determinar cuanto ha cambiado la selección del surtido. Este es revaluado cada tres meses, de ser un cambio muy grande se puede evaluar hacerlo antes.
Cambio en fillrate de ítems	Si el fillrate por parte de un proveedor para un ítem de la ZO empeora puede afectar de manera negativa al funcionamiento de la ZO.	0.2	0.5	0.1	Ya que la criticidad de este punto es baja, además de que sería para un ítem en específico y no afectaría a nivel general el funcionamiento de la ZO, se propone esperar al siguiente proceso de selección para ser reemplazado.
No uso de la ZO por parte de los shopper	Si los shopper dejaran arbitrariamente de usar la ZO	0.2	0.9	0.18	Se deberá generar una estrategia de incentivo para que los shopper realicen el pickeo dentro de la ZO.

Medidas de desempeño

Se medirá y validará el cumplimiento de los objetivos anteriormente mencionados mediante tres métricas. La primera es la cantidad de ítems con quiebres en góndola en la zona oscura, para este proyecto se contarán específicamente los ítems con quiebre en la zona oscura que, sí presenten stock disponible en bodega para su reposición, o bien que se encuentren disponibles en góndola en el piso de venta.

$$\text{Ítems con quiebres} = \text{ítems con quiebres ZO} - \text{ítems insuficientes a reponer}$$

La segunda métrica será la productividad por parte de los shopper, la cual se mide según cuántas unidades es capaz de recolectar o pickear por cada hora.

$$\text{Productividad} = \frac{\text{unidades pickeadas}}{\text{horas}}$$

Por último, el nivel de servicio de la zona oscura, hay que tener en mente que el número de quiebres por sí solo no es un indicador suficiente, ya que, no representa el mismo problema que existan 10 ítems con quiebre si el surtido total es de 100, a que sean 10 ítems con quiebre de un surtido total de 3000 ítems. Es por esta razón que se usa este KPI que muestra una proporción entre los ítems con quiebre y el surtido total de la zona oscura.

$$NSZO = 1 - \left(\frac{\text{Ítems con quiebre en ZO}}{\text{Surtido total ZO}} \right)$$

NSZO= Nivel Servicio Zona Oscura

Desarrollo e implementación de la solución

El desarrollo de esta solución consiste en tomar todos los ítems calificados para el local, es decir, todos los ítems que se encuentran en el surtido del piso de ventas. Para posteriormente descartar los que no cumplan con ciertas reglas para permanecer dentro de la zona oscura, luego se procede a asignar a los que sí califican un puntaje según ciertos factores que veremos más adelante y así obtener un ranking de estos ítems. Estos serán ingresados al surtido de la zona oscura desde el primer ítem con mejor posicionamiento en el ranking, hasta que se defina que se alcanza el surtido permitido según el espacio disponible.

El primer paso será la identificación del proceso actual, al momento de definir el surtido que estará dentro de la zona oscura se consideran ciertos factores, como la cantidad de ventas en los últimos tres meses del ítem, la cantidad de órdenes de compra en las que estuvo presente el ítem, y por último una serie de filtros que califican si es apto para estar dentro de la ZO.

Uno de los filtros que se consideran actualmente, es que en la zona oscura no existe un sector en donde se puedan pesar o contar productos (carne, queso, etc.), por lo que se deben dejar afuera todos los ítems que dependan de esto. Es decir, se eliminará de la lista cualquier ítem que pertenezca al departamento 80 que es al que pertenecen todos los productos de esta condición.

Otro factor que toman en cuenta para el filtro de ítems es que la definición y modulación del surtido de la zona oscura es cada 3 meses, por lo que no sería conveniente ingresar productos que tengan una temporalidad definida. Imaginemos que al momento de elegir el surtido tomamos en consideración las ventas pasadas y en ese momento acaba de terminar Halloween, quizás consideremos un ítem como un dulce de esa festividad, ya que se vendieron muchas unidades en el último periodo. Pero la realidad es que sólo se vende para esta ocasión y no se venderá más hasta la siguiente temporada, por esta razón hay que dejar fuera todos estos productos, que en Walmart son conocidos con ítems In&Out, ver en anexo 2.

Un filtro que también se utiliza actualmente, es que no puede haber ítems de los departamentos de General Merchandising también conocido como GM. GM es el área de productos que contiene principalmente electrodomésticos y demás. A pesar de que estos productos si están disponibles para su compra a través de ecommers, las compras en www.lider.cl se deparan en dos: SOD y CATEX, SOD es lo que aparece en la página web como “Supermercado” y CATEX vendría siendo

“Tecno y Hogar”. La razón por la que no puede estar presente en el surtido es que en Walmart la ZO de las tiendas híbridas sólo abarcan la sección de SOD y no de CATEX.

Otros filtros que se aplican actualmente son: que el ítem haya tenido alguna venta en los últimos 3 meses, que el ítem se encuentre en estado activo al momento de revisar el surtido y por último que el ítem esté habilitado para la tienda en particular para la cual se diseña el surtido.

Teniendo en consideración los filtros actuales, se procedió a analizar si serían de utilidad nuevos filtros para la finalidad del proyecto, solo se considera agregar nuevos filtros, pues no serviría de nada analizar la posibilidad de quitar alguno de los existentes, en virtud de que son fundamentales para el funcionamiento de la ZO.

A pesar de que la problemática es la cantidad de ítems con quiebre en la zona oscura por falta de reposición, se decidió considerar también aquellos ítems que tienen quiebres por una falta del producto en el local. Mediante un análisis por parte del equipo de OmniLab, la empresa informó que la principal causa de los ítems con quiebre por insuficiencia en la tienda es el Fillrate, es decir, que el proveedor no cumplió con la entrega al local generando la falta de este ítem. Siendo alrededor del 66% de los ítems con quiebre por falta de stock en local, se decidió que el Fillrate sería un nuevo indicador para considerar en la selección de surtido.

La empresa toma en consideración el Fillrate en otros aspectos, como por ejemplo al momento de decidir cuánta mercadería se enviará para abastecer un local. Cuando se abastece un local si el Fillrate es superior al 75% no se toman medidas extras como un aumento de mercancía, ya que es considerado un buen nivel para este KPI. Es de aquí que se desprende la decisión de que para que un ítem pueda estar dentro de la ZO debe tener un porcentaje superior a este, es decir, un 75% con una temporalidad del último mes. Este porcentaje se obtiene mediante la siguiente fórmula:

$$\text{Fillrate} = \frac{\text{Suma de cajas ordenadas}}{\text{Suma de cajas recibidas}}$$

Esto en el periodo de tiempo estipulado: 1 mes

El fragmento de código para obtener el Fillrate del último mes para cada ítem se encuentra en el anexo número 3.

Una vez definidos los ítems que no pueden ser considerados, debemos analizar los que sí califican y cómo se están ranqueando actualmente. Originalmente a los ítems calificados para ingresar al surtido se les evaluaba según la cantidad de unidades vendidas, cantidad de órdenes de compra en la que estuvo el ítem y, por último, la cantidad de días en los que se vendió el ítem.

A cada una de estas variables se les asigna un ponderador para definir la posición del ítem en el ranking, en el surtido original se le asigna un 50% a la cantidad de unidades vendidas en los últimos tres meses, 25% para la cantidad de órdenes de compra en las que estuvo el ítem y por último un 25% para la cantidad de días en los que estuvo presente en una compra.


Durante el proceso de determinar las variables que se considerarían para la determinación del surtido, surgió la idea de que hay ítems que tienen relación con otros, es decir, pares de ítems que usualmente se compran juntos. Esto es un factor importante que considerar, ya que una de las finalidades de la zona oscura es el hacer más eficiente la labor del shopper reduciendo la distancia entre ítems. Por lo tanto, si tenemos un ítem A que se encuentra en la zona oscura y otro ítem B que no lo está, y usualmente el ítem B está presente en una orden de compra en el que está el ítem A, el shopper a pesar de recolectar el ítem A en la ZO de igual manera deberá salir al piso de ventas recurrentemente para recolectar el ítem B.

Por esta razón, y después de realizar una búsqueda por diversas opciones para incluir este factor en el modelo, se optó por utilizar el algoritmo Apriori dentro de la evolución de los ítems para el ranking. Apriori es un algoritmo de minería de datos utilizado para descubrir patrones de asociación en conjuntos de datos, siendo su objetivo principal el encontrar conjuntos de elementos que aparecen con frecuencia juntos en transacciones.

El primer paso en este proceso es formar todos los pares posibles de ítems extrayéndolos de compras pasadas, se puede visualizar de la siguiente manera:

Órdenes de compra pasadas:

Pares de ítems posibles:



Como se puede apreciar, además de generar todos los pares posibles de ítems existentes en órdenes de compra pasadas, también elimina pares que se repitan. Si genera un par que sea (ITEM1-ITEM2) no considerara el par de ítems (ITEM2-ITEM1).

Posteriormente a generar estos pares, se procederá a calcular ciertas métricas para cada par de elementos: La primera es el soporte del ítem X, esto es el número de transacciones que contiene X dividido en el total de transacciones.

La segunda métrica sería la confianza, la confianza se interpreta como la probabilidad $P(Y|X)$, es decir, la probabilidad de que una transacción que contiene los ítems de X, también contenga los ítems de Y, se define según la siguiente ecuación:

$$Confianza(X \Rightarrow Y) = \frac{\text{soporte}(\text{union}(X, Y))}{\text{soporte}(X)}$$

La tercera métrica es el Leverage, el Leverage es una medida que compara la probabilidad de que dos ítems se compren juntos en comparación con la probabilidad de que se compren por separado de forma independiente. En otras palabras, el leverage mide cuánto más a menudo ocurre una combinación de elementos de lo que se esperaría si los elementos fueran independientes entre sí.

$$\text{Leverage } (X \rightarrow Y) = P(X \cap Y) - P(X)P(Y)$$

Donde:

$P(X)$: Probabilidad de que se compre el ítem X.

$P(Y)$: Probabilidad de que se compre el ítem Y.

$P(X \cap Y)$: Probabilidad de que se compre el ítem X e Y juntos.

Los resultados del Leverage se interpretan de la siguiente manera:

- Un valor de leverage positivo indica que la presencia de un elemento en una transacción aumenta la probabilidad de que otro elemento también esté presente. Es decir, hay una relación positiva entre los elementos, y la regla de asociación tiene un poder predictivo significativo.
- Un valor de leverage negativo indica que la presencia de un elemento en una transacción disminuye la probabilidad de que otro elemento también esté presente. En otras palabras, hay una relación negativa entre los elementos, lo que indica que la regla de asociación no es útil para predecir la presencia de ambos elementos juntos
- Un valor de leverage cercano a cero indica que los elementos son independientes entre sí y que no hay una relación significativa entre ellos. La regla de asociación no proporciona información adicional sobre la presencia de los elementos.

Ya teniendo el soporte, la confianza y el leverage se procedió a incorporar estas variables en la ponderación. Hay que tener en cuenta que la idea de la incorporación del algoritmo A priori, es dar una importancia a cómo están relacionados ciertos ítems, pero que llevado a un ranking si tenemos un ítem A con ventas igual a X, que tenga una fuerte relación con un ítem B con ventas X+2, el ítem A no debe estar por sobre un ítem con ventas de X+1. Por lo que la empresa definió que la ponderación asignada a este aspecto no podía ser superior a un 10%, manteniendo como prioridad la cantidad de unidades vendidas del ítem. Teniendo esta restricción en consideración, se optó por dejar la ponderación de la siguiente forma: 50% para cantidad de unidades vendidas del ítem, con el fin de seguir priorizando el porcentaje de venta, 20% para la cantidad de órdenes

de compra en las que estuvo el ítem presente, un 20 % para la cantidad de días en los que el ítem tuvo alguna venta y finalmente un 10% para las relaciones Apriori. El fragmento de código para la aplicación de lo anterior se encuentra en el anexo número 4 y 5.

Una parte importante en el proceso de ponderación es que hay que normalizar, ya que cada variable presenta cifras muy diferentes, como por ejemplo, la cantidad de unidades vendidas de un ítem es una cifra que se puede mover entre 1 y 10.000, a diferencia de la cantidad de órdenes en las que estuvo presente el ítem que es una cifra que se puede mover entre 1 y 500. Por lo que para poder aplicar de manera correcta la ponderación debemos escalar esta data. El procedimiento para este proceso se encuentra en el anexo número 5.

Para abordar el objetivo de este proyecto, el cual busca reducir los quiebres en góndola, se optó por evaluar la causa del espacio físico. Mediante un análisis de data, que consistía en comparar el MAXSHELF (Anexo1) con la venta diaria esperada, se pudo identificar que ciertos ítems no contaban con la cantidad necesaria de unidades en góndola para resistir la demanda diaria. Esto combinado con la información de que en la ZO las reposiciones se realizan durante la noche, sería un indicio de que estos ítems tendrían un quiebre en algún momento del día. Al realizar el conteo de los ítems en esta situación arrojó la cifra de 96, este número se acerca al promedio de ítems con quiebres en góndola en la ZO, obteniendo así la causa raíz.

Para la solución de este aspecto se decidió llevar todos los MAXSHELF a una cantidad que permitiera cumplir con al menos 1 DOG (ver en anexo 1), para esto se consideraron cuántas unidades extras habría que incorporar para poder llegar al mínimo requerido. Ya teniendo las unidades mínimas requeridas para este ítem, se debió calcular cuántas cajas serían necesarias para esto, ya que, por regla de Walmart no es posible tener en góndola unidades por separado, sólo se puede reponer en cajas.

A continuación, se calcula el espacio volumétrico necesario para esta expansión. Calculándose de esta manera por dos motivos, el primero es que en la zona oscura no hay restricciones en cuanto a poner una caja sobre otra del mismo ítem, esto en el piso de ventas no ocurre debido a una regla de presentación de las góndolas, pero en este caso no aplica. La segunda razón es que la modulación específica por cada ítem es un proceso extenso, realizado por el equipo de modulares, sin embargo, aun de manera simplificada nos sirve para la obtención de resultados y conclusiones con este proyecto.

Lo siguiente sería escoger los ítems para el surtido, desde el primero de la lista que arroje el código de SQL que incorpora todo lo antes mencionado (ver en anexo 7). Se incorporan ítems hasta el punto de alcanzar una necesidad volumétrica igual a la disponible por la tienda, en este caso, 133 metros cúbicos.

Durante el periodo de este proyecto la empresa incorporó como norma que el mínimo de un ítem en góndola debe ser de dos cajas. Esta regla se incorpora como medida para evitar quiebres en góndola, supongamos que un ítem cuenta por diseño con una caja en góndola con 100 unidades, y durante la noche cuando un reponedor va a revisar si es necesario reponer se da cuenta que dentro de la caja quedan 10 unidades. Aunque se sepa que la demanda del próximo día será de 20 unidades, no hay nada que se pueda hacer, ya que por regla sólo se reponen cajas y no unidades. El que haya ítems con una caja en góndola quiere decir que, para que estas sean repuestas debe haber ocurrido un quiebre, como esto se quiere evitar, se instauró la norma de las 2 cajas en góndola como mínimo.

Con este cambio durante el proyecto, se debió revisar nuevamente el listado de ítems, y aquellos que contaran con menos de una caja en góndola hubo que llevarlos al mínimo de dos. Hay que considerar que, si se quisiera usar el mismo surtido de antes, éste también tendría que someterse a esta modificación, puesto que, existían ítems dentro del surtido original con esta condición.

Con todo lo anteriormente mencionado se obtiene como producto final un código en SQL que se combina con el usado para el surtido original (anexo 7), el cual es capaz de crear una lista de ítems ranqueados desde el mejor candidato para la zona oscura hasta el peor teniendo en consideración todas las variables antes mencionadas. A cada ítem se le asocia cierta información (anexo 8).

Para la implementación de la solución, el primer paso es definir el local para el cual se quiere definir el surtido y correr el código en una fecha cercana a la reestructuración de la ZO para tener data reciente. Ya teniendo esta lista de ítems se precede a entregar esta información al equipo de modulares, que como ya se menciona anteriormente es quien se encarga de definir con mayor precisión, en función del espacio del ítem en góndola, que cantidad de ítems serán los seleccionados para la ZO. Este proceso es complejo y requiere de tiempo, puede demorar hasta dos semanas, por lo que se recomienda correr el código al menos dos semanas antes de la fecha de modificación de la ZO.

Con el nuevo surtido implementado en la ZO es importante monitorear la cantidad de ítems con quiebre, ese monitoreo se realiza manualmente revisando góndola por góndola, ya que a la fecha no hay otro modo. Esta revisión es de vital importancia para ver como se está comportando el nuevo surtido y el dimensionamiento del espacio para cada día, con esta revisión es que se pueden detectar quiebres para luego buscar sus causas y así poder mejorar constantemente en la calidad del surtido en la ZO.

Resultados

Para medir los resultados se hará una comparación del surtido original, un surtido aplicando las mismas reglas utilizadas para el original pero ajustado a la regla de las dos cajas y reducido con el fin de prevenir quiebres, y por último el surtido propuesto obtenido ocupando el modelo de elección propuesto.

Cantidad de ítems Surtido original	Cantidad de ítems surtido original ajustado	Cantidad de ítems surtido Propuesto
2.448	2.220	2.050

Para medir el desempeño del surtido propuesto en términos del porcentaje de ventas, se realizó una comparación con el surtido anterior como podemos ver en la figura 6:




Figura 6: Gráfico % de la venta vs cantidad de ítems a escoger. Elaboración propia

Como se puede apreciar en el gráfico, el surtido original alcanza un mayor porcentaje de ventas a partir de los 1400 ítems, esto se explica porque al haber bajado la ponderación de las unidades de ventas en el código, tenemos que, a medida que avanza el proceso de creación del ranking ciertos ítems que estaban por sobre otros por tener un mayor número de ventas, ahora estarán por debajo, pues se verán afectados por la ponderación a su correlación con otros ítems. Se puede apreciar que la diferencia no se incrementa considerablemente, ya que los ítems que se encuentran después de la posición 1700 en el ranking poseen un porcentaje de venta bajo, por lo que su porcentaje acumulado es cada vez menor. Esto nos da un porcentaje de venta para el surtido original de 59,5%, para el original ajustado de 58,1% y para el presupuesto de 54,9%

Por otra parte, debido a la incorporación del algoritmo Apriori, se midió el impacto de esto mediante la medición del porcentaje promedio de una orden de compra que puede ser completado con el surtido de la zona oscura (Anexo 6):

Surtido Original	Surtido original ajustado	Surtido propuesto
50%	42,56%	46,61%

Podemos ver que, pese a que el porcentaje es más bajo que el original, se debe tener en consideración que el surtido original ya no es una opción viable por la nueva regla de dos cajas. Si lo comparamos con el surtido original ajustado, podemos tener un mayor porcentaje promedio de completitud de la orden de compra. Esto se debe al algoritmo A priori, el cual hizo que en el final del ranking de ítems, en donde la diferencia entre el porcentaje de venta entre ítem e ítem es cercano a 0,04 puntos porcentuales, se le dio una mayor valoración al producto que tuviera mayor correlación con los ítem mejor ranqueados permitiendo tener una mayor completitud de los pedidos en la ZO.

Con respecto al nivel de servicio de la zona oscura del local 97, se obtiene que con la propuesta de surtido será de un 95,12%. Ya que de los 2020 ítems que estarán en la ZO, se proyectó que seguirá habiendo un promedio de 100 ítems con quiebre, siendo estos causados por factores que no se abordaron en el proyecto. A pesar de no llegar al objetivo, igualmente es una mejora de 3,12 puntos porcentuales con respecto al original.

Con respecto a mantener un mínimo de pickeo en la zona oscura de un 25%, podemos ver que se superó este objetivo, logrando estar con 54,9% del porcentaje de venta.

Por último, con respecto al enfoque principal de este proyecto de disminuir los quiebres en la ZO, tenemos que al reducir a 0 la cantidad de ítems que no poseían la cantidad necesaria de unidades en góndola para soportar un día de ventas, esto, bajo el supuesto que se abordará el nivel de experiencia y eficiencia del personal de reposición, que como vimos anteriormente, causa la mitad de los quiebres de la ZO. Por tanto, podemos predecir que se podrán reducir la cantidad de ítems con quiebre en la ZO en un 50%.

Conclusiones

Luego del desarrollo del proyecto se cumple el objetivo general de reducir en un 50% la cantidad de ítems con quiebre en la ZO, además de aportar una forma diferente en cuanto a la evaluación de los ítems al momento de formar un ranking para ingresar a la ZO.

Como recomendaciones se puede señalar que es importante monitorear los quiebres en la zona oscura y sus causas, este proyecto fue posible a la alerta levantada por este proceso. Sería de utilidad buscar una manera de hacer este proceso más rápido, en virtud de que toma una cantidad de tiempo considerable para el personal de tienda.

Un punto que se observó fue que en ciertos locales, en la separación de la ZO con el piso de venta, están las mismas categorías de productos. Esto es un punto que se debería tomar en consideración, pues es válido cuestionar el aporte a la velocidad de pickeo por parte de los shopper de un ítem en la ZO, si ese mismo ítem se encuentra cercano a la separación de ambas zonas en el piso de ventas.

Otra recomendación para la empresa sería entender la forma en que los shopper se sienten con la zona oscura, ya que se identificó que algunos shopper prefieren no usar la zona oscura por malas experiencias pasadas, mayormente por quiebres de ítems que debieron ir a buscar al piso de venta.

Habiendo obtenido un menor porcentaje de las ventas, pero un mayor porcentaje de las órdenes de venta abarcada por el surtido, queda en manos de la empresa decidir a qué dar mayor prioridad. A modo de recomendación, se debería dar valor al porcentaje de la orden de compra ya que esto permite una mayor completitud del pedido dentro de la zona oscura, lo que ayuda al shopper a reducir el tiempo de pickeo, que es uno de los principales objetivos de la ZO.

En términos generales, el proyecto cumple satisfactoriamente con los objetivos y aporta valor a la empresa en el avance de la omnicanalidad y la eficiencia de las operaciones de los supermercados, se recomienda realizar un seguimiento de las variables involucradas en él, esto ya que con el pasar del tiempo el comportamiento de estas puede variar. Finalmente, es fundamental que este modelo se vaya adaptando a las prioridades de la empresa en cuanto a sus objetivos con la zona oscura.

Bibliografía:

1. <https://mundoenlinea.cl/2021/03/25/la-evolucion-del-e-commerce/#:~:text=Cuando%20visualizamos%20el%20e-Commerce%20en%20Chile%2C%20nos%20podemos,esto%20impulsado%20principalmente%20por%20la%20pandemia%20del%20Coronavirus.>
2. [Hosting & Hybrid Cloud Infrastructure - TD Web Services](#)
3. [Reglas de asociación y algoritmo Apriori con R \(cienciadedatos.net\)](#)
4. [Compra desde casa en Supermercado y Mundo Lider](#)
5. [WalmartChile – Walmart Chile es uno de los principales actores en la industria de las ventas al por menor del país \(retail\).](#)
6. [Memoria_Corregida.PDF \(uchile.cl\)](#)
7. [cf-menares_nl.pdf \(uchile.cl\)](#)
8. [RiveraAcostaOscarIvan2018.pdf \(unimilitar.edu.co\)](#)
9. [Identificacion-de-quiebres-de-stock-en-gondola-mediante-un-modelo-de-Markov-oculto-con-informacion-parcial-de-clientes-leales.pdf \(uchile.cl\)](#)

Anexos:

1. Glosario:

- ZO: Zona Oscura
- Góndola: Cubículos del supermercado o ZO en donde están los ítems para su recolección.
- MAXSHELF: Cantidad de unidades de un ítem en góndola.
- DOG: Días que puede soportar el inventario de un ítem en la góndola sin reposición, se calcula en función del MAXSHELF y de la proyección de venta diaria del ítem.
- Forecast: Proyección de venta de un ítem.

2. Filtro In&Out:

Ítems tipo-subtipo: 20-3, 20-4, 37-87, 3-0, 7-0

```
...
, CASE WHEN concat(cast(ITEM.item_type_code as string), '-'
, cast(ITEM.repl_subtype_code as string)) not in ('20-3', '20-4', '37-87', '3-0', '7-0') THEN TRUE ELSE FALSE END AS filtro_in_out
...
```

3. Código Fillrate último mes:

```
-- fillrate del ultimo mes
fillrate_ult_1m AS (
  SELECT
    it.store_nbr
    , it.repl_group_nbr
    , SAFE_DIVIDE(SUM(cajas_recibidas), SUM(cajas_ordenadas)) as fillrate_1m
  FROM item_counts it
  LEFT JOIN fillrate_qry fill
    ON fill.repl_group_nbr = it.repl_group_nbr
  WHERE TRUE
    AND fill.cancel_date BETWEEN current_date('America/Santiago')-
31 AND current_date('America/Santiago')-1
  GROUP BY it.store_nbr, it.repl_group_nbr
)
```

4. Fragmento de código SQL para aplicación algoritmo Apriori

```
-- Generar todos los pares posibles de elementos modelo apriori
pairs AS (
  SELECT
    piua.store_nbr
    , piua.repl_group_nbr AS cid_a
    , piub.repl_group_nbr AS cid_b
    , COUNT(distinct concat(piua.store_nbr, '-', piua.repl_group_nbr, '-',
piub.repl_group_nbr)) AS pair_count
  FROM pedidos_items AS piua
  JOIN pedidos_items AS piub
  ON piua.store_nbr = piub.store_nbr AND piua.sg = piub.sg
  WHERE TRUE
  AND piua.repl_group_nbr < piub.repl_group_nbr -- Evitar duplicados, como
"item_1, item_2" y "item_2, item_1"
  GROUP BY
    1, 2, 3
),

-- Calculo de métricas para cada par modelo apriori
associations AS (
  SELECT
    store_nbr,
    cid_a,
    cid_b,
    total_sgs,
    pair_count,
    support,
    count_cid_a,
    support_a,
    count_cid_b,
    support_b,
    confidence_a_b,
    confidence_b_a,
    IFNULL(IEEE_DIVIDE(support, support_a*support_b), 0) as lift,
    IFNULL(support-(support_a*support_b), 0) as leverage,
    IFNULL(IEEE_DIVIDE(1-support_b, 1-confidence_a_b), 0) as conviction_a_b,
    IFNULL(IEEE_DIVIDE(1-support_a, 1-confidence_b_a), 0) as conviction_b_a
  FROM (
    SELECT
      pairs.store_nbr,
      cid_a,
      cid_b,
      tot.total_sgs,
      pair_count,
      IEEE_DIVIDE(pair_count, tot.total_sgs) AS support,
      i1.qty_sgs AS count_cid_a,
      IEEE_DIVIDE(i1.qty_sgs, tot.total_sgs) AS support_a,
      i2.qty_sgs AS count_cid_b,
      IEEE_DIVIDE(i2.qty_sgs, tot.total_sgs) AS support_b,
      IEEE_DIVIDE(pair_count, i1.qty_sgs) AS confidence_a_b,
      IEEE_DIVIDE(pair_count, i2.qty_sgs) AS confidence_b_a,
    FROM pairs
    JOIN item_counts AS i1
    ON pairs.store_nbr = i1.store_nbr AND pairs.cid_a = i1.repl_group_nbr
    JOIN item_counts AS i2
    ON pairs.store_nbr = i2.store_nbr AND pairs.cid_b = i2.repl_group_nbr
    JOIN venta_totales tot
    ON tot.store_nbr = pairs.store_nbr
  )
)
```

5. Fragmento código SQL para escalar y ponderar:

```
-- Agrupacion de metricas item
metrics_item as (
  SELECT
    store_nbr
    , repl_group_nbr
    , item_nbr
    , qty_unidades
    , qty_sgs
    , qty_dias_venta
    , support as relacion
    , confidence as confianza
    , leverage as palanca
    , qty_unidades_scaled * 0.5 + qty_sgs_scaled * 0.2 + qty_dias_venta_scaled *
0.2 + support_apriori_scaled * 0.06 + confidence_apriori_scaled * 0.02 +
leverage_apriori_scaled * 0.02 as ponderador
    , qty_unidades/total_unidades as ratio_venta
    , qty_unidades/dias_periodo as venta_diaria_estimada
    , percentile99_venta
  FROM (
    SELECT
      item.store_nbr
      , DATE_DIFF(edate, sdate, DAY) as dias_periodo
      , item.repl_group_nbr
      , item.item_nbr
      , qty_unidades
      , ML.MIN_MAX_SCALER(qty_unidades) OVER() AS qty_unidades_scaled
      , qty_sgs
      , ML.MIN_MAX_SCALER(qty_sgs) OVER() AS qty_sgs_scaled
      , qty_dias_venta
      , ML.MIN_MAX_SCALER(qty_dias_venta) OVER() AS qty_dias_venta_scaled
      , support
      , ML.MIN_MAX_SCALER(support) OVER() AS support_apriori_scaled
      , confidence
      , ML.MIN_MAX_SCALER(confidence) OVER() AS confidence_apriori_scaled
      , leverage
      , ML.MIN_MAX_SCALER(leverage) OVER() AS leverage_apriori_scaled
      , percentile99_venta
      , total_unidades
    FROM item_counts item
    LEFT JOIN metrics_apriori_item ap
      ON item.store_nbr = ap.store_nbr AND item.repl_group_nbr =
ap.repl_group_nbr
    LEFT JOIN item_percentiles perc
      ON item.store_nbr = perc.store_nbr AND item.repl_group_nbr =
perc.repl_group_nbr
    LEFT JOIN (select * from tiendas, dates) td
      ON item.store_nbr = td.local
    LEFT JOIN venta_totales tot
      ON item.store_nbr = tot.store_nbr
  )
),
```

6. Cálculo porcentaje promedio de la orden de compra completada por el surtido:

Cada orden de compra cuenta con un número identificador como podemos ver en la primera columna de la figura 8, en cada orden de compra se encuentran los ítems que la conforman como se ve en la segunda columna, la tercera columna muestra cuál de esos ítems está dentro del surtido propuesto. Para efectos de conteo se crea una columna con un 1 para todos los ítems, finalmente si el ítem está presente en el surtido se le asigna un 1.

sg	items	item surtido	totales	presentes
91103094426	646263	#N/D	1	0
91103108468	5010542	#N/D	1	0
91103045499	115090	#N/D	1	0
91103078566	447257	#N/D	1	0
91103074162	597087	597087	1	1
91103125242	762358	762358	1	1
91103041540	822650	#N/D	1	0
91103038001	481797	481797	1	1
91103087307	411051	#N/D	1	0
91103098658	464529	#N/D	1	0
91103055567	252305	#N/D	1	0

Figura 8, extracto hoja Excel. Elaboración propia

Con esta tabla podemos formar una dinámica que nos de la información que necesitamos, figura:

Etiquetas de fila	Suma de totales	Suma de presentes	% de la orden de compra
91102989412	21	12	0.571428571
91102989422	16	6	0.375
91102989504	52	27	0.519230769
91102989556	29	13	0.448275862
91102989601	19	8	0.421052632
91102989611	31	19	0.612903226
91102989619	15	12	0.8
91102989663	38	18	0.473684211
91102989714	23	18	0.782608696
91102989755	39	18	0.461538462
91102989789	13	9	0.692307692
91102989832	23	15	0.652173913
91102989860	22	5	0.227272727

Como podemos ver para la primera fila, para la compra con código 91102989412 hubo 21 ítems, de los cuales 12 se encontraban dentro del surtido seleccionado, dando como porcentaje de

completitud de la orden de compra de 57,14%. El porcentaje de todas las órdenes de compra del último mes es igual a 46,61%

7. Código final, basado en el código original de la empresa:

WITH dates AS (

```
SELECT
    current_date('America/Santiago')-91 AS sdate -- fecha inicio
    , current_date('America/Santiago')-1 AS edate -- fecha fin
),
```

tiendas AS (

```
SELECT 97 AS local
),
```

-- items que estan en la tienda

```
item_in_store as (
    SELECT
        T2.STORE_NBR as store_nbr
        , T1.OLD_NBR AS item_nbr
        , T1.repl_group_nbr
        , 1 AS item_in_store
    FROM `wmt-edw-prod.K2_WM_VM.ITEM` T1
    INNER JOIN `wmt-edw-prod.K2_WM_VM.ITEM_DESC` H1
        ON H1.ITEM_NBR = T1.ITEM_NBR
    INNER JOIN `wmt-edw-prod.K2_WM_REPL_VM.GRS_VENDOR_AGREEMENT` A
        ON A.VENDOR_SEQ_NBR=T1.VENDOR_SEQ_NBR AND A.VENDOR_NBR = T1.VENDOR_NBR AND
A.DEPT_NBR = T1.DEPT_NBR
    INNER JOIN `wmt-edw-prod.K2_WM_VM.INFOREM_MANAGED_SKU` T2
        ON T2.ITEM_NBR = T1.ITEM_NBR
    INNER JOIN `wmt-edw-prod.K2_WM_VM.WHSE_ALIGN` T3
        ON T3.WHSE_TYPE = T1.WHSE_ALIGN_TYPE_CD AND T3.STORE_NBR= T2.STORE_NBR AND
T3.EXPIRE_DATE > CURRENT_DATE -1 AND T3.ALIGN_DATE < CURRENT_DATE + 1
    LEFT JOIN `wmt-edw-prod.K2_WM_REPL_VM.GRS_FULFILLMENT_PARM` T6
        ON T6.ITEM_NBR = T1.ITEM_NBR AND T6.STORE_NBR = T2.STORE_NBR
    INNER JOIN `wmt-edw-prod.WW_MDSE_DM_VM.FINELINE_DIM` DIM
        ON DIM.FINELINE_NBR = T1.FINELINE_NBR AND DIM.DEPT_NBR = T1.DEPT_NBR AND
DIM.CURRENT_IND = 'Y' AND DIM.COUNTRY_CODE IN ('K2')
    LEFT JOIN (
        SELECT
            STORE_NBR
            , REPL_GROUP_NBR
            , MAX_SHELF_QTY
        FROM `wmt-edw-prod.K2_WM_REPL_VM.DMDUNIT_PRES_SCENARIO`
        ) AS MS ON MS.REPL_GROUP_NBR = T1.REPL_GROUP_NBR AND MS.STORE_NBR =
T2.STORE_NBR
    LEFT JOIN (
        SELECT
```

```

        ITEM_NBR
        , STORE_NBR
        , SUM(ORDER_EACH_QTY) RS
    FROM `wmt-edw-prod.K2_WM_REPL_VM.GRS_FILTERED_ORDER` WHERE SCHED_SHIP_DATE =
CURRENT_DATE GROUP BY 1,2
    ) S1
    ON S1.ITEM_NBR = T1.ITEM_NBR AND S1.STORE_NBR = T2.STORE_NBR
WHERE TRUE
    AND T2.STORE_NBR IN (select local from tiendas)
    AND T1.DEPT_NBR NOT IN (66,99)
GROUP BY
    T2.STORE_NBR, T1.REPL_GROUP_NBR, T1.OLD_NBR
),

```

```

-- Informacion de venta de items y obtención del cid
pedidos_items AS (
    SELECT
        oms.local AS store_nbr
        , oms.sg
        , piu.itemnumber AS item_nbr
        , CASE
            WHEN ins.repl_group_nbr IS NULL AND item.repl_group_nbr IS NOT NULL THEN
item.repl_group_nbr
            ELSE ins.repl_group_nbr
            END AS repl_group_nbr
        , DATE(oms.fechacompra) AS fechacompra
        , piu.quantityap
    FROM `wmt-edw-sandbox.cl_operations_omnichannel.orderesoms` oms
    LEFT JOIN `wmt-edw-
sandbox.cl_operations_omnichannel_cmp.ft_pedidositemunidades2` piu
        ON piu.sg = oms.sg
    LEFT JOIN item_in_store ins
        ON piu.STORE = ins.store_nbr AND piu.itemnumber = ins.item_nbr
    LEFT JOIN (
        SELECT
            repl_group_nbr
            , OLD_NBR AS item_nbr
            , item_status_code
        FROM `wmt-edw-prod.K2_WM_VM.ITEM` ITEM
        LEFT JOIN `wmt-edw-prod.WW_MDSE_DM_VM.FINELINE_DIM` FINE
            ON FINE.DEPT_NBR = ITEM.DEPT_NBR AND FINE.FINELINE_NBR = ITEM.FINELINE_NBR
        WHERE TRUE
            AND ITEM.ITEM_STATUS_CODE NOT IN ('D')
            AND FINE.COUNTRY_CODE = 'K2'
            AND FINE.CURRENT_IND = 'Y'
    ) item
        ON item.item_nbr = piu.itemnumber
    WHERE TRUE
        AND oms.local IN (SELECT local FROM tiendas)
        AND oms.fechacompra BETWEEN (SELECT sdate FROM dates) AND (SELECT edate FROM
dates)
),

```

```

-- Percentil 99 para estimación de días de inventario

```

```

item_percentiles as (
  SELECT
    DISTINCT
      store_nbr
      , repl_group_nbr
      , PERCENTILE_CONT(quantityap, 0.99) OVER(PARTITION BY store_nbr,
repl_group_nbr) AS percentile99_venta
  FROM (
    SELECT
      store_nbr
      , fechacompra
      , repl_group_nbr
      , SUM(QUANTITYAP) as quantityap
    FROM pedidos_items
    GROUP BY 1,2,3
  )
),

-- Totales
venta_totales as (
  SELECT
    store_nbr
    , COUNT(distinct sg) AS total_sgs
    , SUM(quantityap) AS total_unidades
    --, IFNULL(SAFE_DIVIDE(Z.vnpk_qty, venta_diaria_estimada), 0) as dos
  FROM pedidos_items

  GROUP BY 1
),

-- Contar las métricas de cada ítem en las transacciones
item_counts AS (
  SELECT
    store_nbr
    , repl_group_nbr
    , item_nbr
    , sum(QUANTITYAP) as qty_unidades
    , count(distinct SG) as qty_sgs
    , count(distinct fechacompra) as qty_dias_venta
  FROM pedidos_items
  WHERE TRUE
  GROUP BY
    store_nbr
    , repl_group_nbr
    , item_nbr
),

-- Generar todos los pares posibles de elementos modelo apriori
pairs AS (
  SELECT
    piua.store_nbr
    , piua.repl_group_nbr AS cid_a
    , piub.repl_group_nbr AS cid_b

```

```

, COUNT(distinct concat(piua.store_nbr, '-', piua.repl_group_nbr, '-',
piub.repl_group_nbr)) AS pair_count
FROM pedidos_items AS piua
JOIN pedidos_items AS piub
  ON piua.store_nbr = piub.store_nbr AND piua.sg = piub.sg
WHERE TRUE
  AND piua.repl_group_nbr < piub.repl_group_nbr -- Evitar duplicados, como
"item_1, item_2" y "item_2, item_1"
GROUP BY
  1, 2, 3
),

-- Calculo de métricas para cada par modelo apriori
associations AS (
  SELECT
    store_nbr,
    cid_a,
    cid_b,
    total_sgs,
    pair_count,
    support,
    count_cid_a,
    support_a,
    count_cid_b,
    support_b,
    confidence_a_b,
    confidence_b_a,
    IFNULL(IEEE_DIVIDE(support, support_a*support_b), 0) AS lift,
    IFNULL(support-(support_a*support_b), 0) AS leverage,
    IFNULL(IEEE_DIVIDE(1-support_b, 1-confidence_a_b), 0) AS conviction_a_b,
    IFNULL(IEEE_DIVIDE(1-support_a, 1-confidence_b_a), 0) AS conviction_b_a
  FROM (
    SELECT
      pairs.store_nbr,
      cid_a,
      cid_b,
      tot.total_sgs,
      pair_count,
      IEEE_DIVIDE(pair_count, tot.total_sgs) AS support,
      i1.qty_sgs AS count_cid_a,
      IEEE_DIVIDE(i1.qty_sgs, tot.total_sgs) AS support_a,
      i2.qty_sgs AS count_cid_b,
      IEEE_DIVIDE(i2.qty_sgs, tot.total_sgs) AS support_b,
      IEEE_DIVIDE(pair_count, i1.qty_sgs) AS confidence_a_b,
      IEEE_DIVIDE(pair_count, i2.qty_sgs) AS confidence_b_a,
    FROM pairs
    JOIN item_counts AS i1
      ON pairs.store_nbr = i1.store_nbr AND pairs.cid_a = i1.repl_group_nbr
    JOIN item_counts AS i2
      ON pairs.store_nbr = i2.store_nbr AND pairs.cid_b = i2.repl_group_nbr
    JOIN venta_totales tot
      ON tot.store_nbr = pairs.store_nbr
    GROUP BY
      1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11
  )
)

```



```

    )
),

-- Metricas de a priori individuales para cada item
metrics_apriori_item as (
    SELECT
        store_nbr
        , repl_group_nbr
        , IFNULL(sum(support), 0) as support
        , IFNULL(sum(confidence), 0) as confidence
        , IFNULL(sum(leverage), 0) as leverage
    FROM (
        SELECT
            store_nbr
            , cid_a as repl_group_nbr
            , sum(support) as support
            , sum(confidence_a_b) as confidence
            , sum(leverage) as leverage
        FROM associations
        GROUP BY store_nbr, cid_a
        UNION ALL
        SELECT
            store_nbr
            , cid_b as repl_group_nbr
            , sum(support) as support
            , sum(confidence_b_a) as confidence
            , sum(leverage) as leverage
        FROM associations
        GROUP BY store_nbr, cid_b
    )
    GROUP BY store_nbr, repl_group_nbr
    ORDER BY store_nbr, support desc, repl_group_nbr
),

```

```

-- Agrupacion de metricas item
metrics_item as (
    SELECT
        store_nbr
        , repl_group_nbr
        , item_nbr
        , qty_unidades
        , qty_sgs
        , qty_dias_venta
        , support as relacion
        , confidence as confianza
        , leverage as palanca
        , qty_unidades_scaled * 0.5 + qty_sgs_scaled * 0.2 + qty_dias_venta_scaled *
0.2 + support_apriori_scaled * 0.06 + confidence_apriori_scaled * 0.02 +
leverage_apriori_scaled * 0.02 as ponderador
        , qty_unidades/total_unidades as ratio_venta
        , qty_unidades/dias_periodo as venta_diaria_estimada
        , percentile99_venta

```

```

FROM (
  SELECT
    item.store_nbr
    , DATE_DIFF(edate, sdate, DAY) AS dias_periodo
    , item.repl_group_nbr
    , item.item_nbr
    , qty_unidades
    , ML.MIN_MAX_SCALER(qty_unidades) OVER() AS qty_unidades_scaled
    , qty_sgs
    , ML.MIN_MAX_SCALER(qty_sgs) OVER() AS qty_sgs_scaled
    , qty_dias_venta
    , ML.MIN_MAX_SCALER(qty_dias_venta) OVER() AS qty_dias_venta_scaled
    , support
    , ML.MIN_MAX_SCALER(support) OVER() AS support_apriori_scaled
    , confidence
    , ML.MIN_MAX_SCALER(confidence) OVER() AS confidence_apriori_scaled
    , leverage
    , ML.MIN_MAX_SCALER(leverage) OVER() AS leverage_apriori_scaled
    , percentile99_venta
    , total_unidades
  FROM item_counts item
  LEFT JOIN metrics_apriori_item ap
    ON item.store_nbr = ap.store_nbr AND item.repl_group_nbr =
ap.repl_group_nbr
  LEFT JOIN item_percentiles perc
    ON item.store_nbr = perc.store_nbr AND item.repl_group_nbr =
perc.repl_group_nbr
  LEFT JOIN (select * from tiendas, dates) td
    ON item.store_nbr = td.local
  LEFT JOIN venta_totales tot
    ON item.store_nbr = tot.store_nbr
)
),

```

```

-- Extraccion de fillrate de los items según fechas de cancelación
fillrate_qry AS (
  SELECT
    T2.CANCEL_DATE
    , T1.REPL_GROUP_NBR
    , SUM((T4.WHPK_ORDER*T3.WHPK_QTY)/T3.VNPK_QTY) AS CAJAS_ORDENADAS
    , SUM((T4.WHPK_QTY_RCVD*T3.WHPK_QTY)/T3.VNPK_QTY) AS CAJAS_RECIBIDAS
    , SUM((T4.WHPK_ORDER*T3.WHPK_QTY)/T3.VNPK_QTY)-
SUM((T4.WHPK_QTY_RCVD*T3.WHPK_QTY)/T3.VNPK_QTY) AS CAJAS_NO_ENTREGADAS
  FROM
    `wmt-edw-prod.k2_WM_VM.PURCHASE_ORDER` T2,
    `wmt-edw-prod.k2_WM_VM.ITEM_DESC` T3,
    `wmt-edw-prod.k2_WM_VM.ITEM` T1,
    `wmt-edw-prod.k2_WM_VM.PO_LINE` T4,
    `wmt-edw-prod.WW_MDSE_DM_VM.FINELINE_DIM` DIM
  WHERE TRUE
    AND T2.PO_NBR=T4.PO_NBR
    AND T2.ORDER_DEPT_NBR NOT IN (66)
    AND CAST(T2.VENDOR_NBR AS INT64) NOT IN (674)

```

```

AND T3.ITEM_NBR=T4.ITEM_NBR
AND T3.ITEM_NBR=T1.ITEM_NBR
AND T1.STORE_FORMAT_CODE IN (1)
AND T2.PO_TYPE NOT IN (40,28)
AND T2.EVENT_DESC NOT IN ('ERROR')
AND T2.CANCEL_DATE BETWEEN current_date('America/Santiago')-31 AND
current_date('America/Santiago')-1 -- PONER INTERVALOS DE FECHAS AQUI
AND DIM.COUNTRY_CODE='K2'
AND DIM.CURRENT_IND='Y'
AND T1.FINELINE_NBR=DIM.FINELINE_NBR
AND T1.DEPT_NBR=DIM.DEPT_NBR
GROUP BY
T2.WHSE_NBR
, T2.PO_NBR
, T2.PO_STATUS
, T2.STEP_STATUS
, T2.EVENT_DESC
, T2.PO_TYPE
, T2.ORDER_DEPT_NBR
, DIM.DEPT_DESC
, T2.VENDOR_NBR
, T2.VENDOR_NAME
, T2.VENDOR_NBR_SEQ
, T1.REPL_GROUP_NBR
, T1.WHPK_QTY
, T2.ORDER_DATE
, T2.CANCEL_DATE
, T2.BUYER_NAME
, DIM.DEPT_CATEGORY_NBR
, DIM.DEPT_SUBCATG_NBR
, DIM.FINELINE_NBR
, DIM.DEPT_CATEGORY_DESC
, DIM.DEPT_SUBCATG_DESC
, DIM.MDSE_SUBGROUP_DESC
, DIM.FINELINE_DESC
),

-- fillrate del ultimo mes
fillrate_ult_1m AS (
SELECT
    it.store_nbr
    , it.repl_group_nbr
    , SAFE_DIVIDE(SUM(cajas_recibidas),SUM(cajas_ordenadas)) as fillrate_1m
FROM item_counts it
LEFT JOIN fillrate_qry fill
    ON fill.repl_group_nbr = it.repl_group_nbr
WHERE TRUE
    AND fill.cancel_date BETWEEN current_date('America/Santiago')-31 AND
current_date('America/Santiago')-1
GROUP BY it.store_nbr, it.repl_group_nbr
),

```

```
-- informacion de items
venta_filtro as (
  select
    metrics.store_nbr
    , ITEM.repl_group_nbr
    , ITEM.old_nbr
    , ITEM.upc_nbr
    , trim(ITEM.signing_desc) as signing_desc
    , FINE.fineline_nbr
    , FINE.dept_subcatg_nbr
    , trim(FINE.dept_subcatg_desc) as dept_subcatg_desc
    , FINE.dept_nbr
    , trim(FINE.dept_desc) as dept_desc
    , FINE.dept_category_nbr
    , trim(FINE.dept_category_desc) as dept_category_desc
    , ITEM.item_type_code
    , ITEM.repl_subtype_code
    , concat(cast(ITEM.item_type_code as string), '-', cast(ITEM.repl_subtype_code
as string)) as type_subtype
    , trim(FINE.mdse_subgroup_desc) as mdse_subgroup_desc
    , trim(FINE.mdse_segment_desc) as mdse_segment_desc
    , ITEM.whse_align_type_cd
    , ITEM.whse_area_code
    , CASE
      WHEN ITEM.DEPT_NBR IN (83,91,93) AND ITEM.WHSE_AREA_CODE = 4 THEN
"CONGELADO"
      WHEN ITEM.DEPT_NBR IN (83,91,93) AND ITEM.WHSE_AREA_CODE != 4 THEN
"REFRIGERADO"
      WHEN ITEM.DEPT_NBR IN (39,56,80,90,94) THEN "REFRIGERADO"
      WHEN ITEM.DEPT_NBR = 97
        AND (NOT (CONTAINS_SUBSTR(ITEM.SIGNING_DESC, 'HUEVO') AND
ITEM.FINELINE_NBR IN (4675,4700,1300,2975,3425,3725))) -- HUEVOS
        AND (NOT (ITEM.FINELINE_NBR IN (4650))) -- QUESOS RAYADOS
      THEN "REFRIGERADO"
      WHEN ITEM.DEPT_NBR = 82 THEN "CHECKOUT"
      ELSE "SECO"
    END AS almacenamiento
    , ITEM.item_status_code
    , ITEM.cancel_wn_out_ind
    , trim(ITEM.mbm_code) as mbm_code
    , ITEM.vendor_nbr
    , ITEM.vendor_seq_nbr
    , item_length_qty
    , item_height_qty
    , item_width_qty
    , item_dim_uom_code
    , item_weight_qty
    , item_weight_uom_cd
    , ITEM.pallet_ti_qty
    , ITEM.pallet_hi_qty
    , doh_max
    , vnpk_qty
    , GRS2.channel_mthd_desc
    , GRS2.channel_mthd_cd
  )
```

```

, IFNULL(nunca_sin, '-') as nunca_sin
, fillrate_1m
, CASE WHEN inlcl.item_in_store = 1 THEN TRUE ELSE FALSE END AS
filtro_item_en_store -- filtro de item en tienda
, CASE WHEN ITEM.ITEM_STATUS_CODE = 'A' THEN TRUE ELSE FALSE END AS
filtro_activo --filtro de item activo
, CASE WHEN ITEM.cancel_wnh_out_ind != 'Y' THEN TRUE ELSE FALSE END AS
filtro_cancel_when_out -- filtro de item no cancel_wnh_out_ind
, CASE WHEN (ITEM.dept_nbr = 93 AND FINE.FINELINE_NBR in
(7625,7575,7600,8125,3900,2925,2950,3225,3375)) THEN FALSE ELSE TRUE END AS
filtro_carnes_granel -- filtro carnes a granel
, CASE WHEN ITEM.dept_nbr != 80 THEN TRUE ELSE FALSE END AS filtro_pesables
-- filtro pesables y fiambreria que se corta
, CASE WHEN ITEM.dept_nbr != 94 THEN TRUE ELSE FALSE END AS filtro_ffvv --
filtro frutas y verduras
, CASE WHEN trim(ITEM.mbm_code) = 'M' THEN TRUE ELSE FALSE END AS
filtro_modulados -- filtro productos modulados
, CASE WHEN concat(cast(ITEM.item_type_code as string), '-'
, cast(ITEM.repl_subtype_code as string)) not in ('20-3', '20-4', '37-87', '3-0', '7-
0') THEN TRUE ELSE FALSE END AS filtro_in_out -- filtro de productos in&out
, CASE WHEN FINE.mdse_subgroup_nbr NOT IN (184,185,187,188) THEN TRUE ELSE
FALSE END AS filtro_gm --filtro de GM
, CASE
WHEN (fillrate_1m IS NOT NULL) AND (fillrate_1m>=0.75) THEN TRUE
ELSE FALSE
END AS filtro_fillrate -- filtro de fillrate
, CASE WHEN instock_recovery = 1 THEN FALSE ELSE TRUE END AS
filtro_instock_recovery
, qty_unidades
, qty_sgs
, qty_dias_venta
, relacion
, ponderador
, venta_diaria_estimada
, ratio_venta
, percentile99_venta
, CASE
WHEN CEIL(SAFE_DIVIDE(percentile99_venta, venta_diaria_estimada))>7 THEN 7
WHEN SAFE_DIVIDE(percentile99_venta, venta_diaria_estimada) IS NULL THEN 7
ELSE CEIL(SAFE_DIVIDE(percentile99_venta, venta_diaria_estimada))
END AS doh
, IFNULL(SAFE_DIVIDE(vnpk_qty, venta_diaria_estimada), 0) as dos
FROM metrics_item metrics
LEFT JOIN `wmt-edw-prod.K2_WM_VM.ITEM` ITEM
ON ITEM.REPL_GROUP_NBR = metrics.repl_group_nbr AND ITEM.OLD_NBR =
metrics.item_nbr
LEFT JOIN `wmt-edw-prod.WW_MDSE_DM_VM.FINELINE_DIM` FINE
ON FINE.DEPT_NBR = ITEM.DEPT_NBR AND FINE.FINELINE_NBR = ITEM.FINELINE_NBR
LEFT JOIN `wmt-edw-sandbox.WM_AD_HOC_K2_OSC.MAX_DOH_CAT_TH_CE` DOH
ON FINE.DEPT_CATEGORY_NBR = DOH.CATEGORY_NBR
INNER JOIN `wmt-edw-prod.K2_WM_VM.INFOREM_MANAGED_SKU` T2
ON T2.ITEM_NBR = ITEM.ITEM_NBR AND T2.STORE_NBR = metrics.store_nbr
LEFT JOIN `wmt-edw-prod.K2_WM_REPL_VM.GRS_FULFILLMENT_PARM` GRS1

```

```

        ON GRS1.ITEM_NBR = ITEM.ITEM_NBR AND GRS1.STORE_NBR = T2.STORE_NBR AND
GRS1.STORE_NBR = metrics.store_nbr
    LEFT JOIN `wmt-edw-prod.K2_WM_REPL_VM.CHANNEL_MTHD_TXT` GRS2
        ON GRS2.CHANNEL_MTHD_CD = GRS1.CHANNEL_MTHD_CD
    LEFT JOIN item_in_store incl1
        ON incl1.store_nbr = metrics.store_nbr AND ITEM.REPL_GROUP_NBR =
incl1.repl_group_nbr
    LEFT JOIN fillrate_ult_1m fill1
        ON fill1.store_nbr = metrics.store_nbr AND ITEM.REPL_GROUP_NBR =
fill1.repl_group_nbr
    LEFT JOIN (
        SELECT
            repl_group_nbr
            , old_nbr
            , 1 as instock_recovery
        from `wmt-edw-sandbox.WM_AD_HOC_K2_OSC.INSTOCK_RECOVERY_NSP_V1`
    ) insrec
        ON ITEM.REPL_GROUP_NBR = insrec.repl_group_nbr AND ITEM.OLD_NBR =
insrec.old_nbr
    LEFT JOIN `wmt-edw-sandbox.WM_AD_HOC_K2_OSC.NUNCA_SIN_3F_VIEW` nuncasin
        ON ITEM.PRODUCT_NBR = nuncasin.PRODUCT_NBR AND nuncasin.FORMATO_CL="LIDER"
    where true
        and FINE.COUNTRY_CODE = 'K2'
        and FINE.CURRENT_IND = 'Y'
        and T2.STORE_NBR in (select local from tiendas)
        --and ITEM.OBSOLETE_DATE IS NULL
    )

select
    distinct
    store_nbr
    , cast(repl_group_nbr as int64) as repl_group_nbr
    , cast(old_nbr as int64) as old_nbr
    , cast(upc_nbr as int64) as upc_nbr
    , signing_desc
    , fineline_nbr
    , dept_subcatg_nbr
    , dept_subcatg_desc
    , dept_nbr
    , dept_desc
    , dept_category_nbr
    , dept_category_desc
    , item_type_code
    , repl_subtype_code
    , type_subtype
    , mdse_subgroup_desc
    , mdse_segment_desc
    , whse_align_type_cd
    , whse_area_code
    , almacenamiento
    , item_status_code
    , cancel_wnh_out_ind
    , mbm_code
    , vendor_nbr

```

```

, doh_max
, vendor_seq_nbr
, channel_mthd_desc
, channel_mthd_cd
, nunca_sin
, item_length_qty
, item_height_qty
, item_width_qty
, item_dim_uom_code
, item_weight_qty
, item_weight_uom_cd
, pallet_ti_qty
, pallet_hi_qty
, vnpk_qty
, round(fillrate_1m, 3) as fillrate_1m
, qty_unidades
, qty_sgs
, qty_dias_venta
, round(relacion, 5) as relacion
, round(ponderador, 5) as ponderador
, rank() over (PARTITION BY store_nbr ORDER BY ponderador desc) as ranking
, round(venta_diaria_estimada, 3) as venta_diaria_estimada
, ratio_venta
, round(percentile99_venta, 5) as percentile99_venta
, round(doh, 5) as doh
, round(dos, 5) as dos
, round(IFNULL(SAFE_DIVIDE(doh, DOS), 0), 5) as cajas_objetivo
, round(IFNULL(CEIL(SAFE_DIVIDE(doh, DOS)), 0), 1) as cajas_objetivo_aprox
, round(IFNULL(SAFE_DIVIDE(vnpk_qty*IFNULL(CEIL(SAFE_DIVIDE(doh, DOS)), 0),
venta_diaria_estimada), 0), 3) as doh_cajas_objetivo
, filtro_item_en_store
, filtro_activo
, filtro_cancel_when_out
, filtro_carnes_granel
, filtro_pesables
, filtro_ffvv
, filtro_modulados
, filtro_in_out
, filtro_gm
, filtro_instock_recovery
, filtro_fillrate
, CASE
  WHEN filtro_item_en_store=TRUE AND filtro_activo=TRUE AND
filtro_cancel_when_out=TRUE AND filtro_carnes_granel=TRUE
  AND filtro_pesables=TRUE AND filtro_ffvv=TRUE AND filtro_modulados=TRUE
AND filtro_in_out=TRUE AND filtro_gm=TRUE
  AND filtro_instock_recovery=TRUE
  THEN TRUE
  ELSE FALSE
END AS candidatos_sin_fr
, CASE
  WHEN filtro_item_en_store=TRUE AND filtro_activo=TRUE AND
filtro_cancel_when_out=TRUE AND filtro_carnes_granel=TRUE

```

```

        AND filtro_pesables=TRUE AND filtro_ffvv=TRUE AND filtro_modulados=TRUE
AND filtro_in_out=TRUE AND filtro_gm=TRUE
        AND filtro_fillrate=TRUE AND filtro_instock_recovery=TRUE
        THEN 'true'
        WHEN filtro_item_en_store=TRUE AND filtro_activo=TRUE AND
filtro_cancel_when_out=TRUE AND filtro_carnes_granel=TRUE
        AND filtro_pesables=TRUE AND filtro_ffvv=TRUE AND filtro_modulados=TRUE
AND filtro_in_out=TRUE AND filtro_gm=TRUE
        AND filtro_fillrate IS NULL AND filtro_instock_recovery=TRUE
        THEN 'revisar_fr'
        ELSE 'false'
        END AS candidatos
FROM venta_filtro

```

order by ranking