

Informe pasantía

## **Mejorar la Emisión de Alertas en la Detección de Objetos**

Florencia Saavedra

Ingeniería Civil Informática

Graymatics

10 de Noviembre, 2023



## **Índice**

2. Índice.
3. Resumen ejecutivo.
4. Introducción.
5. Oportunidad.
7. Objetivos.
8. Metodologías.
11. Medidas de Desempeño.
12. Estado del Arte y Propuestas de Solución.
14. Solución escogida y criterios utilizados.
16. Análisis de riesgos
18. Análisis económico
19. Desarrollo e implementación del proyecto basado en la metodología.
31. Conclusión
33. Anexo

## **Resumen Ejecutivo**

El proyecto en curso, titulado "**Mejorar la Emisión de Alertas en la Detección de Objetos**", se encuentra en un contexto empresarial liderado por Graymatics, una destacada empresa de inteligencia artificial con experiencia en soluciones de detección de objetos. El enfoque principal de esta iniciativa es abordar un desafío crítico que enfrenta la industria de procesamiento de carne en su intento de aumento de productividad y los falsos positivos en las diferentes analíticas que han solicitado. Cabe destacar que la empresa en cuestión decidió continuar con el proyecto, a pesar de las dificultades, generando así la necesidad en Graymatics de mitigar estos falsos positivos lo más posible. Se realizó un análisis completo de las diferentes metodologías a implementar para poder cumplir el objetivo principal. Esto a través de desarrollar algoritmos de detección de objetos de última generación, con el objetivo de mejorar de manera significativa la precisión de las analíticas.

Una parte importante del proyecto es desarrollar e implementar la metodología que permite reducir los falsos positivos relacionados con la productividad de los trabajadores en la línea de producción. Esta metodología se convierte en un elemento clave para distinguir entre movimientos legítimos y validación de detección que requieren atención.

La evaluación del éxito del proyecto se realizó mediante diversas medidas de desempeño. Esto incluye, en primer lugar, la medición de la precisión en las analíticas, lo que aumenta de manera significativa. Además, se espera una reducción sustancial en la ocurrencia de falsos positivos, lo que, a su vez, mejorará la eficiencia operativa al entregar información fidedigna y reducir el tiempo de procesamiento.

## **Introducción**

La empresa Graymatics donde se desarrollara el proyecto de pasantía es el líder de la inteligencia artificial y Deep Learning en Asia, donde ha ido revolucionando rubros con su implementación en diversas áreas para mejorar seguridad, productividad y eficiencia contando con una base de más de 100 analíticas.

Esta se ha desarrollado en diferentes tipos de proyecto, generando soluciones innovadoras con sus avanzadas tecnologías. Uno de los grandes proyectos ha sido Smartcities de India, en la cual se desarrollan estos avances para robos, congestiones de tráfico, violencia hacia las mujeres emitiendo alertas en tiempo real para permitir intervención inmediata. Además permite obtener datos de sistemas como el transporte público, entregando información importante para mejorar el servicio y la experiencia.

Graymatics busca entregar soluciones de alto valor a sus clientes desarrollando algoritmos específicos según las necesidades de cada analítica. Esto utilizando tecnologías de vanguardia como nvidia, yolov7-8, modelos de deep learning que potencien y agilicen el desarrollo de estas soluciones.

Graymatics está altamente capacitado para resolver todo tipo de problemas relacionados al entrenamiento de modelos de IA y machine learning, el gran desafío de este proyecto radica en las analíticas solicitadas: Conteo de personal con casco gris, Conteo de carne en la cinta y Conteo de tempo que cada trabajador pasa en la cinta. La ubicación de las cámaras y formato de trabajo de la empresa permiten un alto número de falsos positivos en las alertas emitidas, lo cual afecta indiscutiblemente en el análisis de productividad que se realizará posteriormente.

## Oportunidad

El proyecto "Mejorar de la Emisión de Alertas en la Detección de objetos" surge en respuesta a una necesidad crítica para satisfacer al cliente dentro de Graymatics, donde la eficiencia y la precisión son fundamentales. La oportunidad radica en abordar un desafío común que enfrentan las empresas de IA, machine learning y específicamente detección de objetos: la detección precisa de objetos y su coherencia con la analítica.

Las analíticas son: Recopilación de información sobre (i) la cantidad total de carne procesada, (ii) el número total de trabajadores con cascos grises que procesan esta carne y (iii) el tiempo total que los trabajadores dedican a procesar la carne. Un ejemplo simple de cómo podríamos obtener una idea de la productividad sería: Número de trabajadores en la cinta: 5 ; Cantidad de carne procesada: 10 ; Cantidad de tiempo que estos trabajadores estuvieron en la cinta: 30 minutos ; 10 carnes / 5 trabajadores = 2 por trabajador en 30 minutos = cada trabajador procesa 1 carne durante 15 minutos. Esto no es del todo correcto, ya que estaríamos dejando de lado múltiples factores que podrían o no hacer este proceso más lento, como la velocidad de la cinta o la cantidad de carne en un tiempo determinado.

El kpi será la productividad que se desplegará ya calculada en la interfaz, esta se calcula por intervalo de tiempo único, por lo tanto en un tiempo x, la cantidad de carnes dividido en la cantidad de cascos que hubo en el intervalo x, será la productividad.

$$KPI = \frac{\text{Cantidad de Cascos en el intervalo } x}{\text{Cantidad de Carnes en el Intervalo } x}$$

Como se mencionó anteriormente, debido a las analíticas solicitadas por el cliente, se pudo prevenir y detectar una serie de causas por las que habrían falsos positivos que podrían entregar información errónea. En primer lugar porque estos dependen de en qué forma entrenaremos el modelo de detección de objeto en este caso si se entrena el modelo con muchas iteraciones ocurrirá *overfitting*, donde el modelo pierde el sentido de generalización, es decir se vuelve muy específico con la data de

entrenamiento y muy pobre respecto a la nueva. Caso contrario y el actual en el proyecto donde el cliente, Agrosuper, entregó muy pocos videos y con imágenes de mala calidad, esto debido a que la detección de objetos funciona diciéndole al modelo “esto es un casco gris”, pero si existe un objeto de tamaño similar y gris, entonces detectara un falso positivo

La oportunidad que se presenta es generar diferentes estrategias para mitigar falsos positivos y en consecuencia mejorar significativamente la precisión en la detección de trozos de carne, tiempo de trabajador en su zona y cuántos trabajadores se encuentran en la cinta. Al abordar esta oportunidad, Graymatics demuestra su capacidad para ofrecer soluciones personalizadas de inteligencia artificial de vanguardia en un sector industrial crítico. Esta mejora no solo beneficia a la empresa en términos de eficiencia y rentabilidad, sino que también fortalece su posición como líder en la industria de la inteligencia artificial y la detección de objetos.

En resumen, el proyecto se basa en la identificación de una oportunidad estratégica para mitigar los falsos positivos y mejorar la detección de objetos, lo que conlleva a una serie de beneficios operativos y económicos tanto para Graymatics como para sus clientes en el sector.

## **Objetivos**

Objetivo General (SMART): Desarrollar una metodología estratégica que logre mitigar falsos positivos para poder mejorar la eficiencia y precisión en la detección de objetos en la línea de producción de la industria de procesamiento de carne a través de la implementación de algoritmos avanzados de detección de objetos durante las semanas de instalación al menos en un 30%.

Objetivos Específicos (SMART):

1. **Definir condiciones y parámetros determinantes del proyecto:** Antes de desarrollar una metodología debemos tener en claro el alcance y las posibilidades del proyecto en base a las condiciones existentes.
2. **Optimización de Algoritmos de Detección:** Refinar y ajustar los algoritmos YOLOv7 y YOLOv8 para su integración con la metodología y en el sistema de detección de Graymatics, con el fin de aumentar significativamente la precisión en la identificación de objetos.
3. **Evaluación Integral del Rendimiento:** Medir y evaluar el rendimiento del sistema mejorado, considerando métricas de precisión en la detección, reducción de falsos positivos y eficiencia operativa. Analizar los resultados del modelo entrenado y el piloto que se desarrollará.

## **Metodologías**

En base a los objetivos que se deben alcanzar, se realizará un **Análisis de factores para una posible Metodología para mitigar los falsos positivos en las analíticas solicitadas**. Se estudiaron y analizaron condiciones concretas para una metodología integral que reduzca los falsos positivos.

En primer lugar está la data de entrenamiento, donde el cliente solo entregó aproximadamente 72 horas de videos por cámara, cada frame fue tomado con una diferencia de 100 seg para poder obtener imágenes de situaciones diferentes, lo que también redujo la cantidad (500-800 frames) para entrenar el modelo, que como se mencionó antes pueden generar varios problemas, ya que el modelo puede no adquirir suficiente conocimiento y capacidad de generalización para realizar detecciones precisas. Por una parte está el *overfitting* que ocurre cuando el conjunto de datos de entrenamiento es pequeño, el modelo aprenderá a memorizar los ejemplos de la data de entrenamiento en lugar de aprender patrones generales. Este problema se evidencia cuando el modelo que funciona bien en el conjunto de entrenamiento, pero tiene un mal rendimiento en datos no vistos como las pruebas futuras. Otro problema será la falta de capacidad de generalización cuando existe una falta de diversidad en el conjunto de entrenamiento, lo que limita la exposición del modelo a una variedad suficiente de situaciones y objetos, por lo que el modelo no es capaz de generalizar adecuadamente a nuevas situaciones o tipos de objetos. Por lo tanto, podría tener dificultades para detectar objetos en condiciones diferentes a las del conjunto de entrenamiento.

Además, como se muestra a continuación, las condiciones de la imagen no son las ideales.



Aquí claramente podemos apreciar una imagen borrosa y de una calidad baja, esto afecta directamente en el rendimiento del modelo de detección de objetos se verá afectado negativamente si las imágenes de entrada son de mala calidad o borrosas. Esto se debe a que los modelos de detección de objetos, como YOLOv8, dependen en gran medida de la calidad y la claridad de las imágenes para funcionar correctamente. Esto incide directamente en el proyecto ya que disminuye en la precisión, provocando que los objetos sean menos distinguibles o que sus contornos no sean nítidos. Esto puede llevar a que el modelo de detección de objetos no sea capaz de identificar los objetos correctamente. También la falta de claridad en las imágenes puede hacer que el modelo detecte objetos que no están presentes o que interprete ruido o artefactos como objetos reales. Esto puede resultar en falsos positivos en las detecciones.

Luego tenemos otros factores como formato de trabajo, se conoce por parte del área de productividad que existen turnos de 8 horas por trabajador, con un descanso cada tres o cuatro horas que es cuando la cinta y el piso se limpian, el mesón de trabajo se ordena. Además, cada trabajador puede ir al baño si así lo necesita, esto es importante sobre todo en el momento de obtener el tiempo promedio de trabajador en su puesto, ya que si se va y regresa otro, no sabremos si serán la misma persona y el promedio será erróneo. Ahora hemos establecido los factores y condiciones tanto contextuales del cliente como de la data de entrenamiento que incidirán en el modelo al momento de entrenarlo.

Parte de los objetivos es la **Optimización de Algoritmos de Detección**, estos algoritmos de última generación se destacan por su capacidad para identificar objetos en imágenes en tiempo real con alta precisión y eficiencia. La implementación de YOLO v8 en el sistema de detección de Graymatics permitirá una detección más precisa de objetos en la línea de producción. La metodología incluye las siguientes etapas:

A. Integración en el Sistema: Los modelos entrenados se integrarán en el sistema de detección de Graymatics, reemplazando o complementando las versiones anteriores de los algoritmos y utilizando los diferentes modelos de detección de objetos.

B. Entrenamiento de Modelos: Se entregarán los modelos de detección utilizando conjuntos de datos relevantes y

representativos de trozos de carne en diversas condiciones de iluminación, posición y orientación. Además de integrar objetos que puedan ser falsos positivos como objetos gris que sean detectados como trabajadores, serán anotados e incluidos en la data de entrenamiento.

Para conseguir el objetivo de evaluación Integral del Rendimiento utilizaremos los primeros resultados del entrenamiento del modelo, en los cuales tenemos f1-score, precision y recall para poder medir y evaluar el rendimiento inicial y luego consecutivamente a través de las semanas que se implemente el modelo, considerando estas métricas lograremos analizar los resultados del modelo entrenado y obtener conclusiones sobre cómo funciona y cómo podemos mejorarlo a través de la metodología que se quiere desarrollar.

## **Medidas de Desempeño**

La evaluación del proyecto se basará en una serie de medidas de desempeño clave que reflejarán su éxito en la mejora de la detección de trozos de carne y la reducción de falsos positivos:

1.     Precisión en la detección: Se analizará y medirá la precisión de la detección del objeto después de la implementación de los algoritmos. Esto se evaluará mediante métricas de F1 score, precisión y recall, que reflejarán la capacidad del sistema para identificar objetos de manera precisa.
2.     Reducción de Falsos Positivos: Se evaluará la eficacia de la metodología al cuantificar el número de falsos positivos. La métrica clave será obtener un parámetro inicial de falsos positivos durante las fases de implementación, comparando unas con otras.
3.     Impacto económico: Aunque el proyecto no requiere costos adicionales para Graymatics, se evaluará el impacto económico en términos de ahorro potencial en costos operativos para la empresa de procesamiento de carne. Esto incluirá una estimación de los ahorros en términos de recursos (Ingenieros) y tiempo dedicados a la gestión de falsos positivos.
4.     Satisfacción del Cliente: La satisfacción del cliente se medirá a través de la retroalimentación directa de la empresa de procesamiento de carne. Se recopilará información sobre la utilidad percibida de la solución y cómo ha estado funcionando a través de la plataforma UI para el cliente.

Estas medidas de desempeño permitirán una evaluación integral y cuantitativa de los resultados del proyecto y aseguraron que se cumplan los objetivos establecidos de mejora en la detección de objetos en la cinta de carne.

## Estado del Arte y Propuestas de Solución

Para poder plantear una solución coherente y que tenga resultados óptimos es necesario comprender plenamente el contexto del proyecto, es esencial conocer el estado actual de la detección de objetos y de las soluciones de inteligencia artificial utilizadas en este campo.

**Estado Actual de la Inteligencia Artificial en Detección de Objetos:** En el campo de la inteligencia artificial, se han producido avances significativos en la detección de objetos en los últimos años. Algoritmos como YOLO (You Only Look Once) y sus versiones posteriores (YOLOv7 y YOLOv8) han demostrado ser efectivos para detectar objetos en tiempo real. Estos algoritmos utilizan redes neuronales convolucionales y técnicas de aprendizaje profundo para identificar y clasificar objetos en imágenes y videos.

El uso de YOLOv8 para entrenar el modelo se justifica por su eficiencia en tiempo real, capacidad para manejar múltiples clases de objetos simultáneamente, facilidad de implementación gracias a su arquitectura de red profunda basada en Darknet, disponibilidad como proyecto de código abierto que permite personalización, desarrollo activo con actualizaciones continuas, buena relación rendimiento-precisión, y requisitos de hardware moderados. Su diseño específico para detección en tiempo real, junto con la capacidad de trabajar con diversos tipos de objetos, lo convierte en una opción sólida. Además, su implementación sencilla y la posibilidad de acceso al código fuente facilitan la integración en el proyecto, ofreciendo flexibilidad y control.

En el estado del arte, se observan diferentes soluciones para la detección de objetos:

- **Series de tiempo:** Como los datos respectivos se tratan de una serie temporal, se puede hacer algo muy avanzado diciendo, "existe esta serie temporal, y construir un modelo de series temporales para estimar el tiempo que cada trabajador ha invertido".
- **Metodología de tiempo:** Se pre definen umbrales para determinar si un trozo de objeto está siendo procesado fuera de los límites de tiempo establecidos y así mitigar falsos positivos.
- **Trucker:** se refiere a un algoritmo que permite el seguimiento continuo de un objeto a medida que se mueve a través de un flujo de imágenes o un video. Un tracker es una parte esencial en aplicaciones de seguimiento de objetos.
- **Integración de Sensores Avanzados:** Utilizar sensores avanzados, como cámaras 3D o láser, para capturar datos tridimensionales de los objetos en la línea de producción. Esto proporciona

información más precisa para la detección de objetos y reduce la probabilidad de falsos positivos.

La elección entre las diferentes opciones como las Series de Tiempo, la Integración de Sensores Avanzados, Algoritmo Trucker, etc. Se basa en una evaluación exhaustiva de las necesidades y recursos según el contexto específico de nuestro proyecto.

La implementación de Series de Tiempo, aunque efectiva para medir el tiempo invertido por los trabajadores, interfiere directamente con el recurso tiempo del proyecto, ya que habría que documentar y construir la data, además de la complejidad que conlleva. Establecer un trucker, es una solución común en esta área, en este caso sería igualmente útil, pero no es una solución completa para la complejidad de las analíticas, como es estimar el tiempo promedio de un trabajador con un trozo de carne y tampoco nos entrega una seguridad debido a la mala calidad y poca cantidad de las imágenes. La Integración de Sensores Avanzados, como cámaras 3D o láser, es prometedora, pero su costo y las modificaciones requeridas en el sistema actual son desafíos que Graymatics no está dispuesto a considerar. La metodología de tiempo destaca porque cubre una necesidad que el trucker obvia y que aborda directamente la analítica de la velocidad de los trabajadores, que sabemos que es un factor clave en la generación de falsos positivos. Además, no implica costos adicionales significativos, ya que se basa en la optimización de recursos y experiencia existente. Esta elección nos permite abordar nuestro desafío principal con eficiencia y eficacia.

## Solución Escogida y criterios utilizados

La solución escogida es una metodología multicriterio, esta decisión fue antepuesta respecto a toda esta amplia gama de soluciones debido a recursos de la empresa y fechas de entrega del cliente.

Durante el desarrollo podemos observar que aplicaremos el algoritmo de tracker, detectar e incluir objetos distractores y habrán parámetros predefinidos para poder aplicar este tipo de metodología, porque lo que se utilizaran ***soft and adaptive thresholding***.

En primer lugar, el tracker será completamente necesario para las analíticas de conteo de trozos de carne en la cinta y tiempo de un trabajador en su puesto de trabajo. Un tracker permite seguir continuamente un objeto a medida que se desplaza a través de los cuadros sucesivos, en un entorno de producción de carne, un tracker permite asignar identidades a objetos específicos y realizar un seguimiento de su tiempo de procesamiento, lo que contribuye a una mejor gestión en la detección de objetos del proyecto.

En segundo lugar, en el entrenamiento del modelo se incluyen aquellos objetos que sean detectados como cascós grises o trozos de carnes, pero que no correspondan a esta clasificación. Para ello los anotaremos y los integraremos a la data, para que luego el modelo sea capaz de detectar estos objetos y no sean considerados parte de la emisión de alertas como falsos positivos.

En tercer lugar y como último criterio de la metodología a desarrollar tenemos adaptive y *soft thresholding*, es una técnica que se utiliza en el procesamiento de imágenes para separar objetos de interés del fondo en condiciones de iluminación o condiciones variables, pero para integrar este concepto en la metodología de forma coherente lo explicaremos con ejemplos. En la primera analítica de carne, si esta no aparece lo suficiente dentro del timeframe que estableceremos, entonces se clasificará como falso, por lo tanto si esta carne ya ha sido procesada, es consecuencia de que no ha estado apareciendo lo suficiente dentro del ROI o el timeframe. Luego para la segunda analítica de personas, usaremos criterios como si aparece más del 80% en este timeframe, es una persona presente. Lo cual se torna un poco complicado, porque si la persona aparece muy raramente en el timeframe, eso es solo ruido y la persona todavía está allí, pero necesitamos decir, "no". Luego, se puede ver que las personas en el recognition stream, se han estado reduciendo en su detección. Entonces, se establece un umbral y se analiza, si esa persona, en el percentil tercero, por ejemplo, no ha estado apareciendo lo suficiente, se elimina. Y en ese momento, se realiza el cálculo de cuánta carne se procesa en ese plazo haciendo el mismo tipo de umbral, esto es lo que llamamos *adaptive*

*thresholding*. Sin duda este es uno de los métodos “hardcoded”, utilizando parámetros predefinidos el cual podría ser un 50%. Por ejemplo, apareció un 50% menos, entre eso y el parámetro base y se hace un corte, y se concluye que ese fue el momento en que los trabajadores dejaron de trabajar.

Obteniendo un dato a comparar luego para próximas observaciones. De todas formas tendremos que pre establecer algunos parámetros, dentro de las opciones previamente mencionadas la metodología integral que se desarrollara se considera una de las mejores opciones para abordar el problema de mitigar falsos positivos en la detección de objetos en la línea de producción de la industria de procesamiento de carne por varias razones:

1. **Enfoque Contextual:** Esta metodología se centra en la velocidad de los trabajadores en la línea de producción. Dado que la velocidad puede variar según el contexto, es una forma efectiva de diferenciar entre movimientos legítimos y situaciones que requieren atención. Al tener en cuenta el contexto, la solución es coherente y se pueden reducir los falsos positivos. Además de cumplir con los tiempos establecidos de entrega con el cliente.
2. **Compatibilidad con el Sistema Existente:** La implementación de esta metodología se puede realizar de manera remota y dentro del sistema de detección de Graymatics. No requiere una infraestructura de hardware adicional o una revisión completa de los algoritmos de detección, lo que lo hace eficiente en términos de costos y recursos.
3. **Efectividad Comprobada:** Las técnicas que se incluyen en la metodología steam establecidas en la industria para abordar problemas similares en sistemas de detección de objetos. Su efectividad en la reducción de falsos positivos ha sido demostrada en diversas aplicaciones es por eso que se trabaja con *soft and adaptive thresholding*.
4. **Medición de Desempeño Clara:** El impacto de esta metodología se puede medir de manera objetiva al comparar la tasa, el recall y precisión de falsos positivos como de falsos negativos a través de la semana de implementación. Esto permite evaluar con precisión su éxito y su contribución a la mejora del sistema de detección.

## Análisis de riesgos

En el análisis de riesgos para el proyecto, se han identificado varios aspectos críticos que podrían impactar la implementación exitosa de la tecnología. En primer lugar, existe el riesgo de fallos en la integración de tecnologías, con una probabilidad y un impacto considerados medianos. Este riesgo es algo común en la empresa, debido a la variedad de clientes y que cada servicio es personalizado. Por lo tanto existen protocolos y documentación necesaria para mitigar este riesgo, además se llevarán a cabo pruebas exhaustivas de integración, respaldadas por un equipo técnico especializado.

Otro riesgo significativo es la posibilidad de cambios en los requisitos del cliente, este fue abordado en una etapa previa del proyecto, donde hubo que cambiar en ciento ochenta grados los objetivos y el producto final del proyecto, por lo tanto se clasifica con una probabilidad e impacto altos, lo que resulta en un riesgo general muy alto. La mitigación propuesta implica mantener una comunicación constante con el cliente y establecer un proceso claro de aprobación de cambios para evitar posibles desviaciones del proyecto, estas reuniones semanales se incluyeron en el contrato para evitar inasistencias por parte del cliente y mitigar este riesgo.

Asimismo, se identificó el riesgo de problemas de cumplimiento legal, esta se complementa con el anterior, debido a que si bien se establecen fechas tentativas los abogados de Graymatics han establecido políticas y secciones específicas en los contratos que respaldan a la empresa, es por eso que se clasifica con una probabilidad moderada y un impacto muy alto. Para mitigar este riesgo, se implementarán medidas como la formalización de contratos, el seguimiento estricto de plazos y la adhesión a un plan estructurado para garantizar el cumplimiento normativo.

En cuanto a problemas técnicos, se reconoce un riesgo medio con un impacto alto. Por el contexto en el que se entrega el producto, este riesgo es medio, ya que tanto las cámaras como la implementación es realizada en la empresa y en el servidor del cliente respectivamente, es por eso que problemas técnicos de este tipo no dependen de Graymatics. La estrategia de mitigación propuesta implica contar con un plan organizado que abarque tanto los requisitos del proyecto como el desarrollo técnico, buscando minimizar los posibles inconvenientes para el cliente.

Adicionalmente, se incorpora la consideración de ciberseguridad como un quinto riesgo. Se identifica una probabilidad baja y un impacto alto, lo que resulta en un riesgo general medio. Nuevamente y

como se mencionó en el punto anterior, estos problemas quedan del lado del cliente, sin embargo la empresa no es indiferente y entrega medidas de prevención para mitigar este riesgo, en las cuales se proponen implementación de firewalls, el cifrado de datos, actualizaciones regulares de software y programas de concientización sobre ciberseguridad para el personal. Se destacan auditorías periódicas de seguridad como parte integral de la estrategia de mitigación, este apartado queda en manos del cliente y se les entrega un listado con las sugerencias, esto debido a que las cámaras, el servidor y la interfaz quedan implementados en productos del cliente, todo pertenece al cliente y Graymatics como empresa simplemente realiza un deployment una única vez.

### Matriz de riesgo

Descripción del Riesgo	Probabilidad	Impacto	Riesgo Resultante	Mitigaciones
<b>Fallo en la Integración de Tecnologías</b>	Medio	Medio	Medio	Realizar pruebas exhaustivas de integración; contar con un equipo técnico de respaldo.
<b>Cambios en los Requisitos del Cliente</b>	Alto	Alto	Muy alto	Mantener una comunicación constante con el cliente y establecer un proceso de aprobación de cambios.
<b>Problemas de Cumplimiento Legal</b>	Medio	Muy Alto	Alto	Establecer contratos, seguir deadlines y el plan estructurado.
<b>Problemas técnicos</b>	Medio	Alto	Alto	Tener un plan organizado con los requisitos y el desarrollo tecnico.
<b>Ciberseguridad</b>	Medio	Alto	Medio	Sugerencias en medidas de prevención

## Análisis económico

En el análisis económico del proyecto, se destaca la eficiencia en la gestión de recursos económicos, ya que el proyecto cuenta con un equipo de personal capacitado, lo cual reduce la necesidad de gastos adicionales significativos y también la elección de la solución. No obstante, se ha registrado un gasto total de \$8000 USD aproximadamente para el grupo de ingenieros asignados al proyecto.

El beneficio del proyecto se enfoca en la generación de valor, centrado en la mejora de la precisión de detección y la mitigación de errores. Este enfoque se traduce en un valor agregado para la empresa, contribuyendo a la satisfacción del cliente. Se destaca que el proyecto representa una inversión rentable que busca maximizar el retorno de la inversión, enfatizando la eficiencia en el uso de los recursos.

Es crucial subrayar que el presupuesto se ha elaborado considerando el recurso de horas hombre, y la estrategia presentada no implica gastos adicionales significativos. Bajo el lema "Maximizando el Valor, Minimizando los Costos", se busca resaltar la eficacia del proyecto al alcanzar sus objetivos sin incurrir en gastos innecesarios.

En resumen, el análisis económico del proyecto demuestra una gestión eficiente de los recursos financieros, destacando el equilibrio entre la inversión realizada y los beneficios esperados. La estrategia propuesta se alinea con la filosofía de maximizar el valor generado, asegurando al mismo tiempo la optimización de los costos asociados al proyecto.

## **Desarrollo e implementación del proyecto**

### **12.1 Desarrollo del proyecto**

Durante las primeras semanas de desarrollo de este proyecto, se llevó a cabo un proceso esencial de configuración y preparación técnica. Un componente crítico de este proceso fue la instalación y configuración de diversas dependencias que garantizarían el funcionamiento fluido de la solución. En este contexto, se trabajó en colaboración con Agrosuper, a quien se le solicitó una máquina virtual, lo que permitió una integración eficiente de las herramientas necesarias.

Las tecnologías clave que se implementaron durante esta fase incluyen CUDA de NVIDIA, el driver de NVIDIA, Docker, sistemas de gestión de bases de datos SQL, entre otros. Estas tecnologías se consideran fundamentales para el desarrollo y la ejecución exitosa de la metodología y su aplicación en el entorno industrial de procesamiento de carne. La configuración de estas herramientas proporciona la infraestructura necesaria para abordar los desafíos planteados y brinda una base sólida para el trabajo técnico que se describe en esta sección del informe.

En paralelo y también como una actividad clave se realizó la definición de la región de interés (ROI) lo que es clave para evitar detección de objetos que puedan ser reconocidos como falsos positivos. Como paso siguiente se anotaron los frames que fueron extraídos de los videos enviados por el cliente. Dentro de las anotaciones, que fueron realizadas con LabelImg, establecimos dos *labels*, “helmet” y “meat”, dejando 600 archivos en formato pascal para el entrenamiento del modelo.

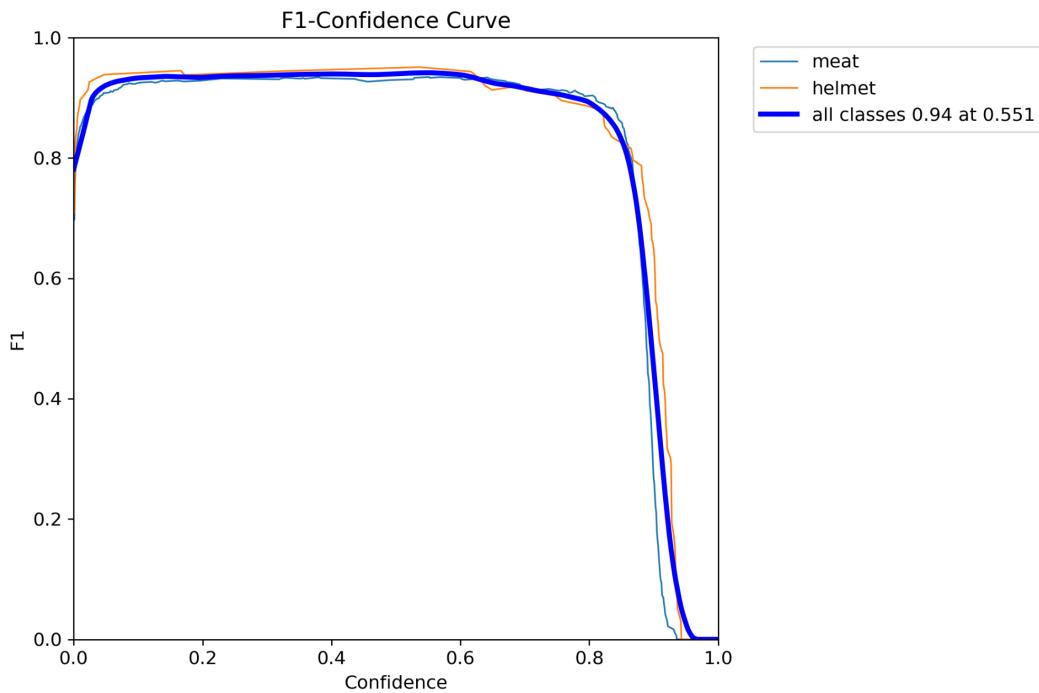
Una vez teniendo esta base técnica sólida, la cual es necesaria para desarrollar el entrenamiento del modelo. En el entrenamiento del modelo, decidimos establecer un nivel de confianza 0.95, los porcentajes de confianza significan que en promedio si se repite el proceso de entrenamiento muchas veces el intervalo de confianza del modelo incluirá el verdadero valor del parámetro en aproximadamente el 95% de las ocasiones. Esto proporciona una medida robusta de la incertidumbre asociada con las estimaciones del modelo. Con este porcentaje estamos equilibrando la precisión y la tolerancia al error, siendo muy utilizado como un punto de referencia y aceptado, además este valor lo ajustaremos validando el rendimiento del modelo a lo largo de la implementación del proyecto según las necesidades específicas del problema y las restricciones de tolerancia al error. En conclusión y alineando con el objetivo del proyecto, un nivel de confianza del 95% ayudará a reducir la probabilidad

de obtener falsos positivos.

Respecto a los porcentajes de división asignados en entrenamiento, validación y prueba, estos dependen de varios factores, incluyendo la cantidad de datos disponibles, la complejidad del modelo y las características específicas del problema que fueron explicadas en detalle anteriormente. En un entorno dinámico es muy probable que se puedan generar falsos positivos, por lo tanto es crucial diseñar una división de datos que permita evaluar de manera efectiva el rendimiento del modelo. En este proyecto los datos son limitados, por lo que se optó por una proporción de 60-20-20, debido a las condiciones del proyecto la evaluación continua del modelo es crucial es por eso que la proporción entre conjuntos no es rígida y puede ajustarse según las necesidades específicas a través de lo observado en las semanas de implementación.

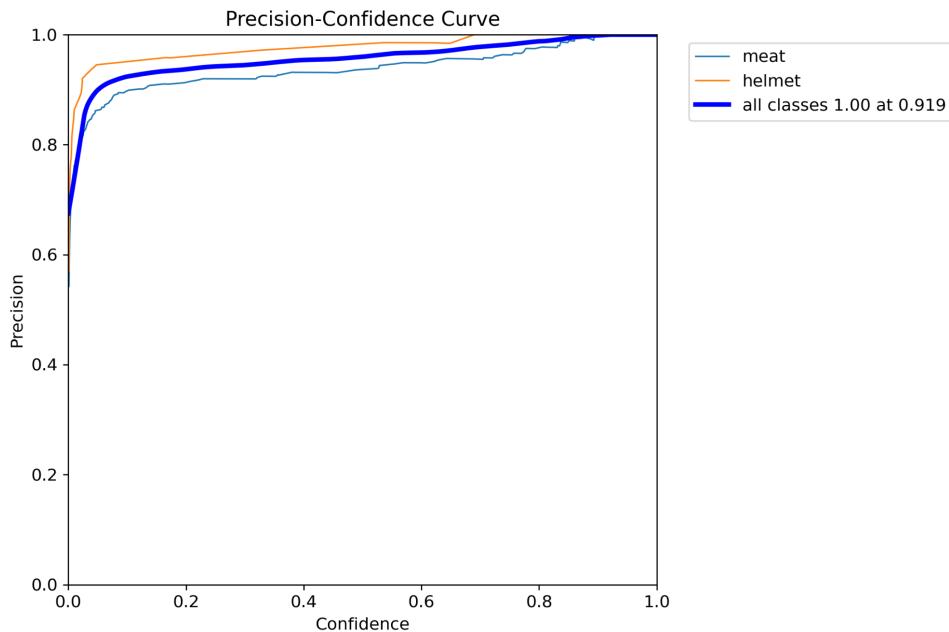
Teniendo las anotaciones, la división de la data y el porcentaje de confianza, se entrenó el modelo con YOLOv8 y los resultados obtenidos que observaremos a través de los gráficos fueron los siguientes.

"Curva de Confianza F1"



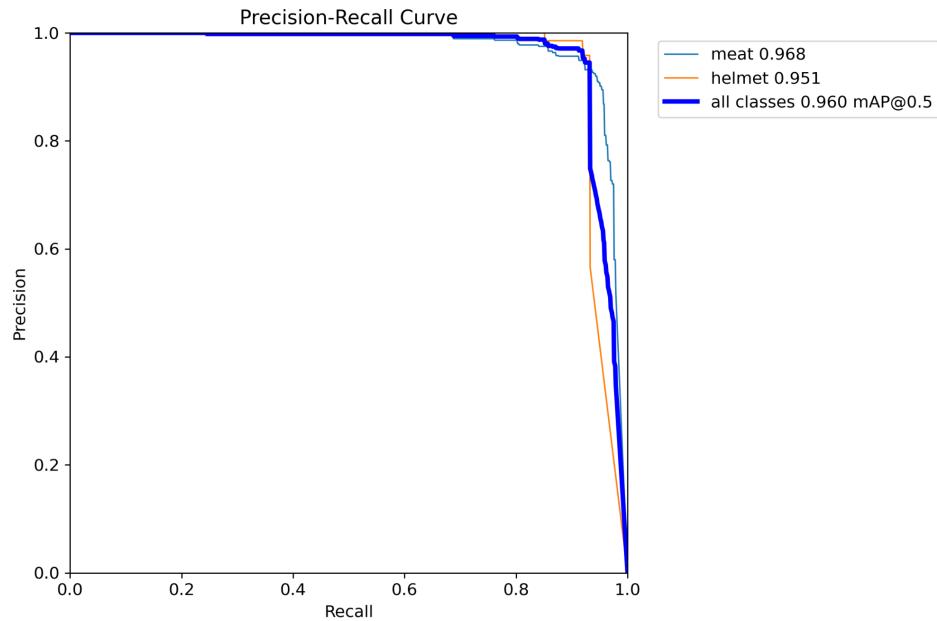
*El eje x representa el porcentaje de confianza mientras que el eje y muestra el valor del puntaje F1 correspondiente. Aquí podemos observar cómo varía el rendimiento del modelo en términos de precisión y recall en función de la confianza. Lo importante de este gráfico es el área bajo la curva F1-confidence, si es más amplia indica una mejor capacidad del modelo para equilibrar precisión y recall a lo largo de diferentes niveles de confianza, es importante observar estos gráficos para luego compararlos a través de las semanas de implementación con las mejoras del modelo una vez aplicada la solución.*

*"Curva de Confianza de Precisión"*



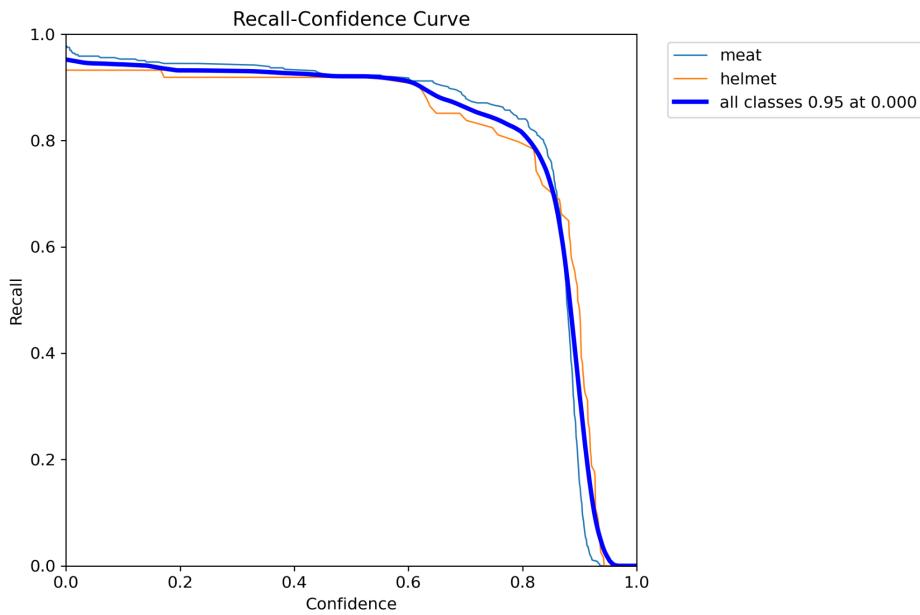
*La curva de precisión y confianza muestra la relación entre la precisión y el porcentaje de confianza.. La curva nos muestra cómo la precisión del modelo varía a medida que se ajusta el umbral de confianza para tomar decisiones. El área bajo la curva muestra si la capacidad es más robusta en el modelo para realizar predicciones precisas en diferentes niveles de confianza. Esta curva tiene como objetivo identificar el punto óptimo donde se logra un equilibrio adecuado entre la precisión de las predicciones y la confianza del modelo.*

*“Curva de precisión-exhaustividad”*



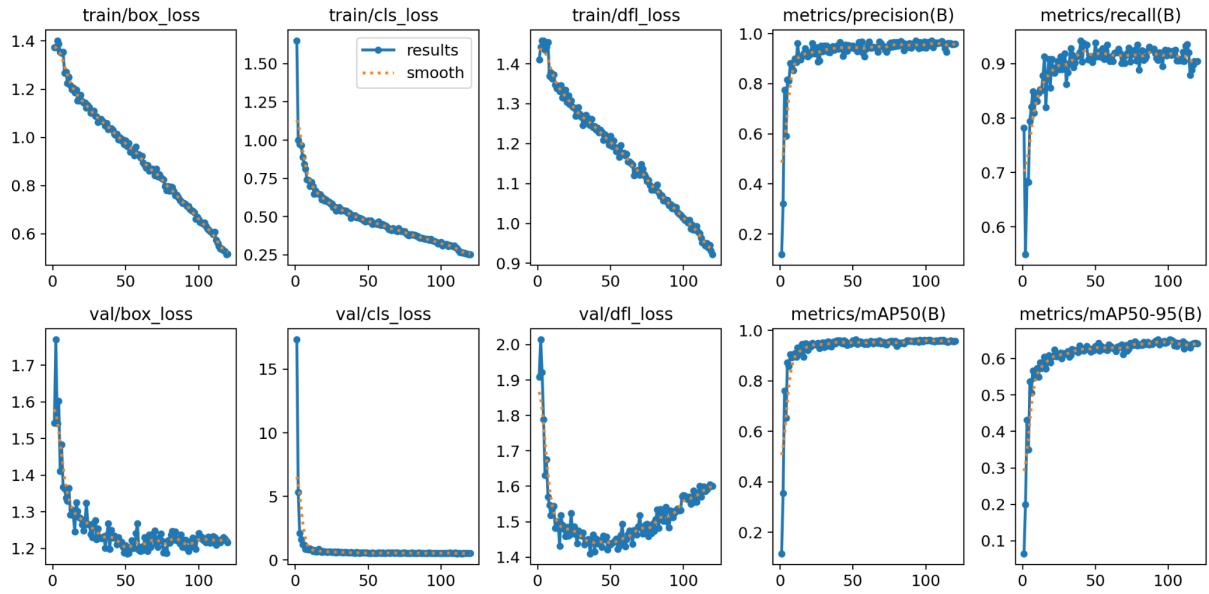
*La curva precision-recall muestra el rendimiento del modelo en relación con la precisión y recall. En este gráfico, el eje x muestra el recall, que es la proporción de instancias positivas identificadas correctamente con respecto al total de instancias positivas reales, mientras que el eje y representa la precisión, que es la proporción de instancias positivas identificadas correctamente con respecto al total de instancias clasificadas como positivas. En la curva cada punto representa un equilibrio diferente entre precisión y exhaustividad. Al analizar la curva, se puede identificar el punto óptimo donde se logra un equilibrio adecuado entre estas dos métricas. Un área bajo la curva más grande indica un mejor rendimiento general del modelo en términos de precisión y recall. Este gráfico proporciona información sobre la capacidad para clasificar correctamente las instancias positivas, a medida que transcurran las semanas de implementación veremos como mejora.*

### *"Curva de Confianza de Exhaustividad"*



*La curva de recall y confianza nos muestra el rendimiento de un modelo de clasificación binaria en relación con recall y el porcentaje de confianza. La curva se genera variando el umbral de decisión del modelo, y cada punto en la curva representa un equilibrio diferente entre recall y confianza. La utilidad del gráfico es identificar el punto óptimo donde se logra un equilibrio adecuado entre el recall y el porcentaje de confianza. Un área bajo la curva más grande sugiere una capacidad más robusta del modelo para identificar correctamente las instancias positivas a diferentes niveles de confianza. Este análisis es crucial para comprender su desempeño cuando la identificación precisa de instancias positivas es fundamental.*

*"Análisis Integral del Rendimiento del Modelo a través de Diversos Gráficos durante el Entrenamiento"*



Los siguientes 10 gráficos proporcionan una visión integral del rendimiento de un modelo de entrenamiento de detección de carne y cascos. Los gráficos "train/box\_loss" y "train/cls\_loss" representan las pérdidas de caja (estas guían al modelo para que aprenda a colocar las cajas de detección de objetos en las posiciones correctas dentro de la imagen.) y clasificación durante el entrenamiento, respectivamente. Estos disminuyen de manera constante a lo largo del tiempo de entrenamiento, indicando que el modelo está aprendiendo a ajustar las cajas y clasificarlas de manera más precisa. Por otro lado, los gráficos "metrics/precision(B)" y "metrics/recall(B)" dan información sobre la precisión y la exhaustividad (recall) del modelo en el conjunto de entrenamiento. Estos aumentan, señalando que el modelo está haciendo predicciones más precisas en el conjunto de entrenamiento y están capturando más efectivamente todos los objetos relevantes en el conjunto de entrenamiento. Los gráficos "val/box\_loss" y "val/cls\_loss" son aplicados al conjunto de validación, evaluando así el rendimiento del modelo en datos no vistos. Estos muestran una tendencia decreciente, pero puede haber un ligero aumento debido a la generalización del modelo a datos no vistos. Finalmente, los gráficos "metrics/mAP50(B)" y "metrics/mAP50-95(B)" representan la precisión media promedio (mAP) en el conjunto de validación, considerando diferentes umbrales de confianza para las detecciones. Debería aumentar, indicando una mejora en la precisión de las detecciones en el conjunto

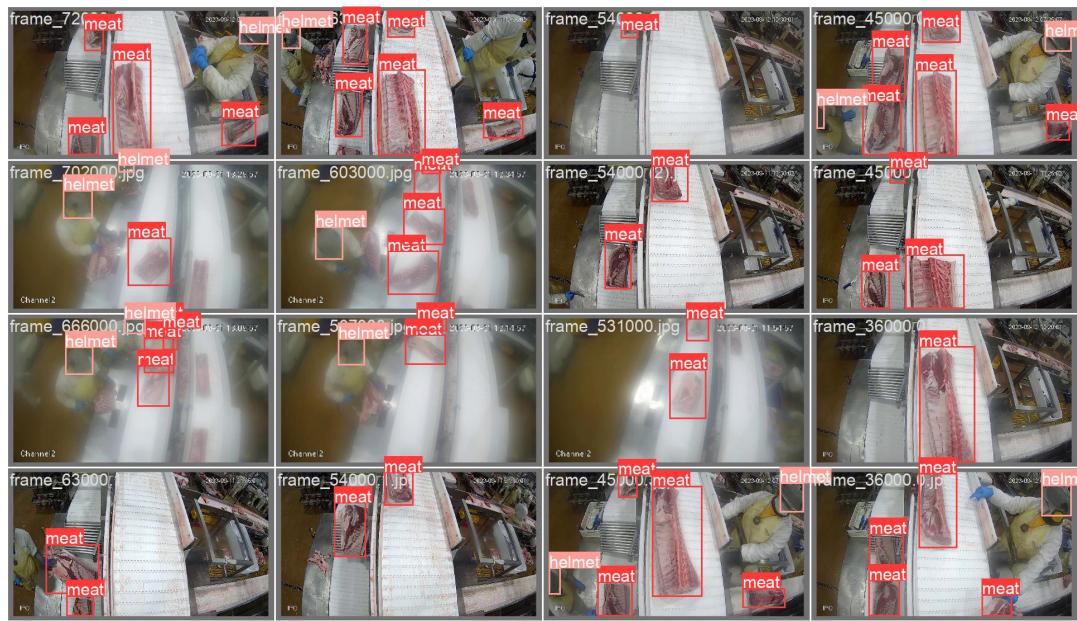
*de validación y mejora en la precisión de las detecciones a diferentes niveles de solapamiento.*

*“Identificación Binaria por el Modelo (0: Carne, 1: Casco)”*



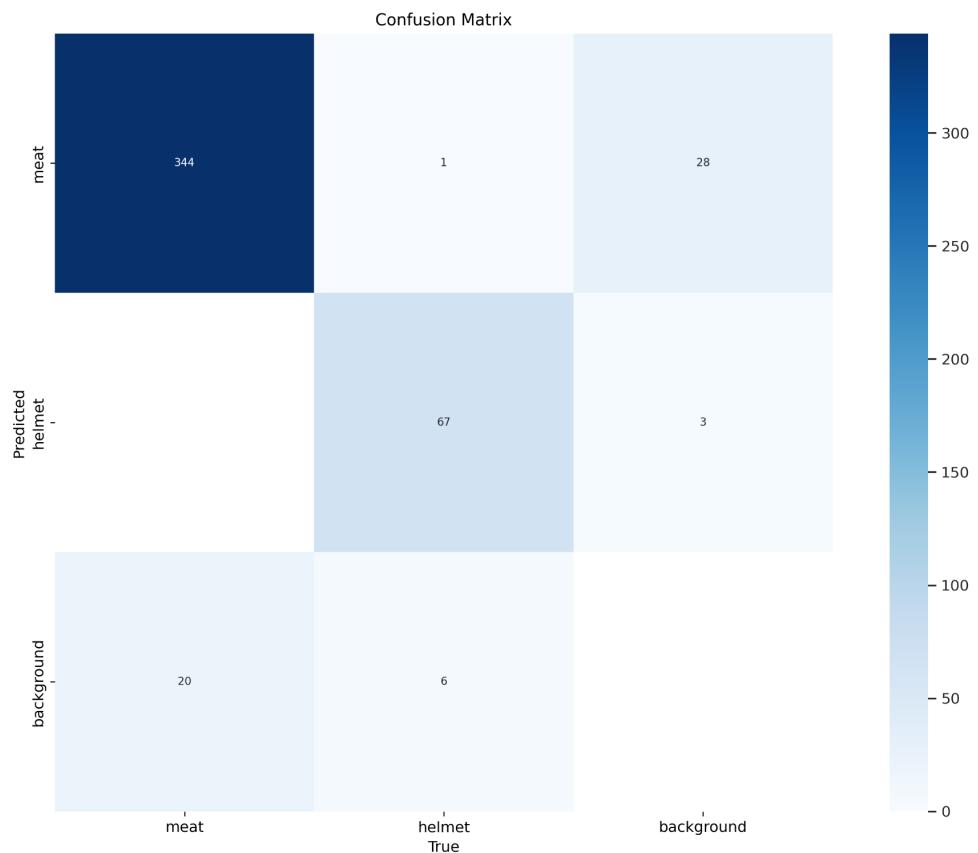
Aquí podemos ver frames del modelo identificando en forma binaria, donde 0 es carne y 1 es casco.

*“Categorización por el Modelo”*



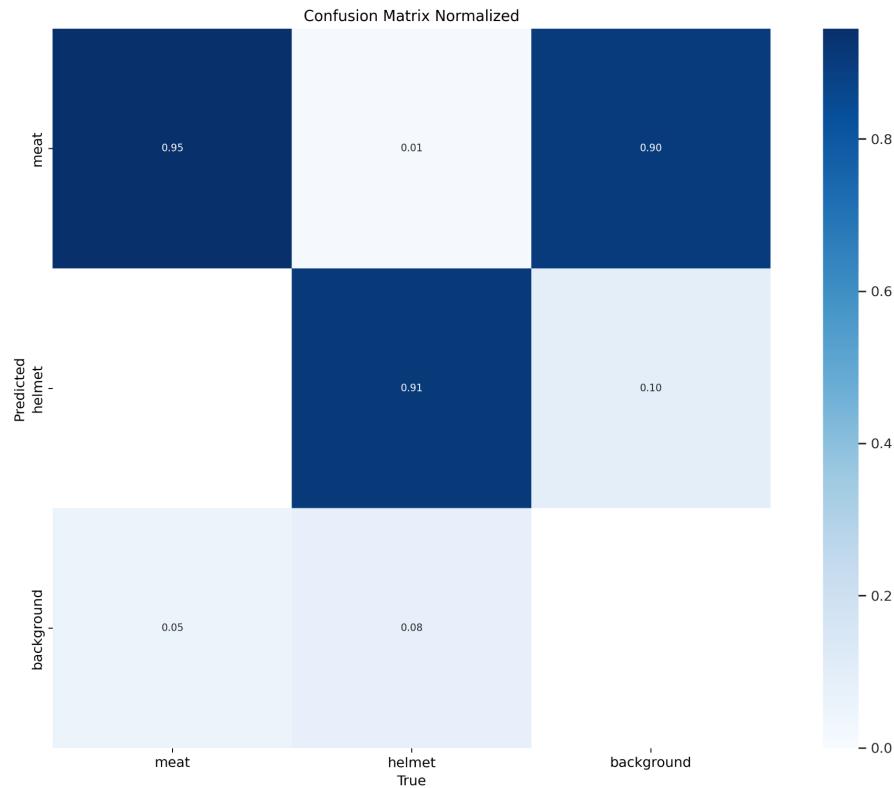
Aquí podemos ver frames del modelo categorizando, la carne y el casco.

### *“Matriz de confusión”*



*Este gráfico es uno de los más importantes debido a que muestra el rendimiento del modelo al comparar las predicciones del modelo con las clases reales en un conjunto de datos. La matriz de confusión tiene cuatro componentes principales: **Verdaderos Positivos**, **Falsos Positivos**, **Falsos Negativos** y **Verdaderos Negativos**, este gráfico nos muestra el alto número de falsos positivos en la carne.*

*“Matriz de confusión normalizada”*



*La matriz de confusión normalizada es la matriz de confusión donde el número de instancias en cada categoría se normaliza por el número total de instancias.*

- **Sensibilidad:** Proporción de verdaderos positivos con respecto al total de positivos reales ( $TP / (TP + FN)$ ).
- **Tasa de Falsos Positivos:** Proporción de falsos positivos con respecto al total de negativos reales ( $FP / (FP + TN)$ ).
- **Tasa de Falsos Negativos:** Proporción de falsos negativos con respecto al total de positivos reales ( $FN / (TP + FN)$ ).
- **Especificidad:** Proporción de verdaderos negativos con respecto al total de negativos reales ( $TN / (TN + FP)$ ).

$/ (FP + TN))$ .

Tras la etapa de entrenamiento del modelo, se procedió a implementar la interfaz gráfica para el cliente, en ella se encuentra el algoritmo desarrollado y el modelo, ofreciendo una visualización detallada del KPI de productividad. Como se puede observar en la Imagen 1, esta interfaz permite observar analíticas separadas y ofrece la capacidad de interactuar con el Adaptive & Soft Thresholding, una herramienta clave que presenta los hiperparámetros ajustables a lo largo de las semanas de implementación.

La plataforma desplegada proporciona una visión integral del rendimiento del proyecto, destacando el KPI de productividad como indicador principal. Además, ofrece analíticas detalladas que se pueden ver en la imagen 2, que permiten al cliente examinar aspectos específicos de la detección, lo que contribuye a la comprensión detallada de la mejora en la precisión y la mitigación de errores.

El Adaptive & Soft Thresholding interactivo, que se puede observar en la imagen 3, se presenta como una funcionalidad esencial, proporcionando la capacidad de ajustar los hiperparámetros. Estos ajustes predefinidos se planifican para ser modificados a lo largo del período de implementación, permitiendo una adaptación dinámica del modelo a medida que se obtienen nuevos datos y se identifican áreas para optimizar el rendimiento.

La interfaz gráfica proporciona una experiencia integral para el cliente al mostrar el KPI de productividad, las analíticas detalladas y el Adaptive & Soft Thresholding interactivo. Los hiperparámetros predefinidos serán ajustados a lo largo de las semanas de implementación para optimizar continuamente el rendimiento del modelo en función de los resultados obtenidos.

## **12.2 Informe sobre Desacuerdo en la implementación y Conclusión del Proyecto con Agrosuper**

Durante la fase de demostración del proyecto con el cliente Agrosuper, se llevó a cabo una sesión para presentar la interfaz gráfica y los resultados obtenidos. Durante esta demostración, se recibió feedback crucial por parte del cliente, quienes expresaron el deseo de visualizar los intervalos de tiempo por productividad de manera independiente en el gráfico de la interfaz. Además, Agrosuper solicitó la implementación de alertas por baja o sobre productividad, con notificaciones a través de Telegram.

Estos requerimientos adicionales desencadenaron un desacuerdo entre ambas partes, ya que la gerencia de Graymatics estableció que no se realizaría ninguna mejora o cambio en el proyecto sin la formalización de un nuevo contrato, que debía ser firmado y pagado previamente. Esta posición se presentó como una política interna para gestionar modificaciones y expansiones en el alcance del proyecto.

En respuesta, Agrosuper expresó su preocupación y señaló que no podrían presentar el proyecto a su gerencia sin contar con las bases visuales necesarias para respaldar el estudio de productividad. Este punto de vista indicaba la necesidad crítica de visualizar los intervalos de tiempo y recibir alertas para evaluar adecuadamente el rendimiento del sistema implementado.

Lamentablemente, las negociaciones no llegaron a una conclusión satisfactoria, resultando en diferencias irreconciliables entre ambas partes. Como consecuencia, el proyecto no avanzará debido a la falta de acuerdo sobre la implementación de nuevas funcionalidades y la formalización de un contrato actualizado.

Durante la fase final de la pasantía, se buscó obtener acceso a las cámaras de Agrosuper para realizar pruebas exhaustivas y concluir el proyecto de manera integral. Sin embargo, debido a políticas internas de la empresa, la solicitud de acceso a las cámaras fue denegada. Esta limitación significativa impidió la culminación completa del proyecto y la validación en condiciones reales.

## Conclusión

El proyecto de mejora en la detección de objetos en la línea de producción de la industria de procesamiento de carne de Agrosuper ha sido un esfuerzo integral para abordar desafíos específicos en Graymatics. Desde la identificación de la necesidad hasta la implementación de soluciones avanzadas de inteligencia artificial, el proceso ha abarcado diversas etapas críticas.

En un principio, se destacó la importancia de comprender plenamente el contexto del proyecto, lo que condujo a la definición clara de objetivos centrados en la mejora de la precisión de detección y la reducción de falsos positivos. La elección de una metodología multicriterio, combinando algoritmos de seguimiento, integración de objetos distractores y adaptive & soft thresholding, se basó en criterios como eficiencia, facilidad de implementación y capacidad para adaptarse a las necesidades del proyecto.

La fase de desarrollo e implementación implicó la configuración técnica, la instalación de tecnologías clave, desarrollo de algoritmos, el entrenamiento del modelo, el despliegue de la interfaz gráfica y la presentación piloto con todo funcionando. Se proporcionó una visualización detallada de los KPI de productividad y de técnicas como adaptive & soft thresholding.

A pesar de que el proyecto no alcanzó su fase de implementación completa, es crucial reconocer que la fundamentación teórica y las decisiones estratégicas iniciales han establecido una base sólida para futuras iniciativas. La elección del porcentaje de confianza, la división adecuada de la data y otros pasos iniciales demostraron ser decisiones fundamentales que permitieron el entrenamiento efectivo del modelo. Estos elementos han proporcionado resultados prometedores en términos de precisión y recall, estableciendo una estructura robusta para abordar el problema de los falsos positivos.

Es cierto que la incorporación de objetos a la data, con especial atención a aquellos que podrían ser clasificados como falsos positivos, no pudo llevarse a cabo completamente. Sin embargo, la metodología planteada y el proceso de anotación de datos sentaron las bases para futuras mejoras y refinamientos. El análisis con soft & adaptive thresholding, aunque no pudo ser implementado por completo, ha sido diseñado con una perspectiva adaptable, permitiendo ajustes continuos a medida que se acumulan más datos y se identifican patrones específicos en el entorno de producción.

Este punto de interrupción en el proyecto brinda una muy valiosa oportunidad para reflexionar sobre

aprender y fortalecer las estrategias para enfrentar desafíos similares en el futuro. La capacidad de reconocer las limitaciones actuales y la disposición para adaptarse a nuevas condiciones son esenciales en el ámbito de la inteligencia artificial y la detección de objetos. Este desenlace subraya la importancia de la comunicación efectiva y la gestión proactiva de expectativas desde las etapas iniciales del proyecto. Las lecciones aprendidas destacan la necesidad de una comprensión clara de los requisitos y la flexibilidad en la gestión de cambios durante la ejecución del proyecto. Aunque el proyecto no llegó a su conclusión deseada, la experiencia adquirida proporciona valiosos insights para futuras iniciativas similares, subrayando la importancia de una colaboración transparente y alineada.

## Anexo

Imagen 1: Interfaz gráfica para el cliente.

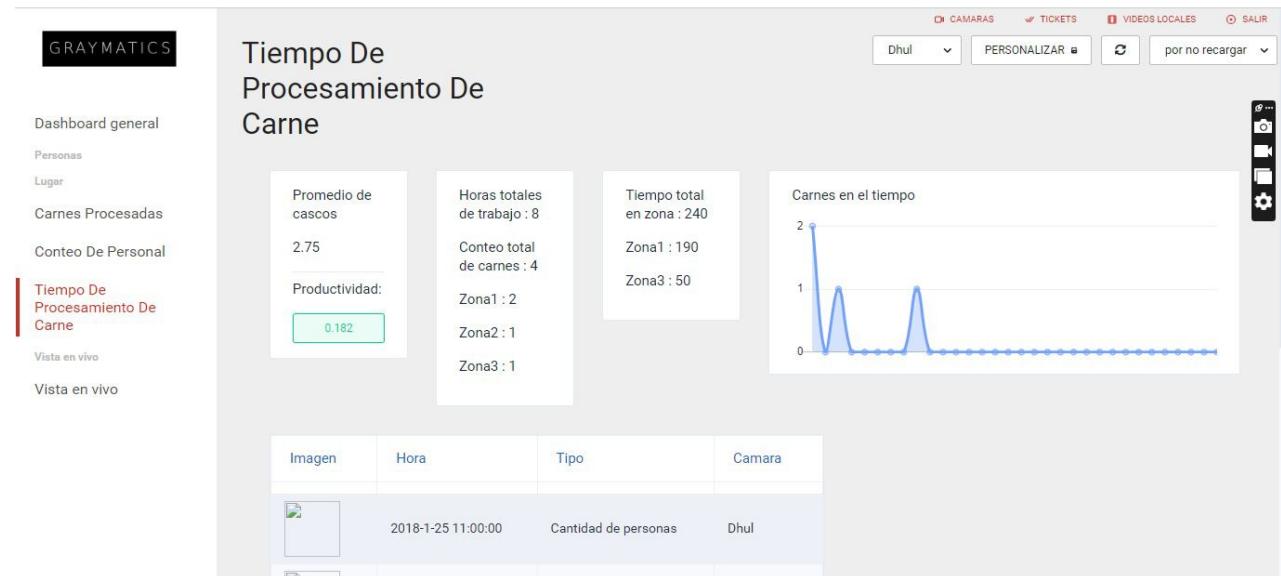


Imagen 2: Algoritmos desarrollados para las analíticas en la interfaz gráfica.

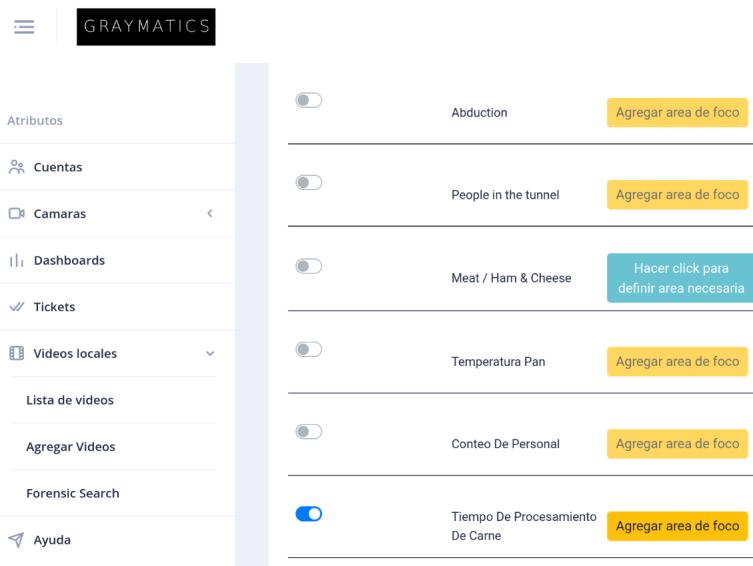


Imagen 3: Adaptive & soft thresholding interactivo en la Interfaz gráfica.

