

Predicción de demanda Dusted en canales de venta para Quintec Distribución.

Alumno: Marco Muñoz Bannura

Universidad: Universidad Adolfo Ibáñez

Carrera: Ingeniería Civil Industrial

Empresa y área: Quintec Distribución Ventas Mayoristas

Profesor: Fernando Vásquez Acuña

Supervisor: Felipe Ocharán Roizental

Fecha: 06-12-2023

Resumen Ejecutivo

La empresa Quintec Distribución S.A. es una destacada empresa de accesorios electrónicos de consumo con presencia en toda Latinoamérica, forma parte de una de las empresas de SONDA S.A. y ha sido un socio clave para Apple en Chile durante más de 30 años. A pesar de esta alianza estratégica con Apple, Quintec Distribución ha evolucionado su modelo de negocio para incluir la distribución de marcas propias en diferentes canales de venta. Estos productos, bajo marcas exclusivas, han demostrado a lo largo de los años ser una fuente de ingresos significativas para la empresa. Uno de los objetivos anuales principales es aumentar la rentabilidad del negocio en base a la distribución a lo largo del país de estas marcas propias, en donde destacan: Dusted, Gmode, Marshall, Belkin, entre otras. En respuesta a este desafío se requiere mejorar la gestión de inventario y planificación de compra de productos de distribución, la optimización de estos procesos se presenta como una prioridad estratégica para garantizar una distribución eficiente a lo largo del país, maximizando la rentabilidad y asegurando una presencia destacada en los diferentes canales de venta.

Propuesto lo anterior, se ha planteado el **objetivo general de mejorar la estimación de demanda de Quintec Distribución específicamente de la marca *Dusted* en un período de 3 meses, en nuestro canal de venta principal Walmart, logrando una conversión en sus contribuciones del 3%**. Este objetivo busca solucionar los distintos desafíos y problemáticas que ha tenido la empresa experimentado en fluctuaciones de demanda debido a cambios en el comportamiento de sus consumidores, la introducción de nuevos productos, la pandemia de COVID-19 y distintos factores económicos a nivel país.

Para realizar este objetivo, se desarrolló un modelo automatizado de predicción de demanda basado en la librería Prophet, el cual utiliza modelos de predicción de series de tiempo, permitiendo el manejo de tendencias y la captura de patrones estacionales. La implementación exitosa del modelo se traduciría en una mayor rentabilidad y eficiencia operativa.

Posterior a la implementación de la solución mencionada, podemos destacar que se mejoró la gestión de inventario reduciendo el porcentaje de demanda insatisfecha a un 9%, reduciendo las pérdidas de venta por falta de stock en un valor total de \$ 8.064.392. Esto generó un aumento en la conversión de ventas en un 25% al obtener un promedio de venta mensual de \$ 35.562.534 en comparación a lo que se tenía antes con un valor de \$17.716.023. Los resultados obtenidos del modelo no solo generaron un aporte económico significativo, sino también aportaron a la relación empresa-cliente al poder responder de manera más eficiente sus solicitudes y requerimientos.

Abstract

Quintec Distribution S.A. is a prominent consumer electronics accessories company with a presence throughout Latin America. It is part of the SONDA S.A. group and has been a key partner for Apple in Chile for over 30 years. Despite this strategic alliance with Apple, Quintec Distribution has evolved its business model to include the distribution of its own brands through various sales channels. Over the years, products under exclusive brands have proven to be a significant source of income for the company. One of the main annual objectives is to increase the profitability of the business through the distribution of these own brands across the country, including notable ones such as Dusted, Gmode, Marshall, Belkin, among others.

In response to this challenge, there is a need to enhance the inventory management and product distribution planning processes. Optimizing these processes is a strategic priority to ensure efficient distribution across the country, maximize profitability, and secure a prominent presence in various sales channels.

Having proposed the above, **the general objective has been set to improve Quintec Distribution demand estimate specifically for the Dusted brand in a period of 3 months, in our main sales channel Walmart, achieving a conversion in its contributions of 3%.** This objective seeks to solve the different challenges and problems that the company has experienced in demand fluctuations due to changes in the behavior of its consumers, the introduction of new products, the COVID-19 pandemic, and different economic factors at the country level.

To achieve this objective, an automated demand prediction model was developed based on the Prophet library, utilizing time series prediction models to handle trends and capture seasonal patterns. The successful implementation of the model would translate into increased profitability and operational efficiency.

Following the implementation of the mentioned solution, it is noteworthy that inventory management was improved, reducing the percentage of unmet demand to 9% and decreasing sales losses due to stockouts by a total value of \$8,064,392. This led to a 25% increase in sales conversion, achieving a monthly average sale of \$35,562,534 compared to the previous \$17,716,023. The results obtained from the model not only generated significant economic contributions but also contributed to the company-client relationship by more efficiently addressing their requests and requirements.

Índice

Resumen Ejecutivo:.....	2
Abstract:.....	3
Introducción:.....	5
Contexto de la empresa:.....	5
Planteamiento del Problema:.....	8
Objetivos:.....	11
Objetivo general:.....	11
Objetivo específico:.....	11
Estado del Arte:.....	12
Propuesta de solución:.....	15
Solución escogida:.....	16
Matriz de riesgo:.....	16
Metodología:.....	19
Metodología SCRUM:.....	20
Matriz de Riesgo:.....	21
Carta Gantt: :.....	23
Evaluación Económica:.....	24
Medidas de desempeño:.....	26
Resultados:.....	27
Conclusiones:.....	28
Recomendaciones:.....	29
Referencias:.....	30
Anexos:.....	31

Introducción

Contexto de la Empresa

Quintec Distribución se destaca como una empresa líder en el dinámico mercado de accesorios y electrónica de consumo, consolidando su posición mediante una expansión por Latinoamérica. Su presencia es parte integral de SONDA S.A., y es reconocida por su especialización, producción y distribución mayorista de productos electrónicos. Cuenta con una trayectoria que abarca más de 30 años, uno de los pilares fundamentales de Quintec Distribución es su visión integradora, que le ha permitido adaptarse a las cambiantes necesidades del mercado. Gracias a esta visión estratégica, han logrado establecer acuerdos exitosos con marcas internacionales de creando sólidas alianzas convirtiéndose de esta manera en un socio estratégico y distribuidor oficial de Apple en Chile.

En 2021, la marca de interés **Dusted** generó un impacto importante en el área de ventas mayoristas. Dentro de sus categorías de ventas principales destaca la expansión de cargadores y cables obteniendo un aporte promedio mensual de **\$308.813.622**. En 2022, la marca siguió su crecimiento aumentando la contribución anual sobre dicha categoría en un **30%** obteniendo un aporte de **\$403.279.894**. A día de hoy, el total de clientes No-MacOnline durante el mes suman **\$62MM** (95% del total) aumentando **2% YoY** y aumentando **5% YtD**. Los clientes principales de la marca **YtD** en orden decreciente son: Walmart, Cencosud, MacOnline, Movistar y Casa Royal. **Walmart** inicia su repo automática y ejecuta su modelo de category management que implica seguir cargando fuertemente el canal. El stock actual de la marca termina por debajo de **100MM** y para evitar quiebres de los productos clave se están coordinando despachos aéreos. Esto apunta directamente a la problemática a resolver (discrepancia entre el stock de Dusted y los pedidos realizados por Walmart). En cuanto a otros datos del área mayorista en base a las futuras decisiones sobre la marca destaca; El stock actual de Dusted son **\$99MM**. En Noviembre se ingresaron **20MM** de productos de la categoría de accesorios telefónicos, en Diciembre se esperan **100MM** de la categoría accesorios para autos, luego en Enero **135MM** acorde a la categoría de cables y cargadores. Por último, a contar de Marzo se ingresarán las últimas compras de Dusted por **270MM** aproximadamente. En cuanto al **Aging** de Dusted 23% del inventario está dentro del primer tramo de 0-90 días, 61% entre 90-180 días y 16% sobre 180 días.

¹Quintec Distribución 2023. Sobre Nosotros. <https://www.quintecdistribucion.cl/sobre-nosotros>

¹Quintec Distribución 2023 Reporte Comercial Product Manager Cierre Mes Noviembre

Dicho lo anterior, tenemos como contexto inicial que el proceso de negocios que funciona en la empresa se fundamenta en la manera en cómo se distribuyen las marcas propias, entre ellas la ya mencionada **Dusted**, para y hacia los clientes. De los productos de esta marca destacan las categorías de cargadores, cables, audífonos, accesorio para autos, baterías, adaptadores, entre otros. La marca se inició a partir de 2017, en donde generaba una contribución anual para Quintec Distribución de \$5.709.203, a día de hoy, la marca Dusted cuenta con más de 15 SKU's y está generando una contribución anual de **\$545.724.135** (datos 2022).

Debido al gran crecimiento exponencial de la marca muchos clientes han decidido apostar por la expansión de los productos Dusted en sus distintos canales de venta, a continuación se presenta el consolidado de clientes en el año 2022 con la contribución total generada acorde a la marca Dusted:

Tabla 1: Cantidad de clientes y su contribución en 2022

Clientes	Total
Cencosud Retail S.A	\$ 99.346.132
Walmart Chile SA	\$ 64.071.143
Empresas La Polar S.A.	\$ 15.436.970
Distribuidora de Industrias Nacionales S.A.	\$ 13.673.400
Electronica Casa Royal Ltda	\$ 12.928.346
Telefonica Moviles Chile S.A.	\$ 65.553.107
Claro Chile SA	\$ 30.832.126
Entel PCS Telecomun. S.A.	\$ 15.656.133
Innovación y Tecnología Empresarial Item Ltda	\$ 101.861.736
Ecommerce	\$ 92.519.535
Persona Natural	\$ 11.269.398
Tecnobuy SPA	\$ 7.966.110
Comercial Samstore Ltda.	\$ 3.273.809
T2 B2B	\$ 7.990.240
Deudores	\$ 2.034.692
Tienda BackOnline Marina Arauco	\$ 1.303.617
WEB BO	\$ 7.641
Total	\$ 545.724.135

Fuente: Reporte Excel Resumen Área Comercial

²Quintec Distribución 2023. Cierre MP Reporte Felipe Ocharán 2022

Como podemos observar, Cencosud Retail S.A., en el año 2022 fue el principal cliente acorde a la marca Dusted para Quintec Distribución generando una contribución anual de **\$99.346.132**. Actualmente en 2023, el cliente **Walmart Chile S.A.**, ha decidido apostar por la expansión de la marca en todos sus canales de venta, tanto en tiendas presenciales como e-commerce.

Este año con el objetivo de optimizar y agilizar el proceso de compra mayorista del cliente Walmart y Quintec, se ha puesto en marcha una plataforma llamada “Retail Link”. Esta plataforma destaca como un creador de informes, reportes que permite analizar una amplia variedad de datos relevantes para respaldar decisiones estratégicas. La información es proporcionada directamente por el cliente y se va retroalimentando en colaboración mutua entre ambas empresas, gracias a esta iniciativa se ha logrado establecer un canal más eficiente y transparente en base a la comunicación de datos cruciales entre ambas empresas. A continuación se detallan los reportes que se pueden obtener a través de la plataforma descrita:

Imagen 1: Retail Link Walmart



²Quintec Distribución 2023. https://retailink2.wal-mart.com/decision_support/

Planteamiento del Problema

Síntomas: Si bien la marca Dusted ha crecido de manera exponencial los últimos años y se ha presentado una colaboración mutua sólida entre las empresas Walmart Chile S.A. y Quintec Distribución, esta última ha detectado una vulnerabilidad en su proceso de distribución mayorista, particularmente por la falta de previsión de demanda precisa de los productos Dusted por parte de Walmart.

El desafío a resolver apunta directamente a la cadena de suministro, la discrepancia entre los pedidos realizados por Walmart y la disponibilidad de stock por parte de Quintec, destaca un desafío importante para la implementación de estrategias de gestión de inventario y predicción de demanda. La falta de capacidad para prever con precisión cuanto se pedirá basándose en la demanda histórica y tendencias del mercado ha llevado a cabo pérdidas en las oportunidades de ventas en un valor promedio anual de **\$47.220.441** (Datos obtenidos de reporte comercial SAP Bussinnes). De esta forma, el problema a resolver es modelar un proceso predictivo de los canales de venta en Walmart, analizando el funcionamiento de la cadena de suministro, el sell-in, el sell-out del cliente y su comportamiento con el objetivo de optimizar y mejorar la eficiencia en la gestión de inventario. El valor agregado al proceso de negocio se destaca principalmente en la capacidad para abordar desafíos específicos ligados a la cadena de suministro, optimizar de manera eficiente el inventario proporciona información valiosa en la toma de decisiones, esto se traduce en una reducción en la pérdida de ventas y una mejora en la relación comercial con el cliente.

Por lo tanto, el proyecto se realizará para que el cliente Walmart S.A., como cliente principal de Quintec con respecto a la marca Dusted, **aumente en promedio sus contribuciones mensuales en un 3%** solucionando las distintas problemáticas mencionadas como porcentaje de demanda insatisfecha, pérdida de ventas por falta de stock y logrando así una conversión en sus ventas.

A modo de ejemplo, a continuación se presentará una de las distintas órdenes de compra realizadas por el cliente Walmart, en donde Quintec Distribución no pudo abastecer el 100% de la orden debido a la falta de stock de distintos productos. Cabe destacar que los productos son enviados por empaques (cada SKU se envía en una caja con cantidad diferente de productos por empaque). La insuficiencia de stock para cumplir con la totalidad de la orden plantea desafíos logísticos y destaca la necesidad de una gestión más precisa de inventarios.

³Quintec Distribución 2023. Reunión Comercial

⁴Quintec Distribución 2023. Comercionet, ORD_WM

Imagen 2:Orden de compra Walmart

Emisor:	Walmart Chile S.A	Receptor:	QUINTEC DISTRIBUCION S.A.
Número de Orden de Compra:	7026583350 (Original)	Fecha generación Mensaje:	13/10/2023
Fecha de Embarque:	13/10/2023	Fecha de Cancelación:	21/10/2023
Condiciones de Pago:	30 días (Condiciones normales)	Lugar de Entrega:	CD 6020 EL PEÑON - Av. Presidente Jorge Alessandri Rodriguez #18.899, San Bernardo.
Departamento de Ventas:	05	Tipo de Orden de Compra:	20
Promoción:	OCTP3	Numero de Proveedor	003574050
Información Comprador	CD 6020 EL PEÑON		
Información Vendedor	QUINTEC DISTRIBUCION SA		

Observaciones: NO PRETICKET TRANSMITTED ===== IF MULTIPLE DESTINATIONS HAVE THE SAME SHIP DATE, PLEASE SHIP TO FURTHEST DESTINATION FIRST AND CLOSEST DESTINATIONS LAST. =====

Línea	Cod. UPC	ITEM	Cod. Prov.	Talla/UM	Color/Desc	Cantidad	Precio Unit.	Unid/Emp.	Empaques	Importe
1	19565521300629	000721227	DUS-CCH-10W-IN	1UN	CAJ	38,00	103.327,00	8	38,00	3.926.426
Descripción		CARG AUT TIPOC.....CARG. ROBOT AUTO 10W								
2	19225618847016	000721233	DUS-WCHA-2IN1	1UN	CAJ	83,00	66.280,00	10	83,00	5.501.240
Descripción		CARG 18W CABLE 2N1.....CARG. QC3.0 DELGADO								

La siguiente orden de compra es entregada directamente a la plataforma ya mencionada anteriormente “Retail Link” , actualmente Walmart está funcionando con una reposición automática cada semana y posee un WOS Target de 6 semanas, sin embargo, no se informa directamente que mix de productos se solicitará cada semana. Esto ha generado pérdidas económicas considerables en el aporte que podría llegar a representar Walmart dentro de la marca Dusted. A continuación se presenta un resumen de la orden de compra, el stock total que había para cubrir el pedido y un análisis en base a la pérdida de venta ocurrida:

Tabla 2: Orden de Compra Walmart

SKU PROVEEDOR	Cantidad Total	Precio Unitario Real	Precio Total	Stock Total
DUS-CCH-10W-IN	304	\$ 12.916	\$ 3.926.426	200
DUS-WCHA-2IN1	830	\$ 6.628	\$ 5.501.240	600
			\$ 9.427.666	

Fuente: Reporte SAP Business

³Quintec Distribución 2023. Reunión Comercial

Como se observa en la tabla 2, la Cantidad Total solicitada es mayor al Stock Total disponible para ambos productos.

Esta disparidad entre la demanda y la disponibilidad de inventario tiene consecuencias negativas directas, eso se analiza en base a la cantidad total o pendiente de despachar.

Del SKU **DUS-CCH-10W-IN** no se entregaron 104 productos, perdiendo una oportunidad de venta de $104 \times 12.916 = \$1.343.264$. En tanto, con respecto al SKU **DUS-WCHA-2IN1** no se entregaron 230 productos, perdiendo una oportunidad de venta de $230 \times 6.628 = \$1.524.440$.

La suma de la pérdida de ventas para ambos SKU nos proporciona el valor total perdido debido a la falta de disponibilidad de inventario. En este caso el valor total representa la suma $\$1.343.264$ (DUS-CCH-10W-IN) + $\$1.524.440$ (DUS-WCHA-2IN1), lo que da como resultado **\$2.867.704**.

Este análisis subraya claramente la raíz del problema: la falta de disponibilidad de inventario ante la incapacidad de predecir la demanda de Walmart, ya que el valor calculado anteriormente representa lo que no se vendió en una semana debido a la falta de stock.

Cabe añadir que existen diversos factores que pueden afectar el comportamiento de Walmart Chile S.A., en base a su reposición automática en los últimos años. Esto surge a raíz de que han experimentado fluctuaciones en la demanda debido a cambios en la preferencia de sus consumidores, la introducción de nuevos productos ha contribuido a este aspecto, y también diversos factores económicos a nivel país. También Walmart Chile S.A. compite directamente con la amplia red de clientes (Cencosud Retail S.A, Electrónica Casa Royal Ltda., Claro Chile SPA, Innovación y Tecnología Empresarial Item Ltda., entre otros) que se abastecen directamente de Quintec Distribución.

Esto ha traído más complicaciones a Quintec Distribución a la hora de estimar su demanda futura ya que también es de considerar que si se genera una mala predicción hay que tener en cuenta los costos de almacenamiento de inventario, la depreciación de sus productos, vida útil, entre otros aspectos.

Tabla 3: Resumen Histórico Tendencia, Estacionalidad e Indicadores Walmart

SKU (IMPORTANCIA TOP)	WOS WALMART HISTÓRICO	% DEMANDA INSATISFECHA 2022	% DEMANDA INSATISFECHA 2023	K-ESIMO MAYOR VENTAS (TOTAL TIENDAS)
DUS-CABL-180-2M	16,66	6%	4,0%	38,7
DUS-CABL-3IN1-FM	16,91875	4%	12,0%	96,7
DUS-CABL-UMFI-FM	10,918	4%	7,3%	238,7
DUS-CABL-USBC-FM	6,31025	7%	10,0%	41,5
DUS-CABL-HDMI2	9,2439	8%	5,0%	162,34

Fuente: Reporte Comercial Excel OneDrive Empresa

⁴Quintec Distribución: Reunión Comercial Walmart Chile S.A. Análisis Retail

Objetivos

Los objetivos del proyecto, tanto general como específico, fueron planteados en conjunto con Quintec Distribución. El objetivo del proyecto tiene un análisis ingenieril ya que a raíz de un problema técnico se crea una solución la cual genera un impacto en el modelo de negocio, esta solución se fundamenta en los conocimientos adquiridos en la carrera Ingeniería Civil Industrial al aplicar optimización, gestión de operaciones avanzada, evaluación de proyectos y programación requiriendo profundidad de conocimiento.

Objetivo General

Mejorar la estimación de demanda de la marca **Dusted**, específicamente en el canal de ventas principal, **Walmart**, durante un período de 3 meses, con el propósito de incrementar sus contribuciones en un 3%.

Objetivo Específicos

1. Aumentar en 12% las ventas, con respecto a la marca Dusted, al mejorar la tasa de conversión en un plazo de 3 meses. Se hará para incrementar los ingresos, obtener una mayor rentabilidad y un posicionamiento favorable en el mercado.
2. Reducir en un 15% la tasa de demanda insatisfecha al mejorar el formato de abastecimiento de Dusted con el modelo de estimación de demanda en un período de 3 meses. Se hará para obtener una mayor satisfacción del cliente ligado a una reducción en el riesgo de pérdida de ventas obteniendo una mejora en la eficiencia operativa.
3. Alcanzar una disminución del 25% en las pérdidas de ventas atribuibles a la falta de existencias, mediante la implementación de estrategias efectivas de gestión de inventario y optimización de la cadena de suministro en un plazo de 3 meses. Se hará para obtener una mayor rentabilidad y fortalecer la posición competitiva de la marca.
4. Alcanzar una tasa de llenado (Fill Rate) del 90% , en 3 meses, con el propósito de asegurar que la mayoría de la demanda sea satisfecha. Se hará para mejorar la reputación de la marca y aumentar la retención del cliente.
5. Lograr una exactitud del pronóstico del 85%, en un período de 2 meses, al reducir el error absoluto porcentual medio. Se hará para obtener una mayor confiabilidad ligado a las predicciones mismas del modelo predictivo.

Estado del Arte

A continuación se presentan 3 distintos casos en los cuales diferentes empresas aplicaron soluciones de aprendizaje automático (machine learning) para abordar distintos desafíos. Cada aplicación destaca características específicas relacionadas a la implementación de series de tiempo para la creación de predicciones.

Ejemplo 1: Facebook Implementación Modelo Prophet

Contexto: El equipo detrás de Prophet fue directamente creado por Facebook, específicamente por el equipo de Core Data Science Team liderados por los investigadores J. Taylor y Ben Letham. Facebook necesitaba una herramienta para mejorar la predicción de sus series temporales acorde a la actividad de sus usuarios y la tendencia en su plataforma Meta. El equipo de Facebook buscó una herramienta que permitiera a los analistas pronosticar datos de manera sencilla, eficiente y sin requerir una técnica profunda o experiencia.

Solución: Con el objetivo de resolver lo mencionado Facebook desarrolló un modelo automatizado aditivo de series de tiempo a la cual denominó Prophet. Utilizó un modelo aditivo que descompone la serie temporal en componentes de tendencia, estacionalidad y días festivos.

Permitió manejar datos faltantes en cualquier tipo de serie temporal e ideó una interfaz amigable y sencilla con la facilidad de poder ajustar los parámetros que necesitaran.

Expansión: Dada la utilidad que generó esta creación de Prophet, la compañía decidió lanzar Prophet como una herramienta abierta, este modelo se vio respaldado debido a la implementación en distintas empresas que adoptaron la filosofía de Prophet, dentro de las empresas destacadas se encuentra: Amazon, Walmart, JPMorgan Chase, entre otras.

Cabe resaltar que la herramienta creada por Facebook se expandió a una comunidad específica de usuarios de machine learning, la popularidad de uso de esta herramienta produjo una retroalimentación constante por distintos equipos de Data Science obteniendo un rendimiento óptimo en comparación con otros modelos predictivos.

⁵Quintec Distribución <https://research.facebook.com/blog/2017/2/prophet-forecasting-at-scale/>

⁵Quintec Distribución https://facebook.github.io/prophet/docs/quick_start.html

⁵Quintec Distribución <https://medium.com/illumination/understanding-fb-prophet-a-time-series-forecasting-algorithm-c998bc52ca10>

Ejemplo 2: Amazon Forecast

Contexto: Amazon Forecast es un servicio de pronóstico de series temporales basado en la nube y desarrollado por Amazon Web Services (AWS) en noviembre de 2018. Se creó como una herramienta de pronóstico de resultados empresariales con facilidad y precisión mediante el machine learning.

Casos de uso: Amazon Forecast no se limita a un sector específico, fue diseñado para ser aplicable a una amplia variedad de industria. Funciona en la previsión de inventarios, demanda, venta minorista, planificación personal y previsión en la demanda de viajes. Las principales empresas que ocupan actualmente Amazon Forecast son: Anaplan, More Retail, Foxconn, ente otras.

Comparación Algoritmos Amazon Forecast

Tabla 4: Tabla Comparativa Redes Neuronales y algoritmos.

	CNN-QR	DeepAR+	Prophet	NPTS	ARIMA	ETS
Proceso entrenamiento computacional	ALTO	ALTO	MEDIO	BAJO	BAJO	BAJO
Series temporales según historia	SI	NO	NO	NO	NO	NO
Series temporales relacionadas con visión de futuro	SI	SI	SI	NO	NO	NO
Acepta metadatos de artículos	SI	SI	NO	NO	NO	NO
Realiza la optimización de hiperparámetros	SI	SI	NO	NO	NO	NO

⁶Quintec Distribución <https://aws.amazon.com/es/forecast/>

⁶Quintec Distribución <https://github.com/awsdocs/amazon-forecast-developer-guide>

Solución: Por lo tanto, Amazon Forecast permite al usuario elegir entre los diversos modelos de pronóstico como Convolutional Neural Networks (CNN), Quantile Regression (QR), DeepAR+, Prophet, NPTS, ARIMA y ETS. Los modelos CNN-QR y DeepAR+ son apropiados para datos con patrones complejos, forman parte de la categoría de modelos basados en red neuronales. Prophet dentro de Amazon Forecast se especializa en datos estacionales con eventos. ARIMA y ETS son modelos estadísticos más clásicos los cuales poseen un enfoque robusto combinando elementos de la regresión autorregresiva (AR) y el promedio móvil de la serie para hacerla estacionaria.

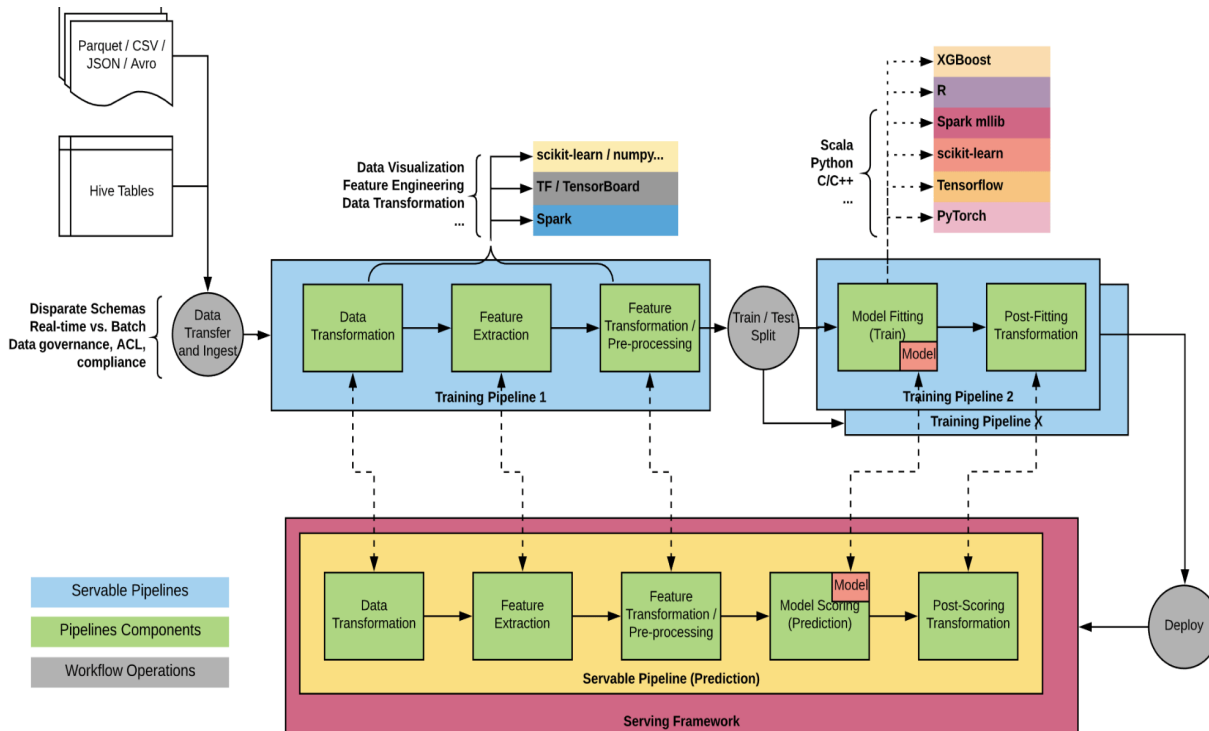
Ejemplo 3: Uber Michelangelo Analítica de Uber

Contexto: Como Uber menciona “Uber Engineering está comprometida con el desarrollo de tecnologías que crean experiencias impactantes y fluidas para nuestros clientes. Estamos invirtiendo cada vez más en inteligencia artificial (IA) y aprendizaje automático (ML) para cumplir con esta visión” (Hermann, J. 2017). A partir de este pensamiento, Uber en 2015, implemento su plataforma llamada Michelangelo, una plataforma interna de aprendizaje automático diseñada para administrar datos, evaluar e implementar predicciones reales

Solución: En la plataforma antes mencionada, los científicos de datos utilizan modelos de regresión de árboles de decisión impulsados por gradientes para generar predicciones. El modelo es implementado en el centro de datos de Uber.

En cuanto al sistema utilizado en la plataforma, Michelangelo es una combinación de sistemas y códigos abiertos, es decir, de uso público. Dentro de la información subida hasta el año 2022, los códigos utilizados son HDFS, ARIMA, Prophet, Spark, TensorFlow y XGBoost. Sin embargo, el machine learning aplicando en Uber suele ser bastante complejo por lo que siempre su plataforma cuenta con reajustes en base a las bibliotecas ocupadas, el formato de datos y el lenguaje necesario.

Imagen 3: Evolución y Representación Modelo



⁷Quintec Distribución Machine Learning Uber; <https://es.scribd.com/document/490461406/C1-caso-Uber>

Propuesta de solución

A continuación, se presentan tres soluciones potenciales que, según la investigación en el estado del arte, abordan directamente la necesidad de predecir la demanda de productos Dusted en el canal de ventas de Walmart.

1. **ARIMA (AutoRegressive Integrated Moving Average):** El modelo autorregresivo integrado de promedio móvil combina elementos de la regresión autorregresiva (AR) y el promedio móvil con la integración de la serie para hacerla estacionaria. Se expresa de la manera $ARIMA(p,q,d)$, en donde, los parámetros p, d y q son los diferentes componentes que posee el modelo.

Autorregresiva (AR): en el modelo AR, la variable dependiente se regresa a sus valores anteriores en el tiempo. La notación $AR(p)$ indica el orden del modelo, donde p representa la cantidad de períodos

Integrada (I): La integración se refiere a la diferenciación de la serie temporal para hacerla estacionaria. El parámetro d representa la cantidad de diferenciaciones.

Media Móvil (MA): La variable dependiente se relaciona con un término de error en el tiempo actual. $MA(q)$ explican una combinación lineal de errores q en el modelo.

La predicción se realiza ocupando estos 3 componentes, el modelo ARIMA destaca por ser técnicamente sofisticado en las predicciones de una variable. Es un modelo muy apropiado para predicciones a largo plazo y sus parámetros tienen patrones claros.

2. **Redes Neuronales LSTM (Long Short-Term Memory):** Fueron propuestas por Sepp Hochreiter y Jürgen Schmidhuber en 1997. Tiene el objetivo principal de almacenar, mediante su red neuronal, una gran cantidad de datos en un largo período de tiempo.

Celda de Memoria: Es la unidad básica del modelo, es donde se almacena y se accede a la información.

Puertas: Existen 3 puertas que regulan el flujo de información; forget gate, input gate y output gate.

Gradientes: Se aborda directamente la serie temporal acorde al desvanecimiento, el gradiente facilita el aprendizaje de patrones a corto y largo plazo.

LSTM representa una mejora en relación de las RNN tradicionales en términos de manejo de tendencias, dependencias a largo plazo en la serie temporal. La capacidad de retener información no la tienen los otros modelos lo que resulta una ventaja a la hora de analizar secuencias temporales.

3. **Prophet:** Prophet se utiliza en los modelos de predicción de series temporales debido a la simplicidad en su uso, tiene una facilidad de ajuste óptima y tiene una reputación clave en base al buen rendimiento predictivo que el modelo posee.

Tendencia: Prophet modela la tendencia en los datos utilizando un enfoque suavizado, la tendencia de los datos puede ser lineal o logística, esto depende directamente de donde se obtenga los datos (su naturaleza), la tendencia es sumamente importante debido a que captura cambios de los productos a largo plazo dentro de la data.

Estacionalidad: Prophet captura patrones estacionales utilizando *componentes de Fourier*, de esta forma se manejan las estacionalidades anuales, semanales y de la misma manera, especificar días festivos que afecten la serie temporal.

Efecto de regresión: Además de la tendencia y estacionalidad, Prophet permite incorporar efectos de regresión, esto incluye eventos importantes o cambios en el comportamiento del usuario. Esto puede tener relación a cyberdays, en los cuales la demanda sufre un cambio brusco dentro del modelo.

Solución Escogida

En base a los criterios de selección elegidos en conjunto por Quintec Distribución se planteó la siguiente matriz:

1. **Uso amigable:** La solución posee una facilidad operativa (30%)
2. **Alcance:** La solución es posible de alcanzar dentro de los plazos establecidos (20%)
3. **Costo de implementación:** La solución posee bajos costos en su desarrollo (20%)
4. **Proceso automatizado:** Los procesos operativos matemáticos quedan estandarizados completamente (30%)

La metodología de selección será ejecutada en una ponderación bajo escala de 1 a 5 en la siguiente tabla:

Tabla 5: Criterios de Decisión

	USO AMIGABLE (30%)	ALCANCE (20%)	COSTOS IMPLEMENTACIÓN (20%)	PROCESO AUTOMATIZADO (30%)	TOTAL PONDERADO
ARIMA	3	3	5	4	3,7
PROPHET	5	4	5	4	4,5
LSTM	2	3	5	5	3,7

⁹Quintec Distribución Informe 2 Marco Muñoz

Solución Escogida Prophet

El modelo utilizado para la automatización en la predicción de demanda será Prophet, este último será implementado en la aplicación de programación Jupyter Notebook Python. Prophet se utiliza en los modelos de predicción de series temporales debido a la simplicidad en su uso, tiene una facilidad de ajuste óptima y tiene una reputación clave en base al buen rendimiento predictivo que el modelo posee.

¿Por qué Prophet? (Evaluación Ingenieril)

Para explicar con mayor detalle el modelo Prophet actualmente utilizado es necesario desglosar el modelo y entender la matemática que ocupa y como maneja los hiperparámetros dentro de las predicciones.

- **Prophet:** Es útil para datos de series temporales con estacionalidades, es un modelo de serie aditivo el cual aborda las características comunes en los conjuntos de datos de series temporales, como tendencias no lineales, efectos estacionales, días festivos, cyberdays, etc.

Se basa en la siguiente formula:

$y(t) = g(t) + s(t) + h(t) + \varepsilon(t)$, donde $g(t)$: componente de tendencia
 $s(t)$: componente de estacionalidad
 $h(t)$: componente de días festivos
 $\varepsilon(t)$: componente de error en el tiempo

Manejo de vacíos y ausencias: Prophet maneja automática los valores faltantes en la serie temporal, y los días en que no hay observaciones. Dentro del modelo real esto aplica a la falta de venta de distintos SKU's en distintas tiendas de Walmart, lo que "ensucia" el modelo y que debe ser corregido. Por lo mismo, Prophet proporciona herramientas para detectar anomalías en los datos, identificando eventos atípicos o consideraciones en los datos originales.

La **suavización exponencial**, en Prophet, se refiere a la reducción de fluctuaciones en una serie temporal, la técnica ocupada es la suavización exponencial segmentada, esto implica el ajuste de regresiones lineales a segmentos específicos de la serie temporal. Los datos se dividen en segmentos, cada segmento es una sección continua de datos en la serie, dentro de cada segmento se ajusta a una regresión lineal, una vez que se ajustan estas regresiones se suavizan para reducir los cambios y obtener una representación más suave sobre la tendencia general.

⁹Quintec Distribución Informe 2 Marco Muñoz

⁹Quintec Distribución https://www.dmae.upct.es/~paredes/am_ti/apuntes/Tema 2. Series y transformadas de Fourier.pdf

Componentes Fourier: Como se mencionó anteriormente, Fourier se ocupa para modelar los efectos estacionales en las series temporales, esta herramienta matemática transforma la serie temporal para descomponerla en componentes sinusoidales (componentes de la serie en seno y coseno). La fórmula general ocupada es:

$f(t) = A \cdot \sin(2\pi \mathbb{F}t + \phi)$, donde A : amplitud de onda
 \mathbb{F} : frecuencia (cada serie posee una frecuencia)
 t : tiempo
 ϕ : fase

Al sumar diferentes componentes sinusoidal con amplitudes, frecuencias, fases específicas, se puede aproximar la serie temporal y así modelar patrones estacionales. El modelo actualmente creado determina automáticamente cuantas componentes de Fourier se necesitan para representar las estacionalidades de los datos, así cada componente determina una estacionalidad específica.

Metodología (Plan de Implementación)

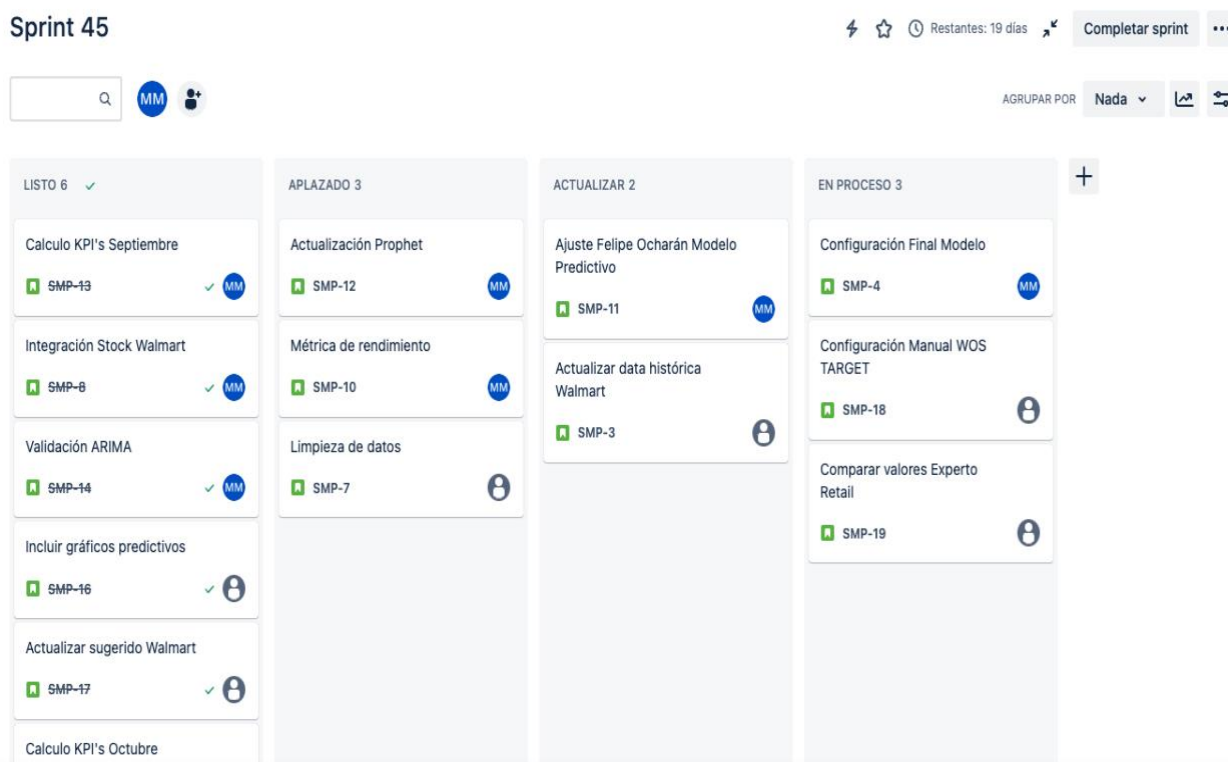
1. **Revisión de datos disponibles:** Hay que examinar claramente los datos históricos presentes que se tienen registro de Walmart acerca de Dusted. Examinar la cantidad de inventario disponible actualmente en Walmart de dicha marca y entender cualquier factor que pueda influir en la demanda. También hay que revisar minuciosamente esta data histórica para asegurar una confiabilidad en los datos precisa. Actualmente los datos se comparan con los datos que adquiere **Experto Retail**, esta es una empresa contratada por Quintec, la cual maneja todos los datos del sell-out de los canales de venta de la marca Dusted, desde ahí se obtienen reportes confiables los que sirven para comparar los datos que se utilizarán en el modelo predictivo.
2. **Preparación datos, limpieza y formateo:** Luego de examinar los datos históricos, y haber obtenido datos más actuales (obtenidos a través de una plataforma de intercambio de información entre Walmart y Quintec “**B2B, Imagen 1**”) se debe realizar una limpieza en los datos, revisar la duplicación de estos mismos, y asegurar de que estén completos.
3. **Modelado Prophet en Jupyter Notebook:** Se realiza una división de los datos y como estos se manejarán en el código. En la creación del código se debe configurar Prophet en base a los requerimientos o comportamientos del cliente, Walmart, por ejemplo, tiene un WOS Target = 6 semanas. Añadir días festivos, cyberdays, ajustar el modelo para finalmente obtener el código base original, el cual debe tener la data histórica ingresada de Walmart.
4. **Integración de Datos Stock:** Hay que cargar dentro del código en Jupyter Notebook Python los datos de stock actual de Walmart, para tener en cuenta la disponibilidad que cuenta Walmart con la marca Dusted así pudiendo filtrar y ajustando la predicción de demanda.
5. **Calculo KPI's:** Luego de probar el modelo se debe calcular los KPI's definidos anteriormente ya que responden de manera directa los objetivos específicos del proyecto.
6. **Ajuste y Monitoreo Continuo:** Debe existir una retroalimentación continua del modelo, porque si bien, el código base queda creado siempre existirán diversos parámetros que deben ser ajustados según los requerimientos de cada usuario. Por ejemplo, no todos los clientes tienen establecido un mismo WOS Target, y esto puede resultar en cambios en la consideración del cálculo del modelo predictivo.
7. **Análisis de Resultados:** Por último, luego de obtener los resultados del modelo, se debe realizar un análisis profundo, teniendo en cuenta el análisis de gráficos que entrega el modelo junto con la explicación dada por ARIMA para así tomar decisiones futuras de manera precisa.

¹¹Quintec Distribución Informe 2 Marco Muñoz

¹¹Quintec Distribución Reportes Semanales W45

Metodología SCRUM

Para abordar el proyecto de la mejor forma se eligió la metodología de trabajo ágil llamada Scrum, la cual es popular en trabajos software debido a su principal ventaja de poseer una gran adaptabilidad para trabajar en distintos contextos. Cabe destacar que la elección de la metodología fue una decisión en conjunto con Felipe Ocharán, Product Owner del proyecto, encargado de filtrar requerimientos, definir la visión y requisitos del modelo a implementar. La creación de épicas, sprint, tareas fueron hechas en “Jira Software”. A continuación se presenta de manera resumida uno de los “sprints” del proyecto:



Fuente: Jira Software Sprint 45

Precisamente se escogió Scrum como metodología de gestión de proyectos debido a la gran capacidad que tiene este método de adaptarse a cambios rápidos en las solicitudes y ofrecer iteraciones de manera eficiente y veloz. También para Quintec Distribución era de suma importancia tener el código operativo lo antes posible y con el carácter de no depender entre actividades/tareas de dicha metodología agilizaba el proceso en cuestión.

¹²Quintec Distribución Reunión Felipe Ocharán

¹²Quintec Distribución Reunión Comercial

Metodología Scrum por Objetivo Específico

Objetivo Específico 1	1.1. Integración Data Histórica stock y ventas Walmart Chile S.A.
	1.2. Analizar factores, identificar métricas, pérdidas en ventas respecto a Órdenes de Compra, revisar tasa de conversión histórica.
Objetivo Específico 2	2.1. Mejorar proceso de abastecimiento ligado al modelo de demanda actual.
	2.2. Validar estrategias, optimizar cadena de suministro, analizar costos de almacenamiento e integrar modelo de procesos
Objetivo Específico 3	3.1. Identificar cuello de botella, puntos débiles en la cadena de suministro. Implementar gestión de inventario.
	3.2. Optimizar procesos de reabastecimiento y almacenamiento.
Objetivo Específico 4	4.1. Implementar tecnologías para el monitoreo constante del modelo predictivo.
	4.2. Analizar procesos actuales, puntos de congestión y obtener análisis.
Objetivo Específico 5	5.1. Retroalimentar el código abierto en Jupyter, analizar matriz de datos y limpiar la serie temporal.
	5.2. Realizar ajustes de hiperparámetros acorde a las solicitudes de Walmart.

Metodología (Matriz de Riesgo)

Para analizar los riesgos considerando las mitigaciones necesarias para implementar exitosamente el modelo predictivo respecto al canal de venta primordial Walmart se presenta la siguiente matriz:

Tabla 6: Matriz de Riesgo

	RARO	POCO PROBABLE	POSIBLE	MUY PROBABLE	CASI SEGURO
DESPRECIABLE	BAJO	BAJO	BAJO	MODERADO	MODERADO
MENORES	BAJO	BAJO	MODERADO	MODERADO	MODERADO
MODERADOS	MODERADO	MODERADO	MODERADO	ALTO	ALTO
MAYORES	MODERADO	MODERADO	ALTO	ALTO	MUY ALTO
CATASTRÓFICA	MODERADO	ALTO	ALTO	MUY ALTO	MUY ALTO

Mitigaciones

RIESGO	PROBABILIDAD	IMPACTO	NIVEL RIESGO	MITIGACIÓN
Requerimiento Manual Modelo	ALTO	ALTO	MAYORES	Capacitación Equipo Operativo
Limitación Datos Complejos	BAJO	MODERADO	BAJO	Preprocesamiento de datos y ajuste de hiperparámetros
Sensibles a Outliers	MODERADO	MODERADO	MODERADO	Filtrado de datos, identificación y tratamiento de atípicos
Tiempo de Entrenamiento	BAJA	ALTO	MODERADOS	Considerar hardware acelerado, paralelización y optimización de procesos

¹⁰Quintec Distribución Reunión Comercial Equipo Operaciones

¹⁰Quintec Distribución Mitigación Formal Requerimiento Manual Modelo Anexo Informe

Mitigación Formal (Anexo Informe): Existe únicamente un riesgo formal con alta probabilidad de ocurrencia ligado al requerimiento manual del modelo predictivo, este riesgo tiene un impacto significativo respecto a una dependencia crítica acorde a la intervención manual de la plataforma. Para mitigar este riesgo, se propone la capacitación del equipo operativo (explicado a detalle en Anexo Informe). Esto implica directamente brindar información exhaustiva para que los miembros del equipo puedan comprender, analizar y ejecutar las tareas manuales del código predictivo de manera correcta. Esto reduce considerablemente la posibilidad de errores en la ejecución del código y también permite una transición más fluida entre las fases operativas y automáticas del modelo.

Producto Backlog (Carta Gantt)

Para la correcta implementación de las actividades del Product Backlog se realizó una carta Gantt a modo de llevar un plan de desarrollo del proyecto de pasantía ordenado con los objetivos y tareas a realizar en las semanas de trabajo correspondiente:

Tabla 7: Carta Gantt

Actividad	SEMANAS																		
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19
Análisis inicial datos	■	■																	
Limpieza y validación data		■	■																
Configuración inicial de Prophet			■	■															
Ajuste de hiperparámetros				■	■														
Integración Stock por canal					■	■													
Desarrollo modelo predictivo						■	■	■											
Implementación operativa							■	■	■										
Pruebas y validación de cambios								■	■										
Cálculo KPI's									■										
Retroalimentación y ajuste										■									
Análisis de Resultados											■	■							
Optimización y toma de decisiones de inventario												■							
Implementación reposición stock													■						
Evaluación de técnicas de pronóstico														■	■				
Reunión comercial Walmart en los parámetros de reposición															■				
Validación Plataforma B2B																■			
Evaluación continua data histórica Walmart																	■	■	
Monitoreo constante del modelo																		■	■
Adaptación de requisitos individuales por canal de venta																			■

Desarrollo del Proyecto

El proyecto se inició el 16 de agosto de 2023 (**día 0**) con un análisis inicial de datos, seguido por la etapa de limpieza y validación de la información, garantizando una coherencia de los datos recolectados. La configuración del modelo Prophet y el ajuste de hiperparámetros se llevaron a cabo en los primeros días, estableciendo las bases para el desarrollo del modelo. La integración de stock por canal permitió una visión completa de la disponibilidad de productos. Durante la fase de desarrollo del modelo, se implementaron mejoras continuas y se realizaron simulaciones del proceso operativo. El cálculo de KPI's proporcionó métricas claves para evaluar el rendimiento del modelo, y la retroalimentación condujo a ajustes precisos. La implementación de reposición de stock y reuniones comerciales con Walmart para ajustar parámetros de reposición se llevaron a cabo según lo programado. El monitoreo constante del modelo y la adaptación a los requisitos individuales por canal de venta se mantuvieron a lo largo de la pasantía. Finalmente, el término exitoso de estas actividades evidencia la eficacia del proyecto, cumpliendo con los plazos establecidos y logrando mejoras significativas en la gestión de inventario y la satisfacción del cliente.

Evaluación Económica

La evaluación económica se centra en analizar el impacto financiero y la contribución que generó la aplicación del modelo predictivo. Para aquello, es necesario señalar que el impacto es medible a partir de Septiembre. Si bien el modelo fue implementado a finales de Agosto de 2023, la reposición de inventario en base a la predicción de demanda fue a partir desde el mes de Septiembre del presente año.

La evaluación económica mediante un análisis de sensibilidad se seleccionó como métrica fundamental para destacar la contribución específica del modelo predictivo implementado en la reposición de inventario. Se optó por comparar dos escenarios: **uno en el cual el modelo no estaba aplicado y otro en el cual sí se implementó**. El análisis de sensibilidad permite examinar cómo variaciones en parámetros clave afectan la rentabilidad del proyecto.

La elección de esta métrica se basa en su capacidad para proporcionar un análisis de cómo factores económicos claves influyen en la viabilidad financiera del proyecto y su impacto en la contribución. Al comparar el escenario premodelo con el escenario postmodelo y ajustar variables específicas en el análisis de sensibilidad, se puede cuantificar el impacto del modelo predictivo en términos económicos.

Imagen 4: Ingresos por SKU Evaluación Económica

SKU	GRUPO	Feb	Mar	Abr	May	Jun	Jul	Ago	Sept	Oct	Nov	Dic	Total
DUS-CABL-180-2M	Cables	\$ 641.914	\$ 761.968	\$ 864.186	\$ 913.687	\$ 916.222	\$ 850.710	\$ 1.251.922	\$ 1.591.777	\$ 1.964.477			
DUS-CABL-3IN1-FM	Cables	\$ 1.027.063	\$ 1.219.149	\$ 1.382.698	\$ 1.461.899	\$ 1.465.955	\$ 1.361.135	\$ 2.003.074	\$ 2.546.843	\$ 3.143.162			
DUS-CABL-MUSB-FM	Cables	\$ 385.148	\$ 457.181	\$ 518.512	\$ 548.212	\$ 549.733	\$ 510.426	\$ 751.153	\$ 955.066	\$ 1.178.686			
DUS-CABL-UMFI-FM	Cables	\$ 1.283.828	\$ 1.523.936	\$ 1.728.373	\$ 1.827.373	\$ 1.832.444	\$ 1.701.419	\$ 2.503.843	\$ 3.183.554	\$ 3.928.953			
DUS-CABL-USBC-FM	Cables	\$ 1.155.445	\$ 1.371.542	\$ 1.555.535	\$ 1.644.636	\$ 1.649.200	\$ 1.531.277	\$ 2.253.459	\$ 2.865.198	\$ 3.536.058			
DUS-CABL-HDMI2	Cables	\$ 513.531	\$ 609.574	\$ 691.349	\$ 730.949	\$ 732.978	\$ 680.568	\$ 1.001.537	\$ 1.273.421	\$ 1.571.581			
DUS-CABL-AUX2	Cables	\$ 256.766	\$ 256.766	\$ 345.675	\$ 365.475	\$ 366.489	\$ 340.284	\$ 500.769	\$ 636.711	\$ 785.791			
DUS-CACH-20PDK	Acc Auto	\$ 770.297	\$ 914.361	\$ 1.037.024	\$ 1.096.424	\$ 1.099.466	\$ 1.020.851	\$ 1.502.306	\$ 1.910.132	\$ 2.357.372			
DUS-CAHO-MGNT2	Acc Auto	\$ 1.412.211	\$ 1.676.329	\$ 1.901.210	\$ 2.010.111	\$ 2.015.688	\$ 1.871.561	\$ 2.754.227	\$ 3.501.909	\$ 4.321.848			
DUS-CAHO-MGSF	Acc Auto	\$ 641.914	\$ 761.968	\$ 864.186	\$ 913.687	\$ 916.222	\$ 850.710	\$ 1.251.922	\$ 1.591.777	\$ 1.964.477			
DUS-EARP-SLEEP	Audifonos	\$ 128.383	\$ 152.394	\$ 172.837	\$ 182.737	\$ 183.244	\$ 170.142	\$ 250.384	\$ 318.355	\$ 392.895			
DUS-HEPH-ANCBK	Audifonos	\$ 898.680	\$ 1.066.755	\$ 1.209.861	\$ 1.279.161	\$ 1.282.711	\$ 1.190.993	\$ 1.752.690	\$ 2.228.488	\$ 2.750.267			
DUS-HUB-C7P	Adaptadores	\$ 385.148	\$ 457.181	\$ 518.512	\$ 548.212	\$ 549.733	\$ 510.426	\$ 751.153	\$ 955.066	\$ 1.178.686			
DUS-IPEN-MGNT	Acc Terceros	\$ 770.297	\$ 914.361	\$ 1.037.024	\$ 1.096.424	\$ 1.099.466	\$ 1.020.851	\$ 1.502.306	\$ 1.910.132	\$ 2.357.372			
DUS-NBHO-MGSF	Acc Terceros	\$ 1.027.063	\$ 1.219.149	\$ 1.382.698	\$ 1.461.899	\$ 1.465.955	\$ 1.361.135	\$ 2.003.074	\$ 2.546.843	\$ 3.143.162			
DUS-PB-PD10AH	Acc Terceros	\$ 256.766	\$ 304.787	\$ 345.675	\$ 365.475	\$ 366.489	\$ 340.284	\$ 500.769	\$ 636.711	\$ 785.791			
DUS-SEST-LED	Acc Terceros	\$ 641.914	\$ 761.968	\$ 864.186	\$ 913.687	\$ 916.222	\$ 850.710	\$ 1.251.922	\$ 1.591.777	\$ 1.964.477			
DUS-WCHA-12K	Cargadores	\$ 513.531	\$ 609.574	\$ 691.349	\$ 730.949	\$ 732.978	\$ 680.568	\$ 1.001.537	\$ 1.273.421	\$ 1.571.581			
DUS-WCHA-20WPK	Cargadores	\$ 898.680	\$ 1.066.755	\$ 1.209.861	\$ 1.279.161	\$ 1.282.711	\$ 1.190.993	\$ 1.752.690	\$ 2.228.488	\$ 2.750.267			
DUS-WCHA-2IN1	Cargadores	\$ 641.914	\$ 761.968	\$ 864.186	\$ 913.687	\$ 916.222	\$ 850.710	\$ 1.251.922	\$ 1.591.777	\$ 1.964.477			
DUS-WCHA-45PDK	Cargadores	\$ 385.148	\$ 457.181	\$ 518.512	\$ 548.212	\$ 549.733	\$ 510.426	\$ 751.153	\$ 955.066	\$ 1.178.686			
DUS-WICH-3IN1	Cargadores	\$ 256.766	\$ 304.787	\$ 345.675	\$ 365.475	\$ 366.489	\$ 340.284	\$ 500.769	\$ 636.711	\$ 785.791			
DUS-WICH-P10W-LT	Cargadores	\$ 128.383	\$ 152.394	\$ 172.837	\$ 182.737	\$ 183.244	\$ 170.142	\$ 250.384	\$ 318.355	\$ 392.895			
Totales		\$15.020.790	\$17.782.026	\$20.221.961	\$21.380.266	\$21.439.595	\$19.906.602	\$29.294.963	\$37.247.578	\$45.968.750			

Fuente: Reporte Comercial Cierre Octubre Felipe Ocharán

Imagen 5: Contribución Total SKU

INGRESOS													
Cientes	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sept	Oct	Nov	Dic	Total
Walmart Chile S.A.	\$12.838.282	\$15.239.357	\$17.283.727	\$18.273.732	\$18.324.440	\$17.014.190	\$25.038.430	\$31.835.537	\$39.289.530				\$195.137.225

Desde el mes de Febrero hasta Julio hubo una contribución promedio mensual de **\$17.716.023**. A partir de la implementación del modelo predictivo (finales de Agosto) hay un aumento en esta contribución en un valor de \$17.846.511, obteniendo una contribución promedio mensual de **\$35.562.354**.

Esto se debe, principalmente, a la reducción en el valor de demanda insatisfecha comparando los dos períodos de análisis: **Período 1:Febrero-Agosto/ Período 2:Octubre-Noviembre**. En el período 1 hay un valor promedio de demanda insatisfecha de 566 productos, a partir de Septiembre hubo una reducción de 232 productos, obteniendo un valor promedio de demanda insatisfecha de 334 productos.

Esto último trajo consecuencias significativas en la disminución de quiebres de inventario, reduciendo la pérdida de oportunidades de venta. A continuación se presenta una tabla que detalla la demanda total real en los períodos de análisis en base a su canal principal Walmart y la demanda insatisfecha por parte de Quintec respecto a quiebres de stock de distintos SKU's.

Tabla 6: Demanda Real vs Demanda Insatisfecha

PORCENTAJE DEMANDA INSATISFECHA													
Cientes	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sept	Oct	Nov	Dic	Total
Walmart Chile S.A.		642	532	602	623	649	660	721	372	295			
DEMANDA TOTAL REAL		2113	2401	3212	1843	2482	2221	2523	3210	2502			
		30%	22%	19%	34%	26%	30%	29%	12%	12%			
Quiebres Stock		\$ 6.924.582	\$ 5.928.642	\$ 5.762.814	\$ 6.201.765	\$ 6.103.921	\$ 5.817.365	\$ 6.874.193	\$ 4.729.349	\$ 4.981.731			

Fuente: Reporte Comercial SAP Business

Como se observa en la tabla 6. el valor promedio mensual que se perdía en el período 1 es de **\$6.230.469** mientras que luego de la implementación del modelo en base a la reposición de stock masiva que se realizó se pudo reducir considerablemente este valor de demanda insatisfecha dividido por la demanda real obteniendo mayores contribuciones de tal forma. El valor promedio mensual de quiebres de stock (oportunidades en las que no se entregó la orden de compra debido a falta de stock) en el período 2 es de **\$4.855.540**. Por lo tanto, se redujo en promedio entre ambos periodos un valor de **\$1.374.929** afectando a la tasa de conversión de ventas como se presentó en la Imagen 4.

¹⁰Quintec Cierre Stock MP

¹⁰Quintec Reporte Comercial Octubre

¹⁰Quintec Informe Global SAP Business

Medidas de Desempeño (KPI's)

El problema u oportunidad a resolver es modelar un proceso predictivo de canales de venta para que la empresa Quintec no cuente con un exceso de inventario o falta de stock a la hora de distribuir sus productos Dusted. Por lo tanto, el objetivo general es mejorar la estimación de demanda de la marca **Dusted**, específicamente en el canal de ventas principal, **Walmart**, durante un período de 3 meses, con el propósito de incrementar sus contribuciones en un 3%.

Objetivo Específico: Aumentar en 12% las ventas, con respecto a la marca Dusted, al mejorar la tasa de conversión en un plazo de 3 meses.

1. KPI alineado: $\%Conversion\ Ventas = \frac{V_f - V_i}{V_i} \times 100\%$

Objetivo Específico: Reducir en un 15% la tasa de demanda insatisfecha al mejorar el formato de abastecimiento de Dusted con el modelo de estimación de demanda en un período de 3 meses.

2.1. KPI alineado: $DI = \sum_{i=1}^n \text{Max}(0, \text{Demanda Real}_i - \text{Ventas Pronosticadas}_i)$

2.2. KPI alineado: $\%DI = \frac{DI\ Total}{Demanda\ Real\ Total} * 100\%$

Objetivo Específico: Alcanzar una disminución del 25% en las pérdidas de ventas atribuibles a la falta de existencias, mediante la implementación de estrategias efectivas de gestión de inventario y optimización de la cadena de suministro en un plazo de 3 meses.

3. KPI alineado: $\%Perdidas\ Ventas = \frac{P_i - P_f}{P_f} \times 100\%$

Objetivo Específico: Alcanzar una tasa de llenado (Fill Rate) del 90% , en 3 meses, con el propósito de asegurar que la mayoría de la demanda sea satisfecha.

4. KPI alineado: $FA = 1 - \frac{|\text{Demanda Real} - \text{Ventas Proyectadas}|}{Demanda\ Real}$

Objetivo Específico: Lograr una exactitud del pronóstico del 85%, en un período de 2 meses, al reducir el error absoluto porcentual medio.

5. KPI alineado: $MAPE = \frac{1}{n} \sum_{i=1}^n \frac{|\text{Demanda Real}_i - \text{Ventas Pronosticadas}_i|}{Demanda\ Real_i} * 100$

Resultados

La tabla a continuación encapsula los resultados esenciales obtenidos tras la implementación del modelo predictivo de demanda **Dusted**, se presenta el cálculo de las métricas obtenidas, los KPI's, valores reales y valores esperados.

Tabla 8: Resultados Modelo Predictivo

OBJETIVO ESPECÍFICO	FÓRMULA (KPI)	VALOR ESPERADO	VALOR REAL OBTENIDO
Aumentar en 12% las ventas	$Ventas = \frac{V_f - V_i}{V_i} \times 100\%$	Incrementar tasa en 12%	Se incrementó la tasa en un 101%
Reducir en un 15% la tasa de demanda insatisfecha	$\%DI = \frac{DI\ Total}{Demanda\ Real\ Total} * 100\%$	Reducción tasa en 15%	Se redujo la tasa en un 15%
Alcanzar una disminución del 25% en las pérdidas de ventas.	$PV = \frac{P_i - P_f}{P_f} \times 100\%$	Reducción tasa en un 25%	Se redujo la tasa en un 28%
Alcanzar una tasa de llenado (Fill Rate) del 90%	$FA = 1 - \frac{ Demanda\ Real - Ventas\ Proyectadas }{Demanda\ Real}$	Alcanzar un FR del 90%	Se alcanzó un FR de 85%
Lograr una exactitud del pronóstico del 85%	$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{ Demanda\ Real_i - Ventas\ Pronosticadas_i }{Demanda\ Real_i}$	Lograr un MAPE del 85%	Se alcanzó un MAPE de 79%

Observaciones

Como se observa en la tabla 8. Muchos de los principales objetivos específicos cumplieron con lo establecido generando una contribución económica importante.

En el caso del objetivo específico acorde a la tasa de ventas se incrementó en un 101%, sin embargo, a pesar de haber mejorado los quiebres de inventario por parte de Quintec, (objetivo específico 2 y 3) este aumento considerable no solo se debe a esta mejora mencionada sino también a que Walmart decidió apostar más por la marca **Dusted** haciendo reposiciones más frecuentes y con un mayor volumen. En cuanto al objetivo específico 4 y 5, si bien no lograron el cometido acorde a la exactitud del pronóstico obtuvo valores cercanos, esto se debe a que si bien el modelo predictivo funciona bien requiere de una mayor data histórica para un modelamiento más robusto en base al aprendizaje automático.

Conclusiones

El rendimiento operativo del modelo predictivo fue aprobado por la empresa **Quintec Distribución** debido a que generó un impacto económicamente positivo acorde a la marca **Dusted** en su canal de ventas principal **Walmart**.

En cuanto a los objetivos específicos, se alcanzaron con creces los objetivos 1, 2 y 3; Sin embargo, los objetivos 4 y 5 no alcanzaron su rendimiento óptimo, por lo que ahí destaca una oportunidad de mejora.

Imagen 5: Contribuciones hasta la Fecha

INGRESOS													
Cientes	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sept	Oct	Nov	Dic	Total
Walmart Chile S.A.		\$12.838.282	\$15.239.357	\$17.283.727	\$18.273.732	\$18.324.440	\$17.014.190	\$25.038.430	\$31.835.537	\$39.289.530			\$195.137.225
Cencosud S.A	\$17.698.051	\$-	\$26.115.890	\$7.000.155	\$4.016.310	\$1.710.195	\$12.558.435	\$14.125.085	\$11.898.932	\$20.420.761			\$115.543.814
Casa Royal Ltda	\$743.140	\$2.981.052	\$6.680.293	\$3.593.049	\$161.710		\$5.175.300	\$7.079.702		\$3.499.275			\$29.913.521
La Polar S.A.		\$1.151.000		\$5.361.810				\$6.738.300					\$13.251.110
Tecnología Ltda	\$19.090.277	\$19.874.155	\$7.340.383	\$1.550.720	\$10.169.308	\$19.900.535	\$5.211.936	\$8.340.335	-\$137.131	\$5.373.989			\$96.714.507
Persona Natural	\$1.716.827	\$3.011.601	\$7.308.866	\$10.567.677	\$6.576.413	\$3.318.544	\$3.400.302	\$3.895.050	\$6.415.859	\$11.039.121			\$57.250.260
Movistar S.A		\$12.722.950	\$5.306.918				\$1.278.550	\$4.502.321	\$1.095.900	\$16.067.239			\$40.973.878
Claro Chile SA	\$1.734.350	\$3.937.150			\$4.046.212								\$9.717.712
Ecommerce	\$1.442.607	\$1.702.535	\$4.088.555	\$6.791.336	\$4.637.596	\$841.275	\$915.897	\$5.865.903	\$11.037.866	\$2.400.015			\$39.723.585
Tecnobuy SPA		\$8.272.860	\$2.720.800					\$2.116.200		\$2.116.200			\$15.226.060
ROM RETAIL SPA			\$2.206.901	\$1.018.020	\$1.389.870	\$1.753.020	\$1.385.826	\$3.408.830	\$2.134.791				\$13.297.258
Belsport Spa			\$1.848.200										\$1.848.200
Deudores	\$417.469	\$265.726	\$701.358	\$721.170	\$840.700	\$348.272	\$578.732	\$378.067	\$246.486	\$71.353			\$4.569.333
T2 B2B	\$400.940	\$221.910	\$645.147	\$420.351	\$571.275	\$326.280	\$345.471	\$493.356	\$263.977	\$141.561			\$3.830.268
Tienda Portal La Reina			\$1.045.633	\$501.363	\$211.623	\$260.355	\$413.128	\$245.229	\$201.565	\$75.605			\$2.954.501
Tienda Marina Arauco	\$83.991	\$209.983	\$33.597							\$8.395			\$335.966
María Sáez Vasquez					\$18.901								\$18.901
Total	\$43.327.652	\$67.189.204	\$81.281.898	\$54.809.378	\$50.913.650	\$46.782.916	\$48.277.767	\$82.226.808	\$64.993.782	\$100.503.044	\$-	\$-	\$640.306.099

Se cumplió objetivo general de mejorar la estimación de demanda de la marca **Dusted**, específicamente en el canal de ventas principal, **Walmart**, durante un período de 3 meses, con el propósito de incrementar sus contribuciones en un 3%. Antes de la implementación del modelo predictivo la contribución de Walmart tenía un valor de **\$124.012.158** acorde a una contribución global de todos los clientes de **\$474.809.273**, por lo que la contribución hasta ese período de Walmart hacia Quintec, en comparación con sus otros clientes era del 26%.

Ahora teniendo en cuenta todos los meses del presente año, y añadiendo los meses donde se implementó el modelo predictivo, las contribuciones de Walmart obtienen un valor de **\$195.137.225** sobre una contribución global de **\$640.306.099**. **Por lo tanto, la contribución final de Walmart representa un 30%, aumentando así un 4% en comparativa de ambos períodos.**

Cabe destacar que los resultados obtenidos del modelo no solo generaron un aporte económico significativo, sino también a nuestra relación como empresa con nuestros clientes al poder responder de mejor manera frente a sus solicitudes y pedidos

Conclusiones (Recomendaciones y Comentarios)

A corto plazo: Se sugiere ampliar el alcance del proyecto de proyección de demanda a otras marcas de Quintec Distribución en los canales mayoristas y minoristas. Esto podría lograrse mediante una inversión adicional en la aplicación de técnicas avanzadas de machine learning para una futura toma de decisiones. Además, se recomienda obtener un análisis mas profundos de los costos actuales de almacenamiento, depreciación de productos para identificar nuevas oportunidades ligados a la gestión de inventario.

A mediano plazo: Se aconseja expandir gradualmente el modelo y garantizar una integración efectiva, la aplicación del modelo en distintos escenarios abordaría mejorar las métricas de desempeños consolidando la eficacia del proyecto en base al uso diario en la toma de decisiones operaciones de la empresa.

A largo plazo: Se recomienda continuar explorando nuevas oportunidades en base a inteligencia artificial y el machine learning. Esto podría incluir la implementación de nuevas tecnologías emergentes, como la automatización avanzada en la cadena de suministro, para mejorar aún más la eficiencia en la gestión. Esto sugiere abordar nuevas técnicas de abastecimiento e integrar distintos datos adicionales como información del mercado, comportamiento global, de consumidores para poder enriquecer el modelo predictivo y hacerlo mas robusto.

Cumplimiento del Modelo Predictivo

El modelo predictivo cumplió sus objetivos gracias a la aplicación de conocimientos adquiridos en la formación de Ingeniería Civil Industrial. La base técnica y metodológica permitió diseñar una solución efectiva para el problema técnico mencionado. La implementación exitosa se reflejó en el rendimiento óptimo del modelo generando un impacto positivo en la toma de decisiones en base a la gestión de inventario.

Principales Aprendizajes

La colaboración estrecha entre socios comerciales, la necesidad de adaptabilidad a entornos cambiantes, la constante búsqueda de resultados óptimos, la expansión integral y gradual de mis conocimientos son los principales aprendizajes que fueron claves en este proceso de pasantía, en donde se me brindó un espacio para mejorar mis conocimientos adquiridos en la carrera y explotarlos de gran manera

Referencias

- <https://facebook.github.io/prophet/>
- <https://medium.com/illumination/understanding-fb-prophet-a-time-series-forecasting-algorithm-c998bc52ca10>
- <https://www.sciencedirect.com/science/article/pii/S0169207021001758>
- https://rua.ua.es/dspace/bitstream/10045/136586/1/Metodos_no_clasicos_de_series_temporales_en_Data_Scie_Penalver_Ripoll_Marina.pdf
- <https://grupo-siayec.com.mx/40-excelencia-en-pronosticos-con-amazon-forecast.html>
- <https://www.quintecdistribucion.cl/>
- <https://towardsdatascience.com/time-series-forecasting-with-facebooks-prophet-in-10-minutes-958bd1caff3f>
- <https://otexts.com/fpp2/arima.html>
- <https://towardsdatascience.com/how-to-forecast-with-arima-96b3d4db111a>
- <https://repositorio.uchile.cl/bitstream/handle/2250/138586/Forecasting%20activity%20using%20sentiment%20indicators%20%20the%20case%20of%20Chile.pdf;sequence=1>
- <https://dcs.uchile.cl/images/dcs/publicaciones/jmirandap/Internacional/A%20Hybrid%20Forecasting%20Methodology%20using%20Feature%20Selection%20and%20Support%20Vector%20Regression.pdf>
- <https://www.mat.uc.cl/~wilfredo/Papers/Palma-Olea-Ferreira-JoF-2013.pdf>

Anexos

1. **Mitigaciones:** Capacitación Equipo Operativo

La implementación del modelo predictivo resulta esencial para la gestión de inventario y la toma de decisiones futuras, para aquello se presenta la guía de capacitación:

Uso Práctico de Jupyter Notebook:

Se hará una capacitación en vivo, donde se guiará al equipo de operaciones el uso de Jupyter Notebook, una herramienta esencial para la ejecución y visualización de los modelos de predicción. Se demostrará la importancia de Jupyter Notebook como lenguaje de programación interactivo para el desarrollo y la presentación de análisis de datos.

Se proporcionarán guías detalladas de instalación del modelo en el servidor ocupado, centrándose específicamente en el sistema operativo Mac OS.

Finalmente se llevará a cabo una sesión presencial para la capacitación inicial, permitiendo la interacción directa y la resolución de dudas.

Explicación Hiperparámetros

- **lp (log likelihood):** es el logaritmo de la función de verosimilitud, se utiliza en la inferencia bayesiana para estimar la calidad de ajuste del modelo.
- **k (coeficientes estacionalidad):** modelan los componentes estacionales, se define en base a que período se incluye en el modelo. Actualmente se generan predicciones semanales. Cada valor representa un componente estacional específico.
- **m (coeficientes tendencia):** modela la tendencia general a lo largo del tiempo
- **delta (coeficiente vacacional):** si se incluyen, y solo si, se incluyen días festivos el valor de delta representa la incidencia de estos días en el modelo.
- **sigma_obs (desviación estándar error observado):** representa la variabilidad del error en los datos observados. Si existe un valor muy alto de sigma_obs en los datos observados indica una mayor incertidumbre en los resultados obtenidos a partir de las predicciones.
- **beta (coeficientes adicionales):** representa otros efectos específicos del dominio o de las características del modelo.

Código Prophet Jupyter Notebook (Respaldo)

Aplicación directa del modelo predictivo en Jupyter Notebook

```
from prophet import Prophet
import easygui
import subprocess
import platform
import tkinter as tk
import pandas as pd

def abrir_finder_o_explorador(archivo):
    try:
        if platform.system() == "Darwin":
            subprocess.run(["open", "--R", archivo])
        elif platform.system() == "Windows":
            subprocess.run(["explorer", "/select,", archivo])
    except Exception as e:
        print(f"Error al abrir el Finder/Explorador: {e}")

root = tk.Tk()
root.withdraw()

archivoventas = easygui.fileopenbox(title="Seleccionar archivo de ventas", f
if not archivoventas:
    print("No se seleccionó ningún archivo de ventas. Saliendo.")
    exit()
else:
    print(f"Archivo de ventas seleccionado: {archivoventas}")
abrir_finder_o_explorador(archivoventas)

archivo_stock = easygui.fileopenbox(title="Seleccionar archivo de stock", filetypes=["*.xlsx", "*.x
if not archivo_stock:
    print("No se seleccionó ningún archivo de stock. Saliendo.")
    exit()
else:
    print(f"Archivo de stock seleccionado: {archivo_stock}")

abrir_finder_o_explorador(archivo_stock)

ventas_df = pd.read_excel(archivoventas, sheet_name='Ventas Walmart')
stock_df = pd.read_excel(archivo_stock, sheet_name='SalaStock')

data = pd.merge(ventas_df, stock_df, how='inner', on='SKU')

data['Semana'] = pd.to_datetime(data['Fecha']).dt.isocalendar().week
data['Stock_Total'] = data.groupby('SKU')['Stock Tienda'].transform('sum')

feriados = pd.to_datetime([
    '2022-01-01', '2022-05-01', '2022-05-21', '2022-06-29', '2022-07-16',
    '2022-08-15', '2022-09-18', '2022-09-19', '2022-10-10', '2022-10-31',
    '2022-11-01', '2022-12-08', '2022-12-25',
    '2022-05-30', '2022-05-31', '2022-06-01', '2022-10-04', '2022-10-05',
    '2022-10-06', '2022-11-25', '2022-11-26', '2022-11-27', '2022-11-28',
    '2023-10-02', '2023-10-03', '2023-10-04'
])

data['feriado'] = pd.to_datetime(data['Fecha']).isin(feriados)

df_prophet = data[['Fecha', 'Cantidad', 'Semana', 'Stock_Total', 'feriado']]
df_prophet.rename(columns={'Fecha': 'ds', 'Cantidad': 'y'}, inplace=True)

feriados_df = pd.DataFrame({
    'holiday': 'feriado',
    'ds': feriados,
    'lower_window': 0,
    'upper_window': 1,
})

df_prophet['feriado'] = pd.to_datetime(df_prophet['ds']).isin(feriados)

modelo = Prophet(yearly_seasonality=False, weekly_seasonality=False, daily_seasonality=False)
modelo.add_country_holidays(country_name='US')
modelo.add_seasonality(name='custom', period=7, fourier_order=3, prior_scale=0.1)
modelo.fit(df_prophet)

futura = modelo.make_future_dataframe(periods=4, freq='W')
futura['feriado'] = futura['ds'].isin(feriados)

forecast = modelo.predict(futura)

julio_forecast = forecast[forecast['ds'].between('2023-07-01', '2023-07-31')]
julio_real = df_prophet[df_prophet['ds'].between('2023-07-01', '2023-07-31')]

resultados_sku = pd.merge(julio_real, julio_forecast[['ds', 'yhat']], how='left', left_on='ds', right_on='ds')
resultados_sku['yhat'] = resultados_sku[['yhat', 'Stock_Total']].min(axis=1)
resultados_sku['SKU'] = data['SKU']

resultados_sku.to_excel('/Users/asistentevm/Documents/Resultados_Prediccion.xlsx', index=False)

print("Proceso completado. Resultados guardados en 'Resultados_Prediccion.xlsx'")
```