



Nestlē

FACULTAD DE
INGENIERÍA Y CIENCIAS

UAI
UNIVERSIDAD ADOLFO IBÁÑEZ

Evaluación e implementación de herramientas para proyectar, automatizar, estandarizar y visualizar el detalle del Bad Good Operacional del almacén por roturas en centros de distribución de Nestlé



Nombre: Catalina Henríquez Henrietta

Universidad: Universidad Adolfo Ibáñez

Carrera: Ingeniería Civil Industrial

Empresa/Área: Nestlé / Supply Chain

- Equipo de control de inventario

Profesor Guía: Fernando Vásquez Acuña

Fecha: Segundo Semestre 2023

Resumen ejecutivo

Nestlé busca reducir el Bad Good Operacional del almacén a nivel empresarial, identificando que las roturas en el almacén son una causa significativa de este problema. Aunque se inició un proyecto para abordar esta situación en 2022, denominado "Roturas", este se detuvo. Ahora se pretende reactivar el proyecto debido a problemas en la implementación del Reason Code y a procesos manuales y tardíos en el análisis de datos.

El proyecto detenido presentó problemas en la implementación del Reason Code a nivel de red, evidenciando centros con baja o nula implementación. Además, se realizan proyecciones manuales de costos por mermas sin actualización ni validación, conduciendo a una subestimación de los costos reales.

La propuesta es automatizar y unificar el análisis de datos en centros de distribución para lograr proyecciones más precisas del Bad Good Operacional del almacén. El objetivo es reducir el Bad Good Operacional del almacén en un 3% en el centro de Quilicura en 3 meses. Para lograrlo, se debe disminuir el tiempo dedicado al análisis y trabajo de datos, mejorar las proyecciones de mermas, implementar nuevas visualizaciones y aumentar la adherencia al Reason Code de roturas.

Se realizó una revisión del estado del arte, sugerencias de soluciones, análisis de riesgo con propuestas de mitigación, evaluación de viabilidad económica y un plan de implementación detallado para el proyecto. Estos pasos se diseñaron para garantizar una ejecución eficiente y exitosa del proyecto "Roturas".

Se detalló la planificación y ejecución del proyecto, que incluyó la implementación de herramientas tecnológicas como Power BI y Jupyter Python para el análisis de datos provenientes de SAP. Se presentó el plan de implementación y las fases clave durante la pasantía, incluyendo el desarrollo del prototipo, la capacitación del personal y la estandarización de códigos de daños.

Los resultados mostraron una reducción del impacto por daño en un 1,96%, aunque no se alcanzó el objetivo principal del 3%. Sin embargo, se lograron mejoras significativas en la eficiencia del análisis de datos, precisión en las proyecciones y aumento en la adherencia al uso de reason code. Se identificaron desafíos y cambios que impactaron en las métricas y el desarrollo del proyecto. Las recomendaciones abarcan aspectos tácticos, estratégicos y operacionales para mejorar la implementación y continuación del proyecto.

A pesar de no cumplir completamente con el objetivo principal, el proyecto ha generado mejoras en la eficiencia operativa, la cultura de análisis de datos y la adopción de herramientas tecnológicas. Se destaca la necesidad de mejoras continuas, adaptación a cambios y consideración de métricas más precisas para futuras implementaciones.

Abstract

Nestlé aims to reduce Operational Bad Goods at the corporate level, identifying warehouse breakages as a significant cause of this issue. Although a project called "Roturas" was initiated in 2022 to address this situation, it was halted. There's now an intention to reactivate the project due to issues in implementing the Reason Code and manual, time-consuming data analysis processes.

The paused project faced problems with the Reason Code implementation at the network level, revealing centers with low or no implementation. Additionally, manual projections of costs due to damages without updates or validation led to an underestimation of actual costs.

The proposal is to automate and unify data analysis in distribution centers to achieve more precise projections of Operational Bad Goods. The goal is to reduce Operational Bad Goods by 3% at the Quilicura center in 3 months. To achieve this, it's necessary to decrease the time dedicated to data analysis and work, enhance damage projections, implement new visualizations, and increase adherence to the Roturas Reason Code.

A review of the state of the art, suggestions for solutions, risk analysis with mitigation proposals, economic viability assessment, and a detailed implementation plan for the "Breakages" project were conducted. These steps were designed to ensure an efficient and successful execution of the project.

The project's planning and execution were detailed, involving the implementation of technological tools like Power BI and Jupyter Python for data analysis from SAP. The implementation plan and key phases during the internship, including prototype development, staff training, and damage code standardization, were presented.

Results showed a 1.96% reduction in damage impact, although the primary goal of 3% wasn't achieved. Nonetheless, significant improvements were made in data analysis efficiency, projection Accuracy, and increased adherence to the Reason Code's usage. Challenges and changes affecting metrics and project development were identified. Recommendations cover tactical, strategic, and operational aspects to enhance project implementation and continuation.

Despite not fully meeting the primary goal, the project has enhanced operational efficiency, data analysis culture, and adoption of technological tools. Continuous improvement, adaptability to changes, and consideration of more precise metrics for future implementations are highlighted as essential.

Índice

1. Introducción.....	4
1.1. Contexto.....	4
1.2. Descripción del problema que se busca solucionar.....	5
1.3. Objetivos del proyecto.....	13
1.3.1. General.....	13
1.3.2. Específicos.....	13
2. Estado del arte.....	15
3. Propuestas de solución.....	18
3.1. Alternativas de solución.....	18
3.2. Solución escogida.....	19
4. Metodología.....	22
4.1. Metodologías de trabajo.....	22
4.2. Metodologías de solución.....	23
5. Medidas de desempeño (KPI's).....	25
❖ Métrica objetivo general.....	25
❖ Métricas de objetivos específicos.....	25
6. Planificación del proyecto y plan de implementación.....	28
6.1. Carta Gantt.....	28
6.2. Plan de implementación de la solución.....	30
7. Riesgos y mitigaciones.....	33
8. Desarrollo proyecto.....	35
8.1. Proyecciones.....	35
8.2. Plan de acción cultura operacional.....	43
8.3. Plan de acción nivel RED.....	48
9. Resultados.....	52
10. Evaluación económica del proyecto.....	56
11. Conclusiones.....	59
12. Recomendaciones.....	61
13. Bibliografía.....	63
14. Anexos.....	64
14.1. Objetivos planteados y proyección para el año 2023 sobre Bad Good Operacional del almacén hecho por la supervisora Ana Ontiveros.....	64
14.2. Plan de mitigación para la pérdida de continuidad.....	65
14.3. Plan de mitigación para la resistencia al cambio de operarios.....	65
14.4. Encuesta realizada a Controles de Stock para medir entendimiento de reason code nuevo.....	66

1. Introducción

1.1. Contexto

Nestlé, una reconocida empresa multinacional suiza con presencia en 20 países alrededor del mundo, destacando en el sector de alimentos y bebidas con vasta experiencia internacional y una presencia de 80 años en Chile, ocupa una destacada posición en la industria alimentaria a nivel global ofreciendo más de 700 tipos de productos secos y refrigerados tales como, helados, lácteos, café, suplementos alimenticios, entre muchos otros. La misión de la organización está orientada a enriquecer la calidad de vida de las personas, sus familias, comunidades y el medio ambiente, promoviendo la salud y el bienestar.

Fundada en 1867 por Henri Nestlé con el propósito de combatir la desnutrición, hoy en día, la empresa se destaca como una de las multinacionales líderes en alimentos y bebidas en Chile, estableciendo alianzas estratégicas con más de 15 marcas influyentes para ampliar su alcance dentro del mercado de alimentos. Sus ventas anuales superan los 400 billones de pesos chilenos y ofrecen trabajo a más de 7000 personas en Chile, aportando cerca de un 0,6% del PIB nacional.

La firma tiene un compromiso con la promoción de un estilo de vida saludable mediante la producción y distribución de productos seguros y de alta calidad, facilitando a los consumidores la toma de decisiones informadas sobre su bienestar.

En el contexto de Nestlé Chile, la colaboración se extiende tanto a productores locales como a la importación de productos desde filiales externas. La compañía presta servicios integrales que incluyen almacenamiento, producción, distribución, importación/exportación y envasado.

Este informe se enfoca en el análisis de las operaciones llevadas a cabo por el equipo de control de stock desde la perspectiva de un Trainee en el equipo en Quilicura, el centro de distribución de mayor envergadura de Nestlé. Dicho equipo es responsable de supervisar los datos de todos los centros en Chile, generando informes semanales relacionados con movimientos de productos, fechas de vencimiento, estrategias de almacenamiento, pérdidas y otros aspectos. Se plantean estrategias y proyectos para optimizar la eficiencia, los cuales son objeto de seguimiento constante.

El departamento antes mencionado, está a cargo de orientar a la compañía hacia la digitalización y automatización de herramientas que promuevan una mayor eficiencia en procesos manuales y la estandarización de datos. Esto incluye la implementación de soluciones en Business Intelligence (BI) y la unificación de criterios entre los diversos equipos que conforman la empresa.

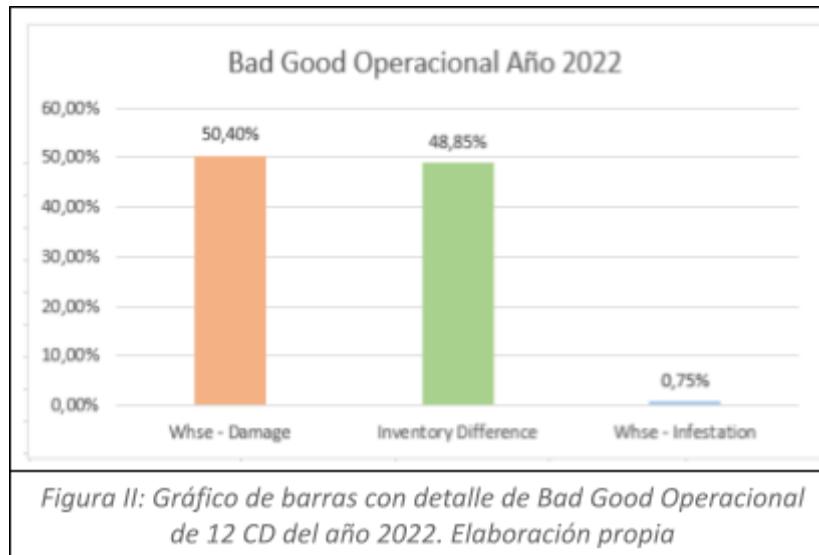
1.2. Descripción del problema que se busca solucionar

- **Síntomas:** En Nestlé se realiza un análisis del Indicador de Costo de Productos Terminados no Vendidos debido a daños en almacenes (Bad Good Operacional del almacén o BG). Este indicador cuantifica las pérdidas ocasionadas por condiciones de almacenamiento deficientes, configuración de pallets y manejo incorrecto de productos. Los datos registrados son los siguientes:

- En el año 2022, los 12 Centros de Distribución (CD) acumularon un BG anual del 0.0296%, equivalente a 27,835.28 cajas y \$277,050,938 CLP en costos por merma. De este total, el 50.40% se debió a daños en cajas, el 0.75% a plagas en almacén y el 48.85% a diferencias entre inventario físico y virtual.

BGE Año 2022				
Reason for goods	Cajas	Valor	% de impacto en CLP	% de impacto en cajas
Whse - Damage	15837,49	\$ 139.626.178	50,40%	56,90%
Inventory Difference	11837,79	\$ 135.347.855	48,85%	42,53%
Whse - Infestation	160,00	\$ 2.076.905	0,75%	0,57%
Total	27835,28	\$ 277.050.938	100,00%	100,00%

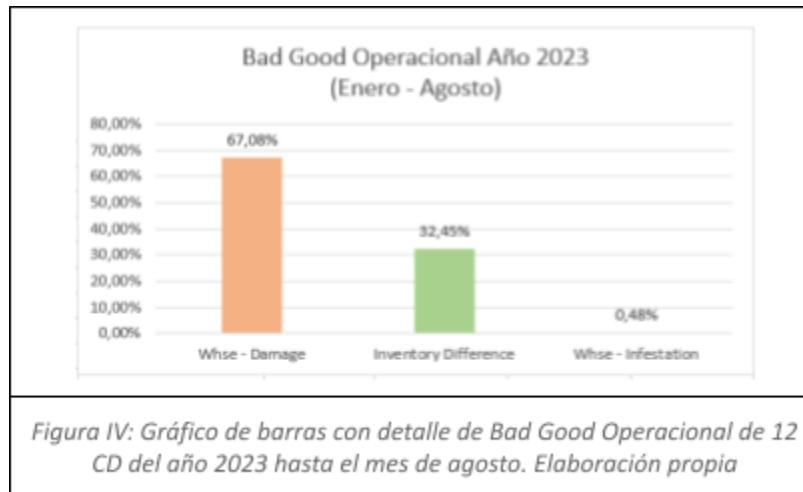
Figura I: Tabla con detalle de Bad Good Operacional de 12 CD del año 2022. Elaboración propia



- Hasta agosto de 2023, el BG en los 12 CD se sitúa en un 0.0277%, correspondiente a 15,364.66 cajas y \$173,194,648 CLP en costos por merma. El 67.08% de estas pérdidas se originó por daños en cajas, el 0.48% por plagas en almacén y el 32.45% por diferencias de inventario y se tiene que Quilicura es el CD con mayor incidencia en el BG a nivel red.

BGE Año 2023 (Enero - Agosto)				
Reason for goods	Cajas	Valor	% de impacto en CLP	% de impacto en cajas
Whse - Damage	10276,47	\$ 116.170.981	67,08%	66,88%
Inventory Difference	4979,54	\$ 56.194.298	32,45%	32,41%
Whse - Infestation	108,65	\$ 829.369	0,48%	0,71%
Total	15364,66	\$ 173.194.648	100,00%	100,00%

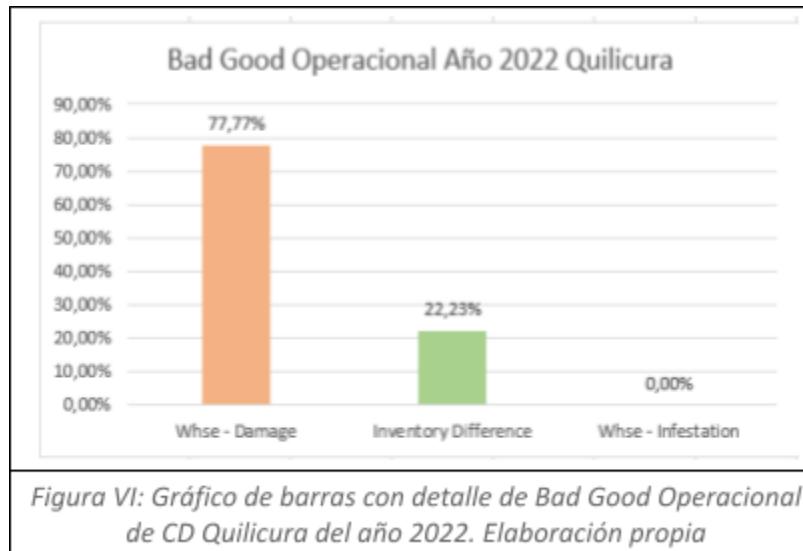
Figura III: Tabla con detalle de Bad Good Operacional de 12 CD del año 2023 hasta el mes de agosto. Elaboración propia



- En lo que va de 2023, el BG en CD Quilicura alcanza el 0.0313%, con 5,579.95 cajas y \$86,124,956 CLP en costos por merma. El 68.01% de estas pérdidas se debieron a daños en cajas y el 31.99% a diferencias de inventario.

BGE Año 2022 Quilicura				
Reason for goods	Cajas	Valor	% de impacto en CLP	% de impacto en cajas
Whse - Damage	4543,24	\$ 61.935.345	77,77%	93,99%
Inventory Difference	290,72	\$ 17.707.363	22,23%	6,01%
Whse - Infestation	0,00	\$ -	0,00%	0,00%
Total	4833,96	\$ 79.642.708	100,00%	100,00%

Figura V: Tabla con detalle de Bad Good Operacional de CD Quilicura del año 2022. Elaboración propia



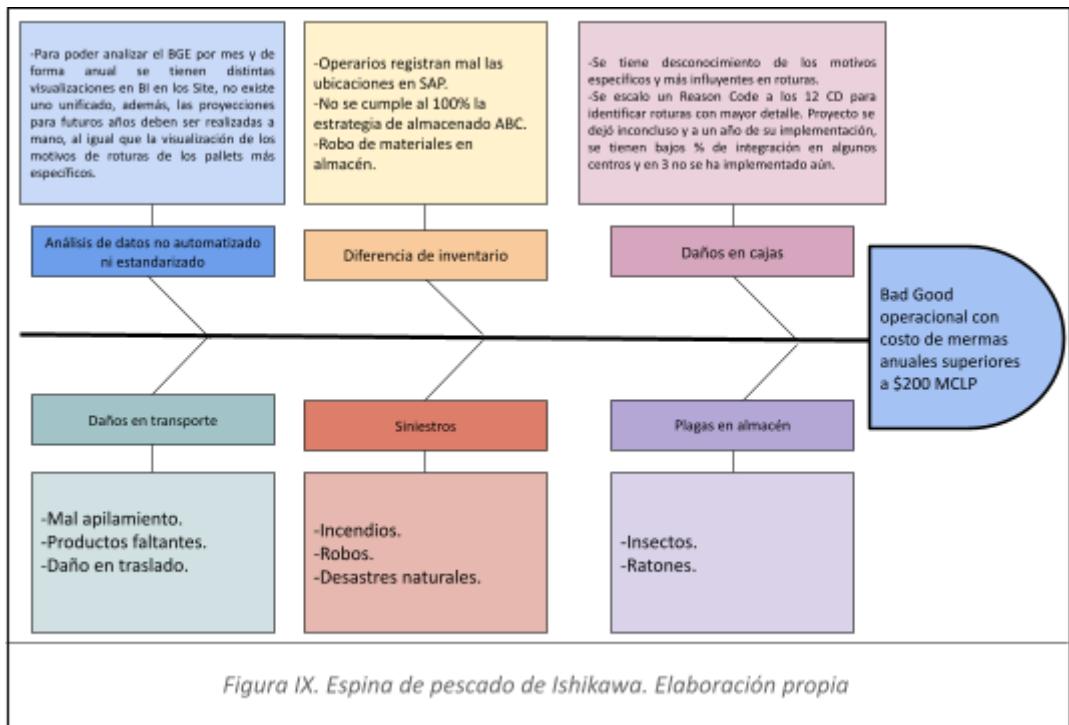
BGE Año 2023 Quilicura (Enero - Agosto)				
Reason for goods	Cajas	Valor	% de impacto en CLP	% de impacto en cajas
Whse - Damage	3419,18	\$ 58.569.883	68,01%	61,28%
Inventory Difference	2160,77	\$ 27.555.073	31,99%	38,72%
Whse - Infestation	0,00	\$ -	0,00%	0,00%
Total	5579,95	\$ 86.124.956	100,00%	100,00%

Figura VII: Tabla con detalle de Bad Good Operacional en CD Quilicura del año 2023 hasta el mes de agosto. Elaboración propia



- **Diagnóstico e investigación del problema:** El análisis de causas raíz se llevó a cabo utilizando el diagrama de espina de pescado de Ishikawa, revelando 6

subproblemas que inciden en el Bad Good Operacional del almacén.



Estas mermas se deben principalmente a la falta de automatización y estandarización en los datos entre los diferentes centros, lo que dificulta la identificación de problemas y oportunidades de mejora. Los aumentos en el BG se derivan de diferencias de inventario, siniestros, plagas, problemas en el transporte y daños en cajas dentro del almacén.

Se han brindado capacitaciones a operarios en el almacén, pero los resultados no han sido consistentes ni medibles. Por tanto, se han tomado medidas, como el proyecto de roturas iniciado en 2022, para implementar un código de roturas en el proceso de ajustes de inventario. Sin embargo, la implementación no está completa en todos los centros, lo que dificulta el análisis y la toma de decisiones.

Adicionalmente, hace falta un análisis unificado de los datos de Reason Code para ayudar con el subproblema de la escasez de información de motivos de roturas, pero no se ha consolidado a nivel de red. Esto ha generado desafíos en la comprensión de las causas de las roturas en el almacén y ha dificultado la toma de decisiones estratégicas.

ID	Tipo	Síntesis	Detalle
D061	Daño Origen Nacional	Roturas	Caja en mal estado o dañada
D062		Filtraciones	Caja humedas
D063		Productos mal embalado	Alertas mal pegadas, defectos en los sellados, mal armado de cajas, producto no va en caja que corresponden
D064		Contaminación suelta interna	Rocas / hongos / mal olor / plagas / grasas detectados en la OPERACIÓN
D065	Daño Origen Importaciones	Roturas	Caja en mal estado o dañada
D066		Filtraciones	Caja humedas
D067		Productos mal embalado	Alertas mal pegadas, defectos en los sellados, mal armado de cajas, producto no va en caja que corresponden
D068	Daño Origen Físico/Químico	Moturas	Caja en mal estado o dañada
D069		Filtaciones	Caja humedas
D070		Produtos mal embalado	Alertas mal pegadas, defectos en los sellados, mal armado de cajas, producto no va en caja que corresponden
D41	Daño Almacenamiento	Daños por estantería	Rocas y hongos
D42		Pallet no se adapta a tamaño de ubicación	Mala configuración de las ubicaciones
D43		Alertas rotas	Daños causados por aplicaciones en peso
D44		Almacenamiento desacorde	Daños causados por aplicaciones en ubicación
D45		Daños por choques de maquinaria con materiales	Mal manejo de maquinarias dentro del almacén
D46		Roturas por dimensiones de almacenar	Daños causados por la dimensión de las cajas al momento de almacenar
D47		Daños por cintas	Retención de cintas adhesivas que dañan el producto o por encima
D48		Daños por choques de pallets	Roturas por choques de pallets debido a falta de topes en estructura
D49		Daños por activo y desactiva en la ubicación	Daño ocasionado al momento de almacenar materiales
D49.0		Daños en rack	Mala maneja al momento de guardar o sacar pallets en altura
D50	Ganga - Despackaje/Envío hasta carga de transporte	Contaminación suelta interna	Rocas / hongos / mal olor / plagas / grasa / humedad otros detectados en la OPERACIÓN
D51		No disponible para venta en uno o más	Materiales fraccionados en buen estado que no se pueden vender
PP1	Picking/Preparación [Paquete Adelante]	Daños por manipulación de unidades	Mala manipulación de material
PP2		Almacenamiento	Mala práctica de almacenamiento por parte de los operarios
PP3		Daños por cada de pallet en altura	Daños por cada de pallet en altura
C49001	Carga - Despackaje/Envío hasta carga de transporte	Daños por sobre repacetado	Daños o roturas por sobre rango de materiales a despacho
C49002		Daños por mala colocación de la maquinaria en cargas de rampa	Graves al realizar los cortes y cargas de los pallets
C49003		Daños por temperatura T3	Daño por exceso de temperatura al momento de transportar
C49004		Daños por temperatura T2	Daño por exceso de temperatura al momento de transportar
COPACK1	Co-packer	Daños por manipulación de pallets	Daños en transpackaging de pallets
COPACK2		Daños por manipulación de material	Daños causados por el personal el momento de transformar el producto
MAG1	Magaz	Daños por manipulación de pallets	Daños en transpackaging de pallets
MAG2		Daños por manipulación de material	Daños causados por el personal el momento de transformar el producto
MAG3		Alerta por UNI Fabriqueno o diseño distinto	Producto no conforme hallado durante proceso de magaz. Unidad distinta, Unidades dañadas o faltantes
OTR	Transporte	Daño en transporte	Daño en generado en la ruta de transporte

Figura X: Reason Code levantado a los 12 CD. Elaborado por Equipo de Control de Inventario

Reason Code	Motivo de daño	Sin considerar datos mal ingresados o sin RC		
		Número de Cajas	CLP	Suma de CLP
D44	Daños causados por aplicaciones en ubicación	-563	\$ -10.147.837	22,55%
PP1	Mala manipulación de material	-891	\$ -7.499.555	18,55%
D061	Cajas en mal estado o dañadas	-299	\$ -5.012.773	11,14%
D47	Roturas por crucetas afiladas que dañen el producto o por empuje	-230	\$ -4.999.252	11,04%
D43	Daños causados por aplicaciones en peso	-166	\$ -3.800.086	8,44%
D45	Mala manejo de maquinarias dentro del almacén	-177	\$ -3.403.914	7,58%
C49002	Empres al realizar los cortes y cargas de los pallets	-135	\$ -2.418.802	5,37%
D46	Daños causados por la dimensión de las cajas al momento de almacenar	-76	\$ -1.650.570	3,67%
C49001	Daños o roturas por sobre carga de materiales a despacho	-101	\$ -1.634.409	3,63%
PP2	Mala práctica de almacenamiento por parte de los operarios	-90	\$ -1.320.535	2,93%
D430	Mala maneja al momento de guardar o sacar pallet en altura	-90	\$ -1.177.707	2,62%
CP1	Rocas / hongos / mal olor / plagas / grasa / humedad otros detectados en la OPERACIÓN	-38	\$ -598.314	1,33%
PP3	Daños por caída de material desde ubicaciones en altura	-25	\$ -481.910	1,07%
D41	Rack con daños	-11	\$ -277.162	0,62%
DK2	Cajas humedas	-12	\$ -193.230	0,43%
D063	Alertas mal pegadas, defectos en los sellados, mal armado de cajas, producto no va en cajas que corresponden	-3	\$ -143.437	0,32%
D48	Roturas por choques de pallets debido a falta de topes en estructura	-4	\$ -116.363	0,26%
D49	Materiales fraccionados en buen estado que no se pueden vender	-1	\$ -58.243	0,13%
COPACK2	Daños causados por el personal el momento de transformar el producto	-5	\$ -57.549	0,13%
D49	Daño ocasionado al momento de almacenar materiales	-2	\$ -44.822	0,10%
D42	Mala configuración de las ubicaciones	-2	\$ -32.789	0,07%
Total		-2931	\$ -45.004.619	100,00%

Figura XIII: Detalle de Reason Code en CD Quilicura hasta 7 de septiembre de 2023. Elaboración propia

Considerando datos mal ingresados o sin RC				
Reason Code	Motivo de daño	Número de Caja	CDP	Suma de CDP
Sin RC	No implementado en registro	-947	\$ -13.052.883	23,28%
G44	Daños causados por apilamientos en ubicación	-583	\$ -10.147.837	17,30%
PP1	Mal manipulación de material	-481	\$ -7.466.955	12,73%
DON1	Cajas en mal estado o bandeo	-298	\$ -5.012.723	8,55%
G47	Roturas por crucetas afiladas que dañan el producto o por empuje	-230	\$ -4.969.252	8,47%
G43	Daños causados por apilamientos en piso	-186	\$ -3.800.086	6,48%
G45	Mal manejo de maquinarias dentro del almacén	-177	\$ -3.403.934	5,80%
CARDES2	Error al realizar los cortes y cargas de los pallets	-135	\$ -2.418.802	4,17%
G46	Daños causados por la dimensión de las cajas al momento de almacenar	-76	\$ -1.690.570	2,81%
CARDES1	Daños o roturas por sobre carga de materiales a despacho	-101	\$ -1.634.409	2,79%
PP2	Malas prácticas de apilamiento por parte de los operarios	-56	\$ -1.320.535	2,25%
DA10	Mala maniobra al momento de guardar o sacar pallet en altura	-56	\$ -1.177.707	2,01%
OP1	Fecas / hongos / mal olor / plagas / grasa / húmedas otros detectados en la OPERACIÓN	-38	\$ -596.324	1,02%
PP3	Daños por caída de material desde ubicaciones en altura	-25	\$ -481.910	0,82%
DA3	Rack con daños	-11	\$ -277.562	0,47%
DO02	Cajas húmedas	-12	\$ -193.230	0,33%
DON8	Aletas mal pegadas, defectos en los sellados,mal armado de cajas,producto no va en cajas que corresponden	-3	\$ -143.437	0,24%
G48	Roturas por choques de pallet debido a falta de topes en estructura	-4	\$ -116.365	0,20%
G4F	Materiales fraccionados en buen estado que no se pueden vender	-1	\$ -58.248	0,10%
COPACK2	Daños causados por el personal el momento de transformar el producto	-5	\$ -57.549	0,10%
G49	Daño ocasionado al momento de almacenar materiales	-2	\$ -44.822	0,08%
DA2	Mala configuración de las ubicaciones	-2	\$ -32.789	0,04%
Total		-3330	\$ -58.657.527	100,00%

Figura XIV: Detalle de Reason Code en CD Quilicura hasta el 7 de septiembre de 2023, considerando datos sin Reason Code. Elaboración propia

En Quilicura, se ha logrado una implementación del 93% en los registros realizados este año de ajustes de inventario por roturas, por lo que se tomará este centro como un ejemplo piloto para lo que se debería realizar con este proyecto. Los motivos más recurrentes de rotura en lo que va del año 2023 fueron malas prácticas de apilamiento de materiales (22.55%), malas prácticas de manipulación de productos en Picking - Preparación (16.59%), cajas en mal estado o bandeo (11.14%), roturas por crucetas afiladas que dañan el producto o por empuje (11.04%).

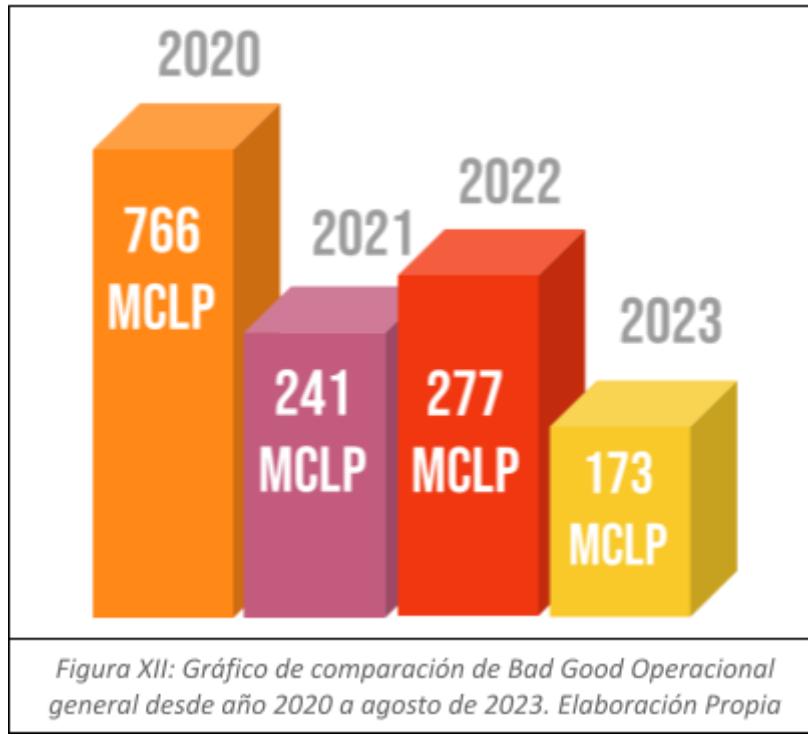
Sumado a esto, tras analizar los datos y comentar los hallazgos con los encargados del almacén, se ha identificado un mal uso del registro (no aplicado de forma correcta en ciertas situaciones) y un no uso por desconocimiento en procesos como el recibo de pedidos dañados o con folio faltante por parte de transporte, donde sí debería ser utilizado en Reason Code.

El equipo de Control & Compliance, encargado de la gestión del inventario, tiene una carga de trabajo que a menudo supera el 90% de su capacidad diaria, limitando el tiempo disponible para el análisis manual de nuevos datos. La falta de un enfoque estandarizado y automatizado para el procesamiento de datos de los 12 centros de distribución (CD) también se ha convertido en un obstáculo.

Además, el proceso de estandarización de datos de Reason Code para los 12 CD consume aproximadamente 5 horas, excluyendo el análisis real de los

datos. Las horas de trabajo dedicadas al análisis y procesamiento de datos siguen aumentando, especialmente debido al crecimiento de la cantidad de datos y la necesidad de reducir el margen de error en las proyecciones. La comprensión de datos también se ve obstaculizada por la falta de registros considerados en la actualidad y la necesidad de actualizar protocolos en SAP.

En cuanto a las proyecciones del BG por sitio, solo CD Quilicura realiza una proyección manual, lo que dificulta la comparación y el análisis de valores reales. En diciembre de 2022 se realizaron las proyecciones y target de BG para el año 2023 ([Anexo 14.1](#)), donde se ha estimado que se iba a generar una disminución de \$56.000.000 CLP con respecto al año anterior (proyectado con 223 MCLP de año 2022 cuantificado), obteniendo un Bad Good Operacional del almacén de \$184.000.000 CLP, sin embargo, en agosto del presente año se ha alcanzado un valor de \$173.000.000 CLP, por lo que se espera superar el objetivo planteado durante el mes de septiembre.



Finalmente, estas pérdidas operacionales tienen un impacto significativo en el área de distribución y finanzas, aumentando los costos y reduciendo el capital de trabajo disponible, lo que afecta la rentabilidad y la competitividad de la empresa en el mercado.

En conclusión, la oportunidad de mejora identificada en Nestlé es la falta de automatización y estandarización en los datos entre los diferentes centros de distribución. Esto dificulta la identificación de problemas y oportunidades de mejora, así como el análisis y la toma de decisiones estratégicas.

Si se lograra implementar la automatización y estandarización de los datos en todos los centros de distribución, se agregaría un gran valor al proceso de negocio, dado que se podría identificar de mejor manera las causas de las pérdidas operacionales, como diferencias de inventario, siniestros, plagas y daños en cajas. Además, se haría más fácil el análisis de datos y la toma de decisiones estratégicas para reducir el Bad Good Operacional del almacén y mejorar la rentabilidad y competitividad de la empresa el comprender de mejor manera las roturas con información más clara sobre estas.

La oportunidad identificada sería implementar herramientas de automatización, estandarización y proyecciones en procesos relacionados al BG del almacén. Con esto se podría disminuir el impacto de los daños en el BG, lo cual sería un valor agregado significativo para la empresa.

1.3. Objetivos del proyecto

Los objetivos, tanto general como específicos, fueron planteados considerando las habilidades ingenieriles y el alcance del proyecto en el acotado tiempo de duración de la pasantía.

1.3.1. General

"Reducir el Bad Good Operacional del almacén por daño en un 3% en el centro de Quilicura (ejemplo piloto del proyecto) en un período de 3 meses"

1.3.2. Específicos

- Mejorar la eficiencia y análisis de datos en el CD, reduciendo en un 80% las horas hombre (HH) utilizadas para trabajar y analizar datos de roturas. Este objetivo busca optimizar el proceso de análisis de datos en el centro de distribución, reduciendo el tiempo y esfuerzo requerido para trabajar y analizar los datos de roturas. Esto permitirá una mayor eficiencia en la gestión de datos y liberará recursos humanos para otras tareas importantes.

- Mejorar las proyecciones de aumento o disminución del Bad Good Operacional del almacén de los 11 CD, tanto consolidado como individualmente y utilizar estas proyecciones para fijar targets de mejora respaldados matemáticamente y mejorar la toma de decisiones estratégicas. Este objetivo busca mejorar la precisión de las proyecciones del Bad Good Operacional del almacén en los diferentes centros de distribución. Al tener proyecciones más precisas, se podrán establecer targets de mejora basados en datos matemáticos y tomar decisiones estratégicas más informadas para reducir las pérdidas operacionales.
- Unificar, estandarizar e integrar los datos de motivos de roturas identificados en el CD e incluidos en la plataforma SAP desde el año 2023 y generar una visualización de los datos mediante una plataforma para el análisis de los reason code. Este objetivo busca unificar y estandarizar los datos de los motivos de roturas identificados en el centro de distribución para que los Supervisores de Control de Stock y el equipo de Control & Compliance puedan visualizar los motivos de roturas. Además, se busca generar una visualización de estos datos para facilitar el análisis y comprensión de los reason code, lo que permitirá identificar patrones y tomar acciones correctivas más efectivas.
- Aumentar el porcentaje de adherencia de los 11 CD a la utilización del Reason Code de daños en sus ajustes de inventario. Este objetivo busca promover y aumentar la utilización del Reason Code de daños en los ajustes de inventario en los diferentes centros de distribución. Al aumentar la adherencia a esta práctica, se podrá tener una mejor trazabilidad de los daños y una mayor precisión en los registros, lo que facilitará el análisis y la toma de decisiones.
- Mejorar el Bad Good Operacional del almacén mediante la mejora del criterio de aumento por daños. Este objetivo busca mejorar el criterio utilizado para determinar el aumento del BG debido a daños, de manera que se pueda medir los resultados finales del proyecto y su impacto en el modelo de negocio de la empresa.

2. Estado del arte

En el proyecto presentado en este informe, se identificó un problema en las prácticas operatorias asociadas a los almacenes de Nestlé. La falta de información sobre las causas de las roturas que generan mermas, así como la carencia de automatización, limpieza y análisis de datos, ha complicado la toma de decisiones a nivel de red.

Para abordar estos desafíos y mejorar los procesos de almacenamiento, se realizó una investigación sobre cómo otras empresas han afrontado problemas similares en sus centros de distribución e inventarios mediante la página web Google Scholar. Tras investigar los proyectos relacionados a la búsqueda en torno a mejoras de mermas en almacenes, se hizo una selección de los casos considerando sus resultados, análisis y metodologías utilizadas, priorizando proyectos con buenos resultados.

- **Caso 1: Plan de mejoramiento para reducir el gasto generado por merma (rotura) en el almacén Homecenter Palmira**

Este proyecto fue planteado por Termal y Meyer (2023), y tuvo como objetivo mejorar las prácticas de manipulación y almacenamiento de mercancía en la compañía, específicamente con relación a la rotura de productos. Se analizaron los procesos de manipulación y almacenamiento de los diferentes productos en cada departamento de venta.

- Metodología: se hizo una investigación descriptiva, obteniendo datos cuantitativos y cualitativos. Los datos cualitativos permitieron identificar las acciones que afectan el cuidado de la mercancía en el proceso operativo y se logró identificar los procesos que generaban mayores mermas en cada área del negocio, destacando las roturas como el motivo principal en más del 50% de los casos. Se generó un plan de trabajo para reducir el gasto en esta merma focalizado a los daños identificados.
- Resultados: Se logró disminuir las incidencias de roturas en las mermas en un 10,16%. Se investigaron las causas de estas roturas y se destacó el uso de una base de datos para implementar acciones de mejora y generar alertas que eviten las roturas frecuentes. (Termal & Meyer, 2023)

- **Caso 2: Mejora continua basada en metodología DMAIC en almacén**

Estas mejoras planteadas por Cueva y Trujillo (2019), tenían como objetivo incrementar la productividad de un almacén mediante el uso y aplicación de

herramientas tales como buenas prácticas de almacenamiento o medición de tiempos.

- Metodología: se usó una metodología de estudio cuasiexperimental y post experimental sobre una muestra de registros y datos de procesos y rentabilidad de una empresa en un período de tiempo fijo. Se generó un plan de mejora utilizando la metodología DMAIC para mejorar los problemas identificados en Picking, rebasto y despacho.
 - Resultados: Se obtuvo como conclusión que la metodología DMAIC puede tener resultados significativos en ciertas áreas de estudio y en otras no ser tan eficiente. Se logró reducir las incidencias por faltantes en 34%, reducir costos operativos de recepción en un 49% y los costos de distribución en un 6%. Se recomienda buscar otras metodologías adicionales que ayuden al proceso de aumentar las buenas prácticas. (Cueva & Trujillo, 2019)
- **Caso 3: Implementación de procesos de control de inventarios en empresa de metal mecánica**

La implementación de procesos de control realizada por Moraida A. (2017), tenía como objetivo medir el impacto de medidas de control de inventarios en la rentabilidad de la empresa.

- Metodología: Se estudiaron los procesos dentro del almacén, identificando las problemáticas con mayor incidencia en costos y se diseñaron reglamentos de función, procedimientos, documentos de control de inventarios y registros de Kardex para controlar pérdidas.
- Resultados: Se logró aumentar la rentabilidad de la empresa. La rentabilidad del margen bruto aumentó en 14%, la rentabilidad operativa aumentó en 7% y la rentabilidad neta aumentó en un 4%. (Moraida A., 2017)

Del análisis del estado del arte, se pueden extraer aspectos clave para el planteamiento y diseño de soluciones en el área de Supply Chain:

- Es esencial comprender en detalle las causas de los daños en la cadena de suministro para facilitar el desarrollo de planes estratégicos de mejora.
- Se sugiere complementar esta colaboración con capacitaciones y procedimientos de mejora.

- La implementación de metodologías de mejora de procesos, como DMAIC puede optimizar los recursos empresariales y facilitar el manejo de la información relacionada con el problema identificado.
- El uso adecuado de las herramientas disponibles en la empresa es relevante para mejorar la eficiencia de los procesos y la calidad de los registros de información.
- La elaboración de planes de acción focalizados permite llevar a cabo cambios efectivos en los procesos productivos y reducir los costos asociados a roturas en las diferentes áreas de la cadena de suministro.

3. Propuestas de solución

3.1. Alternativas de solución

Tras revisar el estado del arte anteriormente expuesto, se han propuesto soluciones específicas para cada uno de los objetivos planteados:

3.1.1. Primer objetivo:

- 3.1.1.1. Automatizar este proceso de forma externa para facilitar los análisis con una empresa de automatización o consultorías.
- 3.1.1.2. Generar la automatización de forma interna mediante el uso de scripts para construir, extraer y limpiar los datos.

3.1.2. Segundo objetivo:

- 3.1.2.1. Contratar un servicio externo especializado en análisis de datos y proyecciones para el seguimiento y alertas sobre futuros datos.
- 3.1.2.2. Desarrollar un script que automatice la creación y actualización de proyecciones utilizando los datos del software ERP SAP. Complementar este proceso con reuniones semanales que involucren a los responsables de todos los centros de distribución de Nestlé para identificar problemas y comprometerse con mejoras.

3.1.3. Tercer objetivo:

- 3.1.3.1. Crear un software que permita concentrar la información valiosa en el proceso de toma de decisiones y generar una visualización de esta.
- 3.1.3.2. Utilizar las herramientas proporcionadas por Nestlé en alianza con Microsoft como power BI para visualizar los datos relevantes en la toma de decisiones.

3.1.4. Cuarto objetivo:

- 3.1.4.1. Realizar capacitaciones de la correcta implementación de Reason Code en cada centro de Nestlé, revisando semanalmente desde la fecha de capacitación la adherencia y generando alarmas ante el no cumplimiento.
- 3.1.4.2. Aplicar sanciones por mala implementación de reason code en forma de amonestaciones a quien haya realizado el ajuste de inventario en SAP.

3.1.5. Quinto objetivo:

3.1.5.1. Generar un plan de acción que permita mejorar el o los criterios de rotura identificados como más influyentes en el centro estudiado.

3.1.5.2. Plantear mejoras de corto plazo con relación a lo que los empleados identifican como más relevante de abordar dentro del almacén.

3.1.6. Objetivo general:

3.1.6.1. Utilizar herramientas tecnológicas para analizar datos y desarrollar planes de acción basados en información concreta del almacén y su historial, investigando los detalles relevantes con los responsables de los procesos.

3.1.6.2. Proponer mejoras que consideren el Bad Good Operacional del almacén y las proyecciones futuras basadas en datos históricos y actuales, identificando oportunidades de mejora según el rendimiento de los almacenes.

3.1.6.3. Contratar a un nuevo analista de roturas que se encargue de recopilar información, realizar proyecciones y diseñar planes de acción para cada centro, aliviando la carga de trabajo de los gerentes de cada sitio.

3.2. Solución escogida

Se realizó la selección de la o las soluciones a realizar utilizando los siguientes criterios de decisión acordados con el equipo de Control & Compliance y considerando los plazos de la pasantía:

Tabla I: Criterios de selección para la solución del proyecto

Criterios	Consideraciones de criterio	Ponderación
Alcance en el tiempo (restricción de 3 meses)	Considera el tiempo que podría tomar llevar a cabo la implementación de la solución y obtener resultados.	25%
Costo de implementación (Debe ser aprobado por jefe de Supply Chain)	Considera todos los costos asociados a implementar solución planteada, mantenerla y como esta reducirá otros tipos de costos en cambio.	20%
Alineación con negocio (Importante para ir de la mano con otros proyectos e implementaciones)	Considera los futuros proyectos, visión y objetivos que tiene la empresa y si estas soluciones se alinean con esto.	20%
Impacto de la solución (Es relevante para el negocio obtener el mayor valor posible)	Considera el impacto esperado de la solución en el proceso de negocio, métricas, disminución de horas utilizadas, bases de datos nuevas y otras mejoras asociadas.	20%
Automatización (Necesario para poder mejorar eficiencia en procesos)	Considera la automatización y utilización de herramientas tecnológicas que pueda o no poseer la empresa.	15%

Para categorizar las soluciones se realizó una evaluación mediante una escala Likert de 1 a 5 por cada criterio descrito, donde 1 está totalmente en desacuerdo: la solución no es viable para el proyecto y 5 está totalmente de acuerdo: la solución es completamente viable con el proyecto:

Tabla II: Ponderación de soluciones propuestas según criterio de selección

Solución	Alcance en el tiempo	Costo de implementación	Alineación con negocio	Impacto de solución	Automatización	Ponderación
Alternativas seleccionadas	25%	20%	20%	20%	15%	100%
3.1.1.1.	2	1	3	5	5	3,05
3.1.1.2.	5	4	5	5	5	4,80
3.1.2.1.	3	1	4	5	5	3,50
3.1.2.2.	5	5	4	5	5	4,80
3.1.3.1.	4	3	5	5	5	4,35
3.1.3.2.	5	5	5	5	5	5,00
3.1.4.1.	5	5	5	4	1	4,20
3.1.4.2.	4	3	1	3	1	2,55
3.1.5.1.	5	5	5	5	5	5,00
3.1.5.2.	5	5	5	5	5	5,00
3.1.6.1.	5	5	5	5	5	5,00
3.1.6.2.	5	5	5	5	5	5,00
3.1.6.3.	3	1	5	5	5	3,70

Se seleccionaron las soluciones por objetivo que tuvieran clasificación más alta según su viabilidad para el proyecto y en las categorías con más de una opción posible se verificó si es que se podría llevar a cabo en conjunto. Se decidió la siguiente solución para el proyecto:

Solución seleccionada: Automatización interna mediante el uso de scripts para construir, extraer y limpiar datos, y planes de acción para potenciar una red colaborativa de mejora.

El proyecto consiste en generar la automatización interna en Nestlé a través de scripts para construir, extraer y limpiar datos. Se desarrollará un script para automatizar la creación y actualización de proyecciones utilizando datos extraídos del software ERP SAP. Además, se plantearán reuniones semanales con los responsables de los centros de distribución de Nestlé para identificar problemas y comprometerse con mejoras.

Se utilizarán herramientas proporcionadas por Nestlé en alianza con Microsoft, como Power BI, para visualizar los datos relevantes en la toma de decisiones. También se realizarán capacitaciones sobre la implementación de Reason Code en cada centro de Nestlé, revisando semanalmente la adherencia y generando alarmas en caso de incumplimiento.

Se generará un plan de acción para mejorar los criterios de rotura identificados como más influyentes en el centro estudiado. Además, se propondrán mejoras de corto plazo basadas en las necesidades identificadas por los empleados del almacén.

Se utilizarán herramientas tecnológicas para analizar datos y así desarrollar planes de acción basados en información concreta del almacén y su historial. Esto permitirá identificar oportunidades de mejora según el rendimiento de los almacenes y establecer objetivos claros.

La implementación de esta solución permitirá disminuir el Bad Good Operacional del almacén causado por daños en un 3% y mejorar la eficiencia de los procesos involucrados, lo que se traducirá en una mayor rentabilidad y satisfacción del cliente.

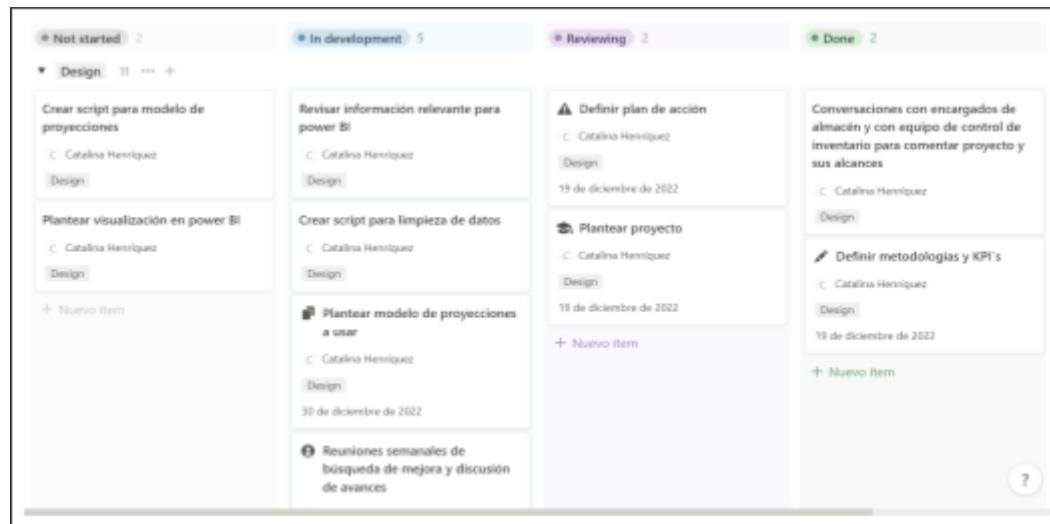
4. Metodología

4.1. Metodologías de trabajo

Para llevar a cabo el proyecto de manera organizada, se aplicarán las metodologías DMAIC y Agile SCRUM. La metodología DMAIC, que representa las etapas de Definir, Medir, Analizar, Mejorar y Controlar, ofrece un enfoque estructurado para la mejora de procesos y la resolución de problemas.

En la etapa de Definir, se establecen los objetivos, problemas, oportunidades y expectativas del proyecto. La etapa de Medir se enfoca en la recopilación de datos relevantes y la definición de métricas clave. La fase de Analizar implica la búsqueda de causas raíz y problemas mediante herramientas de análisis y análisis estadístico. En la etapa de Mejorar, se generan e implementan soluciones propuestas, integrando planes de acción. Finalmente, en la fase de Control, se establecen medidas de seguimiento y se implementan correcciones si es necesario.

Por otro lado, la metodología Agile SCRUM se basa en un tablero tipo "Kanban" que organiza tareas en cuatro fases: "No iniciado", "En desarrollo", "En revisión" y "Completado". Esta metodología permite categorizar, jerarquizar y controlar las actividades necesarias para alcanzar los objetivos y garantizar una implementación eficaz de la solución.



The Kanban board displays the following tasks:

- Not started:**
 - Crear script para modelo de proyecciones
 - Plantear visualización en power BI
- In development:**
 - Revisar información relevante para power BI
 - Crear script para limpieza de datos
 - Plantear modelo de proyecciones a usar
 - Reuniones semanales de búsqueda de mejora y discusión de avances
- Reviewing:**
 - Definir plan de acción
 - Plantear proyecto
- Done:**
 - Conversaciones con encargados de almacén y con equipo de control de inventario para comentar proyecto y sus alcances
 - Definir metodologías y KPI's

Figura XV: Tablero SCRUM tipo Kanban para el proyecto desarrollado en aplicación de organización Notion. Elaboración propia

4.2. Metodologías de solución

A continuación, se definen las metodologías a utilizar para cada uno de los objetivos planteados para el proyecto:

4.2.1. Primer objetivo:

- Revisar y validar el modo actual de obtención y procesamiento de datos, junto con su tiempo estimado de ejecución.
- Plantear mejoras mediante automatización y digitalización de trabajo para procesamiento y análisis de datos.

4.2.2. Segundo objetivo:

- Levantamiento de información de cálculo de proyecciones actual, cómo fueron fijados los objetivos y cómo se validaron los resultados obtenidos de las proyecciones.
- Estandarizar y automatizar cálculo de proyecciones de Bad Good Operacional del almacén mediante script de procesamiento de datos para aplicar un modelo de proyección.
- Validación de resultados con medidas estadísticas de precisión de modelos predictivos.
- Generación de targets anuales respaldados en predicciones.

4.2.3. Tercer objetivo:

- Levantamiento de visualizaciones existentes en power BI de reportes de Bad Good - IRA.
- Solicitar y diseñar integración de detalle de códigos de roturas y su detalle de costo en cajas y CLP por CD en power BI.
- Compartir visualización a nivel de red del reporte en power BI y capacitar sobre su análisis esperado y correcto registro de códigos para procesamiento de datos.

4.2.4. Cuarto objetivo:

- Levantamiento de información sobre porcentaje de adherencia actual y condiciones que debilitan o afectan esta medida de desempeño.
- Levantamiento de información recibida por parte de operarios en almacén y como identifican los Reason Code para registrarlos en SAP para validar un uso correcto de estos motivos.

- Capacitaciones a nivel red de correcta implementación de Reason Code en daños operacionales.
- Plan de acción para corregir errores en la identificación de daños en almacén en caso de ser necesario (por mala asociación de daños a Reason Codes).
- Levantamiento de planes de acción a nivel de red para colaborar en los análisis realizados y los pasos a seguir para generar nuevas medidas de mejora.

4.2.5. Quinto objetivo:

- Levantamiento de información sobre el proceso actual de extracción de datos, revisar parámetros de entrada para el cálculo de BG y sus componentes de impacto, plataformas de visualización de información utilizadas actualmente y construcciones o visualizaciones faltantes necesarias para analizar datos.
- Levantamiento de medidas tomadas actualmente a nivel de red para mejorar este indicador.
- Estandarizar y automatizar la visualización y obtención de datos para cálculo de Bad Good Operacional para todos los CD, que permite ver el detalle de los componentes que afectan el cálculo del BG.
- Compartir a nivel de red un instructivo con movimientos en SAP y fórmula oficial del cálculo de la tasa de Bad Good Operacional del almacén para acompañar el uso de la información mostrada en Power BI.
- Planteamiento e implementación de planes de acción
- Levantamiento de medidas aplicadas en el proyecto a nivel de red para fomentar el trabajo colaborativo para lograr mejoras.

5. Medidas de desempeño (KPI's)

Para evaluar los impactos y resultados del proyecto en los procesos comerciales de Nestlé, es esencial definir las medidas de desempeño que se ajusten a los objetivos planteados y establecer las variaciones esperadas al finalizar el proyecto. A continuación, se presentan las métricas para medir el cumplimiento de cada objetivo, con sus respectivos métodos de cálculo, valor inicial (si corresponde) y el valor objetivo posterior a la implementación del proyecto.

❖ Métrica objetivo general

- Porcentaje de impacto en CLP en Bad Good Operacional del almacén

$$\frac{\text{Valor en CLP de cajas mermadas por daño}}{\text{Valor de Bad Good Operacional Total en CLP (por daño y diferencia de inventario)}} \times 100$$

Este indicador se calcula dividiendo el valor en pesos chilenos (CLP) del total de cajas o unidades mermadas por daño en el almacén, registradas en SAP durante los ajustes de inventario, entre el valor total del Bad Good Operacional del almacén (BG), que comprende el daño por roturas y las diferencias de inventario registradas en el ajuste de SAP. El resultado se multiplica por 100 para obtener el porcentaje de impacto del daño por roturas en el Bad Good Operacional del almacén.

Actualmente, el porcentaje de impacto del daño por roturas sobre el BG en el mes de agosto es del **68,01%**. Se espera reducir este indicador en un **5%** en el centro de distribución de Quilicura.

Tabla III: Valor actual y esperado del impacto de roturas en el BGE

Valor actual	Valor esperado
87,56%	84,56%

❖ Métricas de objetivos específicos

- Objetivo específico 1: Horas Hombre en trabajo de procesamiento y análisis de datos

$$\sum \text{Horas Hombre utilizadas en el trabajo y análisis de roturas}$$

Para calcular este indicador, se sumaron las estimaciones de tiempo dedicado a las tareas manuales, que abarcan la limpieza, estandarización y

organización de la información. Además, se incluyó el tiempo invertido en el análisis de datos con el fin de identificar problemas y proponer mejoras.

Tabla V: Valor actual y esperado de la horas hombre utilizadas para procesar y analizar datos

Valor actual	Valor esperado
6 horas	1 hora 30 minutos

- Objetivo específico 2: Porcentaje de exactitud de proyecciones (Accuracy)

$$MAE = \frac{1}{n} \sum_{t=1}^n |e_t|$$

$$MAPE = \frac{1}{n} \sum_{t=1}^n \left| \frac{e_t}{y_t} \right| \times 100$$

$$MSE = \frac{1}{n} \sum_{t=1}^n e_t^2$$

$$sMAPE = \frac{1}{n} \sum_{t=1}^n \frac{|e_t|}{\frac{y_t + \hat{y}_t}{2}} \times 100$$

Tabla VI: Valor actual y esperado de la precisión de proyecciones de BGE

Valor actual	Valor esperado
Desconocido	>85%

Para verificar la precisión de las proyecciones, se emplearán medidas estadísticas, que implican la comparación entre los datos históricos y las proyecciones calculadas mediante el modelo elegido. Se establece como objetivo una precisión general superior al 85%.

- Objetivo específico 3: Número de visualizaciones en power BI de roturas

$$NTVPB = \text{Número total de visualizaciones en power BI de roturas}$$

Tabla VII: Valor actual y esperado de la cantidad de visualizaciones en Power BI de roturas

Valor actual	Valor esperado
0 Visualizaciones	88 Visualizaciones

Se implementará dentro del informe de BG existente en Power BI para obtener la cuantificación de visualizaciones de las nuevas muestras de información. Se busca lograr al menos dos visualizaciones semanales por cada uno de los 11 CD durante un mes.

- Objetivo específico 4: Porcentaje de adherencia a la implementación de reason code por CD

$$\frac{\text{Número de registros con reason code bien implementado}}{\text{Total de registros considerados}} \times 100$$

Tabla VIII: Valor actual y esperado del porcentaje de adherencia a la implementación de Reason Codes

Valor actual	Valor esperado
63,90%	>80%

Actualmente, el porcentaje de implementación a nivel de red es del 63,90%. Se tiene como objetivo aumentar este indicador a un 80% para finales de año con la implementación del proyecto.

- Objetivo específico 5: Tasa de Bad Good Operacional del almacén

$$\frac{\text{Cajas dañadas} + \text{Cajas infestadas} + \text{Cajas mermadas por diferencia de inventario}}{\text{NNS}} \times 100$$

La tasa de Bad Good Operacional (porcentaje) se calcula dividiendo el total de cajas mermadas operacionalmente por las cajas que generaron un ingreso monetario a la empresa.

En el caso del centro de distribución de Quilicura, esta métrica actualmente se encuentra en un 0,0237% para el mes de agosto. Se tiene como objetivo reducirla a un 0,018%.

Tabla IV: Valor actual y esperado de la tasa de BGE

Valor actual	Valor esperado
0,0307%	0,02%

6. Planificación del proyecto y plan de implementación

6.1. Carta Gantt

La planificación se basará en una carta Gantt de proyecto que incluye cuatro fases clave durante la pasantía:





Figura XVII: Carta Gantt de proyecto de octubre a diciembre. Elaboración propia.

Nombre de la tarea	% de avance	Fecha de inicio	Fecha de finalización	Asignado	Estado	02.10.2023	03.10.2023	04.10.2023
Proyecto Roturas								
Medir rentabilidad del proyecto o viabilidad	90%	17.08.2023	15.12.2023	Catalina	Abierto			
Implementación de solución	100%	30.09.2023	20.10.2023	Catalina	En progreso			
Proyecciones								
Revaluar y definir modelos matemáticos adecuados para el problema	80%	01.10.2023	10.11.2023	Catalina	Abierto			
Generar script para limpiar y conectar datos influyentes en BG	100%	02.10.2023	10.10.2023	Catalina	Terminado			
Conexión de SAP con PBI para trabajar script de proyecciones	100%	02.10.2023	15.10.2023	Catalina	Terminado			
Plantear modelo predictivo a resolver	100%	10.10.2023	15.10.2023	Catalina	Terminado			
Validación de precisión de resultados	50%	22.10.2023	25.10.2023	Catalina	En progreso			
Mejorar modelo en base a precisión obtenida vs deseada	50%	22.10.2023	30.10.2023	Catalina	En progreso			
Plan de acción cultura de trabajo								
Realizar Gema de datos en Almacén para identificar nuevas oportunidades de mejora/identificar LUP s/Ver flujos de trabajo	61%	01.09.2023	11.11.2023	Catalina	Abierto			
Generar instructivo sobre estándar de RC en ajustes de inventario con otros datos como número de pedido para no ensuciar la muestra de datos con RC	100%	01.09.2023	11.11.2023	Catalina	En progreso			
Generar material de LUP's	90%	11.10.2023	30.10.2023	Catalina	En progreso			
Integración en WOR semanal de almacén	100%	13.10.2023	22.11.2023	Catalina	En progreso			
Reforzar porque es importante registrar el RC de manera correcta	60%	16.10.2023	27.10.2023	Catalina	En progreso			
Generar material de concientización de datos para charla	15%	17.10.2023	26.11.2023	Catalina	En progreso			
Levantar uso incorrecto de RC a transporte (Registrar el motivo correcto) + Definición de motivos y casos aplicables	100%	20.10.2023	27.10.2023	Catalina	En progreso			
Generar material de buenas prácticas esperadas de operarios	40%	20.10.2023	29.11.2023	Catalina	En progreso			
Realizar Charlas de concientización	0%	22.10.2023	11.11.2023	Catalina	No iniciado			
Distribuir LUP's	0%	23.10.2023	11.11.2023	Catalina	No iniciado			

Figura XVIII: Carta Gantt de la solución detallada del proyecto parte 1. Elaboración propia.

Plan de acción nivel RED	95%	01.09.2023	11.11.2023	Catalina	Abierto	
Preguntar sobre problemáticas o dolores asociados a la implementación de RC	95%	01.09.2023	10.10.2023	Catalina	En progreso	
Informar sobre avances de proyecto, medidas implementadas, material nuevo generado, análisis realizado y avances de KPI's	70%	01.09.2023	11.11.2023	Catalina	En progreso	
Plantear integración en WOR gestión de stock red para análisis de BGE desde el punto de vista de roturas	100%	01.10.2023	20.10.2023	Catalina	Terminado	
Plantear medidas de control para mantener niveles de implementación	100%	01.10.2023	30.10.2023	Catalina	Terminado	
Revisar y re-estandarizar el reason code de la RED	100%	09.10.2023	20.10.2023	Catalina	Terminado	
Generar visualizaciones de RC en PBI	90%	13.10.2023	22.10.2023	Catalina	En progreso	
Crear instructivo de registro de Reason Codes estandarizado para ajustes de inventario de todos los tipos de daños dentro de Z55, Z05, Z56, Z06	100%	16.10.2023	17.10.2023	Catalina	Terminado	
Generar instructivo o procedimiento sobre análisis o reporte esperado de datos de roturas a nivel mensual	100%	20.10.2023	25.10.2023	Catalina	Terminado	
Levantar información de implementación de RC, estándar, su importancia y preguntar por ayuda que sea necesaria para el proceso	100%	20.10.2023	30.10.2023	Catalina	Terminado	
Generar un SP o One place con información de medidas tomadas en otros CD sobre daños, gestión de almacén, instructivos útiles, entre otros	100%	30.10.2023	11.11.2023	Catalina	Terminado	
Obtención y análisis de resultados						
Medir KPI's de forma semanal/mensual para evaluar desempeño	28%	16.08.2023	15.11.2023	Catalina	Abierto	
Hacer una revisión de las actividades y plazos establecidos	70%	16.08.2023	15.11.2023	Catalina	En progreso	
Revisar funcionalidad de PBI's y evaluar mejoras en diseño, fórmulas y tablas	0%	21.10.2023	15.11.2023	Catalina	No iniciado	
Proporcionar recomendaciones para el desarrollo del proyecto a gran escala	0%	11.11.2023	15.11.2023	Catalina	No iniciado	
Analizar logros y fallos de las medidas y herramientas utilizadas	0%	11.11.2023	15.11.2023	Catalina	No iniciado	
Generar plan de acción 2024	0%	11.11.2023	15.11.2023	Catalina	No iniciado	

Figura XIX: Carta Gantt de la solución detallada del proyecto parte 2. Elaboración propia

6.2. Plan de implementación de la solución

El plan de implementación del proyecto contempla una serie de etapas para poder implementar la solución propuesta previamente y cumplir con los objetivos planteados en un período de 15 semanas que es el tiempo de duración de la pasantía:

- Día cero: Preparación y lanzamiento del proyecto:
 - Presentación a los Equipos:
 - Realizar una presentación detallada del proyecto a todos los equipos involucrados y colaboradores que deban aprobar su ejecución, destacando los beneficios y objetivos que se esperan.
 - Comunicación Interna:
 - Enviar correos e informar en reuniones internas explicando la importancia del proyecto, sus objetivos y la colaboración necesaria.
 - Infraestructura Tecnológica:
 - Se debe verificar que la infraestructura tecnológica, incluyendo el acceso a SAP, Power BI y otras herramientas necesarias, estén listas para el despliegue de la solución.
- Fase de Implementación: Semanas 1-12:
 - Desarrollo de Scripts:

- Iniciar con la creación del script para la automatización interna de la creación y actualización de proyecciones de daño operacional.
- Reuniones Semanales de Identificación de Problemas:
 - Comenzar con las reuniones semanales incluyendo a los responsables de los centros de distribución para identificar problemas y buscar mejoras.
- Capacitación sobre Reason Code:
 - Iniciar las capacitaciones sobre la implementación de Reason Code con todos los supervisores de control de stock de los centros de distribución.
- Despliegue de Herramientas de Visualización:
 - Implementar Power BI de roturas tras identificar análisis necesarios en reuniones semanales.
- Fase de Análisis y Acción (Semana 2 a 14):
 - Análisis de Datos y Generación de Alarmas:
 - Utilizar herramientas tecnológicas básicas como Excel para analizar datos de manera provisoria y generar alarmas en caso de incumplimiento de la implementación de Reason Code para corregir de forma inmediata.
 - Preparar del Plan de Acción para Mejorar Criterios de Rotura:
 - Preparar los elementos necesarios para el plan de acción que se defina para el proyecto.
 - Propuestas de Mejoras a Corto Plazo:
 - Recoger y evaluar propuestas de mejoras a corto plazo basadas en las necesidades identificadas por los supervisores de control de stock en reuniones.
- Evaluación Continua y Ajustes: A partir de la Semana 13:
 - Evaluación de Resultados:
 - Evaluar las medidas de desempeño planteadas para cada objetivo del proyecto. Monitorear y analizar el desempeño de la solución.

- Ajustes y Optimización:
 - Realizar ajustes en los scripts, procesos y planes de acción según sea necesario para corregir errores o mejorar la eficiencia.
- Retroalimentación y Mejora Continua:
 - Recoger la retroalimentación de los colaboradores involucrados y equipos para mejorar la solución de forma iterativa

7. Riesgos y mitigaciones

A continuación, se puede ver la evaluación de riesgos del proyecto y sus mitigaciones, donde se consideraron 5 niveles de probabilidad de ocurrencia y 5 niveles de gravedad del problema, los cuales otorgan una ponderación a los problemas identificados como más influyentes en el resultado final del proyecto.

GRAVEDAD	X	PROBABILIDAD	=	IMPACTO DEL RIESGO
IN SIGNIFICANTE		MUY PROBABLE		BAJO
MENOR		PROBABLE		MEDIANO
MODERADA		POSIBLE		ALTO
IMPORTANTE		NO ES PROBABLE		
CATASTRÓFICA		MUY IMPROBABLE		

Figura XX: Tipos de gravedad y probabilidad de ocurrencia para medir el impacto del riesgo de distintas situaciones en el proyecto. Elaboración propia.

IMPACTO DEL RIESGO	PROBABILIDAD	GRAVEDAD				
		1 IN SIGNIFICANTE	2 MENOR	3 MODERADA	4 IMPORTANTE	5 CATASTRÓFICA
5 MUY PROBABLE	5	10	15	20	25	
4 PROBABLE	4	5	12	16	20	Pérdida de continuidad en la implementación de los componentes de la solución
3 POSSIBLE	3	6	9	12	15	Operarios no siguen plan de acción planteado (Resistencia al cambio)
2 NO ES PROBABLE	2	4	6	8	10	Mal funcionamiento de SCRIPT de proyecciones
1 MUY IMPROBABLE	1	2	3	4	5	Caída de Internet y no uso de power BI por este motivo

Figura XXI: Posibles situaciones de riesgo para el proyecto ponderadas según su probabilidad de ocurrencia y gravedad dentro del transcurso del proyecto. Elaboración propia.

Se ponderó el impacto del riesgo de 5 situaciones consideradas como posibles riesgos dentro del proyecto, se clasificó su impacto en el proyecto y finalmente, se propusieron medidas de mitigación como se muestra a continuación:

RIESGOS	PROBABILIDAD	GRAVEDAD	IMPACTO DE RIESGO	MITIGACIÓN
Pérdida de continuidad en la implementación de los componentes de la solución	5	3	15	Reuniones operacionales semanales para controlar y acompañar el proceso a nivel de red.
Operarios no siguen plan de acción planteado (Resistencia al cambio)	4	4	16	Realizar capacitaciones y campañas de concientización de los daños operacionales y la importancia de la mejora de procesos.
Pérdida de conexión de obtención de datos de BW en Power BI (desactualización de datos).	3	3	9	Revisión diaria de la actualización del BI verificando fecha y hora de la última actualización para levantar estos datos en caso de algún incidente, descargando manualmente la data de la BW y actualizando manualmente el BI de manera momentánea.
Mal funcionamiento de SCRIPT de proyecciones	3	2	6	Hacer pruebas y marcha blanca previo a su puesta en funcionamiento oficial y difusión a nivel de red.
Caida de internet y no uso de power BI por este motivo	2	2	4	Sugerir la contratación de redes de respaldo para el CD.

Figura XXII: Riesgos asociados al proyecto ordenados según su impacto en el proyecto y las medidas de mitigación propuestas para disminuir la probabilidad de ocurrencia de estos. Elaboración propia.

Para los riesgos más importantes del proyecto, es decir, la pérdida de continuidad ([Anexo 14.2](#)) y la resistencia al cambio de los operarios ([Anexo 14.3](#)), se detalló un plan de mitigación.

8. Desarrollo proyecto

Para este punto del proyecto, se planteó un prototipo de análisis de datos y posterior implementación de mejoras utilizando el centro de Quilicura como el subsistema en el cual se evaluará el desempeño del prototipo aplicado.

En la creación de la solución se emplearon conocimientos de programación en la plataforma de Jupyter Python, y se utilizaron datos provenientes del ERP SAP que utiliza la empresa con todos los datos relacionados a roturas en el almacén. Estos datos incluyen diferencias de inventario, plagas y daños operacionales registrados en la base de datos, considerando los siguientes datos:

Variable	Explicación
Plant	Planta o centro de distribución que realizó el ajuste. Esta información trae un campo escrito y otro con un identificador numérico de cada CD.
Storage Location	Almacén donde se encontraba el material ajustado. Esta información trae un campo escrito y otro número de almacén.
Posting Month/Year	Mes y año (Mes.Año) en que se registró el ajuste del material en SAP.
Posting Week/Year	Semana y año (Semana.Año) en que se registró el ajuste del material en SAP.
Posting Date	Fecha (Dia.Mes.Año) en que se registró el ajuste del material en SAP.
Movement Type	Tipo de movimiento ejecutado en el ajuste (701, 718, Z55, ZCS, entre otros movimientos de SAP) que explican el tipo de ajuste (Diferencia de inventario, daño, entre otros). Esta variable trae el campo con el movimiento y otro campo con el nombre de este movimiento.
Reason for Goods Mvt	Motivo del movimiento de ajuste realizado. Este indica por ejemplo si el daño se produjo por operaciones, plaga, transporte, entre otros. Trae el motivo en formato numérico y un campo con su descripción escrita.
YGTSGTXT1	Este campo se utiliza para ingresar comentarios en formato texto al ajuste. Aquí se registran manualmente los reason code de daños operacionales.
Material	Nombre e ID de material ajustado.
Nestec Prod Category	Categoría del material ajustado (Café, Ambiente, Helados, entre otros).
Qty in CS	Cantidad de cajas de material ajustadas.
Qty in KG	Cantidad de KG de material ajustados.
Qty in PAL	Cantidad de pallets de material ajustado.
Qty in M	Cantidad de metros de material ajustados (poco usado).
Qty Value	Cantidad de pesos chilenos equivalentes al material ajustado.
Figura XXIII: Variables obtenidas de movimientos ajustes registrados en ERP SAP. Elaboración propia.	

8.1. Proyecciones

Para el prototipo inicial del Script de proyecciones, se utilizaron pocas variables y se descargó la data de forma manual para cargarla en el código. Se seleccionaron las

variables influyentes en el cálculo del Bad Good Operacional del almacén, que corresponden a los campos “Plant”, “Movement Type” y “Reason for Goods Mvt” para diferenciar el daño operacional, diferencia de inventario y plagas por centro, a los campos de Posting para poder separar la data por semana, mes y año (al igual que las proyecciones), y los campos de “Qty in CS” y “Qty Value” para medir el Bad Good Operacional en cajas y en pesos que son las medidas utilizadas en el cálculo oficial.

El Script de proyecciones llamado “SCRIPT_limpieza_de_datos_y_proyecciones” contiene la carga, limpieza y agrupación de datos, además de las proyecciones de merma, como se puede ver a continuación:

```
In [1]: import pandas as pd
import xlrd
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np
import openpyxl
import sklearn

In [2]: #Cargo los datos
arch17 = pd.read_excel('Data_2017.xlsx',sheet_name = 0, header = 6)
arch18 = pd.read_excel('Data_2018.xlsx',sheet_name = 0, header = 6)
arch19 = pd.read_excel('Data_2019.xlsx',sheet_name = 0, header = 6)
arch20 = pd.read_excel('Data_2020.xlsx',sheet_name = 0, header = 6)
arch21 = pd.read_excel('Data_2021.xlsx',sheet_name = 0, header = 6)
arch22 = pd.read_excel('Data_2022.xlsx',sheet_name = 0, header = 6)
arch23 = pd.read_excel('Data_2023.xlsx',sheet_name = 0, header = 6)

In [3]: #Convierto los archivos en dataFrame
df_17 = pd.DataFrame(arch17)
df_18 = pd.DataFrame(arch18)
df_19 = pd.DataFrame(arch19)
df_20 = pd.DataFrame(arch20)
df_21 = pd.DataFrame(arch21)
df_22 = pd.DataFrame(arch22)
df_23 = pd.DataFrame(arch23)

In [4]: #Renombro las columnas del dataFrame
df_17 = df_17.rename(columns={'Unnamed: 1': "Plant_text", "Unnamed: 3": "Storage_Location_text", "Unnamed: 8": "Movement_Type_text", "Unnamed: 9": "Reason_for_Goods_Mvt", "Unnamed: 10": "Posting_Month_Year", "Unnamed: 11": "Posting_Week_Year", "Unnamed: 12": "Posting Date", "Unnamed: 13": "Movement_Type_text", "Unnamed: 14": "Reason for Goods Mvt", "Unnamed: 15": "Reason_for_Goods_Mvt_text", "Unnamed: 16": "Reason_Code_return", "Unnamed: 17": "Material", "Unnamed: 18": "Material_text", "Unnamed: 19": "Nestec_Prod_Category", "Unnamed: 20": "Nestec_Prod_Category_text", "Cant_salida": "Cant_salida1", "Cant_salida1": "Cant_ventas", "Cant_cajas": "Cant_KG", "Cant_paletizado": "Cant_metro", "Cant_metro": "Cant_CLP"})
df_18 = df_18.rename(columns={'Unnamed: 1': "Plant_text", "Unnamed: 3": "Storage_Location_text", "Unnamed: 8": "Movement_Type_text", "Unnamed: 9": "Reason_for_Goods_Mvt", "Unnamed: 10": "Posting_Month_Year", "Unnamed: 11": "Posting_Week_Year", "Unnamed: 12": "Posting Date", "Unnamed: 13": "Movement_Type_text", "Unnamed: 14": "Reason for Goods Mvt", "Unnamed: 15": "Reason_for_Goods_Mvt_text", "Unnamed: 16": "Reason_Code_return", "Unnamed: 17": "Material", "Unnamed: 18": "Material_text", "Unnamed: 19": "Nestec_Prod_Category", "Unnamed: 20": "Nestec_Prod_Category_text", "Cant_salida": "Cant_salida1", "Cant_salida1": "Cant_ventas", "Cant_cajas": "Cant_KG", "Cant_paletizado": "Cant_metro", "Cant_metro": "Cant_CLP"})
df_19 = df_19.rename(columns={'Unnamed: 1': "Plant_text", "Unnamed: 3": "Storage_Location_text", "Unnamed: 8": "Movement_Type_text", "Unnamed: 9": "Reason_for_Goods_Mvt", "Unnamed: 10": "Posting_Month_Year", "Unnamed: 11": "Posting_Week_Year", "Unnamed: 12": "Posting Date", "Unnamed: 13": "Movement_Type_text", "Unnamed: 14": "Reason for Goods Mvt", "Unnamed: 15": "Reason_for_Goods_Mvt_text", "Unnamed: 16": "Reason_Code_return", "Unnamed: 17": "Material", "Unnamed: 18": "Material_text", "Unnamed: 19": "Nestec_Prod_Category", "Unnamed: 20": "Nestec_Prod_Category_text", "Cant_salida": "Cant_salida1", "Cant_salida1": "Cant_ventas", "Cant_cajas": "Cant_KG", "Cant_paletizado": "Cant_metro", "Cant_metro": "Cant_CLP"})
df_20 = df_20.rename(columns={'Unnamed: 1': "Plant_text", "Unnamed: 3": "Storage_Location_text", "Unnamed: 8": "Movement_Type_text", "Unnamed: 9": "Reason_for_Goods_Mvt", "Unnamed: 10": "Posting_Month_Year", "Unnamed: 11": "Posting_Week_Year", "Unnamed: 12": "Posting Date", "Unnamed: 13": "Movement_Type_text", "Unnamed: 14": "Reason for Goods Mvt", "Unnamed: 15": "Reason_for_Goods_Mvt_text", "Unnamed: 16": "Reason_Code_return", "Unnamed: 17": "Material", "Unnamed: 18": "Material_text", "Unnamed: 19": "Nestec_Prod_Category", "Unnamed: 20": "Nestec_Prod_Category_text", "Cant_salida": "Cant_salida1", "Cant_salida1": "Cant_ventas", "Cant_cajas": "Cant_KG", "Cant_paletizado": "Cant_metro", "Cant_metro": "Cant_CLP"})
df_21 = df_21.rename(columns={'Unnamed: 1': "Plant_text", "Unnamed: 3": "Storage_Location_text", "Unnamed: 8": "Movement_Type_text", "Unnamed: 9": "Reason_for_Goods_Mvt", "Unnamed: 10": "Posting_Month_Year", "Unnamed: 11": "Posting_Week_Year", "Unnamed: 12": "Posting Date", "Unnamed: 13": "Movement_Type_text", "Unnamed: 14": "Reason for Goods Mvt", "Unnamed: 15": "Reason_for_Goods_Mvt_text", "Unnamed: 16": "Reason_Code_return", "Unnamed: 17": "Material", "Unnamed: 18": "Material_text", "Unnamed: 19": "Nestec_Prod_Category", "Unnamed: 20": "Nestec_Prod_Category_text", "Cant_salida": "Cant_salida1", "Cant_salida1": "Cant_ventas", "Cant_cajas": "Cant_KG", "Cant_paletizado": "Cant_metro", "Cant_metro": "Cant_CLP"})
df_22 = df_22.rename(columns={'Unnamed: 1': "Plant_text", "Unnamed: 3": "Storage_Location_text", "Unnamed: 8": "Movement_Type_text", "Unnamed: 9": "Reason_for_Goods_Mvt", "Unnamed: 10": "Posting_Month_Year", "Unnamed: 11": "Posting_Week_Year", "Unnamed: 12": "Posting Date", "Unnamed: 13": "Movement_Type_text", "Unnamed: 14": "Reason for Goods Mvt", "Unnamed: 15": "Reason_for_Goods_Mvt_text", "Unnamed: 16": "Reason_Code_return", "Unnamed: 17": "Material", "Unnamed: 18": "Material_text", "Unnamed: 19": "Nestec_Prod_Category", "Unnamed: 20": "Nestec_Prod_Category_text", "Cant_salida": "Cant_salida1", "Cant_salida1": "Cant_ventas", "Cant_cajas": "Cant_KG", "Cant_paletizado": "Cant_metro", "Cant_metro": "Cant_CLP"})
df_23 = df_23.rename(columns={'Unnamed: 1': "Plant_text", "Unnamed: 3": "Storage_Location_text", "Unnamed: 8": "Movement_Type_text", "Unnamed: 9": "Reason_for_Goods_Mvt", "Unnamed: 10": "Posting_Month_Year", "Unnamed: 11": "Posting_Week_Year", "Unnamed: 12": "Posting Date", "Unnamed: 13": "Movement_Type_text", "Unnamed: 14": "Reason for Goods Mvt", "Unnamed: 15": "Reason_for_Goods_Mvt_text", "Unnamed: 16": "Reason_Code_return", "Unnamed: 17": "Material", "Unnamed: 18": "Material_text", "Unnamed: 19": "Nestec_Prod_Category", "Unnamed: 20": "Nestec_Prod_Category_text", "Cant_salida": "Cant_salida1", "Cant_salida1": "Cant_ventas", "Cant_cajas": "Cant_KG", "Cant_paletizado": "Cant_metro", "Cant_metro": "Cant_CLP"})

In [5]: #Verifico el nombre de las columnas de uno de los data frame
df_17.columns

Out[5]: Index(['Plant', 'Plant_text', 'Storage Location', 'Storage_Location_text', 'Posting Month/Year', 'Posting Week/Year', 'Posting Date', 'Movement Type', 'Movement_Type_text', 'Reason for Goods Mvt', 'Reason_for_Goods_Mvt', 'Reason_for_Goods_Mvt_text', 'Reason_Code_return', 'Material', 'Material_text', 'Nestec Prod Category', 'Nestec_Prod_Category', 'Nestec_Prod_Category_text', 'Cant_salida', 'Cant_salida1', 'Cant_ventas', 'Cant_cajas', 'Cant_KG', 'Cant_paletizado', 'Cant_metro', 'Cant_CLP'], dtype='object')
```

Figura XXIV: Carga de datos desde archivos .CSV obtenidos desde la BW de SAP a Data frames y cambio de nombre de columnas para trabajo de datos. Elaboración propia.

Tras cargar la data en distintos dataframes, estos fueron unificados para limpiar la data y se filtraron los almacenes que no son considerados en el BG del almacén por cada centro.

Limpieza de datos

Unifico los datos de los data frame que cargo y genero un dataframe filtrando los valores para identificar los daños operacionales, diferencias de inventario e infestación.

```
In [10]: # Unir Los DataFrames por columnas comunes (fecha, CLP y cajas)
columnas_unificar = ['Plant', 'Plant_text', 'Storage_Location', 'Storage_Location_text',
'Posting Month/Year', 'Posting Week/Year', 'Posting Date',
'Movement Type', 'Movement_Type_text', 'Reason For Goods Mvt',
'Reason_for_Goods_Mvt_text', 'Reason_Code_return', 'Material',
'Material_text', 'Nestle_Prod_Catogory', 'Nestle_Prod_Catogory_text',
'Cant_salida', 'Cant_valida', 'Cant_ventas', 'Cant_sakjas', 'Cant_XB',
'Cant_paletizado', 'Cant.metro', 'Cant_CLP']

# Concatenar Los DataFrames
df_unificado = pd.concat([df_17[columnas_unificar], df_18[columnas_unificar], df_19[columnas_unificar], df_20[columnas_unificar]])

# Reiniciar los índices del DataFrame unificado
df_unificado.reset_index(drop=True, inplace=True)

In [11]: # Define los valores deseados para el filtro
filtros = [
    ((df_unificado['Plant'] == 76) & ((df_unificado['Storage Location'] == '0000') | (df_unificado['Storage Location'] == '0009')) |
    ((df_unificado['Plant'] == 85) & (df_unificado['Storage Location'] == '0001')) |
    ((df_unificado['Plant'] == 88) & (df_unificado['Storage Location'] == '0002')) |
    ((df_unificado['Plant'] == 90) & (df_unificado['Storage Location'] == '0003')) |
    ((df_unificado['Plant'] == 91) & (df_unificado['Storage Location'] == '0004')) |
    ((df_unificado['Plant'] == 93) & (df_unificado['Storage Location'] == '0005')) |
    ((df_unificado['Plant'] == 94) & (df_unificado['Storage Location'] == '0006')) |
    ((df_unificado['Plant'] == 97) & ((df_unificado['Storage Location'] == '0001') | (df_unificado['Storage Location'] == '0002')) |
    ((df_unificado['Plant'] == 100) & (df_unificado['Storage Location'] == '0007')) |
    ((df_unificado['Plant'] == 103) & (df_unificado['Storage Location'] == '0008')) |
    ((df_unificado['Plant'] == 3597) & ((df_unificado['Storage Location'] == '0001') | (df_unificado['Storage Location'] == '0002')) |
    ((df_unificado['Plant'] == 3598) & (df_unificado['Storage Location'] == '0003'))
]

# Aplica el filtro para obtener los datos deseados
df_unificado = df_unificado[filtros]
```

Figura XXV: Limpieza de datos parte I. Elaboración propia.

Luego, se filtraron los datos con motivo de ajuste “3” que es daño operacional en almacén, “7” de plagas o infestación y los ajustes por movimiento 700 a 718 que son de diferencia de inventario. Estos datos pasaron por un nuevo filtro donde se eliminaron aquellos que tuviesen el texto “Resultado” pues no deben ser incluidos en el cálculo.

```
In [12]: #Filtro en una nueva base los datos registrados por daño con el código 3 y guardo las columnas de interés en un nuevo df
valor_deseado = '3'
datos_filtrados_danoop = df_unificado[df_unificado['Reason for Goods Inv'] == valor_deseado]

In [13]: #Filtro en una nueva base los datos registrados por infestados con el código 7 y guardo las columnas de interés en un nuevo df
valor_deseado2 = '7'
datos_filtrados_infest = df_unificado[df_unificado['Reason for Goods Inv'] == valor_deseado2]

In [14]: # Filtrar los datos donde 'Movement Type' está en el rango del 700 al 732 para sacar las diferencias de inventario
inicio = 700
fin = 732

# Filtrar las filas con valores no numéricos en la columna "Movement Type"
datos_filtrados_difinv = df_unificado[df_unificado['Movement Type'].str.isnumeric()]

# Convertir la columna "Movement Type" a tipo int
datos_filtrados_difinv.loc[:, 'Movement Type'] = datos_filtrados_difinv['Movement Type'].astype(int)

# Filtrar las filas dentro del rango deseado
datos_filtrados_difinv = datos_filtrados_difinv[datos_filtrados_difinv['Movement Type'].between(inicio, fin, inclusive='both')]

In [15]: #En esta sección limpio el nuevo df bormando los datos registrados como "Resultado"
#Crea un filtro booleano para las filas que contienen "Resultado" en "Reason_Code_returns"
filtro_resultado = datos_filtrados_danoop['Reason_Code_returns'].str.contains('Resultado')
#Elimina las filas que cumplen con el filtro
datos_filtrados_danoop = datos_filtrados_danoop[~filtro_resultado]

In [16]: filtro_resultado = datos_filtrados_infest['Reason_Code_returns'].str.contains('Resultado')
#Elimina las filas que cumplen con el filtro
datos_filtrados_infest = datos_filtrados_infest[~filtro_resultado]

In [17]: filtro_resultado = datos_filtrados_difinv['Reason_Code_returns'].str.contains('Resultado')
#Elimina las filas que cumplen con el filtro
datos_filtrados_difinv = datos_filtrados_difinv[~filtro_resultado]
```

Figura XXVI: Limpieza de datos parte II. Elaboración propia.

A continuación, se realizó una verificación de los datos para asegurar que no hubiera datos nulos dentro de la data.

```
In [18]: # Comprueba si hay datos nulos en el DataFrame
datos_nulos_dano = datos_filtrados_danoop.isnull().sum()

Out[18]: Plant          0
Plant_text        0
Storage_Location  0
Storage_Location_text  0
Posting Month/Year 0
Posting Week/Year  0
Posting Date      0
Movement Type     0
Movement_Type_text 0
Reason for Goods Inv 0
Reason_for_Goods_Inv_text 0
Reason_Code_returns 0
Material          0
Material_text      0
Nestec Prod Category 0
Nestec_Prod_Category_text 0
Cant_salida       0
Cant_salida2      0
Cant_ventas       0
Cant_cajas        0
Cant_X0          0
Cant_paletizado   0
Cant.metro        0
Cant_Clip         0
dtype: int64
```

Figura XXVII: Limpieza de datos parte III. Elaboración propia.

Con la data limpia, se comenzó a agrupar los datos por semana, mes y año, por daño operacional, plaga y diferencias de inventario, y también con estos tres componentes juntos en un dataframe único.

```
In [21]: dataframes = [datos_filtrados_danoop, datos_filtrados_infest, datos_filtrados_difinv]
df_totalbg_unificado = pd.concat(dataframes, ignore_index=True)

In [22]: import pandas as pd

# Me aseguro de que la columna "Posting Date" esté en formato datetime
datos_filtrados_danoop['Posting Date'] = pd.to_datetime(datos_filtrados_danoop['Posting Date'])

# Creo una nueva columna para el año y otra para el mes
datos_filtrados_danoop['Año'] = datos_filtrados_danoop['Posting Date'].dt.year
datos_filtrados_danoop['Mes'] = datos_filtrados_danoop['Posting Date'].dt.month

# Agrupo los datos por mes y año y calcula la suma de "Cant_CLP" y "Cant_cajas"
monthly_data_dano = datos_filtrados_danoop.groupby(['Año', 'Mes']) \
    .agg({'Cant_CLP': 'sum', 'Cant_cajas': 'sum'}) \
    .reset_index()

print("Datos mensuales:")
print(monthly_data_dano)

Datos mensuales:
      Año Mes Cant_CLP Cant_cajas
0   2017  1 -28940711 -3871.293
1   2017  2 -20504491 -1581.564
2   2017  3 -28732713 -2328.445
3   2017  4 -26291152 -1872.559
4   2017  5 -88588305 -4362.034
... ...
77  2023  6 -8688999 -728.469
78  2023  7 -9341151 -677.133
79  2023  8 -10395909 -786.805
```

Figura XXVIII: Ejemplo de código para agrupar datos en CLP y Cajas por mes. Elaboración propia.

```
In [26]: # Me aseguro de que la columna "Posting Date" esté en formato datetime
datos_filtrados_danoop['Posting Date'] = pd.to_datetime(datos_filtrados_danoop['Posting Date'])

# Agrupo los datos por año y calcula la suma de "Cant_CLP" y "Cant_cajas"
yearly_data_dano = datos_filtrados_danoop.groupby(datos_filtrados_danoop['Posting Date'].dt.year) \
    .agg({'Cant_CLP': 'sum', 'Cant_cajas': 'sum'})

# Se reinicia el índice para tener una estructura más plana
yearly_data_dano.reset_index(inplace=True)

# Se cambian los nombres de las columnas para mayor claridad
yearly_data_dano.columns = ['Año', 'Suma_Cant_CLP', 'Suma_Cant_cajas']

print(yearly_data_dano)

      Año Suma_Cant_CLP Suma_Cant_cajas
0  2017 -459334486 -41890.083
1  2018 -360956967 -37606.430
2  2019 -382339536 -43551.230
3  2020 -247855711 -28379.683
4  2021 -373666988 -21680.789
5  2022 -140661341 -16010.669
6  2023 -129756362 -13223.268
```

Figura XXIX: Ejemplo de agrupación de datos en CLP y Cajas por año. Elaboración propia.

```
In [31]: datos_filtrados_danoop['Posting_Week/Year'] = datos_filtrados_danoop['Posting_Week/Year'].astype(str)
datos_filtrados_infest['Posting_Week/Year'] = datos_filtrados_infest['Posting_Week/Year'].astype(str)
datos_filtrados_difim['Posting_Week/Year'] = datos_filtrados_difim['Posting_Week/Year'].astype(str)

In [32]: # Agrupo los datos por semana y año y calculo la suma de "Cant_CLP" y "Cant_cajitas"
weekly_data_danoop = datos_filtrados_danoop.groupby('Posting_Week/Year') \
    .agg({'Cant_CLP': 'sum', 'Cant_cajitas': 'sum'}) \
    .reset_index()

print(weekly_data_danoop)
```

Posting_Week/Year	Cant_CLP	Cant_cajitas
0	1.2027	-3936692 -500.623
1	1.2028	-2388995 -353.148
2	1.2029	-6646781 -783.821
3	1.2022	-433761 -79.139
4	1.2021	-4647647 -588.009
..
350	9.2029	-2834311 -407.327
351	9.202	-11795123 -1702.865
352	9.2021	-5745635 -729.916
353	9.2022	-2951864 -339.791
354	9.2023	-5865620 -585.091

[355 rows x 3 columns]

Figura XXX: Ejemplo de agrupación de datos en CLP y Cajas por semana. Elaboración propia.

Luego, con la data lista para trabajar, se realizaron pruebas con distintos modelos de proyecciones para comparar y seleccionar los que obtengan un mejor resultado en cuanto a precisión. Se decidió realizar las proyecciones con un modelo de alisamiento triple de datos como el Holt-Winters, debido a que, los costos por merma con los cuales se realizan las proyecciones son muy variables mes a mes y por centro, por lo que se necesita de una herramienta que permita manejar datos con variabilidad compleja y patrones estacionales, esto con el fin de que se tenga una flexibilidad al modelar la tendencia, la estacionalidad y los cambios en la variabilidad de manera efectiva. Este modelo permite capturar cambios en las tendencias a corto y largo plazo, así como fluctuaciones estacionales y se adapta a estos gracias al suavizado de datos.

Se hizo un modelo de alisado triple para proyectar el BG por centro de distribución con la data histórica desde 2017 a 2023 y también se utilizó un modelo de alisado simple para proyectar el BG por reason code, dado que, no se tiene data histórica, los datos que se tienen de reason code son solo de 2023.

```
In [194]: from statsmodels.tsa.holtwinters import SimpleExpSmoothing
# Filtrar datos solo para el año 2023
df_2023 = df_totalbg_unificado[df_totalbg_unificado['Posting Date'].dt.year == 2023]

# Crear un diccionario para almacenar los modelos de suavizado simple por Reason Code para 2023
modelos_suavizado_simple_2023 = {}

# Iterar sobre cada Reason Code
for reason_code, df_RC in dataframes_por_RC.items():
    # Filtrar datos del Reason Code para el año 2023
    df_RC_2023 = df_totalbg_unificado[df_totalbg_unificado['Posting Date'].dt.year == 2023]

    # Convertir la columna 'Posting Date' a tipo datetime
    df_RC_2023['Posting Date'] = pd.to_datetime(df_RC_2023['Posting Date'])

    # Establecer 'Posting Date' como índice del DataFrame y ordenar por fecha
    df_RC_2023.set_index('Posting Date', inplace=True)
    df_RC_2023.sort_index(inplace=True)

    # Ajustar el modelo de suavizado exponencial simple para el año 2023
    model = SimpleExpSmoothing(df_RC_2023['Cant_CLP'])
    model_fit = model.fit()

    # Almacenar el modelo en el diccionario con el nombre del Reason Code como clave
    modelos_suavizado_simple_2023[reason_code] = model_fit

# Realizar proyecciones para cada Reason Code en el año 2024 basado en el modelo ajustado con datos de 2023
proyecciones_por_RC_simple_2023 = {}
for reason_code, model_fit in modelos_suavizado_simple_2023.items():
    proyeccion = model_fit.forecast(steps=52) # Proyectar 52 semanas (equivalente a un año)
    proyecciones_por_RC_simple_2023[reason_code] = proyeccion

# Ejemplo de cómo acceder a las proyecciones para un Reason Code específico en el año 2024
RC_seleccionado = 'PP1'
proyección_RC_seleccionado_2023 = proyecciones_por_RC_simple_2023[RC_seleccionado]
print(f"Proyección para el Reason Code {RC_seleccionado} en 2024:")
print(proyección_RC_seleccionado_2023)
```

Proyección para el Reason Code PP1 en 2024:
98879 -10981.520879

*Figura XXXI: Modelo de Holt Winters de alisado simple para proyectar el BGE por reason code.
Elaboración propia.*

```
In [175]: from statsmodels.tsa.holtwinters import ExponentialSmoothing
import pandas as pd

# Crear un diccionario para almacenar los modelos de suavizado triple por centro
modelos_suavizado = {}

# Iterar sobre cada centro
for centro, df_centro in dataframes_por_centro.items():
    # Convertir la columna 'Posting Date' a tipo datetime
    df_centro['Posting Date'] = pd.to_datetime(df_centro['Posting Date'])

    # Establecer 'Posting Date' como índice del DataFrame y ordenar por fecha
    df_centro.set_index('Posting Date', inplace=True)
    df_centro.sort_index(inplace=True)

    # Ajustar el modelo de suavizado triple
    model = ExponentialSmoothing(df_centro['Cant_CLP'], trend='add', seasonal='add', seasonal_periods=3)
    model_fit = model.fit()

    # Almacenar el modelo en el diccionario con el nombre del centro como clave
    modelos_suavizado[centro] = model_fit

# Realizar proyecciones para cada centro en el año 2024
proyecciones_por_centro = {}
for centro, model_fit in modelos_suavizado.items():
    proyección = model_fit.forecast(steps=52) # Proyectar 52 semanas (equivalente a un año)
    proyecciones_por_centro[centro] = proyección

# Ejemplo de cómo acceder a las proyecciones para un centro específico
centro_seleccionado = 'Macul Helados'
proyección_centro_seleccionado = proyecciones_por_centro[centro_seleccionado]
print(f"Proyección para el centro {centro_seleccionado}:")
print(proyección_centro_seleccionado)
```

Proyección para el centro Macul Helados:

139997	-2203.825314
139998	-7194.630507
139999	1785.372996
140000	-2222.675526

*Figura XXXII: Modelo de Holt Winters de alisado triple para proyectar el BGE por centro de distribución.
Elaboración propia.*

```
In [257]: # Inicializar un diccionario para almacenar la suma de proyecciones por Reason Code
suma_proyecciones_por_RC = {}

# Supongamos que "proyeccion_RC_seleccionada_2023" es un diccionario con las proyecciones para cada Reason Code
for reason_code, proyeccion in proyecciones_por_RC_simple_2023.items():
    suma_proyecciones_por_RC[reason_code] = sum(proyeccion)

# Imprimir la suma de las proyecciones para cada Reason Code
for reason_code, suma_proyeccion in suma_proyecciones_por_RC.items():
    print(f"Suma de las proyecciones para Reason Code {reason_code}: {suma_proyeccion}")

Suma de las proyecciones para Reason Code otros: -920725.7169114137
Suma de las proyecciones para Reason Code CARDE52: -1075979.3412340642
Suma de las proyecciones para Reason Code D441: -608203.1693288995
Suma de las proyecciones para Reason Code D446: -859042.5837366396
Suma de las proyecciones para Reason Code D471: -784176.9598118534
Suma de las proyecciones para Reason Code D501: -868879.9297069899
Suma de las proyecciones para Reason Code PP11: -179117.07143949726
Suma de las proyecciones para Reason Code CARDE51: -919561.6735362418
Suma de las proyecciones para Reason Code D45: -854250.933735747
Suma de las proyecciones para Reason Code PP2: -807606.9006303053
Suma de las proyecciones para Reason Code PP3: -1522206.8641859514
Suma de las proyecciones para Reason Code D44: -11104.693664889559
Suma de las proyecciones para Reason Code D43: -285297.80001645489
Suma de las proyecciones para Reason Code D042: -5560995.75081856428
Suma de las proyecciones para Reason Code D491: -215942.06002132912
Suma de las proyecciones para Reason Code D0F1: -338004.99105178866
Suma de las proyecciones para Reason Code D0D3: -179325.99476164047
Suma de las proyecciones para Reason Code COPACK2: -406580.4580278124
Suma de las proyecciones para Reason Code DAL: -1416042.15318325876
Suma de las proyecciones para Reason Code D0I2: -411592.7352959999
Suma de las proyecciones para Reason Code D410: -2872616.54022569
Suma de las proyecciones para Reason Code D42: -470292.41507421975
Suma de las proyecciones para Reason Code CPW1: -2594377.088953701
Suma de las proyecciones para Reason Code DWF: -944237.3395643188
Suma de las proyecciones para Reason Code COPACK1: -3076.830036429976
Suma de las proyecciones para Reason Code M0Q1: -480001.4020985635
Suma de las proyecciones para Reason Code D0I3: -43979.5473
Suma de las proyecciones para Reason Code CPFE: -3751455.852950354
Suma de las proyecciones para Reason Code MAQ2: -86218.6820687332
Suma de las proyecciones para Reason Code D0I1: -3768310.5134174994
Suma de las proyecciones para Reason Code DTR: -825480.8809163645
Suma de las proyecciones para Reason Code MAQ3: -681000.4348837204
```

Figura XXXIII: Proyecciones mensuales sumadas para obtener la proyección para el año 2024 por Reason code de daño. Elaboración propia.

```
In [89]: # Sumar las proyecciones para cada centro
suma_proyecciones_por_centro = {}

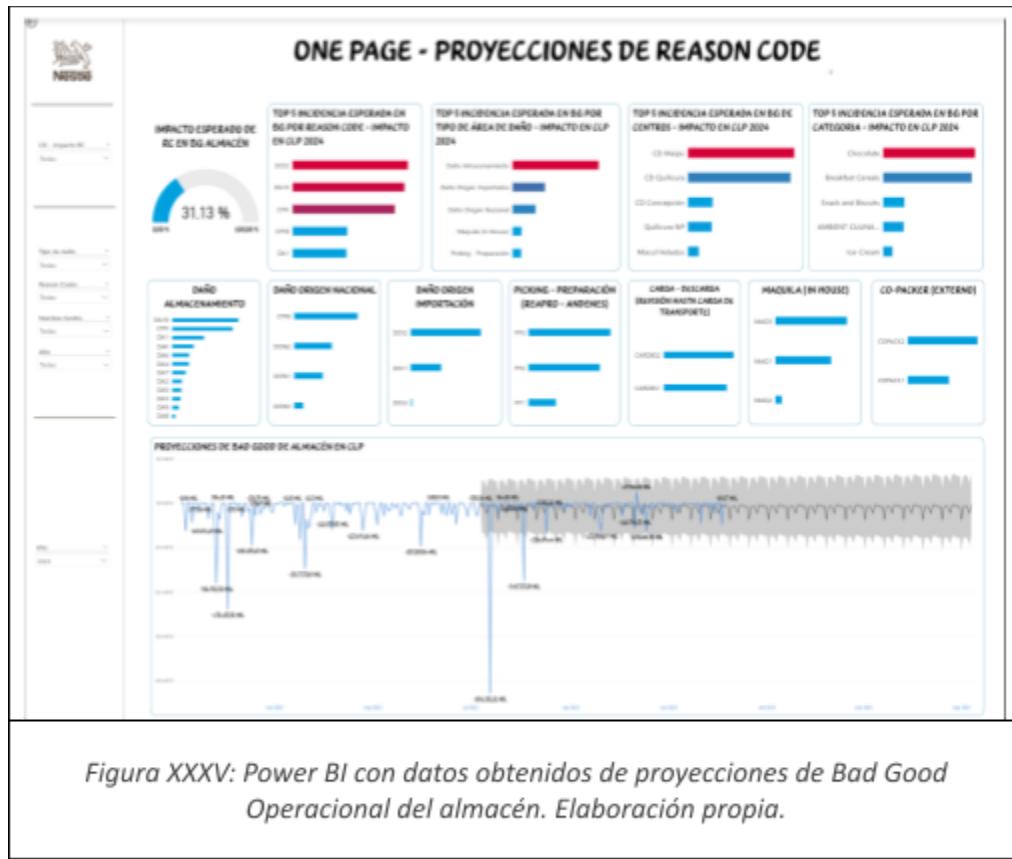
for centro, proyeccion in proyecciones_merma_por_centro.items():
    suma_proyecciones_por_centro[centro] = proyeccion.sum()

# Imprimir la suma de las proyecciones para cada centro
for centro, suma_proyeccion in suma_proyecciones_por_centro.items():
    print(f"Suma de las proyecciones para {centro}: {suma_proyeccion}")

Suma de las proyecciones para Macul Helados: -138902.0286487727
Suma de las proyecciones para Macul Refrigerados: -223140.8272948903
Suma de las proyecciones para CD Antofagasta: -1243389.678504949
Suma de las proyecciones para CD Quillium: -874728.3957826286
Suma de las proyecciones para CD Concepción: -450541.490956101125
Suma de las proyecciones para CD Temuco: -36796.970968006634
Suma de las proyecciones para CD Punta Arenas: -129644.9803445154
Suma de las proyecciones para Optimus: -1145511.9804188225
Suma de las proyecciones para Keylogistics: -492975.8033064326
Suma de las proyecciones para CD Maipú: -1523329.1391536929
Suma de las proyecciones para Macul OP-R-FS: -980760.9926512222
Suma de las proyecciones para Quilicura MP: -755918.5609182643
Suma de las proyecciones para CD Arica: -1502470.6044501053
```

Figura XXXIV: Proyecciones mensuales sumadas para obtener la proyección para el año 2024 por centro de distribución. Elaboración propia.

Con estas proyecciones de merma, se realizó una visualización en Power BI para poder analizar los datos obtenidos y fijar planes de acción focalizados a los daños esperados en un futuro.



8.2. Plan de acción cultura operacional

Para desarrollar esta sección del proyecto, se llevaron a cabo reuniones semanales con los equipos de Control de Stock y Control & Compliance en el centro de distribución de Quilicura. En estas reuniones, se establecieron los parámetros y alcances de la solución, se discutieron las causas recurrentes de los daños operacionales en el centro de distribución y se crearon Lecciones Únicas de Punto (LUPs) basadas en los errores identificados, detallando la forma correcta de abordar los procesos.

Antes de implementar cambios o sugerencias de buenas prácticas para los operarios, se realizaron visitas regulares al almacén durante dos meses. El propósito fue analizar las roturas, recopilar información y evidencia proporcionada por los colaboradores sobre estas incidencias.

Se utilizó la evidencia fotográfica recopilada en el almacén para desarrollar material de mejora de procesos, el cual fue transmitido a los operarios durante una capacitación. En esta sesión, se presentó el material, se explicaron detalladamente los casos de mejora y se resaltaron los riesgos asociados a algunos procesos existentes. El

objetivo fue crear conciencia entre los participantes, quienes firmaron un compromiso para implementar estas mejoras y promover las buenas prácticas entre sus colegas para reducir las pérdidas.

LECCIÓN DE UN PUNTO (LUP)		Nº LUP:	
Tema:	Guardado de pallet en ubicación	Fecha:	10-10-2023
Preparado por:	Catalina Henriquez	Departamento:	Operaciones
Área:	Toda las Áreas	Grua/Transpaletas:	Grua y transpaleta
ESPECIALIDAD / CATEGORÍA		CLASIFICACIÓN	
Mecánica	<input checked="" type="checkbox"/> Operación	Proyecto	Conocimiento Básico
Eléctrica	<input checked="" type="checkbox"/> Lubricación	Proyectos	Caso de Mejora
Hidráulica	<input checked="" type="checkbox"/> Mantenimiento	Administrativo	Caso de Problema
Pneumática	<input checked="" type="checkbox"/> Calidad		Desarrollo de Conocimientos
		VIP	VIP
		Presentada por:	Revisada por:
		Aprobada por:	Aprobada por:





pallets guardados muy atrás, muy adelante o ladeado en la ubicación, podría ocasionar desplazamiento de pallets y otros daños operacionales, además de posibles accidentes.





Se debe almacenar el pallet de forma que quede centrado en la ubicación, verificando que no esté muy cerca de los bordes y se encuentre derecho

*Figura XXXVI: LUP de guardado de pallet en almacén.
Elaboración propia.*

LECCIÓN DE UN PUNTO (LUP)				Nº LUP:	
Tema:	Guardado de saldos en altura			Fecha:	18-10-2023
Preparado por:	Catalina Henríquez			Departamento:	Operaciones
Área:	Toda las Áreas			Grisia/Traspale:	Grisia y transpaleta
ESPECIALIDAD / CATEGORÍA				CLASIFICACIÓN	
Mecánica	ISO Operación	Uso del	Lubricación	<input type="checkbox"/> Desempeño Básico	
Eléctrica	Lubricación	Uso del	Electricidad	<input type="checkbox"/> Caso de Mejora	
Industria	Energiedad	Uso del	Administración	<input type="checkbox"/> Caso de Problema	
Ingeniería	Ciudad	Uso del		Transmisión de Conocimientos	
V.W.		V.W.		V.W.	
Procedimientos		Procedimientos		Procedimientos	
Acción de apoyo		Acción de apoyo		Acción de apoyo	



X
 No se deben guardar pallets en ubicaciones de altura sin FILM y/o mal puesto/incompleto.
 Puede provocar daños operacionales y/o accidentes.



✓
 Se debe almacenar el pallet en altura con FILM que cubra todo el material que contenga el pallet, independientemente de la cantidad de unidades restantes en el pallet.

Figura XXXVII: LUP guardado de saldos en altura. Elaboración propia.

LECCIÓN DE UN PUNTO (LUP)				Nº LUP:
Tema:	Guardado de pallet en rack doble	Fecha:	10-10-2023	
Preparada por:	Catalina Henríquez	Departamento:	Operaciones	
Área:	Toda las Áreas	Grua/Traspalera:	Grua y traspalera	
ESPECIALIDAD / CATEGORÍA <input checked="" type="checkbox"/> Operación <input type="checkbox"/> Fijación <input checked="" type="checkbox"/> Lubricación <input type="checkbox"/> Limpieza <input checked="" type="checkbox"/> Seguridad <input type="checkbox"/> Adhesión <input checked="" type="checkbox"/> Reutilizable <input type="checkbox"/> Calidad		CLASIFICACIÓN		
		<input checked="" type="checkbox"/> Conocimiento Básico <input checked="" type="checkbox"/> Caso de Mejora <input type="checkbox"/> Caso de Problema <input type="checkbox"/> Transmisión de Conocimientos	V D Preparada por:	V R Revisada por:
			V D Revisada por:	V D Aprobada por:
 X <p>Pallet solo guardado en la posición del frente. posible daño por manipulación y retrabajo.</p>  ✓ <p>Se debe almacenar el pallet en la ubicación trasera del rack. así evitamos retrabajos y posibles daños</p>				

Figura XXXVIII: LUP guardado de pallet en rack doble. Elaboración propia.

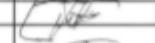
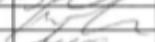
WHS Safety & Health		Quality		REGISTRO DE ASISTENCIA		CONTINUOUS EXCELLENCE	
Taller:	LUP de Reparamiento - Proyecto roturas					0088.PL.032-03	
Departamento:	Control de Compliance - Control stock						
Fecha:	2023	Hora inicio:	15 : 15	Hora término:	15 : 52	Firma:	
Relator:	Catalina Henríquez						
Nombre empresa externa (si aplica): N/A							
Nº	Nº SAP	RUT	Nombre completo del colaborador	Área	Firma		
1	1093012	25200327-5	José Srukllan	Grua			
2	10521702	11636587-0	Jean Pavez	Grua			
3	16306466	11.193.760-8	Patricio Ríos	OPERA			
4	10403240	14.199.517-9	Luis Pacheco	IL			
5	11115300	16.478.415-0	Edmundo Vásquez A.	OPERA			
6	11044774	161-3-774	Fernan Rojas	IL			
7	10557187	40320556-1	Mario González	OPERA			
8	11174812	15620193-6	Jesús Flores	IL			
9	11082604	14.162193-4	Marco Morales	OPERA			
10	11083404	26.312.548-9	Fernan Alvarado	OPERA			
11	10385218	11076498-2	Cristian Cortés	IL			
12	10302211	15.454.104-3	Ugo Gremecut	IL			
13	10493901	13.310.32-2	Mauricio Muñoz	OPERA			
14	10528691	11.638.823-5	Sergio Riquelme	IL			
15	11042005	11.041.116-1	José Díaz	OPERA			
16	103000740	12.364.138-3	Juan Coloma	OPERA			
17							
18							
19							
20							
Contenidos de la Capacitación							
1	LUP Guardado de saldos en altura						
2	LUP Guardado de pallet en ubicación						
3	LLUP Movimientos de máquina apliadora en pasillos del almacén						
4	LLUP Guardado de pallet en rack doble						
5							
6							
7							
8							

Figura XXXIX: Hoja de asistencia firmada por grueros en turno de tarde que asistieron a una de las capacitaciones de entrega de LUPS. Elaboración propia.

A través de las visitas periódicas al almacén y el análisis de los datos de roturas, en colaboración con el equipo de control de stock, se identificaron errores en la identificación de los "Reason Codes" de daños. Esto generaba registros incorrectos al realizar ajustes en SAP. Se llevó a cabo una reunión con el personal operativo para discutir casos y comprender los códigos de "Reason Codes" uno a uno. Esto llevó a la necesidad de re-estandarizar el "Reason Code" actual y definir qué ajustes podían realizarse debido a daños, especialmente aquellos relacionados con daños de transporte ajustados como daños de almacén, impactando negativamente en los indicadores.

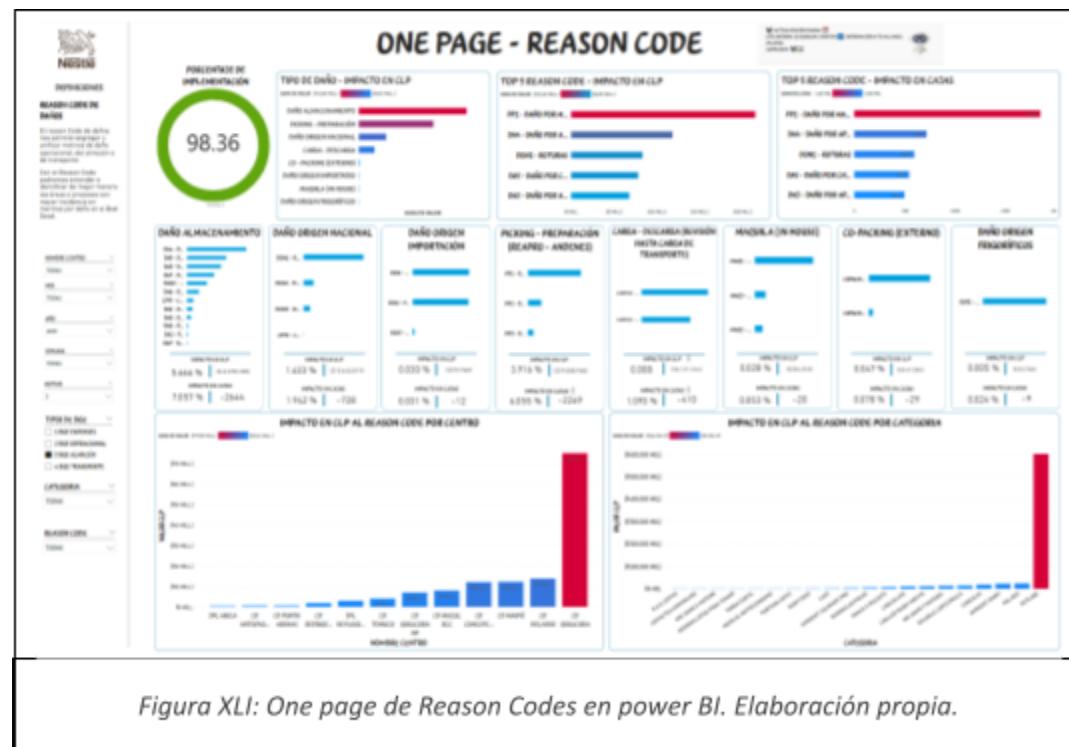
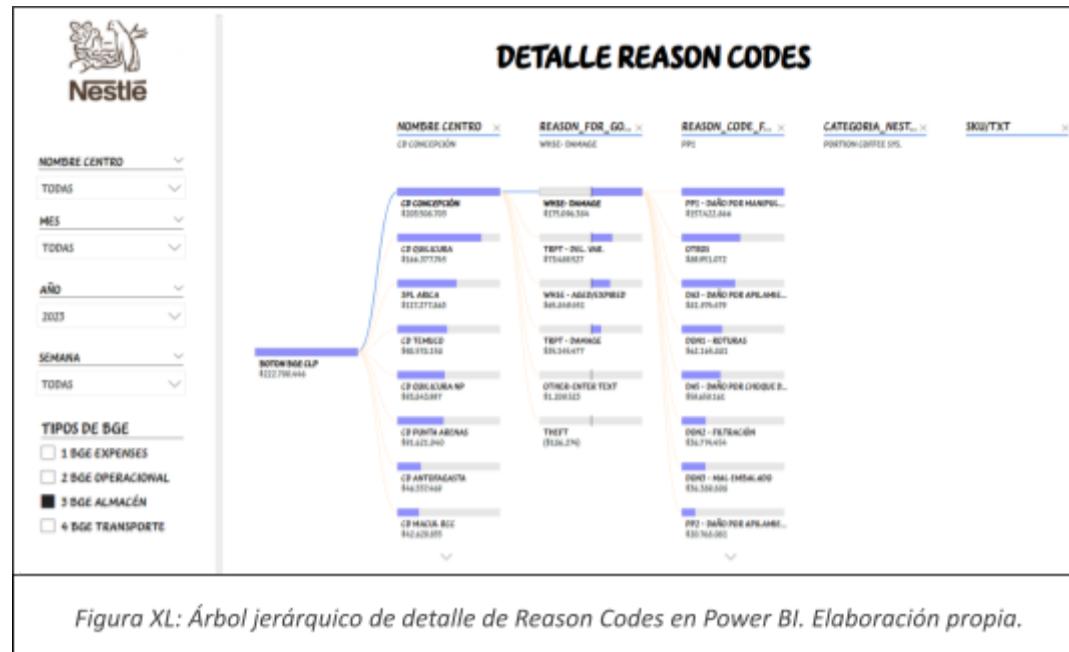
Este enfoque permitió una mejor identificación de las causas de las roturas en el almacén. Se cambió el énfasis de las mejoras del área de Picking (donde el "PP1" era

el "Reason Code" más utilizado, referente a roturas en el proceso de Picking y preparación) hacia el área de daño en almacenamiento, correspondiente a los códigos "DA", que fueron abordados durante las capacitaciones.

8.3. Plan de acción nivel RED

En el transcurso del proyecto, se incorporó una sección en las reuniones operativas semanales de control de KPI para abordar los temas relacionados con las roturas a nivel nacional y los progresos del proyecto. Durante estas sesiones, se discutieron los cambios y análisis implementados en el centro de Quilicura, proponiendo la creación de un espacio colaborativo en SharePoint entre los equipos de Control de Stock. Esta plataforma permitió el intercambio de ideas y cambios realizados para mejorar el "Bad Good Operacional" del almacén. Se cargaron y explicaron lecciones aprendidas, detallando el proceso para su creación y proporcionando ejemplos de medidas implementadas, con el objetivo de que pudieran ser replicadas en otros centros.

Se llevó a cabo la implementación de un informe en Power BI, el cual se compartió en las reuniones junto con un manual de uso y una explicación grabada. Este informe visualiza datos relacionados con los "Reason Codes" de cada centro y de Nestlé Chile. Incluye un indicador de porcentaje de implementación en el total de datos, una tabla con el detalle de los materiales ajustados por "Reason Code", un ranking de las roturas más significativas (ya sea por centro o en general), y un gráfico que muestra los "Reason Codes" registrados y su frecuencia en un período definido.



Reason Codes 2023

```

SELECT
  [Measures].[SalesAmount]
  ON COLUMNS,
  [Measures].[SalesAmount]
  ON ROWS
FROM [ReasonCodes]
WHERE [ReasonCodes].[ReasonCode].CurrentMember;

```

Detalles de la consulta MDX:

- Origen:** Se ha seleccionado el origen "AllLogic.mds" con "Sales" y "Sales", "[Implementation]=3,0".
- Query:** "SELECT [Measures].[SalesAmount] ON COLUMNS, [Measures].[SalesAmount] ON ROWS FROM [ReasonCodes] WHERE [ReasonCodes].[ReasonCode].CurrentMember;"
- Detalles de la consulta:**
 - Se muestra la estructura jerárquica de los niveles de detalle (L0, L1, L2, L3) para las dimensiones.
 - Los miembros se agrupan en categorías como [REASON_CODE].[LEVEL_0].[ALLMEMBERS], [REASON_CODE].[LEVEL_1].[ALLMEMBERS], etc.
 - Las medidas se agrupan en categorías como [SALES].[LEVEL_0].[ALLMEMBERS], [SALES].[LEVEL_1].[ALLMEMBERS], etc.
- Propiedades:** Se muestran propiedades como MEMBER_CAPTION, MEMBER_UNIQUE_NAME, REASON_CODE.[LEVEL_0].[ALLMEMBERS], SALES.[LEVEL_0].[ALLMEMBERS], etc.
- Notas:** Una nota indica que no se han detectado errores de sintaxis.

Figura XLII: Consulta MDX para obtener datos de Reason Code de BW en SAP. Elaboración propia.

Además, se proporcionó una guía paso a paso para realizar análisis semanales y mensuales de estos datos, junto con una plantilla para cada centro de distribución sobre cómo obtener la información necesaria desde el Power BI de roturas. Esto permitió a los supervisores tener un mayor control y poder identificar los daños más recurrentes en sus almacenes, al mismo tiempo que reducía el tiempo necesario para analizar los datos de manera manual.

Esta implementación facilitó al equipo de Control & Compliance identificar los centros con menor porcentaje de implementación, lo que llevó a reuniones individuales con dichos centros para investigar las razones detrás de esto y encontrar maneras de mejorar la implementación del proyecto. Se ofreció asistencia en la identificación de roturas a través de análisis de casos y se mantuvo un canal de comunicación abierto para brindar apoyo en los ajustes necesarios.

Se tomó la decisión de re-estandarizar el "Reason Code" de daños para Quilicura y aplicarlo a los demás centros de distribución. Se llevó a cabo un análisis del "Reason Code" actual para identificar discrepancias en su comprensión y aplicabilidad en conjunto con cada centro. Se redefinieron los códigos, generando un "Reason Code" más conciso que cada supervisor pudo compartir en su almacén, eliminando identificadores de daño que no deberían ser utilizados en ningún centro para evitar errores en la identificación.

Además, se proporcionó un estándar sobre cómo registrar el "Reason Code" en los ajustes de SAP para permitir la inclusión de esta información, así como el número de pedido en el campo de texto. Esto evitó la priorización de una información sobre otra y facilitó la limpieza automatizada de la data en Power BI al agregar un formato específico.

Posteriormente, para reforzar y verificar la comprensión de los cambios, se llevó a cabo una evaluación con casos de análisis para los 8 supervisores de Control de Stock. Estos casos permitieron identificar los "Reason Codes" que se debían aplicar en cada situación. Se brindó retroalimentación y explicaciones detalladas de cada caso junto con el "ID" aplicable para el ajuste, con el fin de asegurar una comprensión clara de los cambios realizados.

9. Resultados

Los resultados obtenidos del proyecto, orientado a reducir el impacto de las pérdidas por daños en el Bad Good Operacional del centro de distribución de Quilicura y cumplir con los objetivos específicos establecidos, muestran una disminución del impacto por daño en un 1,96%.

Tabla V: Valores de BGE del almacén Quilicura por mes

% impacto de daño en BGE Quilicura	% de impacto en CLP	% de impacto en cajas	Valor CLP	BGE
Agosto	87,57%	77,93%	\$ 6.156.208	\$7.030.147
Septiembre	69,41%	67,96%	\$ 5.184.918	\$7.469.705
Octubre	89,67%	80,12%	\$ 6.286.108	\$7.009.947
Noviembre	85,61%	67,51%	\$ 5.291.020	\$6.180.593

En relación con el primer objetivo específico, se registró una reducción aproximada del 89,44% en las horas de trabajo dedicadas al análisis de datos de roturas, lograda gracias a la automatización mediante la consulta MDX en Power BI, mencionada previamente.

Tabla VI: Horas de trabajo utilizadas en el trabajo y análisis de datos antes y después de implementar el proyecto

Horas utilizadas para trabajar y analizar RC	Antes del proyecto - Manual (Min)	Después del proyecto - Automatizado (Min)
Descarga de datos	30	5
Limpieza y separación de datos	265	2
Visualización de datos	20	1
Análisis	45	30
Total de tiempo (minutos)	360	38

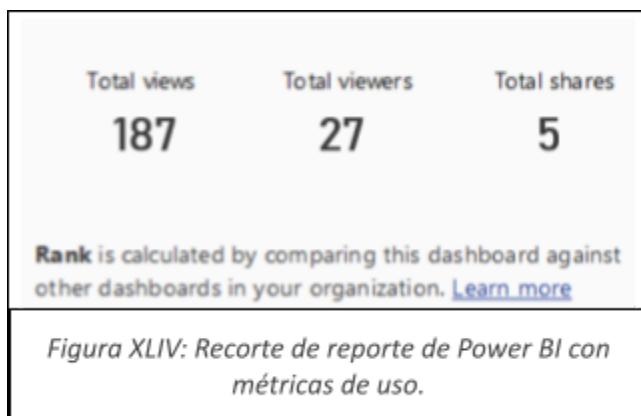
Respecto al segundo objetivo específico, enfocado en mejorar la precisión de las proyecciones, el modelo utilizado demostró una precisión del 96,89%, siendo esta métrica una nueva fuente de información valiosa para la toma de decisiones y la definición de metas de mejora por centro.

MAE: 2.536023501227706
MAPE: 1.7763933636202884
sMAPE: 1.7766689518373382
MSE: 8.533534217415388
Accuracy: 96,887586%

Figura XLIII: Resultados de métricas de precisión aplicadas al modelo de proyecciones desarrollado en python. Elaboración propia.

Si bien se tiene un valor de Accuracy bastante alto, las otras métricas de precisión utilizadas mantienen valores fuera de los márgenes deseables, es decir, bajo 1. Esto podría indicar una mala calidad de datos o un desempeño deficiente del modelo en el contexto del problema estudiado.

La implementación de Power BI en el proyecto para integrar y estandarizar los datos de roturas, junto con los manuales y reportes entregados a los Supervisores de Stock, promovió su uso, obteniendo un total de 187 visualizaciones entre mediados de octubre y mediados de noviembre, mostrando una aceptación positiva en los equipos de otros centros para su integración en sus responsabilidades de control y logrando el objetivo específico 3.



En cuanto a la medida de desempeño del cuarto objetivo específico, se tiene que el porcentaje de adherencia al uso de reason code aumentó de un 63,9% a un 94,61% para el mes de octubre y 98,36% para el mes de diciembre.

```
1 Conteo = DIVIDE(COUNTROWS(FILTER('Reason codes', NOT(CONTAINSSTRING('Reason codes'[Reason_code_filtro], "otros")))), COUNTROWS("Reason codes"))
```

Figura XLV: Medida aplicada en PBI para obtener porcentaje de implementación de Reason Codes. Elaboración propia.



Finalmente, el Bad Good Operacional de Quilicura descendió de un 0,0307% a un 0,0235%, evidenciando una tendencia hacia la meta esperada, con una diferencia de 0,0035%, considerándose un resultado satisfactorio pese a no alcanzar la cifra estimada.



A continuación, se presenta una tabla resumen de los resultados comparados con los valores iniciales de los KPI's del proyecto:

Tabla VII: Valores de KPI's iniciales, versus los valores obtenidos como resultados del proyecto medidos hasta noviembre de 2023

KPI	Valor inicial	Resultado final
General	87,57%	85,61%
Objetivo 1	6 horas	38 minutos
Objetivo 2	Desconocido	96,89%
Objetivo 3	0	187
Objetivo 4	63,90%	95,83%
Objetivo 5	0,0307%	0,0235%

10. Evaluación económica del proyecto

Se realizó una evaluación económica del proyecto con los resultados obtenidos para medir la utilidad de este en la empresa de forma retrospectiva. El análisis se cuantificó mediante criterios o indicadores de rentabilidad y un flujo de caja estimado mes a mes desde el inicio de la pasantía, dado que hay componentes que se desconocían para el análisis como los costos fijos de Nestlé, pero se pretendía comparar la situación inicial de la empresa versus la situación final.

Se utilizaron los indicadores de VAN y TIR para la evaluación económica del proyecto ya finalizado, para poder considerar todos los flujos de caja dentro del proyecto y no sólo la inversión inicial. Esto permite tener una evaluación integral de los costos y beneficios que produjo el proyecto. Adicionalmente, con la TIR, se puede comparar la rentabilidad del proyecto y ver el rendimiento del retorno de la inversión inicial, evaluando si se supera o no la tasa de descuento requerida (para Chile es de un 10% y es la que se utilizó para la evaluación).

Adicionalmente, se realizó la estimación del valor presente neto de los ahorros que generó el proyecto para cuantificar el valor de estos ahorros en términos de valor presente considerando la tasa de descuento antes mencionada.

Por último, con esta tasa de descuento considerada en la TIR se pone un enfoque en el análisis de riesgo de la inversión, lo que nos da un análisis integral, completo y robusto en torno al desempeño económico del proyecto.

Es importante considerar que:

- En agosto, el Bad Good Operacional por daño fue de \$6.156.208 y en noviembre fue de \$5.291.020. Es decir, la reducción en el Bad Good Operacional por daño entre agosto y noviembre fue de \$865,188 (no explícito en el flujo de caja).
- Se tuvo un ahorro en las horas hombre utilizadas mes a mes en los procesos de análisis antes mencionados para este proyecto.
- La adherencia al uso de Reason Codes aumentó del 63.90% al 98.36%. El impacto económico directo podría ser estimado considerando la mejora en la calidad de los datos y las decisiones que pueden resultar de este aumento en la adherencia, pero no está determinado de manera clara.
- Hasta agosto, cada 10000 cajas (valorizadas en \$11.519 CLP cada una aproximadamente), se estaban dañando por motivo de daño en almacén 42 cajas, es decir, \$489.023 cada 10.000 cajas. Tras finalizar el proyecto, se logró disminuir esta merma a 30 cajas cada 10.000, lo que implica un ahorro de \$17.193 cada 10.000 cajas en

mermas operacionales en el mes de noviembre. Esto significa, que, del total de cajas dañadas, se consiguió un ahorro de \$5.158.017 CLP en el mes de noviembre al disminuir el impacto de daño en cajas (Daño total en cajas en agosto por el costo promedio de una caja, menos el daño total en cajas en noviembre por el costo promedio de una caja).

Variable	Detalle
Sueldos de trabajadores involucrados en proceso	Inversión en horas hombre que hace Nestlé mes a mes en el proceso considerando 15 grueros y 2 analistas de datos
Ahorro proyecto	Considera los ahorros conseguidos por disminución en mermas operacionales
Entradas de dinero	Incluye las entradas por ventas, ventas salvage y exportaciones
Costos variables	Incluye todos los costos por daños, vencimientos, donaciones, etc. No se conocen los costos fijos, por lo que no serán considerados.
Utilidad Antes de Impuestos	Utilidad antes de aplicar impuesto a la renta del 10%
Utilidad Despues de Impuestos	Utilidad después de aplicar el impuesto a la renta
Flujo operacional	Total de ingreso o movimiento operacionales de dinero
Flujo de capitales	Total de movimiento de capitales en el proyecto
Inversión fija	Inversión en horas hombre evaluadas en lo que vale la hora de trabajo de un practicante para realizar el proyecto
Flujo de caja privado	Suma de Flujo operacional más el Flujo de capitales

Figura XLVIII: Variables consideradas en la evaluación económica de flujos de caja. Elaboración propia.

Meses	Julio	Agosto	Septiembre	Octubre	Noviembre
Sueldos de trabajadores involucrados en proceso	\$ -26.735.360	\$ -26.735.360	\$ -26.735.360	\$ -26.735.360	\$ -26.735.360
venta	\$ 24.583.746.424	\$ 23.848.164.136	\$ 24.020.445.085	\$ 20.098.512.550	
venta salvage	\$ 496.230	\$ 7.379.682	-	-	-
exportacion	\$ 1.068.179.835	\$ 777.663.072	\$ 850.954.705	\$ 1.079.504.025	
Daño WH	\$ -6.156.208	\$ -5.184.918	\$ -6.286.108	\$ -5.291.020	
Daño CS	\$ -34.263.229	\$ -45.114.328	\$ -3.122.320	\$ -32.448.907	
daño transp	\$ -219.211	-	\$ -2.524.338	\$ -7.536.480	
dif inv	\$ -873.939	\$ -2.284.787	\$ -723.839	\$ -889.573	
dif trnsp	\$ -8.128.403	\$ -2.284.787	\$ -592.537	\$ -139.920	
SSV	\$ -90.299.343	\$ -131.232	\$ -45.623.152	\$ -43.702.569	
Donaciones	\$ -148.984.875	\$ -145.727.178	\$ -125.109.487	\$ -39.695.864	
Abastecimiento	\$ -7.173.411.677	\$ -4.495.316.593	\$ -5.263.164.240	\$ -4.550.782.351	
Daño otros	\$ -32.288.348	\$ -78.519.621	\$ -797.296	\$ -953.395	
robo	\$ -6.360.983	\$ -2.333.323	\$ -105.201.448	-	
vencido	\$ -486.527.592	\$ -33.340.857	\$ -169.289.259	\$ -126.267.984	
Daño importado	\$ -7.824.318	\$ -18.496.494	\$ -40.919.324	\$ -12.552.672	
UAI	\$ 17.630.349.003	\$ 19.777.737.412	\$ 19.081.311.082	\$ 16.331.020.480	
Impuesto a la empresa	\$ 1.763.034.900	\$ 1.977.773.741	\$ 1.908.131.108	\$ 1.633.102.048	
UDI	\$ 15.867.314.103	\$ 17.799.963.671	\$ 17.173.179.974	\$ 14.697.918.432	
Flujo de caja privado (sin proyecto)	\$ 15.867.314.103	\$ 17.799.963.671	\$ 17.173.179.974	\$ 14.697.918.432	

Figura XLIX: Flujos de caja estimados de Nestlé sin proyecto en los meses de Julio hasta Noviembre.
Elaboración propia.

Meses	Julio	Agosto	Septiembre	Octubre	Noviembre
Sueldos de trabajadores involucrados en proceso	\$ -26.735.360	\$ -26.735.360	\$ -26.735.360	\$ -26.735.360	\$ -26.735.360
venta	\$ 24.583.746.424	\$ 23.848.164.136	\$ 24.020.445.085	\$ 20.098.512.550	
venta salvage	\$ 496.230	\$ 7.379.682	-	-	-
exportacion	\$ 1.068.179.835	\$ 777.663.072	\$ 850.954.705	\$ 1.079.504.025	
Ahorro proyecto					\$ 5.158.017
Daño WH	\$ -6.156.208	\$ -5.184.918	\$ -6.286.108	\$ -5.291.020	
Daño CS	\$ -34.263.229	\$ -45.114.328	\$ -3.122.320	\$ -32.448.907	
daño transp	\$ -219.211	-	\$ -2.524.338	\$ -7.536.480	
dif inv	\$ -873.939	\$ -2.284.787	\$ -723.839	\$ -889.573	
dif trnsp	\$ -8.128.403	\$ -2.284.787	\$ -592.537	\$ -139.920	
SSV	\$ -90.299.343	\$ -131.232	\$ -45.623.152	\$ -43.702.569	
Donaciones	\$ -148.984.875	\$ -145.727.178	\$ -125.109.487	\$ -39.695.864	
Abastecimiento	\$ -7.173.411.677	\$ -4.495.316.593	\$ -5.263.164.240	\$ -4.550.782.351	
Daño otros	\$ -32.288.348	\$ -78.519.621	\$ -797.296	\$ -953.395	
robo	\$ -6.360.983	\$ -2.333.323	\$ -105.201.448	-	
vencido	\$ -486.527.592	\$ -33.340.857	\$ -169.289.259	\$ -126.267.984	
Daño importado	\$ -7.824.318	\$ -18.496.494	\$ -40.919.324	\$ -12.552.672	
UAI	\$ 17.630.349.003	\$ 19.777.737.412	\$ 19.081.311.082	\$ 16.336.178.497	
Impuesto a la empresa	\$ 1.763.034.900	\$ 1.977.773.741	\$ 1.908.131.108	\$ 1.633.102.048	
UDI	\$ 15.867.314.103	\$ 17.799.963.671	\$ 17.173.179.974	\$ 14.702.560.647	
Flujo Operacional	\$ 15.867.314.103	\$ 17.799.963.671	\$ 17.173.179.974	\$ 14.702.560.647	
Inversión fija	\$ -1.575.450				
Flujo de capitales	\$ -1.575.450	-	-	-	
Flujo de caja privado (Con proyecto)	\$ -1.575.450	\$ 15.867.314.103	\$ 17.799.963.671	\$ 17.173.179.974	\$ 14.702.560.647

Figura L: Flujos de caja estimados de Nestlé con la implementación del proyecto entre los meses de Julio y Noviembre. Elaboración propia.

Meses	Julio	Agosto	Septiembre	Octubre	Noviembre
Flujo de caja privado [sin proyecto]	0	\$ 15.867.314.103	\$ 17.799.963.671	\$ 17.173.179.974	\$ 14.697.918.432
Flujo de caja privado [Con proyecto]	\$ -1.575.450	\$ 15.867.314.103	\$ 17.799.963.671	\$ 17.173.179.974	\$ 14.702.560.647
Delta proyecto	\$ -1.575.450	\$ -	\$ -	\$ -	\$ 4.642.215

*Figura LI: Delta de los flujos de caja estimados para la situación con proyecto versus sin proyecto.
Elaboración propia.*

VAN	\$ 1.595.245,36
TIR	31%

*Figura LII: VAN y TIR estimadas del proyecto.
Elaboración propia.*

Se puede destacar que, si bien el cambio en los flujos de caja no es muy evidente, se tiene un ahorro de más de 5 millones de pesos en los flujos de Nestlé tras el proyecto (atribuibles a este y otros factores), el cual tuvo un tiempo corto de medición tras su implementación, por lo que en un corto periodo de tiempo puede producir cambios en la gestión del almacén y ahorros en las mermas. Adicionalmente, se tiene un VAN de proyecto positivo y una TIR estimada de retorno de la inversión de 31%, lo que indica que el proyecto fue rentable a corto plazo para la empresa.

11. Conclusiones

El análisis previo del proyecto muestra que no se logró el objetivo principal de reducir el impacto por daños en un 3%. Esto se debió al corto período para implementar y evaluar el proyecto, y a la sobreestimación de su impacto en la reducción de mermas operativas. Una extensión temporal del proyecto podría haber permitido mejores resultados mediante la iteración de medidas de mejora basadas en el análisis de datos.

Se puede rescatar el cumplimiento de las métricas de objetivos específicos, obteniendo una eficiencia en el análisis de datos y una utilización continua de las herramientas aplicadas en el proceso para facilitar la toma de decisiones de los colaboradores, lo que optimiza su proceso de formación e implementación de mejoras en los almacenes. Además, con las proyecciones de alta precisión, se pudieron fijar metas para los meses restantes del año y para el año 2024 más realistas y enfocadas que fomentan las mejoras en cada CD.

Es importante destacar que el proyecto sufrió cambios debido a desafíos y decisiones tomadas en el transcurso del tiempo, que afectaron principalmente a las medidas de desempeño utilizadas y al desarrollo del proyecto en cuanto a la forma de registrar la data. En primer lugar, se decidió que era necesario cambiar la forma de medición del KPI para el objetivo general y

para el objetivo específico 5, puesto que no representaban el cambio mes a mes y era más complicado diferenciar el impacto del proyecto desde su implementación. Por otro lado, en conjunto con la empresa, se estimó que la medida de desempeño del Bad Good Operacional estaba siendo calculada de forma errónea, por lo que, se redefinió su forma de cálculo y se cambió el valor inicial de este KPI para el proyecto, alterando también los resultados esperados.

También, a medida que se avanzó en el proyecto, se hizo evidente que sería complicado llegar al objetivo general fijado en un comienzo, que pretendía disminuir el impacto del daño operacional en un 5%, puesto que, el tiempo era acotado y para llegar a estos resultados era necesario investigar nuevas metodologías y herramientas que pudieran formar un plan de acción robusto en un período de tiempo más extendido, por lo que se decidió modificar el resultado esperado del KPI a un 3%.

A pesar de no alcanzar el objetivo general, se observa una mejora desde el inicio del proyecto, con avances en la automatización y mayor eficiencia en los procesos. Los equipos disponen de mejores herramientas para generar cambios positivos, fomentando una cultura operativa mejorada y decisiones más fundamentadas para reducir mermas. Aunque no se alcanzó plenamente la meta, el proyecto representó un punto de partida sólido para propuestas adicionales de mejora operativa.

Este proyecto fue clave para entender el trabajo de un ingeniero dentro de un equipo de trabajo y en el contexto laboral. Los principales desafíos fueron el manejo de personas, la alineación de información con otros equipos y la comunicación en la empresa, además del tiempo que fue una constante preocupación para el éxito y desarrollo de este. Por otro lado, el aplicar modelos de proyecciones para mermas fue un otro gran desafío por la aleatoriedad de los datos, para poder generar proyecciones más exactas es necesario una investigación más profunda de las variables que influyen en la problemática abordada.

Se debe destacar la oportunidad ofrecida durante el transcurso de la pasantía para liderar un proyecto con un equipo de trabajo comprometido tras cada paso e implementación, que entregó conocimientos clave, participación constante y aptitudes clave para proceder en cada etapa. Sumado a esto, fue relevante para el desarrollo de este trabajo el conocimiento adquirido en los cursos de ciencias de datos, estadística aplicada, gestión de personas y formulación y evaluación de proyectos.

12. Recomendaciones

En base al impacto que obtuvo la solución propuesta en este proyecto y su alcance, se generaron las siguientes recomendaciones para después de la implementación de este. Se ordenaron según tipo (Táctica, estratégica y operacional):

- Recomendaciones tácticas:
 - Buscar una métrica que logre medir de mejor manera el impacto del daño operacional en el BG, puesto que la métrica escogida para este proyecto se ve muy afectada por los otros componentes del Bad Good Operacional. Una disminución en diferencias de inventario aumenta el porcentaje de daño operacional, aunque este haya disminuido de igual manera.
 - Cargar más datos a las proyecciones a medida que se vaya generando para dar más precisión al entrenar mejor a los modelos de machine learning.
 - Seguimiento Proactivo: Implementar un sistema de alerta temprana basado en los análisis de Power BI para identificar patrones o tendencias inusuales en los KPI's y tomar medidas preventivas antes de que los problemas se intensifiquen, dado que no fue posible implementarlo en el corto tiempo de implementación del proyecto.
 - Capacitación Continua: Mantener sesiones de capacitación regulares para los equipos operativos sobre nuevas oportunidades de mejora identificadas en los procesos actuales, el uso adecuado de los "Reason Codes" y la importancia de su correcta aplicación. Esto puede realizarse mediante estudios de casos y ejemplos prácticos.
- Recomendaciones estratégicas:
 - Expansión del Proyecto: Considerar la implementación a gran escala del modelo desarrollado y las lecciones aprendidas de un punto en otros centros de distribución de la red para obtener resultados similares en otros lugares, promover la mejora colaborativa y mejorar los indicadores a nivel nacional.
 - Fomentar cultura de Mejoras Continuas: Reforzar sistema de feedback regular y canales de comunicación abiertos en torno a los cambios implementados con los equipos de operaciones para recopilar observaciones y sugerencias que puedan contribuir a futuras mejoras en el proceso.
- Recomendaciones operacionales:

- Mejora en la estandarización: Continuar con el proceso de estandarización de los "Reason Codes" de manera iterativa para una identificación más precisa y uniforme de las causas de las roturas en todos los centros de distribución y de nuevos daños no identificados que puedan surgir.
- Optimización y automatización de Herramientas de Análisis: Reforzar la integración y uso de otras herramientas analíticas y de modelado predictivo que puedan complementar o mejorar la eficiencia de las proyecciones y el análisis de datos. Buscar nuevas formas de automatización, como, por ejemplo, modelos de machine learning con IA que permitan hacer las proyecciones más precisas y que se mantengan constantemente actualizadas.

Esta combinación de estrategias y tácticas podría proporcionar una base sólida para la continuación y mejora del proyecto a futuro, asegurando un seguimiento constante de los indicadores clave y adaptándose a las necesidades cambiantes de la operación. Es importante que se mejore la comunicación entre los equipos dentro de la compañía para que estén todos alineados con los cambios e implementaciones.

13. Bibliografía

1. Termal, Z., & Meyer, F. (2023). Formulación de plan de mejoramiento que involucre las áreas de transporte, almacenamiento, surtido y cuidado de la mercancía para reducir el gasto generado por merma (Rotura) en el almacén Homecenter Palmira.
2. Cueva Yauri, J. C., & Trujillo Aparicio, J. D. G. (2019). Mejora continua basado en la metodología DMAIC en los procesos para incrementar la productividad de un almacén de tiendas por departamentos.
3. Moraida Huaca, A. G. (2017). Implementación de procesos de control de inventarios y su impacto en la rentabilidad de la empresa Metal Mecánica Sermetal SAC, del distrito de Pataz-La Libertad, 2016.

14. Anexos

14.1. Objetivos planteados y proyección para el año 2023 sobre Bad Good Operacional del almacén hecho por la supervisora Ana Ontiveros.

OBJETIVOS 2023

Supply Chain Inventory Control 2022 -2023

DETALLE POR CENTRO DE DISTRIBUCIÓN

INVENTORY DIFFERENCES- IRA

Centro Distribución	Target 2023		% Mejora	IRA Target
	MONTH	YEAR		
CL DC Maipú	-\$1.400.000	-\$16.800.000	7%	97%
CL DC Quilicura	-\$1.400.000	-\$16.800.000	3%	99%
CL DC Temuco	-\$500.000	-\$6.000.000	6%	97%
CL DC Macul OP-R-FS	-\$907.890	-\$10.894.682	30%	90%
DC Macul H	-\$206.796	-\$2.481.556	2%	96%
DC Macul R	-\$827.185	-\$9.926.225	2%	96%
CL DC Concepción	-\$500.000	-\$6.000.000	1%	97%
CL DC Quilicura NP	-\$475.851	-\$5.710.214	1%	97%
CL DC Keylogistics	-\$335.855	-\$4.030.260	4%	95%
CL Punta Arenas	-\$296.426	-\$3.557.107	2%	97%
CL DI 3PL Arica	-\$100.717	-\$1.208.598	25%	95%
Mercomex	-\$115.547	-\$1.386.559	0%	99%
CL DC Antofagasta	-\$190.000	-\$2.280.000	0%	97%
Totales	-\$7.256.267	-\$87.075.199	8%	

DAMAGE WH

Centro Distribución	Target 2023		% Mejora
	MONTH	YEAR	
CL DC Quilicura	-\$3.300.000	-\$39.600.000	0%
CL DC Maipú	-\$900.000	-\$10.800.000	10%
CL DC Macul OP-R-FS	-\$710.000	-\$8.520.000	5%
CL DC Temuco	-\$710.000	-\$8.520.000	16%
CL DC Concepción	-\$650.000	-\$7.800.000	24%
DC Macul Helados	-\$500.000	-\$6.000.000	0%
Macul Refrigerados	-\$500.000	-\$6.000.000	0%
CL DC Keylogistics	-\$255.000	-\$3.060.000	15%
CL DC Quilicura - NP	-\$250.000	-\$3.000.000	0%
Mercomex	-\$200.000	-\$2.400.000	0%
CL DC Punta Arenas	-\$80.000	-\$960.000	0%
CL DI 3PL Arica	-\$55.000	-\$660.000	8%
CL DC Antofagasta	-\$27.389	-\$328.667	45%
Totales	-\$8.137.389	-\$97.648.667	

**TOTAL BGE 2023 =
INVENTORY DIFFERENCES + DAMAGE WH = 184 MCLP
REDUCCIÓN VS 2022 : 56 MCLP**

14.2. Plan de mitigación para la pérdida de continuidad

Mitigación del riesgo de pérdida de continuidad y seguimiento de implementación:

- Planificación detallada:
 - Desarrollar un plan de implementación detallado con hitos claros y fechas límite para cada actividad incluida en el proyecto.
- Monitoreo continuo:
 - Establecer un proceso de control en reuniones semanales y revisar en conjunto indicadores o progreso de implementación con los colaboradores para reconocer problemáticas de forma temprana y aplicar correcciones.
- Respaldo de datos:
 - Realizar copias de seguridad regulares de los datos importantes dentro del proyecto antes y durante la implementación.

14.3. Plan de mitigación para la resistencia al cambio de operarios

Mitigación del riesgo de resistencia al cambio:

- Comunicación efectiva:
 - Establecer un plan de comunicación claro y detallado que destaque los beneficios del cambio.
 - Incluir sesiones informativas en reuniones operacionales semanales para explicar el propósito y las mejoras esperadas del proyecto de roturas.
- Participación de los colaboradores:
 - Involucrar a los empleados desde las etapas iniciales del proyecto para motivar su participación y aportes en las mejoras.
- Capacitaciones y apoyo:
 - Proporcionar capacitación sobre cada implementación de herramientas a procesos y tecnologías.
 - Establecer un espacio de consultas o reuniones personales con colaboradores dentro del proceso para resolver dudas y apoyar en la implementación.

14.4. Encuesta realizada a Controles de Stock para medir entendimiento de reason code nuevo

Preguntas sobre Reason Codes nuevos

En esta sección se expondrán casos de roturas identificadas en el CD, su tarea es identificar a que reason code correspondería para ser ajustado.

5. Un gruero se encuentra guardando un pallet en una ubicación. Al momento de girar con la máquina apiladora, se identifica una rotura en las cajas cercanas a donde realizó el giro el gruero. Esta rotura fue causada por la cercanía de la parte trasera de la máquina con un pallet almacenado al momento de realizar el giro. ¿Qué reason code de daño correspondería a este caso? *

- DA6
- DA5
- DA1
- DA8

6. En una Gemba de daño se identifican cajas con unidades faltantes en un pallet. Se analiza la situación y se determina que la caja no puede ser vendida. ¿Qué reason code debería identificarse en este caso? *

- DAF
- COPACK3
- MAQ3
- DON3

7. Un gruero se encuentra armando un pedido y se le indica sacar materiales de un pallet que llegó desde otro CD. A medida que va sacando cajas, identifica un olor extraño proveniente del pallet. Sigue sacando cajas hasta identificar que en el medio del pallet hay cajas húmedas con hongos. ¿Qué reason code debería aplicar en este caso? *

- DOF2
- CPFI
- DOI2
- CPFE

8. Al momento de almacenar un pallet en altura en una ubicación de rack doble, el gruero empuja por accidente el pallet que se encontraba en la ubicación trasera del rack con el pallet que estaba almacenando. Este choque entre los pallet produjo un desplazamiento del pallet que estaba previamente almacenado y se cayó de su ubicación. ¿Qué reason code de daños aplicaría en esta situación? *

- DA6
- DA10
- DA4
- PP1

9. Un gruero se encuentra armando un pedido para ser despachado. Se aproxima a una ubicación en altura para sacar una cajas de un pallet con saldos (cajas sobrantes tras armar un pedido previo). Al momento de tomar el pallet para bajarlo a piso, una de las cajas se desliza del pallet por falta de film y se daña en la caída. ¿Qué reason code de daños aplicaría en esta situación? *

- DAS
- DA6
- PP3
- DAF

10. El operador se encuentra en el anden cargando un pedido a un camión para ser despachado. Debido a un movimiento brusco con la grúa el pallet se desestabiliza y se cae golpeándose con la rampa del camión. ¿Qué reason code de daños se aplicaría en esta situación? *

- CARDES1
- CARDES2
- PP1
- PP3

11. Se tiene un PDQ de 991 latas de café de 170 gr cada una. Este PDQ se compone de cartón, exhibidor y el material FERT de café. Este material FERT del PDQ se ve dañado en el proceso de transformación o maquilado del producto y esto es identificado en el CD al momento de recibir el PDQ desde un Copacker externo. ¿Qué reason code de daños aplicaría en este caso? *

- MAQ2
- MAQ1
- COPACK1
- COPACK2